ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



ĐỒ ÁN CHUYÊN NGÀNH

DỰ ĐOÁN THÔNG SỐ SỨC KHOẺ CỦA PIN BẰNG MÔ HÌNH HỌC SÂU ĐƯỢC HỖ TRỢ TỪ THÔNG TIN HOÁ LÝ CỦA HỆ PIN

Health forecasting for battery systems using physics and chemistry-informed deep learning methods

Hướng đồ án:	Khoa học Máy tính
Giảng viên hướng dẫn:	.....
Sinh viên thực hiện:	Huỳnh Quốc Thắng MSSV: 2313178
Nhóm:	15
Học kỳ:	HK261

TP. Hồ Chí Minh, tháng 10/2026

Lời cam đoan

Tôi xin cam đoan đồ án chuyên ngành "Dự đoán thông số sức khoẻ của pin bằng mô hình học sâu được hỗ trợ từ thông tin hoá lý của hệ pin" là kết quả làm việc của riêng tôi dưới sự hướng dẫn của giảng viên hướng dẫn. Các bộ dữ liệu sử dụng đều là dữ liệu công khai và được trích dẫn nguồn đầy đủ. Mọi số liệu, bảng và hình trong báo cáo được tính trực tiếp từ kết quả thực nghiệm do tôi thực hiện; các phần tham khảo từ công trình khác đều được ghi rõ trong danh mục tài liệu tham khảo. Tôi xin chịu hoàn toàn trách nhiệm nếu có bất kỳ sai phạm nào so với lời cam đoan này.

TP. Hồ Chí Minh, tháng 10 năm 2026
Sinh viên thực hiện

Huỳnh Quốc Thắng

Lời cảm ơn

Tôi xin chân thành cảm ơn giảng viên hướng dẫn đã định hướng đề tài, góp ý về phương pháp đánh giá và theo sát quá trình thực hiện đồ án. Tôi cũng cảm ơn quý thầy cô Khoa Khoa học và Kỹ thuật Máy tính, Trường Đại học Bách khoa – ĐHQG-HCM, đã trang bị nền tảng kiến thức để tôi có thể thực hiện đề tài này. Cảm ơn các nhóm nghiên cứu tại Đại học Giao thông Tây An, Đại học Thiên Tân, MIT–Stanford–Toyota Research Institute và Đại học Khoa học và Công nghệ Hoa Trung, Trung tâm Nghiên cứu Ames của NASA đã công bố dữ liệu lão hoá pin, và nhóm tác giả PINN4SOH đã công bố mã nguồn tiền xử lý. Cuối cùng, tôi cảm ơn gia đình và bạn bè đã luôn động viên trong suốt thời gian thực hiện đồ án.

Tóm tắt

Đồ án nghiên cứu bài toán ước lượng trạng thái sức khoẻ (SOH) của cell lithium-ion khi chỉ có ít lần đo dung lượng. Mô hình đề xuất là một mạng nơ-ron có thông tin vật lý (PINN) bán giám sát: mạng nghiệm dự đoán SOH từ 16 đặc trưng đoạn sạc, gắn với một động học suy giảm dạng xám luôn không âm; ba hàm mất mát vật lý không dùng nhãn nên áp được lên mọi chu kỳ chưa đo dung lượng. Đồ án thiết kế và chứng minh một giao thức đánh giá không rò rỉ (kiểm định chéo 5 fold theo cell, phân tầng theo chế độ thí nghiệm, lặp 5 lần), đo định lượng tác động của các dạng rò rỉ thường gặp, và so sánh với sáu mô hình đối chứng ở bốn mức nhãn trên bốn bộ dữ liệu công khai (387 cell, 9.719 lượt huấn luyện). Ở 10 % nhãn, tỉ số sai số giữa PINN bán giám sát và mạng nơ-ron cùng kiến trúc chỉ học có nhãn là 0,39–0,90; khi tăng lên 70 % nhãn, lợi ích giảm dần (0,85–1,09), và một mô hình gradient boosting được tinh chỉnh tốt vẫn có sai số thấp nhất trên phần lớn các bộ dữ liệu. Mô hình cải tiến PINN-lai kết hợp ba mạng PINN bán giám sát với GBDT rồi làm trơn bằng một bộ lọc xu thế nhân quả, được chọn chỉ trên tập validation; trên test, sai số của nó bằng 0,67–0,95 lần PINN ban đầu, thấp hơn GBDT ở 10/16 trường hợp bộ dữ liệu × mức nhãn. Với 30 % cell có nhãn, PINN-lai có sai số thấp hơn MLP và PINN bán giám sát học với 70 % cell có nhãn trên cả bốn bộ, nhưng vẫn kém GBDT học với 70 % cell có nhãn. Thêm lịch sử của cell vào đầu vào (trung bình trượt nhân quả của đặc trưng sạc) giảm sai số của PINN-lai còn 0,89–0,97 lần trên TJU và HUST khi có từ 30 % nhãn nhưng không giúp trên XJTU và khi chỉ có 10 % nhãn; dùng lịch sử theo lựa chọn trên validation, PINN-lai có sai số thấp hơn GBDT ở 16/16 trường hợp. Bộ lọc quỹ đạo được chỉ ra là không bảo đảm SOH không tăng, và ép không tăng làm sai số tăng ở bộ có dung lượng tăng thật. Trên đúng cách chia của PINN4SOH, dựng lại từ nhật ký công bố, PINN-lai với tiền xử lý không rò rỉ có sai số bằng 0,23–0,63 lần số công bố trên TJU và MIT, ngang trên XJTU, chỉ kém trên HUST, nơi số công bố nhờ chuẩn hoá theo cả vòng đời cell; cùng tiền xử lý với bài, nó thấp hơn số công bố ở mọi mức của thí nghiệm ít mẫu. Khi tính nhãn theo số lần đo dung lượng thay vì số cell, đo thưa trên mọi cell chỉ với 1,2–6,0 % số chu kỳ cho PINN-lai sai số bằng 0,85–0,93 lần gắn nhãn đầy đủ cho 30 % số cell và 0,97–1,05 lần khi gắn cho 70 % số cell. Đo thêm cell mới theo cùng lịch và cập nhật bằng bộ lọc Kalman, sai số còn 0,34–0,77 lần GBDT học với 70 % số cell có nhãn đầy đủ. Đồ án mở rộng sang dự báo SOH tương lai, dung lượng còn lại và số chu kỳ còn lại tới ngưỡng cuối đời bằng mạng PINN-dự báo trả tham số của nghiệm đóng của động học xám; khi cell không được đo lần nào, sai số SOH chỉ bằng 0,21–0,60 lần các mô hình ngoại suy theo từng cell và sai số RUL thấp hơn GBDT 1,1–1,5 lần.

Từ khoá: pin lithium-ion, trạng thái sức khoẻ, PINN, học bán giám sát, rò rỉ dữ liệu, kiểm định chéo, kết hợp mô hình, ngân sách đo, dự báo tuổi thọ còn lại.

Mục lục

Lời cam đoan i

Lời cảm ơn ii

Tóm tắt iii

Danh mục từ viết tắt viii

1 Giới thiệu đề tài 1

1.1 Đặt vấn đề . . . 1
1.2 Phát biểu bài toán . . . 1
1.3 Mục tiêu, đối tượng và phạm vi . . . 2
1.4 Câu hỏi nghiên cứu . . . 2
1.5 Đóng góp . . . 3
1.6 Cấu trúc báo cáo . . . 3

2 Cơ sở lý thuyết 4

2.1 Suy giảm dung lượng của pin lithium-ion . . . 4
2.2 Học sâu cho dữ liệu chuỗi thời gian . . . 4
2.3 Mạng nơ-ron có thông tin vật lý . . . 5
2.4 Học bán giám sát . . . 6
2.5 Kết hợp mô hình và độ bất định . . . 6
2.6 Dự báo suy giảm và tuổi thọ còn lại . . . 7
2.7 Đánh giá mô hình và rò rỉ dữ liệu . . . 7

3 Các công trình liên quan 8

3.1 Các hướng ước lượng SOH . . . 8
3.2 Nhận xét và khoảng trống nghiên cứu . . . 9

4 Dữ liệu và phương pháp đề xuất 11

4.1 Dữ liệu . . . 11
4.2 Mô hình PINN bán giám sát . . . 13
4.3 Mô hình kết hợp PINN-lai . . . 16
4.4 Đầu vào có lịch sử của cell . . . 18
4.5 Dự báo SOH tương lai, dung lượng còn lại và RUL . . . 19
4.6 Học và cập nhật với vài lần đo dung lượng . . . 20
4.7 Các mô hình đối chứng . . . 21
4.8 Cấu hình huấn luyện . . . 22

5 Hiện thực hệ thống và thiết kế thí nghiệm 23

5.1 Kiến trúc hiện thực . . . 23
5.2 Các yêu cầu đối với giao thức . . . 24

5.3 Đơn vị chia: cell, không phải chu kỳ . . . 25
5.4 Chọn số fold, tỉ lệ validation và số lần lặp . . . 26
5.5 Phân tầng theo chế độ thí nghiệm . . . 26
5.6 Quy trình chống rò rỉ trong cùng bộ dữ liệu . . . 27
5.7 Giao thức đánh giá dự báo . . . 28
5.8 So với công trình đã công bố và ngân sách đo . . . 29
5.9 Kiểm toán rò rỉ . . . 29
5.10 Chỉ số đánh giá . . . 30
5.11 Phương pháp thống kê . . . 30
6 Kết quả và đánh giá **31**
6.1 Kiểm toán rò rỉ . . . 31
6.2 PINN và học có nhãn khi thay đổi lượng nhãn . . . 32
6.3 So với các mô hình học có nhãn khác . . . 35
6.4 So với các mô hình học sâu theo đề cương . . . 35
6.5 Lợi ích đến từ đâu . . . 37
6.6 Quỹ đạo dự đoán theo lượng nhãn . . . 38
6.7 Tham số vật lý học được . . . 38
6.8 Kiểm tra phần vật lý . . . 39
6.9 Mô hình kết hợp PINN-lai . . . 41
6.10 Đầu vào có lịch sử của cell . . . 45
6.11 So với PINN4SOH trên đúng cách chia của bài . . . 48
6.12 Dự báo SOH tương lai, dung lượng còn lại và RUL . . . 49
6.13 Dự báo khi dung lượng hồi phục . . . 52
6.14 Bộ dữ liệu NASA . . . 53
6.15 Ngân sách đo dung lượng . . . 55
6.16 Thảo luận chung . . . 58
7 Kết luận và hướng phát triển **60**
7.1 Kết luận . . . 60
7.2 Đối chiếu với đề cương . . . 61
7.3 Hướng phát triển . . . 61

Danh sách hình vẽ

4.1 Kiến trúc mô hình: mạng nghiệm dự đoán SOH, mạng tốc độ mô tả động học suy giảm; hai mạng gắn với nhau qua các hàm mất mát vật lý. 14

5.1 Kiến trúc hiện thực: năm khối của hệ thống, từ dữ liệu thô tới báo cáo và công cụ minh hoạ. 24

6.1 MAE theo cell của cùng một mô hình (MLP, 70 % nhãn) dưới các cách chia và chuẩn hoá khác nhau; vạch đứt là cách chia đúng (theo cell) 31

6.2 MAE theo cell theo lượng nhãn: MLP và các biến thể có vật lý 32

6.3 Quỹ đạo SOH của cùng một cell test mỗi bộ khi có 10, 30 và 70 % số cell mang nhãn (lần lặp 0) 39

6.4 Một cell test của XJTU có dung lượng tăng đầu đời và một cell TJU (30 % nhãn, lần lặp 0): SOH đo được, dự đoán của PINN-lai trước khi lọc, sau bộ lọc xu thế và sau bộ lọc không tăng (4.14) với (w, a) chọn trên validation. 46

6.5 MAE theo cell trên test của PINN-semi không có (nét đứt) và có lịch sử (nét liền), trên ba bộ có dạng lịch sử được chọn; trên MIT không dạng nào được chọn. 46

6.6 MAE theo cell trên test của PINN-lai tinh chỉnh không có (nét đứt) và có lịch sử (nét liền), cạnh GBDT có hoặc không lịch sử chọn trên validation. 47

6.7 MAE theo cell trên test của MLP và PINN-semi khi cả hai cùng có đầu vào lịch sử. 48

6.8 So với PINN4SOH trên đúng cách chia của bài 50

6.9 Dự báo cho một cell test mỗi bộ (lần lặp 0, gốc ở 40 % đời, cell có sai số ở trung vị): lịch sử SOH ước lượng tới gốc, dự báo của GBDT, PINN-dự báo và mô hình kết hợp kèm khoảng 90 %; trục phải là dung lượng (Ah). 51

6.10 Bộ NASA 54

6.11 SOH đo được và ước lượng trên ba cell đánh giá của cách chia NASA-L (hạt giống 0, 16 đặc trưng sạc). 56

6.12 MAE theo cell trên NASA 56

6.13 MAE theo cell trên test theo phần trăm số chu kỳ của cell train có đo dung lượng (hai trục thang log) 57

Danh sách bảng

3.1 Tóm tắt các hướng tiếp cận liên quan. 10

4.1 Thống kê bốn bộ dữ liệu sau tiền xử lý 13
4.2 Hiểu biết vật lý và thành phần mô hình tương ứng. 15
4.3 Các mô hình được so sánh. 22
4.4 Cấu hình huấn luyện chung cho MLP và các biến thể PINN. 22

5.1 Các thí nghiệm và số lượt huấn luyện. 24
5.2 Tham số đánh giá dự báo của từng bộ 28

6.1 MAE theo cell của mọi mô hình theo lượng nhãn 33
6.2 Lượng nhãn tương đương 34
6.3 Tỉ số MAE của PINN-semi so với MLP và GBDT 35
6.4 MAE theo cell của mọi mô hình chính 36
6.5 R^2 của mọi mô hình chính 36
6.6 RMSE và MAPE của mọi mô hình chính ở 30 % nhãn 37
6.7 Tách nguồn gốc lợi ích ở 30 % nhãn 37
6.8 Kiểm tra phần vật lý trên cell test 40
6.9 MAE theo cell của PINN-lai và các mô hình 43
6.10 Tỉ số MAE của PINN-lai so với từng mô hình 43
6.11 MAE theo cell khi có và không có lịch sử 47
6.12 So với PINN4SOH trên đúng cách chia của bài 49
6.13 MAE của SOH dự báo ở ba tầm 51
6.14 MAE của RUL dự báo 52
6.15 Dự báo có và không xét hồi phục dung lượng 53
6.16 Bộ NASA, kiểm định chéo theo cell 55
6.17 Cách chia NASA-L của SambaMixer 55
6.18 MAE theo cell theo ngân sách đo dung lượng 57

7.1 Đối chiếu mục tiêu và nhiệm vụ của đề cương (giai đoạn 1) với phần đã thực hiện. 62

Danh mục từ viết tắt

Viết tắt	Ý nghĩa
BMS	Hệ thống quản lý pin (Battery Management System)
CC–CV	Sạc dòng không đổi – áp không đổi (Constant Current – Constant Voltage)
CNN	Mạng nơ-ron tích chập (Convolutional Neural Network)
GBDT	Cây quyết định tăng cường gradient (Gradient Boosting Decision Tree)
GPR	Hồi quy quá trình Gauss (Gaussian Process Regression)
KTC	Khoảng tin cậy
LAM	Mất vật liệu hoạt động (Loss of Active Material)
LFP	Lithium sắt phốt phát ($LiFePO_4$)
LLI	Mất lithium khả dụng (Loss of Lithium Inventory)
LSTM	Mạng bộ nhớ dài – ngắn hạn (Long Short-Term Memory)
MAE	Sai số tuyệt đối trung bình (Mean Absolute Error)
MAPE	Sai số phần trăm tuyệt đối trung bình (Mean Absolute Percentage Error)
MLP	Perceptron nhiều lớp (Multilayer Perceptron)
NCA, NCM	Oxit niken–coban–nhôm, oxit niken–coban–mangan
ODE	Phương trình vi phân thường (Ordinary Differential Equation)
PINN	Mạng nơ-ron có thông tin vật lý (Physics-Informed Neural Network)
PINN-semi	PINN bán giám sát, loss vật lý áp lên cả cell không nhãn
PINN-lai	Mô hình kết hợp: ba PINN-semi, GBDT và bộ lọc quỹ đạo
RMSE	Căn bậc hai sai số bình phương trung bình (Root Mean Square Error)
RUL	Số chu kỳ còn lại tới ngưỡng cuối đời (Remaining Useful Life)
SEI	Lớp điện phân rắn trên bề mặt anode (Solid Electrolyte Interphase)
SOH	Trạng thái sức khoẻ (State of Health)

CHƯƠNG 1

Giới thiệu đề tài

1.1 Đặt vấn đề

Pin lithium-ion là nguồn năng lượng chính của xe điện, thiết bị di động và hệ thống lưu trữ điện. Trong quá trình sử dụng, dung lượng của pin giảm dần do các phản ứng phụ bên trong cell: lớp SEI dày lên, lithium bị mất khỏi chu trình, vật liệu điện cực bị suy thoái. Trạng thái sức khoẻ (State of Health, SOH) đo mức suy giảm này và thường được định nghĩa bằng tỉ số giữa dung lượng hiện tại và dung lượng danh định:

$$\mathrm{SOH}_n = \frac{Q_n}{Q_{\text{danh định}}}, \tag{1.1}$$

trong đó Q_n là dung lượng đo được ở chu kỳ thứ n. Hệ thống quản lý pin (BMS) cần SOH để ước tính quãng đường còn lại, điều chỉnh chiến lược sạc và cảnh báo thời điểm thay pin; với pin xe điện, mốc cuối đời thường được chọn ở SOH khoảng 0,8.

Khó khăn thực tế nằm ở nhãn. Muốn biết chính xác Q_n phải xả đầy cell theo một quy trình chuẩn, mất nhiều giờ và phải dừng vận hành. Ngược lại, dữ liệu điện áp và dòng điện trong lúc sạc được BMS ghi lại ở mọi chu kỳ, của mọi cell, gần như không tốn chi phí. Bài toán vì vậy có dạng điển hình của học ít nhãn: rất nhiều dữ liệu đầu vào nhưng chỉ một phần nhỏ có nhãn.

1.2 Phát biểu bài toán

Xét tập cell $\mathscr{C}$. Mỗi cell c có chuỗi chu kỳ $n = 0, 1, \dots, L_c$; ở mỗi chu kỳ, từ đoạn sạc CC–CV ta trích được vector đặc trưng $\mathbf{x}_{c,n} \in \mathbb{R}^{16}$. Nhãn $y_{c,n} = \mathrm{SOH}_{c,n}$ chỉ được biết trên một tập con các cell huấn luyện $\mathscr{C}_L \subset \mathscr{C}_{\text{train}}$; các cell còn lại $\mathscr{C}_U = \mathscr{C}_{\text{train}} \setminus \mathscr{C}_L$ chỉ có đặc trưng sạc. Mục tiêu là học hàm

$$\hat{y} = F(\mathbf{x}_{c,n}, n) \tag{1.2}$$

sao cho sai số trên các cell *chưa từng xuất hiện* khi huấn luyện là nhỏ nhất. Mô hình chỉ dùng dữ liệu của chu kỳ hiện tại, nên có thể chạy trực tuyến trong BMS.

Cách đặt trên đếm nhãn theo cell, trong khi chi phí thật nằm ở số lần đo (mỗi nhãn là một lần xả đầy ở điều kiện chuẩn); đồ án xét thêm biến thể nhãn chỉ có ở một số chu kỳ rải trên mọi cell train.

Bài toán thứ hai là dự báo: đứng ở chu kỳ k của một cell, chỉ dùng dữ liệu tới chu kỳ k, dự báo SOH và dung lượng ở các chu kỳ $k + h$ sắp tới, cùng số chu kỳ còn lại trước khi SOH xuống

dưới một ngưỡng cuối đời τ (remaining useful life, RUL).

1.3 Mục tiêu, đối tượng và phạm vi

Đề tài thuộc hướng Khoa học Máy tính và gồm hai giai đoạn; đồ án chuyên ngành này là giai đoạn 1, tập trung vào bài toán một cell (đơn pin). Theo đề cương, giai đoạn 1 có năm mục tiêu:

(i) nắm kiến thức nền về học máy, học sâu cho dữ liệu chuỗi thời gian và về dữ liệu lão hoá pin, gồm các ràng buộc hoá lý có trong dữ liệu;

(ii) tái lập bảng thống kê mô tả của các bộ dữ liệu, phân tích phân phối, ngoại lai và các mẫu gây nhiễu;

(iii) hiện thực và so sánh có kiểm định với ít nhất bốn mô hình nền MLP, CNN, LSTM, Transformer bằng MAE, RMSE, MAPE;

(iv) tinh chỉnh các mô hình và giải thích vì sao tinh chỉnh làm kết quả tốt lên hay xấu đi;

(v) đề xuất cải tiến có cơ sở lý thuyết để chuẩn bị cho giai đoạn 2; ở đây là mô hình học sâu có thông tin vật lý (PINN) bán giám sát và mô hình kết hợp.

Đối tượng nghiên cứu là cell lithium-ion trong bốn bộ dữ liệu lão hoá công khai (NCM, NCA/NCM, LFP) và bộ NASA PCoE. Đầu vào là 16 đặc trưng trích từ đoạn sạc CC–CV của từng chu kỳ; đầu ra là SOH tại chu kỳ đó, và SOH, dung lượng, RUL ở các chu kỳ sau. Dữ liệu nhiều cell ghép song song, phân tích mất cân bằng giữa các cell và giao diện trực quan thuộc giai đoạn 2. Đồ án không xây dựng mô hình điện hoá chi tiết.

1.4 Câu hỏi nghiên cứu

CH1. Cùng một lượng cell có nhãn, PINN bán giám sát có sai số thấp hơn mô hình học có nhãn thuần tuý không?

CH2. Lợi ích đó thay đổi thế nào khi lượng nhãn đi từ 10 % tới 70 % số cell?

CH3. So với các mô hình học có nhãn mạnh khác (hồi quy tuyến tính, hồi quy Gauss, gradient boosting), PINN đứng ở đâu?

CH4. Lợi ích đến từ đâu: dữ liệu không nhãn, phương trình động học hay chỉ ràng buộc đơn điệu?

CH5. So với các mô hình học sâu cho chuỗi thời gian mà đề cương yêu cầu (MLP, CNN, LSTM, Transformer), PINN bán giám sát và mô hình kết hợp đứng ở đâu theo MAE, RMSE, MAPE và R^2?

CH6. Có giảm sai số thêm được mà không dùng thêm nhãn, và có biết được dự đoán đáng tin tới đâu không?

CH7. Có dự báo được SOH, dung lượng và RUL không, kể cả khi dung lượng hồi phục sau khoảng nghỉ?

CH8. Trên đúng cách chia của PINN4SOH và SambaMixer, mô hình của đồ án đứng ở đâu?

CH9. Nếu tính nhãn theo số lần đo dung lượng thay vì số cell, nên đo ở đâu?

CH10. Thêm lịch sử của cell vào đầu vào có giảm sai số không, và bộ lọc quỹ đạo có giữ SOH không tăng không?

1.5 Đóng góp

1. Một mô hình PINN bán giám sát: mạng nghiệm gắn với động học suy giảm dạng xám luôn không âm và ba hàm mất mát vật lý không dùng nhãn.
2. Một giao thức đánh giá không rò rỉ: chia theo cell, kiểm định chéo 5 fold phân tầng, lặp 5 lần, kèm kiểm toán rò rỉ định lượng.
3. So sánh với chín mô hình đối chứng, gồm bốn mô hình học sâu theo đề cương (MLP, CNN, LSTM, Transformer), ở bốn mức nhãn trên bốn bộ dữ liệu công khai (387 cell) và bộ NASA, bằng MAE, RMSE, MAPE, R^2; 9.719 lượt huấn luyện, có kiểm định thống kê.
4. Mô hình cải tiến PINN-lai: ba PINN-semi kết hợp GBDT và một bộ lọc xu thế nhân quả, chọn trên validation, kèm khoảng dự đoán phù hợp; đầu vào có lịch sử của cell ở các bộ mà validation cho thấy có lợi.
5. Dự báo SOH tương lai, dung lượng còn lại và RUL bằng mạng PINN-dự báo có nghiệm đóng của động học xám làm lớp đầu ra, kết hợp GBDT, có tách phần hồi phục dung lượng.
6. So trên đúng cách chia của PINN4SOH (dựng lại từ nhật ký công bố) và của SambaMixer trên bộ NASA PCoE.
7. Đặt lại bài toán ít nhãn theo số lần đo: đo thưa mọi cell khi huấn luyện, bộ lọc Kalman cập nhật theo cell khi dùng.

1.6 Cấu trúc báo cáo

Chương 2 và 3 trình bày cơ sở lý thuyết và các công trình liên quan, Chương 4 mô tả dữ liệu và các mô hình, Chương 5 là hiện thực hệ thống và thiết kế thí nghiệm, Chương 6 là kết quả, Chương 7 là kết luận và hướng phát triển.

CHƯƠNG 2

Cơ sở lý thuyết

Chương này trình bày các kiến thức nền mà mô hình và giao thức đánh giá của đồ án dựa vào: cơ chế suy giảm dung lượng của pin lithium-ion, các mô hình học sâu cho dữ liệu chuỗi thời gian, mạng nơ-ron có thông tin vật lý, học bán giám sát, kết hợp mô hình cùng ước lượng độ bất định, dự báo tuổi thọ còn lại, và cách đánh giá mô hình khi dữ liệu có cấu trúc nhóm.

2.1 Suy giảm dung lượng của pin lithium-ion

Dung lượng của cell lithium-ion giảm theo hai nhóm cơ chế chính [7]: mất lithium khả dụng (loss of lithium inventory, LLI), chủ yếu do lớp SEI phát triển trên bề mặt anode, và mất vật liệu hoạt động (loss of active material, LAM) do nứt hạt, bong tách hoặc hoà tan kim loại chuyển tiếp. Trong giai đoạn đầu, dung lượng thường giảm chậm và gần tuyến tính; ở giai đoạn sau nhiều cell đi vào vùng "đầu gối" (knee), nơi tốc độ suy giảm tăng nhanh [3]. Các phản ứng phụ phụ thuộc nhiệt độ theo quy luật dạng Arrhenius: nhiệt độ cao làm SEI phát triển nhanh hơn [56]. Hai quan sát này là cơ sở cho phần động học xám ở Chương 4: tốc độ suy giảm luôn không âm, tăng khi SOH giảm và tăng theo nhiệt độ.

Các quy luật thực nghiệm. Khi SEI dày lên và bị giới hạn bởi khuếch tán qua lớp SEI, lượng lithium mất đi tỉ lệ với căn bậc hai của thời gian [11, 39]. Wang và cộng sự [57] khớp mất mát dung lượng của cell graphite/LFP bằng một hàm luỹ thừa của điện lượng trao đổi nhân thừa số Arrhenius; Schmalstieg và cộng sự [47] tách lão hoá theo lịch và theo chu kỳ, mỗi phần một hàm luỹ thừa. Các mô hình này gọn nhưng cần bộ hệ số riêng cho mỗi hệ hoá học và không mô tả được đoạn đầu gối [16]. Phương trình xám của đồ án giữ dạng nhân của chúng (thừa số theo trạng thái, thừa số Arrhenius), còn phần phụ thuộc vào từng cell để mạng học.

2.2 Học sâu cho dữ liệu chuỗi thời gian

Dữ liệu lão hoá pin là chuỗi thời gian theo hai trục. Trong một chu kỳ, điện áp, dòng điện và nhiệt độ thay đổi theo thời gian (theo kênh); qua các chu kỳ, các đại lượng tóm tắt của từng chu kỳ trôi dần khi cell già đi (theo chu kỳ). Đồ án làm việc trên trục chu kỳ: mỗi chu kỳ được tóm thành 16 đặc trưng sạc, và mô hình ước lượng SOH ở chu kỳ n từ đặc trưng của chu kỳ đó hoặc của một cửa sổ L chu kỳ gần nhất $\mathbf{x}_{n-L+1}, \dots, \mathbf{x}_n$. Bốn họ mô hình học sâu thường dùng cho dạng

dữ liệu này:

MLP. Mạng truyền thẳng $\hat{y} = f_K \circ \ldots \circ f_1(\mathbf{x}_n)$ với $f_k(\mathbf{h}) = \sigma(W_k\mathbf{h} + \mathbf{b}_k)$ chỉ nhìn một chu kỳ, không có khái niệm thứ tự.

CNN. Mạng tích chập một chiều trượt bộ lọc dọc trục chu kỳ: $h_n = \sigma(\sum_{j=0}^{k-1} W_j \mathbf{x}_{n-j\delta} + \mathbf{b})$, với kích thước k và độ giãn δ. Khi bộ lọc chỉ nhìn các chu kỳ trước (tích chập nhân quả), đầu ra ở chu kỳ n không dùng dữ liệu tương lai [5].

LSTM. Mạng hồi quy giữ một trạng thái nhớ $\mathbf{c}_n = \mathbf{f}_n \odot \mathbf{c}_{n-1} + \mathbf{i}_n \odot \tanh(W_c[\mathbf{h}_{n-1}, \mathbf{x}_n] + \mathbf{b}_c)$ và đầu ra $\mathbf{h}_n = \mathbf{o}_n \odot \tanh(\mathbf{c}_n)$; các cổng quên $\mathbf{f}_n$, vào $\mathbf{i}_n$, ra $\mathbf{o}_n$ có dạng $\sigma(W[\mathbf{h}_{n-1}, \mathbf{x}_n] + \mathbf{b})$ và cho phép giữ thông tin qua nhiều bước [22].

Transformer. Tầng tự chú ý tính $\mathrm{softmax}(QK^\top/\sqrt{d})\,V$ trên mọi cặp vị trí trong cửa sổ, với Q, K, V là ba phép chiếu tuyến tính của đầu vào [55]. Phép tính này không phân biệt thứ tự, nên một mã hoá vị trí được cộng vào đầu vào: $\mathrm{PE}_{p,2i} = \sin(p/10000^{2i/d})$, $\mathrm{PE}_{p,2i+1} = \cos(p/10000^{2i/d})$, với p là vị trí trong cửa sổ.

Mô hình chuỗi sang chuỗi (sequence-to-sequence) dùng một bộ mã hoá đọc lịch sử và một bộ giải mã sinh chuỗi đầu ra, đúng dạng của bài toán dự báo SOH ở các chu kỳ sau (Mục 4.5). SambaMixer [21] thay tầng chú ý bằng mô hình không gian trạng thái chọn lọc (Mamba). Với nhiều cell ghép trong một khối pin, mạng tích chập đồ thị coi mỗi cell là một nút [28]; hướng này thuộc giai đoạn 2.

2.3 Mạng nơ-ron có thông tin vật lý

Xét phương trình $\mathcal{N}[u] = 0$ với nghiệm $u(\mathbf{z})$. PINN xấp xỉ u bằng mạng u_φ và cực tiểu

$$\mathcal{L}(\varphi) = \frac{1}{|D|}\sum_{(\mathbf{z},y)\in D}\big(u_\varphi(\mathbf{z}) - y\big)^2 + \lambda\frac{1}{|P|}\sum_{\mathbf{z}\in P}\big(\mathcal{N}[u_\varphi](\mathbf{z})\big)^2, \tag{2.1}$$

trong đó D là tập điểm có nhãn và P là tập điểm "collocation" chỉ cần đầu vào. Khi phương trình đã biết, số hạng thứ hai đóng vai trò tín hiệu học bổ sung không cần nhãn. Với pin, phương trình suy giảm không được biết chính xác, nên một phần của $\mathcal{N}$ phải học từ dữ liệu: đây là chỗ khác nhau giữa động học hộp đen (học hoàn toàn) và động học xám (giữ cấu trúc vật lý, chỉ học phần chưa biết).

Huấn luyện PINN khó hơn huấn luyện mạng thường. Nghiên cứu của Wang, Teng và Perdikaris [58] cho thấy gradient của các số hạng trong hàm mất mát có thể chênh nhau nhiều bậc, khiến mạng bỏ qua một số hạng; họ đề xuất cân lại trọng số trong lúc học. Krishnapriyan

và cộng sự [29] chỉ ra rằng ràng buộc mềm làm mặt mất mát khó tối ưu khi hệ số của phương trình lớn. Hai kết quả này giải thích vì sao đồ án tăng dần trọng số vật lý trong 20 % số bước đầu và giữ hệ số của $\mathscr{L}_{\text{ode}}$ nhỏ.

Braun, Raible và Huber [9] tổng hợp 212 công trình học máy có thông tin vật lý trong lĩnh vực dự báo và quản lý sức khoẻ thiết bị, xếp chúng thành bốn nhóm: đưa vật lý vào dữ liệu (thiên lệch quan sát), vào kiến trúc (thiên lệch quy nạp), vào hàm mất mát (thiên lệch học), và kết hợp. Pin lithium-ion là đối tượng được nghiên cứu nhiều nhất. Theo cách xếp này, PINN của đồ án thuộc nhóm thứ ba; bộ lọc quỹ đạo ở Mục 4.3 đưa cùng giả định đơn điệu vào bước suy luận. Navidi và cộng sự [37] so sánh bốn cách xây mô hình lai cho chẩn đoán suy giảm trên 24 cell theo dõi bốn năm, theo độ chính xác, độ phức tạp và khả năng ngoại suy; không có cách nào thắng ở mọi tiêu chí.

2.4 Học bán giám sát

Học bán giám sát tận dụng dữ liệu không nhãn qua một giả định về cấu trúc của dữ liệu, ví dụ tính trơn của hàm cần học hoặc tính nhất quán của dự đoán. Trong đồ án, giả định được dùng là giả định vật lý: quỹ đạo SOH của mọi cell, kể cả cell chưa đo dung lượng, phải thoả phương trình suy giảm, không tăng theo thời gian và nằm trong miền giá trị hợp lý. Các ràng buộc này tính được chỉ từ đặc trưng sạc, nên mỗi cell không nhãn đều đóng góp gradient cho mạng nghiệm.

Các họ bán giám sát khác dựa trên chính dự đoán của mô hình: gán nhãn giả [31], chưng cất tri thức [19], Mean Teacher [51]. Nhãn giả chỉ tốt bằng mô hình sinh ra nó; ràng buộc vật lý không phụ thuộc mô hình nào, nhưng chỉ cho biết dạng của quỹ đạo, không cho biết mức SOH.

2.5 Kết hợp mô hình và độ bất định

Trung bình dự đoán của nhiều mô hình là cách đơn giản nhất để giảm phương sai. Bagging [10] huấn luyện cùng một mô hình trên các mẫu bootstrap; stacking [62] học trọng số kết hợp các mô hình khác loại trên dữ liệu không dùng để huấn luyện chúng. Với mạng nơ-ron, Lakshminarayanan, Pritzel và Blundell [30] cho thấy chỉ cần huấn luyện vài mạng giống nhau với khởi tạo ngẫu nhiên khác nhau rồi lấy trung bình là đủ cải thiện độ chính xác, và độ phân tán giữa các mạng là một ước lượng độ bất định dùng được.

Độ phân tán đó lại không đảm bảo khoảng tin cậy có độ phủ đúng. Dự đoán phù hợp (conformal prediction) [54, 32] giải quyết việc này mà không cần giả định về phân phối: trên một tập hiệu chỉnh tách riêng, tính phần dư của mô hình, lấy phân vị phù hợp làm nửa độ rộng khoảng. Nếu các mẫu hiệu chỉnh và mẫu mới hoán đổi được cho nhau, khoảng thu được có độ phủ ít nhất bằng mức đặt ra [1]. Thelen và cộng sự [52] nhấn mạnh rằng các quyết định như thay pin cần biết độ tin cậy của dự đoán, không chỉ một con số.

2.6 Dự báo suy giảm và tuổi thọ còn lại

Ước lượng SOH cho biết dung lượng hiện tại; dự báo cho biết dung lượng ở các chu kỳ sắp tới và số chu kỳ còn lại trước khi pin chạm một ngưỡng cuối đời τ (remaining useful life, RUL). Các cách tiếp cận chia làm ba nhóm [24]. Nhóm thứ nhất khớp một hàm thực nghiệm, thường là tổng hai hàm mũ, lên dung lượng đã đo của chính cell rồi ngoại suy, có thể kèm bộ lọc Bayes để cập nhật tham số khi có thêm số đo [20]; cách này không cần dữ liệu của cell khác nhưng rất nhạy với độ dài và nhiễu của lịch sử, nhất là trước điểm đầu gối, nơi quỹ đạo đã thấy chưa chứa dấu hiệu tăng tốc [3]. Nhóm thứ hai học trực tiếp từ nhiều cell một ánh xạ từ lịch sử tới dung lượng tương lai hoặc tới RUL, bằng mạng hồi quy [63] hay mô hình dựa trên đặc trưng của các chu kỳ đầu [48]. Nhóm thứ ba ghép hai nhóm trên: dạng hàm lấy từ hiểu biết về cơ chế suy giảm, còn tham số của nó được học từ dữ liệu của nhiều cell. Đánh giá dự báo dùng thêm các chỉ số riêng cho RUL, chẳng hạn tỉ lệ dự báo rơi trong một dải sai số tương đối quanh RUL thật [45].

Một khó khăn riêng của dự báo là dung lượng đo được không giảm đều. Sau một khoảng nghỉ, các ion lithium phân bố lại trong điện cực và cell lấy lại một phần dung lượng, rồi mất dần trong vài chu kỳ tiếp theo; một số giao thức sạc–xả còn làm dung lượng dao động đều theo chu kỳ của chính giao thức. Phần thay đổi thuận nghịch này chồng lên xu thế suy giảm không thuận nghịch. Mô hình dự báo coi mọi biến động là xu thế sẽ hiểu sai cả mức lẫn tốc độ suy giảm ngay sau một lần hồi phục; SambaMixer [21] xử lý bằng cách đưa khoảng thời gian giữa hai chu kỳ vào mô hình.

2.7 Đánh giá mô hình và rò rỉ dữ liệu

Kiểm định chéo là cách chuẩn để ước lượng sai số tổng quát [2]. Khi dữ liệu có cấu trúc nhóm, ở đây là các chu kỳ thuộc cùng một cell, việc chia phải theo nhóm; nếu không, các mẫu gần như trùng nhau sẽ nằm ở cả hai phía train và test. Kapoor và Narayanan [25] tổng kết rò rỉ dữ liệu là một nguyên nhân phổ biến khiến kết quả học máy trong khoa học không tái lập được; các dạng thường gặp gồm chia không đúng đơn vị, tiền xử lý dùng thống kê của tập test và chọn mô hình trên tập test [53].

Khi so sánh hai mô hình bằng kiểm định chéo lặp lại, các tập huấn luyện chồng lấp nhau nên kết quả các fold không độc lập; phép kiểm t thông thường vì vậy quá lạc quan [13]. Nadeau và Bengio [36] đề xuất hiệu chỉnh phương sai, được Bouckaert và Frank [8] kiểm chứng cho kiểm định chéo lặp lại. Khi thực hiện nhiều phép so sánh, phương pháp Holm [23] kiểm soát xác suất mắc ít nhất một sai lầm loại I.

CHƯƠNG 3

Các công trình liên quan

Chương này tổng quan các hướng ước lượng SOH đã công bố, từ mô hình cơ chế tới học máy, học chuyển giao và mô hình lai có thông tin vật lý, rồi rút ra các khoảng trống mà đồ án nhắm tới.

3.1 Các hướng ước lượng SOH

Su, Xu và Dong [49] tổng quan các phương pháp ước lượng SOH từ cấp cell tới cấp khối pin; đồ án đi theo cách phân nhóm của họ.

Mô hình cơ chế. Mô hình điện hoá giả hai chiều (P2D) của Doyle, Fuller và Newman [14] và các dạng rút gọn như mô hình hạt đơn mô tả chi tiết quá trình bên trong cell; mô hình mạch tương đương [40] đơn giản hơn và được dùng nhiều trong BMS. Ưu điểm là diễn giải được; nhược điểm là cần nhiều tham số khó đo, việc hiệu chỉnh tham số theo lão hoá tốn kém.

Học máy dựa trên đặc trưng. Severson và cộng sự [48] cho thấy đặc trưng trích từ đường cong xả của 100 chu kỳ đầu đủ để dự đoán tuổi thọ của 124 cell LFP bằng hồi quy tuyến tính có chuẩn hoá. Richardson, Osborne và Howey [43] dùng hồi quy Gauss để dự báo SOH kèm độ bất định. Roman và cộng sự [44] xây dựng một quy trình học máy hoàn chỉnh cho ước lượng SOH; BatteryML [64] là nền tảng mã nguồn mở chuẩn hoá cách đọc dữ liệu, trích đặc trưng và so sánh mô hình trên nhiều bộ dữ liệu. Zhu và cộng sự [65] dùng đặc trưng của điện áp hồi phục sau sạc và công bố bộ dữ liệu TJU. Nhóm phương pháp này cho kết quả tốt khi có đủ nhãn, nhưng phụ thuộc nhiều vào lượng nhãn và phân phối dữ liệu huấn luyện.

Học sâu. Mạng hồi quy LSTM [63], mạng tích chập và các kiến trúc dựa trên chú ý học trực tiếp từ chuỗi đo. Với dữ liệu nhiều cell ghép song song, Piombo và cộng sự [38] công bố bộ dữ liệu thiết kế thí nghiệm đủ yếu tố để nghiên cứu mất cân bằng giữa các cell, là dữ liệu dự kiến của giai đoạn 2. Các mô hình này mạnh khi có nhiều dữ liệu có nhãn và dễ quá khớp khi ít nhãn. Gần đây, SambaMixer [21] dùng mô hình không gian trạng thái Mamba trên chuỗi điện áp, dòng điện và nhiệt độ của lần xả, kèm mã hoá vị trí theo thời gian lấy mẫu và theo khoảng thời gian giữa hai chu kỳ để học hiện tượng hồi phục dung lượng sau khoảng nghỉ; trên bộ NASA, mô hình này đạt MAE khoảng 1 % SOH.

Học chuyển giao. Ma và cộng sự [35] dùng học chuyển giao sâu để cá nhân hoá dự báo sức khoẻ cho từng cell và công bố bộ dữ liệu HUST. Hướng này giảm nhu cầu nhãn ở miền đích nhưng vẫn cần một phần nhãn để thích nghi. Lu và cộng sự [34] đi xa hơn: một nhóm mạng sâu kết hợp thích nghi miền ước lượng SOH cho pin đích không có nhãn nào, thử trên 65 cell của 5 nhà sản xuất. Kết quả này cho thấy dữ liệu không nhãn của chính pin đích mang nhiều thông tin, và cũng là lý do đồ án đưa cell không nhãn vào huấn luyện.

Dữ liệu thực tế và dữ liệu dạng bảng. Sulzer và cộng sự [50] chỉ ra rằng dữ liệu ngoài hiện trường có điều kiện vận hành không kiểm soát, cảm biến kém chính xác và rất ít lần đo dung lượng chuẩn; họ cho rằng kết hợp học máy với mô hình vật lý là hướng triển vọng vì giúp suy luận từ dữ liệu nhiễu và ngoại suy sang điều kiện mới. Một điểm ít được nhắc trong các bài về PINN cho pin là đặc trưng trích từ đường sạc là dữ liệu dạng bảng. Grinsztajn, Oyallon và Varoquaux [18] so sánh trên 45 bộ dữ liệu bảng cỡ vừa và thấy mô hình cây như gradient boosting vẫn vượt mạng nơ-ron; mạng nơ-ron khó học các hàm mục tiêu không trơn và bị ảnh hưởng nhiều hơn bởi đặc trưng không mang thông tin. Vì vậy đồ án luôn đặt GBDT làm đối chứng, và kết quả ở Chương 6 xác nhận đây là đối thủ khó nhất khi có đủ nhãn.

Mô hình lai và PINN. Mạng nơ-ron có thông tin vật lý (PINN) của Raissi, Perdikaris và Karniadakis [41] đưa phần dư của phương trình vi phân vào hàm mất mát; phần dư này được tính tại các điểm không cần nhãn. Karniadakis và cộng sự [26] tổng kết hướng học máy có thông tin vật lý, còn Aykol và cộng sự [4] thảo luận việc kết hợp vật lý với học máy cho bài toán tuổi thọ pin. Wen và cộng sự [60] áp dụng PINN cho dự báo và quản lý sức khoẻ pin. Gần với đồ án nhất là PINN4SOH của Wang và cộng sự [59]: dùng chính bốn bộ dữ liệu của đồ án, 16 đặc trưng đoạn sạc, mạng nghiệm $u(\mathbf{x}, t)$ và một mạng động học dạng hộp đen $G(\mathbf{x}, t, u, u_{\mathbf{x}}, u_t)$.

3.2 Nhận xét và khoảng trống nghiên cứu

Từ các công trình trên có thể rút ra năm khoảng trống. Thứ nhất, các mô hình học có nhãn phụ thuộc mạnh vào lượng nhãn, trong khi dữ liệu sạc không nhãn hầu như chưa được khai thác. Thứ hai, các PINN cho pin hiện có dùng nhãn trong phần vật lý hoặc chỉ áp vật lý lên cell có nhãn, nên vật lý chỉ đóng vai trò chuẩn hoá chứ không thay được nhãn. Thứ ba, kết quả công bố thường dựa trên một cách chia duy nhất, ít khi kiểm định thống kê, ít khi kiểm tra rò rỉ và ít khi so với mô hình cây, vốn mạnh trên dữ liệu dạng bảng. Thứ tư, hầu hết chỉ đưa ra một giá trị SOH mà không kèm khoảng tin cậy có độ phủ được kiểm chứng. Thứ năm, lượng nhãn được đếm theo số cell có nhãn, trong khi chi phí thật nằm ở số lần đo dung lượng và ở chỗ đặt các lần đo đó. Đồ án nhắm vào cả năm điểm này.

Bảng 3.1. Tóm tắt các hướng tiếp cận liên quan.

Công trình	Phương pháp	Vật lý	Không nhãn	Ghi chú
Severson 2019 [48]	đặc trưng xả + hồi quy tuyến tính	không	không	dự đoán tuổi thọ sớm, bộ MIT
Richardson 2017 [43]	hồi quy Gauss	không	không	có độ bất định
Roman 2021 [44]	quy trình học máy	không	không	so sánh nhiều mô hình
Zhu 2022 [65]	điện áp hồi phục + học máy	không	không	bộ TJU
Ma 2022 [35]	học chuyển giao sâu	không	một phần	bộ HUST
Lu 2023 [34]	nhóm mạng sâu + thích nghi miền	không	có	không cần nhãn pin đích
Wang 2011 [57]	hàm luỹ thừa + Arrhenius	có	không	mô hình thực nghiệm, cell LFP
Raissi 2019 [41]	PINN tổng quát	có	có	phương trình đã biết
Navidi 2024 [37]	so sánh bốn cách lai	có	không	chẩn đoán suy giảm
Wang 2024 [59]	PINN, động học hộp đen	có	không	cùng bốn bộ dữ liệu
Thelen 2024 [52]	học máy xác suất (tổng quan)	một phần	–	độ bất định
Đồ án	PINN bán giám sát, động học xám, nhóm mạng + lọc quỹ đạo	có	có	loss vật lý không dùng nhãn, khoảng dự đoán phù hợp

CHƯƠNG 4

Dữ liệu và phương pháp đề xuất

Chương này mô tả các bộ dữ liệu và cách tiền xử lý, rồi trình bày các thành phần của phương pháp: mô hình PINN bán giám sát, mô hình kết hợp PINN-lai, đầu vào có lịch sử của cell, và phần mở rộng dự báo SOH tương lai, dung lượng còn lại và RUL. Cuối chương là các mô hình đối chứng, gồm bốn mô hình học sâu theo đề cương, và cấu hình huấn luyện chung.

4.1 Dữ liệu

Bốn bộ dữ liệu được chọn vì chúng phủ ba hệ hoá học khác nhau, nhiều chế độ sạc–xả và nhiệt độ, và vì chúng đã được dùng trong công trình gốc của PINN4SOH, nên kết quả của đồ án so được với tài liệu. Chương này mô tả nguồn gốc, đặc trưng đầu vào và cách làm sạch dữ liệu; mọi bước làm sạch chỉ dùng quá khứ của chính cell để không đưa thông tin tương lai vào mô hình.

4.1.1 Nguồn dữ liệu

Đồ án dùng bốn bộ dữ liệu lão hoá pin công khai. Tất cả là cell hình trụ 18650 được sạc–xả lặp lại trong phòng thí nghiệm cho tới khi dung lượng giảm sâu.

- **XJTU** — Đại học Giao thông Tây An, công bố cùng PINN4SOH [59]: 55 cell NCM, dung lượng danh định 2,0 Ah, sáu chế độ thí nghiệm (sạc 2C, sạc 3C, xả ngẫu nhiên R2.5 và R3, bước ngẫu nhiên RW, mô phỏng quỹ đạo vệ tinh) ở nhiệt độ phòng.
- **TJU** — Zhu và cộng sự [65]: 130 cell thuộc ba nhóm hoá học (NCA, NCM và hỗn hợp NCM+NCA), thử ở 25, 35 và 45 °C với nhiều tốc độ sạc, tạo thành chín nhóm điều kiện.
- **MIT** — Severson và cộng sự [48]: cell LFP/graphite 1,1 Ah, nhiều giao thức sạc nhanh khác nhau, chia thành ba đợt thí nghiệm, buồng nhiệt 30 °C.
- **HUST** — Ma và cộng sự [35]: 77 cell LFP/graphite 1,1 Ah, cùng chế độ sạc nhanh và 77 chế độ xả nhiều bước khác nhau, 30 °C.

Đặc trưng đoạn sạc của cả bốn bộ được trích theo cùng một quy trình và công bố kèm PINN4SOH [59]; nhờ vậy bốn bộ có chung không gian đặc trưng.

Bộ thứ năm, NASA — Saha và Goebel [46], là bộ thường dùng nhất trong các công trình về SOH và RUL. Đồ án dùng 18 cell 18650 NCA (danh định 2,0 Ah) có chế độ xả cố định, đúng tập cell mà SambaMixer [21] dùng (bỏ cell số 45 vì chỉ có 17 lần sạc đầy đủ), thử ở 4, 24 và

43 °C với dòng xả 1–4 A, chia thành sáu nhóm theo giao thức. Dữ liệu gốc chỉ có chuỗi đo, nên đồ án tự trích 16 đặc trưng đoạn sạc theo đúng định nghĩa của PINN4SOH (đoạn CC từ 4,0 tới 4,2 V, đoạn CV từ 0,5 xuống 0,1 A) từ lần sạc ngay trước mỗi lần xả; nhãn là dung lượng của lần xả chia cho 2,0 Ah. Các lần xả hỏng mà tài liệu của NASA đã cảnh báo (dung lượng thấp hơn trung vị bảy lần xả lân cận quá 10 %) bị loại. Khác với bốn bộ kia, giữa các lần xả của NASA có những khoảng nghỉ dài tới hàng trăm giờ, và dung lượng hồi phục rõ sau mỗi khoảng nghỉ đó; khoảng nghỉ trước mỗi lần xả được giữ lại để dùng như một đặc trưng thứ 17.

4.1.2 Đặc trưng đầu vào

Mỗi chu kỳ được mô tả bằng 16 đặc trưng thống kê của đoạn sạc CC–CV:

- điện áp trong pha dòng không đổi: trung bình, độ lệch chuẩn, độ nhọn, độ lệch, độ dốc, entropy;
- dòng điện trong pha áp không đổi: trung bình, độ lệch chuẩn, độ nhọn, độ lệch, độ dốc, entropy;
- điện lượng nạp và thời gian của pha CC và của pha CV.

Ngoài 16 đặc trưng, mô hình nhận thêm biến thời gian $t_n = n/1000$, với n là chỉ số chu kỳ gốc. Hằng số 1000 dùng chung cho mọi cell; không chuẩn hoá theo tuổi thọ riêng của từng cell, vì làm vậy sẽ đưa thông tin tương lai vào đầu vào (Mục 5.9).

4.1.3 Tiền xử lý

Nhãn. $y_{c,n} = Q_{c,n}/Q_{\text{danh định}}$ với dung lượng danh định của từng bộ ở Bảng 4.1. Chu kỳ thiếu dung lượng được giữ lại với nhãn trống và chỉ dùng cho loss vật lý.

Lọc ngoại lai nhân quả. Chu kỳ n bị loại nếu có đặc trưng không hữu hạn, hoặc nếu có đặc trưng lệch xa so với 50 chu kỳ liền trước của chính cell đó. Với đặc trưng thứ j:

$$m_{n,j} = \text{median}(x_{n-50..n-1,j}), \quad s_{n,j} = \max\Big(\frac{\text{IQR}(x_{n-50..n-1,j})}{1{,}349},\, 0{,}01\,|m_{n,j}|\Big), \quad z_{n,j} = \frac{|x_{n,j} - m_{n,j}|}{s_{n,j}}, \tag{4.1}$$

và chu kỳ bị loại nếu $\max_j z_{n,j} > 5$ (cần ít nhất 10 chu kỳ lịch sử). Hệ số 1,349 đổi khoảng tứ phân vị sang độ lệch chuẩn của phân phối chuẩn; ngưỡng 5 được chọn trước khi huấn luyện để tỉ lệ chu kỳ bị loại (1,6 %) tương đương bộ lọc 3σ dùng cả vòng đời (2,2 %). Sau lọc còn 305.802 chu kỳ.

Chuẩn hoá. Mỗi đặc trưng được chuẩn hoá z-score bằng trung bình μ và độ lệch chuẩn σ tính trên đặc trưng của các cell huấn luyện (cả có nhãn và không nhãn): $\tilde{\mathbf{x}} = (\mathbf{x} - \mu)/(\sigma + 10^{-6})$.

4.1.4 Thống kê mô tả

Bảng 4.1. Thống kê bốn bộ dữ liệu sau tiền xử lý. "Nhóm" là số chế độ thí nghiệm khác nhau dùng để phân tầng.

Bộ	Hoá học	Cell	Chu kỳ	Nhóm	Tuổi thọ (min / trung vị / max)	SOH đầu	SOH cuối	$Q_{\text{đđ}}$ (Ah)
XJTU	NCM	55	22.431	6	110 / 392 / 942	0,83–1,00	0,78–0,89	2,0
TJU	NCA/NCM	130	56.697	9	25 / 377 / 1.246	0,88–0,98	0,66–0,90	3,5 / 2,5
MIT	LFP	125	82.450	3	36 / 622 / 2.156	0,95–1,00	0,82–0,97	1,1
HUST	LFP	77	144.224	1	1.123 / 1.855 / 2.672	1,06–1,12	0,80–0,82	1,1
Tổng		387	305.802					

Bốn bộ khác nhau rõ rệt về hoá học, tuổi thọ và mức đa dạng điều kiện vận hành. XJTU và TJU (họ niken) có tuổi thọ ngắn và nhiều chế độ; MIT và HUST (LFP) có tuổi thọ dài hơn nhiều. SOH đầu đời của HUST lớn hơn 1 do dung lượng thực tế của cell mới cao hơn dung lượng danh định. TJU là bộ duy nhất có nhiều mức nhiệt độ, nên cũng là bộ duy nhất mà hệ số Arrhenius có thể học được (Mục 6.7).

4.2 Mô hình PINN bán giám sát

4.2.1 Tổng quan

Mô hình gồm hai mạng nối với nhau qua hàm mất mát (Hình 4.1). Mạng nghiệm F_φ dự đoán SOH; mạng tốc độ G_θ cùng hai tham số vật lý λ, E_a mô tả tốc độ suy giảm. Khi suy luận chỉ cần F_φ.

4.2.2 Mạng nghiệm

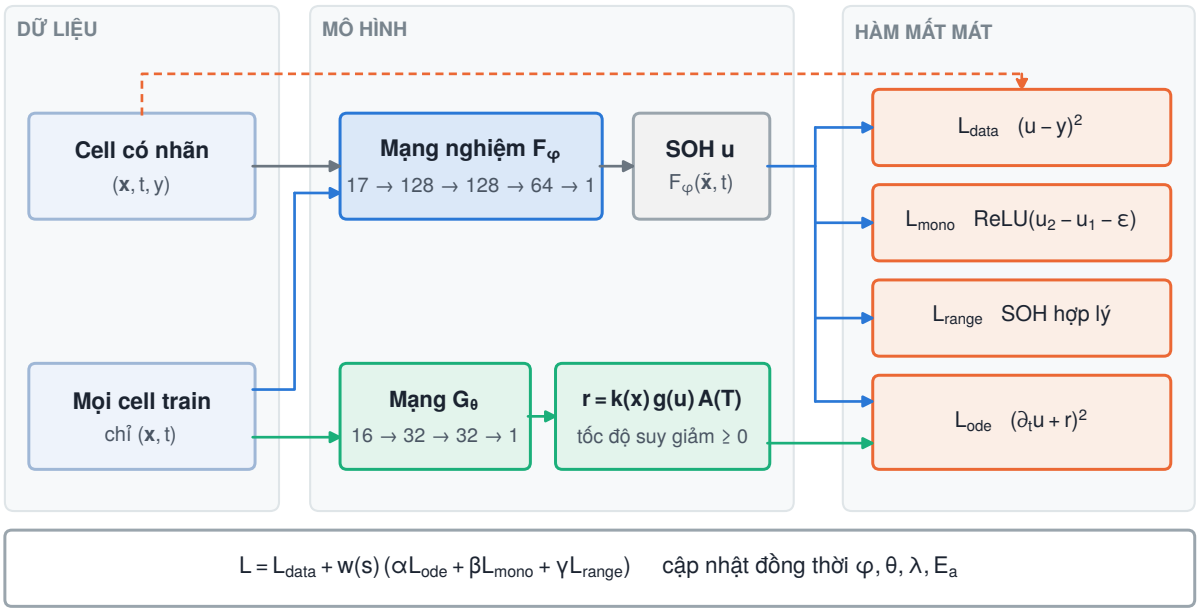
$$u = F_\varphi(\tilde{\mathbf{x}}, t), \qquad F_\varphi : \mathbb{R}^{17} \to \mathbb{R}, \tag{4.2}$$

là perceptron nhiều lớp 17–128–128–64–1 với hàm kích hoạt SiLU.

4.2.3 Động học suy giảm dạng xám

$$r(\tilde{\mathbf{x}}, u, T) = \underbrace{\operatorname{softplus}\big(G_\theta(\tilde{\mathbf{x}})\big)}_{k(\mathbf{x})} \underbrace{e^{\lambda\ \operatorname{clip}(1-u,\,-0{,}5,\,1)}}_{g(u)} \underbrace{e^{-\frac{E_a}{R_g}\left(\frac{1}{T}-\frac{1}{T_{\text{ref}}}\right)}}_{A(T)}, \tag{4.3}$$

với G_θ là perceptron 16–32–32–1, $\lambda = \operatorname{softplus}(\lambda_{\text{raw}})$, $E_a = 10^4 \operatorname{softplus}(e_{\text{raw}})$ J/mol, $R_g = 8{,}314$ J/(mol·K), $T_{\text{ref}} = 298{,}15$ K. Thừa số k là tốc độ cơ sở phụ thuộc trạng thái điện hoá (thể



Hình 4.1. Kiến trúc mô hình: mạng nghiệm dự đoán SOH, mạng tốc độ mô tả động học suy giảm; hai mạng gắn với nhau qua các hàm mất mát vật lý.

hiện qua đặc trưng sạc), g làm suy giảm tăng nhanh khi SOH thấp (hiện tượng đầu gối), A là hệ số Arrhenius. Phương trình mà mạng nghiệm phải thoả:

$$\frac{\partial u}{\partial t} = -\,r(\tilde{\mathbf{x}}, u, T). \tag{4.4}$$

4.2.4 Hàm mất mát

Với cặp chu kỳ (n_1, n_2) của cùng một cell, $n_2 \geq n_1 + h$, $h \sim \mathcal{U}\{5, \ldots, 50\}$, ký hiệu $u_i = F_\varphi(\tilde{\mathbf{x}}_{n_i}, t_{n_i})$:

$$\mathcal{L}_{\text{data}} = \frac{1}{B}\sum (u - y)^2 \qquad \text{(chỉ chu kỳ có nhãn)}, \tag{4.5}$$

$$\mathcal{L}_{\text{ode}} = \frac{1}{B}\sum \left(\partial_t u_1 + r(\tilde{\mathbf{x}}_{n_1}, u_1, T)\right)^2, \tag{4.6}$$

$$\mathcal{L}_{\text{mono}} = \frac{1}{B}\sum \text{ReLU}(u_2 - u_1 - \varepsilon), \qquad \varepsilon = 0{,}002, \tag{4.7}$$

$$\mathcal{L}_{\text{range}} = \frac{1}{B}\sum \big[\,\text{ReLU}(u_1 - 1{,}15) + \text{ReLU}(0{,}4 - u_1) + \mathbb{1}_{\text{đầu}}\big(\,\text{ReLU}(u_1 - 1{,}10) + \text{ReLU}(0{,}85 - u_1)\big)\big], \tag{4.8}$$

$$\mathcal{L} = \mathcal{L}_{\text{data}} + w(s)\left(\alpha\,\mathcal{L}_{\text{ode}} + \beta\,\mathcal{L}_{\text{mono}} + \gamma\,\mathcal{L}_{\text{range}}\right), \qquad w(s) = \min\left(1, s/(0{,}2S)\right), \tag{4.9}$$

với $\alpha = 0{,}02$, $\beta = 0{,}5$, $\gamma = 1$, $S = 4000$ bước. $\mathbb{1}_{\text{đầu}} = 1$ nếu n_1 là chu kỳ đầu của cell. Đạo hàm $\partial_t u$ tính bằng vi phân tự động.

4.2.5 Cơ chế bán giám sát

PINN-semi lấy một nửa số cặp chu kỳ từ cell có nhãn và một nửa từ cell không nhãn. Ba loss vật lý không chứa y (Mệnh đề 4.2), nên gradient của chúng theo φ trên cell không nhãn là tín hiệu học thật sự: mạng nghiệm bị buộc phải cho quỹ đạo hợp lý vật lý trên chính những cell mà nó sẽ phải tổng quát tới.

4.2.6 Phần vật lý nằm ở đâu

Mạng nghiệm F_φ tự nó là một perceptron nhiều lớp bình thường, giống hệt MLP đối chứng. Điều làm mô hình trở thành PINN nằm ở hàm mất mát và ở các điểm mà hàm mất mát được tính, không nằm ở kiến trúc mạng hay ở bước suy luận. Vật lý ở đây là vật lý ở mức hiện tượng: những quy luật định tính đã biết về lão hoá pin (dung lượng không tự hồi phục, suy giảm nhanh dần khi pin già, phản ứng phụ tăng theo nhiệt độ), được viết thành phương trình và bất đẳng thức. Đồ án không giải mô hình điện hoá chi tiết (P2D, mô hình hạt đơn) và không mô hình hoá đặc trưng sạc bằng phương trình nào. Bảng 4.2 nối từng hiểu biết vật lý với thành phần tương ứng.

Bảng 4.2. Hiểu biết vật lý và thành phần mô hình tương ứng.

Hiểu biết vật lý	Biểu diễn	Tác động vào đâu	Cần nhãn
Dung lượng không tăng theo thời gian vận hành	$\partial u/\partial t = -r, r \geq 0$	đạo hàm riêng $\partial F_\varphi/\partial t$ tại điểm $(\tilde{\mathbf{x}}_{n_1}, t_{n_1})$, qua $\mathscr{L}_{\text{ode}}$	không
Quỹ đạo SOH thực tế không tăng (cho phép hồi phục nhỏ ε)	$u_2 \leq u_1 + \varepsilon$	cặp chu kỳ (n_1, n_2) thật của cùng cell, qua $\mathscr{L}_{\text{mono}}$	không
Suy giảm nhanh dần khi pin già (đầu gối)	$g(u) = e^{\lambda(1-u)}$	thừa số trong r	không
Phản ứng phụ tăng theo nhiệt độ	$A(T)$ dạng Arrhenius	thừa số trong r	không
SOH nằm trong miền hợp lý, cell mới gần 1	các hàm ReLU chặn	giá trị u_1, qua $\mathscr{L}_{\text{range}}$	không
Dung lượng đo được	$(u - y)^2$	chu kỳ có nhãn, qua $\mathscr{L}_{\text{data}}$	có

Có ba điểm cần phân biệt. Thứ nhất, các ràng buộc được tính tại *điểm collocation*: mọi chu kỳ của mọi cell train, kể cả cell chưa đo dung lượng, ghép thành cặp (n_1, n_2); đây là chỗ dữ liệu không nhãn đi vào mô hình. Thứ hai, $\mathscr{L}_{\text{ode}}$ ràng buộc đạo hàm riêng theo t khi giữ nguyên đặc trưng sạc, còn $\mathscr{L}_{\text{mono}}$ ràng buộc tổng biến thiên dọc quỹ đạo thật, nơi cả $\mathbf{x}$ lẫn t cùng đổi; hai ràng buộc này tác động vào hai hướng khác nhau của hàm F_φ, và Mục 6.8 đo riêng từng hướng. Thứ ba, khi suy luận chỉ dùng F_φ: vật lý định hình hàm được học, chứ không tham gia vào việc

tính dự đoán.

4.2.7 Tính chất của mô hình

Mệnh đề 4.1 (Tốc độ suy giảm không âm)**.** *Với mọi tham số* θ, λ_{raw}, e_{raw} *và mọi* $(\tilde{\mathbf{x}}, u, T)$, $T > 0$*:* $r(\tilde{\mathbf{x}}, u, T) \geq 0$*. Do đó mọi nghiệm của* (4.4) *không tăng theo* t*.*

Chứng minh. $\text{softplus}(z) = \ln(1 + e^z) > 0$ với mọi z thực vì $1 + e^z > 1$. Hai thừa số còn lại là hàm mũ của số thực nên dương. Tích của ba số dương là dương; trong số học dấu phẩy động, softplus có thể tràn dưới về 0 nên phát biểu đúng là $r \geq 0$. Khi đó $\partial u/\partial t = -r \leq 0$. □

Mệnh đề 4.2 (Loss vật lý không dùng nhãn)**.** $\mathscr{L}_{ode}$, $\mathscr{L}_{mono}$, $\mathscr{L}_{range}$ *chỉ phụ thuộc đặc trưng và thời điểm của cặp chu kỳ* $(\tilde{\mathbf{x}}_{n_i}, t_{n_i})$*, nhiệt độ* T *và tham số* $(\varphi, \theta, \lambda, E_a)$*; không phụ thuộc* y*. Vì vậy chúng tính được trên mọi cell chỉ có dữ liệu sạc.*

Chứng minh. Trực tiếp từ định nghĩa: không biểu thức nào chứa y; $\partial_t u_1$ là đạo hàm của F_φ theo đầu vào t, không qua nhãn. □

Mệnh đề 4.3 (Tập không của loss đơn điệu)**.** $\mathscr{L}_{mono} = 0$ *khi và chỉ khi* $u_2 \leq u_1 + \varepsilon$ *với mọi cặp trong batch; khi vi phạm, gradient theo* $u_2 - u_1$ *bằng* $1/B$ *cho mỗi cặp vi phạm, không phụ thuộc mức vi phạm.*

Chứng minh. $\text{ReLU}(z) \geq 0$ và bằng 0 khi và chỉ khi $z \leq 0$, nên tổng các số hạng không âm bằng 0 khi và chỉ khi từng số hạng bằng 0. Đạo hàm của ReLU bằng 1 trên $z > 0$. □

Mệnh đề 4.4 (Dạng tích phân của phần dư)**.** *Nếu* u *thoả* (4.4) *dọc một quỹ đạo và* r *khả vi liên tục theo* t *trên* $[t_1, t_2]$*, thì phần dư dạng Euler* $\rho = u_2 - u_1 + r_1 \Delta t$ *thoả* $|\rho| \leq \frac{1}{2} \max |\dot{r}| \, \Delta t^2$.

Chứng minh. $u_2 - u_1 = -\int_{t_1}^{t_2} r(s)\, ds = -r_1 \Delta t - \int_{t_1}^{t_2} (r(s) - r_1)\, ds$, và $|r(s) - r_1| \leq \max |\dot{r}| \, (s - t_1)$. Lấy tích phân được cận $\frac{1}{2} \max |\dot{r}| \Delta t^2$. □

Mệnh đề 4.4 cho thấy dạng Euler dọc quỹ đạo và dạng đạo hàm riêng $\partial_t u$ là hai ràng buộc khác nhau: dạng thứ nhất ràng buộc tổng biến thiên dọc chuỗi chu kỳ thực (khi đặc trưng $\mathbf{x}$ cũng thay đổi), dạng thứ hai ràng buộc đạo hàm theo t khi giữ $\mathbf{x}$ cố định. Cả hai được so sánh ở Chương 6.

4.3 Mô hình kết hợp PINN-lai

Chương 6 sẽ cho thấy sai số còn lại của PINN-semi chủ yếu là lệch mức theo từng cell, và GBDT có sai số thấp nhất khi có đủ nhãn. Mục này mô tả các thành phần được xem xét để cải tiến mô hình và mô hình kết hợp được chọn.

4.3.1 Các thành phần được xem xét

Sáu thành phần được xem xét, mỗi thành phần dựa trên một kết quả đã công bố hoặc một quan sát ở Chương 6; Mục 6.9.2 chọn trong số đó chỉ bằng tập validation.

Nhóm mạng. Huấn luyện $M = 3$ mạng PINN-semi giống hệt nhau, chỉ khác hạt giống khởi tạo và thứ tự lấy batch, rồi lấy trung bình $\bar{F} = \frac{1}{M}\sum_m F^{(m)}$ [30]. Cả ba mạng dùng đúng cùng cách chia và cùng tập cell có nhãn, nên không có nhãn nào được thêm vào.

Kết hợp với GBDT. Lấy trung bình dự đoán của nhóm mạng và của GBDT, $\hat{y} = \omega\bar{F} + (1-\omega)g$. Đây là dạng đơn giản nhất của kết hợp mô hình khác loại [62]. Lý do để kỳ vọng nó giúp là hai mô hình có thiên lệch quy nạp khác hẳn nhau: cây quyết định học tốt các hàm không trơn trên dữ liệu bảng [18], còn PINN-semi dùng được cell không nhãn và cho quỹ đạo trơn, gần đơn điệu.

Bộ lọc quỹ đạo. Vật lý cũng có thể được đưa vào ở bước suy luận chứ không chỉ khi huấn luyện. Tại chu kỳ n của một cell, lấy w dự đoán gần nhất $\hat{y}_{n-w+1}, \dots, \hat{y}_n$, khớp một đường thẳng bằng bình phương tối thiểu [12] với ràng buộc độ dốc không dương, rồi lấy giá trị đường thẳng tại n:

$$\tilde{y}_n = \bar{y} + \min(0, \hat{\beta})\,(t_n - \bar{t}), \qquad \hat{\beta} = \frac{\sum_i (t_i - \bar{t})(\hat{y}_i - \bar{y})}{\sum_i (t_i - \bar{t})^2}, \tag{4.10}$$

với $\bar{t}, \bar{y}$ là trung bình trên cửa sổ. Bộ lọc chỉ dùng dự đoán của các chu kỳ đã qua, không dùng nhãn, nên chạy được trực tuyến. Một lựa chọn tự nhiên khác là hồi quy đơn điệu [6] trên toàn bộ quá khứ, nhưng Mệnh đề 4.5 cho thấy nó lệch xuống.

Ba hướng khác. Chưng cất từ GBDT dùng dự đoán của GBDT trên cell không nhãn làm mục tiêu mềm cho mạng [19, 31], thêm số hạng $\lambda_{\mathrm{KD}}\,\overline{(F_\varphi - g)^2}$. Ràng buộc vật lý mạnh hơn tăng trọng số đơn điệu lên $\beta = 2$, hoặc thêm phần dư Euler dọc quỹ đạo với hệ số $\alpha_E = 2$. Đặc trưng tương đối nối thêm $(\mathbf{x}_n - \mathbf{x}_{\mathrm{ref}})/|\mathbf{x}_{\mathrm{ref}}|$ so với trung bình ba chu kỳ đầu của cell, theo tinh thần của $\Delta Q(V)$ trong [48].

4.3.2 Mô hình PINN-lai

Mô hình cải tiến, gọi là PINN-lai, gồm ba bước:

$$\bar{F}(\mathbf{x}, t) = \tfrac{1}{3}\textstyle\sum_{m=1}^{3} F_{\varphi_m}(\tilde{\mathbf{x}}, t), \tag{4.11}$$

$$\hat{y}_n = \tfrac{1}{2}\,\bar{F}(\mathbf{x}_n, t_n) + \tfrac{1}{2}\,g(\mathbf{x}_n, t_n), \tag{4.12}$$

$$\tilde{y}_n = \text{bộ lọc (4.10) với } w = 10 \text{ trên } \hat{y}_{n-9}, \dots, \hat{y}_n, \tag{4.13}$$

trong đó F_{φ_m} là ba mạng PINN-semi cấu hình như Mục 4.2 và g là GBDT như Mục 4.7, cùng học trên đúng các cell có nhãn của fold. Huấn luyện tốn gấp ba PINN-semi cộng một GBDT; suy luận vẫn chỉ cần đặc trưng sạc của chu kỳ hiện tại và chín dự đoán trước đó của chính cell.

Mệnh đề 4.5. *Xét một cửa sổ w điểm cách đều. (i) Nếu $\hat{y}_i = a - c\,t_i$ với $c \geq 0$ thì $\tilde{y}_n = \hat{y}_n$: bộ lọc không làm lệch một quỹ đạo giảm tuyến tính. (ii) Nếu $\hat{y}_i = a - c\,t_i + \epsilon_i$ với ϵ_i độc lập, kỳ vọng 0, phương sai σ^2, và ràng buộc độ dốc không kích hoạt, thì $\tilde{y}_n$ không chệch và* $\mathrm{Var}(\tilde{y}_n) = \sigma^2 \dfrac{2(2w-1)}{w(w+1)}$*; với $w = 10$ là $0{,}345\,\sigma^2$. (iii) Giá trị cuối của hồi quy đơn điệu giảm trên $\hat{y}_1, \ldots, \hat{y}_n$ luôn không lớn hơn $\hat{y}_n$, nên khi $\hat{y}$ có nhiễu nó lệch xuống. (iv) Dãy $\tilde{y}_1, \tilde{y}_2, \ldots$ không nhất thiết đơn điệu: ràng buộc chỉ đặt lên độ dốc trong từng cửa sổ, còn hai chu kỳ liền nhau dùng hai cửa sổ khác nhau. Dãy*

$$m_1 = \tilde{y}_1, \qquad m_n = m_{n-1} + a\,\min(0,\ \tilde{y}_n - m_{n-1}), \quad 0 < a \leq 1, \tag{4.14}$$

thì luôn không tăng; $a = 1$ cho cực tiểu luỹ tiến của $\tilde{y}$.

Chứng minh. (i) Đường thẳng khớp đúng dữ liệu, độ dốc $-c \leq 0$ nên ràng buộc không tác động. (ii) Đây là phương sai của giá trị dự đoán bình phương tối thiểu tại đầu mút: $\sigma^2(\frac{1}{w} + \frac{(t_n - \bar{t})^2}{S_{tt}})$ với $t_n - \bar{t} = \frac{w-1}{2}$ và $S_{tt} = \frac{w(w^2-1)}{12}$ khi bước bằng 1; rút gọn được biểu thức trên. (iii) Với hồi quy đơn điệu giảm, giá trị tại điểm cuối bằng $\min_{j \leq n}$ trung bình của $\hat{y}_j, \ldots, \hat{y}_n$ [6]; chọn $j = n$ cho thấy nó không vượt $\hat{y}_n$. (iv) Lấy $\hat{y} = (0{,}9;\ 0{,}9;\ 0{,}95)$, $w = 2$: $\tilde{y}_2 = 0{,}9$, còn cửa sổ thứ ba có độ dốc dương bị chặn về 0 nên $\tilde{y}_3 = 0{,}925 > \tilde{y}_2$. Với (4.14), $m_n - m_{n-1} = a\,\min(0, \tilde{y}_n - m_{n-1}) \leq 0$. □

4.4 Đầu vào có lịch sử của cell

PINN-semi, MLP và GBDT đều dự đoán SOH ở chu kỳ n chỉ từ 16 đặc trưng sạc của chính chu kỳ đó và chỉ số chu kỳ. Đặc trưng của một chu kỳ có nhiễu đo, trong khi các chu kỳ liền trước mang thông tin về gần như cùng một trạng thái của cell. Đồ án thêm lịch sử vào đầu vào bằng các đại lượng nhân quả, chỉ dùng chu kỳ n và các chu kỳ trước của cùng cell nên vẫn chạy trực tuyến được: trung bình trượt mũ

$$\mathbf{z}_1^{(a)} = \mathbf{x}_1, \qquad \mathbf{z}_n^{(a)} = a\,\mathbf{x}_n + (1-a)\,\mathbf{z}_{n-1}^{(a)}, \tag{4.15}$$

nhớ khoảng $1/a$ chu kỳ, và độ dốc bình phương tối thiểu của từng đặc trưng trên 20 chu kỳ gần nhất. Bốn dạng được thử: chỉ $\mathbf{z}^{(0,3)}$ thay cho $\mathbf{x}$; $\mathbf{x}$ nối với $\mathbf{z}^{(0,1)}$; $\mathbf{x}$ nối với $\mathbf{z}^{(0,3)}, \mathbf{z}^{(0,1)}, \mathbf{z}^{(0,03)}$; và $\mathbf{x}$ nối với $\mathbf{z}^{(0,1)}, \mathbf{z}^{(0,03)}$ cùng độ dốc. GBDT thử thêm $\mathbf{x}$ nối với độ dốc, và $\mathbf{x}, \mathbf{z}^{(0,1)}$ nối với độ lệch của $\mathbf{x}$ so với trung bình 5 chu kỳ đầu của cell. Đây là một lớp hồi quy tuyến tính với hệ số cố định, cùng ý tưởng với mô hình không gian trạng thái của SambaMixer [21] nhưng không học hệ số. Mọi mô hình dùng được cùng đầu vào, nên phép so sánh tách được tác động của lịch sử khỏi tác động của vật lý. Với mỗi bộ và mỗi loại mô hình, dạng lịch sử được chọn trên tập validation và

chỉ được giữ khi nó giảm MAE validation ít nhất 2 %; nếu không, mô hình dùng đặc trưng gốc. PINN-lai có lịch sử dùng đúng công thức (4.11)–(4.13) với ba PINN-semi và GBDT đã chọn cho bộ.

4.5 Dự báo SOH tương lai, dung lượng còn lại và RUL

Mô hình ở các mục trên trả lời câu hỏi pin đang ở đâu. Mục này mở rộng sang câu hỏi pin sẽ đi tới đâu: tại chu kỳ gốc k của một cell, dự báo SOH ở mọi chu kỳ $k+h$, $h > 0$, rồi suy ra dung lượng còn lại $\hat{Q}(k+h) = \hat{y}(k+h)\, C_{\text{dđ}}$ (Ah, $C_{\text{dđ}}$ là dung lượng danh định) và $\text{RUL}_k = \min\{h : \hat{y}(k+h) \le \tau\}$.

Thông tin tại gốc. Bộ dự báo chỉ dùng các chu kỳ $\le k$: đặc trưng sạc $\mathbf{x}_1, \dots, \mathbf{x}_k$ và một chuỗi SOH lịch sử $s_1, \dots, s_k$. Chuỗi lịch sử có hai nguồn, ứng với hai kịch bản: dung lượng đo thật, khi BMS có đo dung lượng định kỳ; hoặc SOH do PINN-lai ước lượng từ đặc trưng sạc, khi cell không được đo dung lượng lần nào. Từ đó tạo vectơ $\mathbf{z}_k$ gồm 23 thành phần: mức hiện tại ℓ_k (bộ lọc (4.10) với $w = 10$ áp lên s), độ dốc bình phương tối thiểu trên 30 và 100 chu kỳ gần nhất, mức ban đầu ℓ_0 (trung bình 5 chu kỳ đầu) và độ giảm $\ell_0 - \ell_k$, $k/1000$, $1000/T$, cùng trung bình 16 đặc trưng sạc đã chuẩn hoá trên 10 chu kỳ gần nhất.

Nghiệm đóng của động học xám. Mạng tốc độ ở Mục 4.2 mô tả $\partial u/\partial t = -r(\mathbf{x})\, e^{\lambda(1-u)} A(T)$. Đặc trưng sạc của các chu kỳ tương lai chưa biết, nên trong tầm dự báo coi $r(\mathbf{x})A(T)$ là hằng số. Đặt $v = 1 - u$, phương trình trở thành $\mathrm{d}v/\mathrm{d}N = a_0 e^{\lambda v}$; tích phân từ gốc k cho

$$\Delta v(h) = v(k+h) - v(k) = -\frac{1}{\lambda}\ln(1 - \lambda a h), \tag{4.16}$$

trong đó a là tốc độ suy giảm tại gốc (trên 1000 chu kỳ) và h tính bằng nghìn chu kỳ. Khi $\lambda > 0$ suy giảm tăng tốc và đường cong dốc đứng khi h tiến tới $1/(\lambda a)$, đúng hình dạng của điểm đầu gối; khi $\lambda < 0$ suy giảm chậm dần; khi $\lambda \to 0$ ta có $\Delta v = ah$. Với mọi $a \ge 0$, Δv không âm và không giảm theo h, nên dự báo luôn đơn điệu mà không cần số hạng phạt. RUL cũng có dạng đóng:

$$h_\tau = \frac{1 - e^{-\lambda(\ell_k - \tau)}}{\lambda a}. \tag{4.17}$$

PINN-dự báo. Một mạng hai lớp ẩn 64 nút nhận $\mathbf{z}_k$ và trả (a, λ), với a qua hàm softplus và $\lambda = 80\tanh(\cdot/80)$; dự báo là $\hat{y}(k+h) = \ell_k - \Delta v(h; a, \lambda)$, giới hạn trong [0,40; 1,15]. Hàm mất mát là sai số bình phương giữa $\hat{y}(k+h)$ và SOH đo trên các cặp (gốc, tầm) lấy từ cell train: mỗi cell cho 40 gốc cách đều, mỗi gốc 40 điểm đích cách đều trong phần đời còn lại, nên các cell có trọng số gần bằng nhau bất kể độ dài. Khác với PINN-semi, vật lý ở đây là ràng buộc cứng: nghiệm của phương trình động học chính là lớp đầu ra. Ba thành viên với hạt giống khác nhau được lấy trung bình, dừng sớm theo MAE trên cell validation.

GBDT trực tiếp và mô hình kết hợp. GBDT học ánh xạ $(\mathbf{z}_k, h) \mapsto \ell_k - y(k+h)$ trên cùng các cặp, với ràng buộc đơn điệu tăng theo h, cùng cấu hình và cách chọn số cây như GBDT đối chứng. Mô hình kết hợp lấy trung bình hai dự báo, theo đúng lý do của PINN-lai: GBDT nội suy tốt trong miền tầm dự báo đã thấy nhưng đi ngang bên ngoài miền đó, còn PINN-dự báo ngoại suy theo dạng hàm của động học.

Mô hình đối chứng. (i) Giữ nguyên: $\hat{y}(k+h) = \ell_k$. (ii) Ngoại suy tuyến tính theo độ dốc 100 chu kỳ gần nhất, chặn để không dương. (iii) Khớp vật lý theo cell: khớp (4.16) với ba tham số (u_0, a_0, λ) lên nửa sau lịch sử của chính cell, có phạt nhẹ λ, rồi ngoại suy, đại diện cho nhóm mô hình thực nghiệm khớp theo từng cell [20].

Xét hồi phục dung lượng. Bản cải tiến tách lịch sử tại gốc thành ba phần, chỉ dùng 60 chu kỳ gần nhất: (i) xu thế, là đường thẳng khớp bằng hồi quy Huber nên vài điểm hồi phục không kéo lệch được mức và độ dốc; (ii) dao động đều, chu kỳ $P \in [2{,}2;\ 15]$ với hai hài trên phần dư, chỉ giữ khi giải thích được ít nhất 60 % phương sai trên cả cửa sổ lẫn từng nửa cửa sổ; (iii) phần hồi phục hiện tại e_k, phần dư của chu kỳ cuối sau khi trừ hai phần trên, co về 0 một khoảng bằng hai lần mức nhiễu cục bộ để nhiễu đo không bị coi là hồi phục. Dự báo trở thành

$$\hat{y}(k+h) = \ell_k + e_k\, g(h) - \Delta v(h; a, \lambda) + p_k(h), \qquad g(h) = \rho + (1-\rho)\, e^{-h/\tau_r}, \tag{4.18}$$

trong đó ℓ_k là giá trị xu thế tại gốc, Δv là nghiệm đóng (4.16) chỉ cho phần suy giảm không thuận nghịch, $p_k(h)$ là dao động ngoại suy, ρ là phần hồi phục được giữ lại và τ_r là thời gian tắt của phần còn lại. Cặp (ρ, τ_r) được ước lượng trực tiếp trên cell train của từng fold: tại mỗi lần hồi phục (SOH đo vượt trung vị năm chu kỳ trước đó quá 0,004), phần lệch của SOH so với xu thế cộng dao động trong 30 chu kỳ sau được khớp bằng $e_k\, g(h)$, dò lưới $\rho \in \{0; 0{,}1; \ldots; 1\}$ và $\tau_r \in \{0{,}5; 1; \ldots; 40\}$ chu kỳ; bộ có dưới năm lần hồi phục nhận $\rho = 0$. GBDT học phần giảm của xu thế sau khi trừ hai thành phần thuận nghịch, với trọng số trong mô hình kết hợp tăng tuyến tính từ 0 tại $h = 0$ tới $\frac{1}{2}$ tại $h = 0{,}1L$. Các lựa chọn này được chốt trên cell validation của lần lặp đầu tiên, trước khi chạy trên test.

Khoảng dự báo. Sai số có dấu (thật trừ dự báo) của mô hình kết hợp trên cell validation được chia theo tầm tương đối h/L (L là trung vị số chu kỳ của bộ, các nhóm cận 0,05; 0,1; 0,25; 0,5; 1); cộng phân vị 5 % và 95 % của mỗi nhóm vào dự báo cho khoảng 90 %. Cận dưới và cận trên của RUL là lúc biên dưới và biên trên của khoảng cắt ngưỡng τ.

4.6 Học và cập nhật với vài lần đo dung lượng

Nhãn của bài toán là dung lượng đo bằng một lần xả đầy ở điều kiện chuẩn, nên chi phí nhãn nằm ở số lần đo chứ không ở số cell. Giao thức chính đếm nhãn theo cell: 30 % cell có nhãn

nghĩa là mọi chu kỳ của 30 % số cell đều được đo. Mục này mô tả cách mô hình dùng một số ít lần đo rải trên nhiều cell, ở hai thời điểm: khi huấn luyện và khi dùng mô hình cho một cell mới.

Nhãn thưa khi huấn luyện. Mỗi cell train được đo dung lượng ở chu kỳ đầu, sau mỗi qL chu kỳ (L là trung vị số chu kỳ của các cell train) và ở chu kỳ cuối của thử nghiệm; các chu kỳ còn lại chỉ có đặc trưng sạc. Với PINN-semi, $\mathscr{L}_{\text{data}}$ chỉ tính trên các chu kỳ được đo, còn ba loss vật lý vẫn tính trên cặp chu kỳ của mọi hàng của mọi cell: ràng buộc đơn điệu và phần dư động học nối các lần đo với nhau, nên thông tin của một lần đo lan sang các chu kỳ lân cận mà không cần nhãn ở đó. GBDT không có cơ chế này; với nó, SOH ở các chu kỳ giữa hai lần đo được lấy theo nội suy tuyến tính trước khi học (lan nhãn). PINN-lai ở chế độ này giữ nguyên công thức (4.11)–(4.13), với ba mạng PINN-semi học từ nhãn thưa và GBDT học nhãn nội suy.

Cập nhật theo cell khi dùng. Sai số còn lại của PINN-lai chủ yếu là độ lệch mức riêng của từng cell (Mục 6.9), không thể sửa nếu không có thông tin nào về chính cell. Khi cell mới cũng được đo vài lần (lúc nhận pin, khi bảo dưỡng định kỳ), gọi p_n là SOH do mô hình ước lượng ở chu kỳ n và y_n là SOH đo được; sai số được mô hình hoá

$$y_n - p_n = b_n + \varepsilon_n, \qquad b_{n'} - \mu_0 = e^{-(n'-n)/\ell}\,(b_n - \mu_0) + \eta, \qquad \operatorname{Var}\varepsilon = R,\ \operatorname{Var} b = P_0, \tag{4.19}$$

tức độ lệch b_n của cell trôi chậm và hồi quy về trung bình μ_0 với độ dài tương quan ℓ (quá trình Ornstein–Uhlenbeck), còn ε_n là nhiễu nhanh. Bộ lọc Kalman cập nhật b mỗi khi có một lần đo. Ước lượng hiệu chỉnh là $p_n + \hat{b}_n$, với $\hat{b}_n$ chỉ dùng các lần đo ở chu kỳ $\le n$, kèm khoảng 90 % $\pm 1{,}645\sqrt{\hat{P}_n + R}$. Bốn tham số lấy trên cell validation của chính fold: μ_0 là sai số trung bình, R là nửa phương sai của sai phân bậc một, P_0 là phần phương sai còn lại, ℓ chọn trên lưới theo MAE riêng cho từng lịch đo. Với dự báo, đường dự báo của mô hình kết hợp có xét hồi phục được cộng thêm độ lệch hậu nghiệm tại gốc, trôi dần về μ_0 theo (4.19) trong tầm dự báo.

4.7 Các mô hình đối chứng

Mọi mô hình dùng cùng đặc trưng $[\tilde{\mathbf{x}}, t]$ (mô hình chuỗi nhận thêm các chu kỳ trước của chính cell), cùng cách chia, cùng tập cell có nhãn và cùng normaliser.

Hai biến thể cắt bỏ dùng để tách nguồn gốc lợi ích: *chỉ đơn điệu* ($\alpha = \gamma = 0$) và *PINN-semi dạng Euler* (dùng phần dư dọc quỹ đạo thay cho $\partial_t u$, $\alpha = 2$).

CNN, LSTM, Transformer. Đầu vào ở chu kỳ n là cửa sổ nhân quả L chu kỳ gần nhất của chính cell (16 đặc trưng sạc đã chuẩn hoá và chỉ số chu kỳ; đầu cửa sổ lặp lại chu kỳ đầu khi cell chưa đủ L chu kỳ), đầu ra là SOH ở chu kỳ n, nên cả ba chạy trực tuyến như các mô hình khác. CNN có 32 kênh, kích thước 5, độ giãn 1 và 2 (vùng nhìn 13 chu kỳ); LSTM 32 nút ẩn;

Bảng 4.3. Các mô hình được so sánh.

Mô hình	Nhóm	Mô tả
Ridge	học có nhãn	hồi quy tuyến tính chuẩn hoá L2; $\alpha \in \{10^{-3}, \dots, 10^{3}\}$ chọn theo validation
GPR	học có nhãn	hồi quy Gauss [42], nhân RBF + nhiễu trắng, 1 500 điểm có nhãn chọn ngẫu nhiên
GBDT	học có nhãn	gradient boosting trên cây [17], dạng histogram [27]; số cây chọn theo validation
MLP	học có nhãn	cùng kiến trúc với mạng nghiệm, chỉ $\mathscr{L}_{\text{data}}$
CNN	học có nhãn, chuỗi	tích chập nhân quả trên cửa sổ L chu kỳ gần nhất
LSTM	học có nhãn, chuỗi	một lớp LSTM trên cùng cửa sổ
Transformer	học có nhãn, chuỗi	một lớp encoder tự chú ý, mã hoá vị trí hình sin
PINN-sup	vật lý trên cell có nhãn	như PINN-semi nhưng loss vật lý chỉ tính trên cell có nhãn
PINN hộp đen	vật lý, bán giám sát	động học dạng PINN4SOH [59]: $u_t = G(\mathbf{x}, t, u, u_{\mathbf{x}}, u_t)$, cùng loss không nhãn
PINN-semi	vật lý, bán giám sát	mô hình đề xuất

Transformer 32 chiều, 4 đầu chú ý. Cả ba chỉ học có nhãn với AdamW (tốc độ học 10^{-3}), batch 128, cắt gradient ở chuẩn 1, dừng sớm theo MAE trên cell validation. Độ dài cửa sổ chọn trên validation trong $\{16, 48\}$: $L = 16$ cho CNN và Transformer; $L = 48$ cho LSTM.

4.8 Cấu hình huấn luyện

Bảng 4.4. Cấu hình huấn luyện chung cho MLP và các biến thể PINN.

Thành phần	Giá trị
Bộ tối ưu	AdamW [33], tốc độ học $2 \cdot 10^{-3}$, weight decay 10^{-5}
Lịch tốc độ học	cosine, giảm về 10^{-4} trong 4 000 bước
Batch	512 điểm có nhãn; 512 cặp chu kỳ cho loss vật lý
Cắt gradient	chuẩn $L_2 \le 5$
Dừng sớm	MAE trên validation mỗi 100 bước, dừng sau 12 lần không cải thiện, giữ trọng số tốt nhất

Trọng số vật lý (α, β) và dạng phần dư được chọn trước theo MAE validation ở một thí nghiệm sơ bộ và giữ cố định trong toàn bộ các thí nghiệm của báo cáo; không có siêu tham số nào được chọn theo tập test.

CHƯƠNG 5

Hiện thực hệ thống và thiết kế thí nghiệm

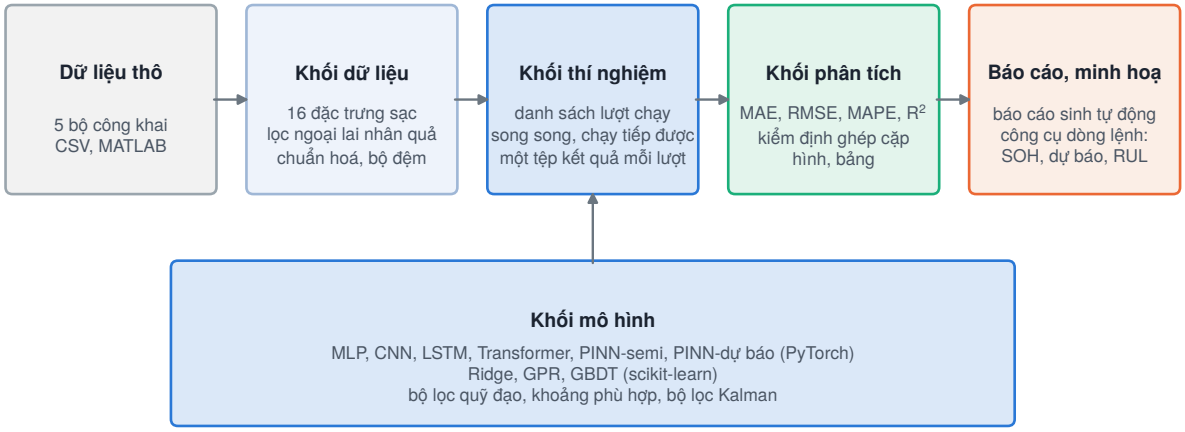
Chương này mô tả cách hệ thống được hiện thực và cách đánh giá: chia dữ liệu theo đơn vị nào và thành bao nhiêu phần, vì sao chọn đúng các con số đó, và làm sao bảo đảm không có thông tin của tập test lọt vào quá trình huấn luyện.

5.1 Kiến trúc hiện thực

Hệ thống được hiện thực bằng Python thành một đường ống năm khối (Hình 5.1), chạy được từ dữ liệu thô tới báo cáo bằng một lệnh và cho kết quả giống từng bit khi chạy lại.

1. Khối dữ liệu đọc dữ liệu đa định dạng của năm bộ (bảng CSV của bốn bộ chính, tệp MATLAB của NASA), trích 16 đặc trưng của đoạn sạc, lọc ngoại lai chỉ bằng dữ liệu quá khứ, chuẩn hoá bằng thống kê của cell train và lưu bộ đệm.
2. Khối mô hình gồm các mạng nơ-ron viết bằng PyTorch (MLP, CNN, LSTM, Transformer, PINN-semi, PINN-dự báo), các mô hình cổ điển của scikit-learn (Ridge, GPR, GBDT) và các bước hậu xử lý độc lập: bộ lọc quỹ đạo, khoảng dự đoán phù hợp, bộ lọc Kalman theo cell.
3. Khối thí nghiệm biểu diễn mỗi thí nghiệm bằng một danh sách lượt chạy (bộ dữ liệu, mô hình, mức nhãn, lần lặp, fold); bộ lập lịch chạy song song nhiều tiến trình một luồng, lượt dài trước, bỏ qua lượt đã có kết quả nên chạy tiếp được sau khi dừng, và ghi mỗi lượt thành một tệp có đủ cấu hình, chỉ số, dự đoán validation và test.
4. Khối phân tích chỉ đọc các tệp kết quả, không huấn luyện lại: tính chỉ số, kiểm định ghép cặp, chọn siêu tham số trên validation, vẽ hình.
5. Khối báo cáo sinh toàn bộ báo cáo này, mọi con số đọc từ kết quả phân tích. Một công cụ dòng lệnh nhận dữ liệu sạc của một cell và trả SOH ước lượng, dự báo SOH, dung lượng còn lại, RUL kèm hình quỹ đạo, làm bản mẫu cho giao diện của giai đoạn 2.

Mọi thí nghiệm chạy trên CPU (Intel Xeon 2,1 GHz, 4 lõi); phần mềm gồm Python 3.11, PyTorch, scikit-learn, NumPy, SciPy, pandas và Matplotlib. Mỗi lượt dùng một luồng và hạt giống cố định; chạy lại 20 lượt mẫu trên máy khác cho dự đoán trùng từng bit với kết quả báo cáo. Bảng 5.1 liệt kê các thí nghiệm và số lượt huấn luyện.



Hình 5.1. Kiến trúc hiện thực: năm khối của hệ thống, từ dữ liệu thô tới báo cáo và công cụ minh hoạ.

Bảng 5.1. Các thí nghiệm và số lượt huấn luyện.

Thí nghiệm	Nội dung	Lượt
Kiểm định chéo chính	MLP, PINN-semi ở 4 mức; PINN-sup, 2 biến thể cắt bỏ ở 30 %	1.100
Đối chứng học có nhãn	Ridge, GPR, GBDT ở 4 mức nhãn	1.200
Mở rộng biến thể vật lý	PINN-sup ở 10, 50 %; PINN hộp đen ở 4 mức	600
Kiểm toán rò rỉ	4 cách chia/chuẩn hoá sai, MLP 70 % nhãn, 2 lần lặp	160
Cải tiến mô hình (Mục 6.9)	9 hướng trên validation; PINN-lai, 3 lần lặp, 4 mức nhãn	1.680
Dự báo SOH tương lai và RUL	GBDT + 3 PINN-dự báo mỗi fold, 5 fold × 3 lần lặp × 4 bộ	75
Dự báo có xét hồi phục	cùng fold với E22, thêm bộ NASA; học lại cả mô hình E22 để so ghép cặp	75
Bộ NASA	2 bộ đặc trưng × 2 mức nhãn × 15 fold; cách chia của SambaMixer, 3 hạt giống	330
Tham số vật lý	NASA, TJU: trọng số ODE, ràng buộc Euler, giá trị khởi tạo; 70 % nhãn	100
So với PINN4SOH	đúng cách chia của bài, 39 nhóm (đầy đủ và ít mẫu) × 2 cách tiền xử lý × 3 hạt giống	1.002
Ngân sách đo	đo thưa mọi cell train, 4 lịch đo × 4 bộ × 5 fold × 3 lần lặp	1.560
Đầu vào có lịch sử	chọn dạng trên validation; PINN-semi, MLP, GBDT có lịch sử, 3 lần lặp × 5 fold	1.416
CNN, LSTM, Transformer	chọn cửa sổ trên validation; 4 mức nhãn × 4 bộ × 3 lần lặp × 5 fold; NASA	421
Tổng		**9.719**

5.2 Các yêu cầu đối với giao thức

Y1. *Không rò rỉ*: mô hình và mọi bước tiền xử lý không được dùng bất kỳ thông tin nào của cell test.

Y2. *Phủ hết dữ liệu*: mỗi cell đều phải được dùng làm test, để kết quả không phụ thuộc vào việc chọn may rủi một nhóm cell test.

Y3. *Phủ hết điều kiện thí nghiệm*: mỗi fold phải có cell của mọi chế độ thí nghiệm, để không có fold nào chỉ kiểm tra trên một chế độ lạ.

Y4. *Đủ nhãn ở mức thấp nhất*: ở 10 % nhãn, bộ nhỏ nhất (XJTU, 55 cell) vẫn phải có vài cell có nhãn.

Y5. *Đủ cell validation* để dừng sớm và chọn siêu tham số ổn định.

Y6. *Đủ chỗ cho mức nhãn cao nhất*: tập train phải chứa được 70 % số cell có nhãn.

Y7. *Ước lượng ổn định*: đủ số lần lặp để kết quả không phụ thuộc một cách xáo ngẫu nhiên.

Y8. *Ghép cặp*: mọi mô hình dùng đúng cùng các tập cell, để so sánh được theo từng cell.

5.3 Đơn vị chia: cell, không phải chu kỳ

Các chu kỳ liên tiếp của một cell gần như giống nhau: SOH chỉ thay đổi rất ít giữa hai chu kỳ kề nhau. Nếu chia ngẫu nhiên theo chu kỳ, gần như mọi chu kỳ test đều có một chu kỳ "hàng xóm" trong tập train, và bài toán suy biến thành nội suy dọc một quỹ đạo đã biết nhãn.

Mệnh đề 5.1 (Cận sai số khi chia theo chu kỳ)**.** *Giả sử mỗi chu kỳ được đưa vào train độc lập với xác suất q. Xét bộ dự đoán không dùng đặc trưng nào, chỉ chép nhãn của chu kỳ train gần nhất trong cùng cell. Khi bỏ qua hiệu ứng ở hai đầu cell, khoảng cách d tới chu kỳ train gần nhất thoả*

$$\mathbb{E}[d] = \frac{1}{1-(1-q)^2}, \tag{5.1}$$

và sai số tuyệt đối kỳ vọng không vượt quá $\mathbb{E}[d] \cdot \overline{|\Delta y|}$, với $\overline{|\Delta y|}$ là biến thiên nhãn trung bình giữa hai chu kỳ liền kề.

Chứng minh. $d > j$ khi và chỉ khi $2j$ chu kỳ gần nhất về hai phía đều không thuộc train, xác suất $(1-q)^{2j}$, nên $\mathbb{E}[d] = \sum_{j\geq 0} P(d > j) = 1/(1-(1-q)^2)$. Theo bất đẳng thức tam giác, sai số chép nhãn không vượt quá tổng d biến thiên liền kề $|\Delta y_{n+si}|$, $i = 0, \dots, d-1$, dọc quỹ đạo từ chu kỳ test n tới chu kỳ train gần nhất. Sự kiện $\{d > i\}$ chỉ phụ thuộc cách chia nên độc lập với n; lấy kỳ vọng với n phân bố đều trên cell được $\sum_{i\geq 0} P(d > i)\, \overline{|\Delta y|} = \mathbb{E}[d] \cdot \overline{|\Delta y|}$. □

Với $q = 0{,}7$, $\mathbb{E}[d] = 1{,}099$ chu kỳ. Chu kỳ test gần như luôn có một chu kỳ kề bên trong train. Một mô hình được đánh giá theo cách chia này vì vậy có thể đạt kết quả rất tốt chỉ bằng cách nhớ quỹ đạo, không phải bằng cách học quan hệ giữa đặc trưng sạc và SOH. Đơn vị chia của đồ án là cell: mọi chu kỳ của một cell nằm trọn trong train, validation hoặc test.

Hai mô phỏng kiểm tra mệnh đề trên toàn dải q: với 10^6 vị trí gán ngẫu nhiên, khoảng cách trung bình lệch công thức (5.1) không quá 0,3 %; với phép chép nhãn trên quỹ đạo SOH thật của cả 387 cell và q từ 0,1 tới 0,9, 35 trong 36 điểm nằm dưới hoặc trong khoảng 5 % quanh cận (điểm vượt nhẹ đến từ hai đầu cell). Ở mọi $q \geq 0{,}5$, sai số chép nhãn nhỏ hơn MLP được đánh giá đúng cách từ 5 lần trở lên.

5.4 Chọn số fold, tỉ lệ validation và số lần lặp

Mỗi fold gồm ba phần: test $1/K$, validation v, train $1 - 1/K - v$. Yêu cầu Y6 buộc train chứa được $f_{\max} = 70\,\%$ số cell.

Mệnh đề 5.2 (Số fold nhỏ nhất)**.** *Điều kiện* $1 - 1/K - v \geq f_{\max}$ *tương đương* $K \geq 1/(1 - v - f_{\max})$ *(biến đổi trực tiếp). Với* $v = 0{,}10$ *và* $f_{\max} = 0{,}70$*, số fold nhỏ nhất là* $K = 1/0{,}2 = 5$.

Trong các giá trị khả thi, $K = 5$ được chọn vì mỗi fold có nhiều cell test nhất (XJTU: 11 cell) nên MAE của từng fold ổn định hơn, chi phí nhỏ nhất (số lượt tỉ lệ với K), và tỉ lệ train 70 % trùng với giao thức 70/15/15 của các công trình trước, nên mức 70 % nhãn tương ứng với "dùng hết nhãn" ở đó. $K = 10$ chỉ còn 5–6 cell test mỗi fold ở XJTU và gấp đôi chi phí.

Tỉ lệ validation. Validation dùng để dừng sớm và chọn siêu tham số. Có một đánh đổi: $v = 5\,\%$ chỉ còn 3 cell validation ở XJTU, quá ít để dừng sớm ổn định; $v = 15\,\%$ buộc $K \geq 7$ (Mệnh đề 5.2) và tăng chi phí 40 %. $v = 10\,\%$ cho 6 cell validation ở bộ nhỏ nhất mà vẫn giữ $K = 5$. Cell validation có nhãn và nằm ngoài "ngân sách nhãn" của các mức 10–70 %, như nhau cho mọi mô hình.

Số lần lặp. Một lần kiểm định chéo cho mỗi cell đúng một dự đoán, nên kết quả vẫn phụ thuộc một cách xáo ngẫu nhiên. Lặp lại với R cách xáo khác nhau cho mỗi cell R dự đoán từ R mô hình khác nhau; sai số của cell được lấy trung bình qua các lần lặp. Để chọn R, đồ án mô phỏng lấy lại trên kết quả thật: với mỗi $R' \in \{1, \ldots, 5\}$, lấy mọi tổ hợp R' trong 5 lần lặp, tính lại tỉ số MAE giữa PINN-semi và MLP ở 30 % nhãn.

Độ dao động của ước lượng giữa các tổ hợp giảm gần như $1/\sqrt{R}$: một lần lặp có thể đổi kết luận ở XJTU và TJU, còn với 4–5 lần lặp ước lượng gần như cố định; độ rộng khoảng tin cậy thì bão hoà sớm, vì phần còn lại đến từ khác biệt thật giữa các cell. Các thí nghiệm chính dùng $R = 5$; các thí nghiệm về sau (PINN-lai, đầu vào có lịch sử, CNN, LSTM, Transformer, ngân sách đo) dùng ba lần lặp đầu của cùng các cách chia để giảm chi phí, và luôn so ghép cặp trên đúng các lần lặp đó.

5.5 Phân tầng theo chế độ thí nghiệm

Các cell trong cùng một bộ được thử ở nhiều chế độ khác nhau (Bảng 4.1). Nếu chia hoàn toàn ngẫu nhiên, có thể một fold không có cell nào của một chế độ, trong khi fold khác lại toàn cell của chế độ đó. Thuật toán chia dùng bộ đếm chạy liên tục qua các nhóm:

1. Xáo thứ tự cell trong từng nhóm (với hạt giống của lần lặp r); chọn ngẫu nhiên điểm bắt đầu k_0.

2. Duyệt các nhóm theo thứ tự cố định; cell thứ i trong thứ tự duyệt toàn cục được gán vào fold $(k_0 + i) \bmod K$.
3. Ở fold k: test là các cell thuộc fold k; từ phần còn lại lấy $\mathrm{round}(vN)$ cell làm validation theo vòng tròn qua các nhóm; phần còn lại là train.
4. Ở mức nhãn f: lấy $\mathrm{round}(fN)$ cell train làm cell có nhãn theo một thứ tự vòng tròn cố định qua các nhóm; các cell train còn lại là cell không nhãn.

Mệnh đề 5.3 (Phân hoạch và cân bằng)**.** *Với mỗi lần lặp: (i) các tập test của K fold rời nhau và hợp lại bằng toàn bộ $\mathscr{C}$, nên mỗi cell được test đúng một lần; (ii) số cell test của hai fold bất kỳ lệch nhau không quá 1; (iii) trong mỗi nhóm thí nghiệm b có n_b cell, số cell của nhóm trong mỗi fold bằng $\lfloor n_b/K \rfloor$ hoặc $\lceil n_b/K \rceil$.*

Chứng minh. (i) Mỗi cell nhận đúng một chỉ số fold. (ii) Trong N số nguyên liên tiếp, số phần tử cùng số dư modulo K bằng $\lfloor N/K \rfloor$ hoặc $\lceil N/K \rceil$. (iii) Cell của nhóm b chiếm n_b chỉ số liên tiếp; áp dụng (ii). □

Mệnh đề 5.4 (Tập có nhãn lồng nhau)**.** *Với cùng fold và lần lặp, nếu $f_1 < f_2$ thì tập cell có nhãn ở mức f_1 là tập con của tập ở mức f_2.*

Chứng minh. Thứ tự vòng tròn ở bước 4 chỉ phụ thuộc hạt giống, không phụ thuộc f; tập có nhãn là $\mathrm{round}(fN)$ phần tử đầu của cùng một thứ tự, và $\mathrm{round}(f_1 N) \le \mathrm{round}(f_2 N)$. □

Nhờ Mệnh đề 5.4, khi tăng mức nhãn khác biệt duy nhất là có thêm nhãn, không phải đổi sang nhóm cell khác. Kiểm tra trên cả 5 lần lặp của 4 bộ cho thấy mọi cell đều được test đúng một lần ở mỗi lần lặp và số cell của một nhóm trong các fold lệch nhau không quá 1, đúng như Mệnh đề 5.3.

Ghép cặp và hạt giống. Ở fold k của lần lặp r, mọi mô hình dùng chung hạt giống $100r + k$ cho việc chọn cell có nhãn, khởi tạo trọng số và lấy mẫu batch. Mọi mô hình vì vậy thấy đúng cùng cell train, cùng cell có nhãn, cùng cell validation và được đánh giá trên đúng cùng cell test. Nhờ đó so sánh được theo từng cell (Mục 5.11).

5.6 Quy trình chống rò rỉ trong cùng bộ dữ liệu

Định nghĩa 5.5 (Rò rỉ)**.** Một giao thức bị rò rỉ nếu tham số của mô hình đã huấn luyện, hoặc bất kỳ quyết định tiền xử lý hay chọn mô hình nào, phụ thuộc vào đặc trưng hoặc nhãn của cell test, hoặc vào thông tin không có tại thời điểm dự đoán (chẳng hạn các chu kỳ tương lai của chính cell).

Bốn quy tắc về phần dữ liệu được dùng ở từng bước:

1. Normaliser chỉ fit trên đặc trưng của cell train (có nhãn và không nhãn).
2. Bộ lọc ngoại lai quyết định giữ hay bỏ chu kỳ n chỉ bằng các chu kỳ trước n của chính cell đó.
3. Biến thời gian $t = n/1000$ dùng hằng số chung, không chuẩn hoá theo tuổi thọ từng cell.
4. Dừng sớm và chọn siêu tham số chỉ dựa trên validation; tập test chỉ được dùng một lần để đánh giá.

Mệnh đề 5.6 (Ước lượng không chệch)**.** *Giả sử các cell là mẫu độc lập cùng phân phối từ một tổng thể. Theo bốn quy tắc trên, tham số $\hat{\theta}$ của mô hình là hàm của dữ liệu cell train và cell validation, độc lập với dữ liệu cell test. Khi đó $\mathbb{E}[\mathrm{MAE}_{test} \mid \hat{\theta}]$ bằng sai số kỳ vọng của $\hat{\theta}$ trên một cell mới của tổng thể.*

Chứng minh. Normaliser, các hàm mất mát và tiêu chí dừng sớm không chứa dữ liệu cell test, còn bộ lọc của cell test chỉ dùng chính cell đó, nên $\hat{\theta}$ là hàm của dữ liệu train và validation. Vì các cell độc lập, với mỗi cell test c, $\mathbb{E}[\mathrm{MAE}_c \mid \hat{\theta}] = \mathbb{E}_{c' \sim \text{tổng thể}}[\mathrm{MAE}_{c'}(\hat{\theta})]$; lấy trung bình qua các cell test. □

5.7 Giao thức đánh giá dự báo

Dự báo dùng đúng các fold của Mục 5.3 (5 fold theo cell, 10 % cell validation, lần lặp 0–2) ở mức 70 % nhãn, nên mọi cell được dự báo đúng một lần mỗi lần lặp. Bộ dự báo học trên lịch sử đo của cell train. Ở kịch bản không đo dung lượng, lịch sử của cell test là ước lượng PINN-lai của chính fold đó, tức từ mô hình chưa thấy cell này.

Gốc dự báo SOH đặt ở 20, 40 và 60 % số chu kỳ ghi được của cell (chỉ để chọn điểm đánh giá, không phải đầu vào); sai số được báo cáo ở ba tầm $h = 0{,}1L$, $0{,}25L$, $0{,}5L$ và trên toàn bộ phần đời còn lại. Ngưỡng cuối đời τ của mỗi bộ được ấn định trước, là mức SOH thấp nhất (bước 0,01) mà ít nhất 80 % cell đã chạm tới, vì phần lớn cell của MIT và XJTU dừng đo trước mức 0,8 thường dùng; chu kỳ cuối đời thật là chu kỳ đầu tiên mà trung vị trượt 9 chu kỳ của SOH đo không vượt quá τ. Gốc dự báo RUL đặt ở 25, 50 và 75 % chu kỳ cuối đời thật. Bảng 5.2 tóm tắt các tham số.

Bảng 5.2. Tham số đánh giá dự báo của từng bộ: L là trung vị số chu kỳ ghi được, τ là ngưỡng cuối đời.

Bộ	Số cell	L (chu kỳ)	Tầm $0{,}1L$, $0{,}25L$, $0{,}5L$	τ	Cell có chu kỳ cuối đời	$C_{\mathrm{dđ}}$ (Ah)
XJTU	55	392	39, 98, 196	0,84	78 %	2,0
TJU	130	377	38, 94, 189	0,81	79 %	2,5–3,5
MIT	125	622	62, 156, 311	0,87	81 %	1,1
HUST	77	1855	186, 464, 928	0,81	96 %	1,1

Chỉ số gồm MAE của SOH theo cell ở từng tầm, quy ra dung lượng (mAh); MAE của RUL (chu kỳ) và tỉ lệ dự báo RUL nằm trong $\pm 20\,\%$ RUL thật [45]; độ phủ thực tế của khoảng 90 %. Sai số của một cell lấy trung bình qua lần lặp và các gốc; so sánh dùng Wilcoxon ghép cặp theo cell, hiệu chỉnh Holm trong mỗi bộ.

Bản có xét hồi phục chạy trên đúng các fold và hạt giống đó nên được so ghép cặp với bản đầu; mỗi cell có thêm tối đa ba gốc đặt ngay sau một lần hồi phục (SOH đo vượt trung vị năm chu kỳ trước quá 0,004, sau đỉnh của giai đoạn kích hoạt đầu đời), sai số ngắn hạn tính trong tầm $0{,}1L$ sau gốc. Bộ NASA dùng cùng giao thức, với ngưỡng cuối đời 70 % như tài liệu của NASA và SambaMixer, và thêm đúng cách chia NASA-L của SambaMixer.

5.8 So với công trình đã công bố và ngân sách đo

Cách chia của PINN4SOH. Để so trực tiếp với PINN4SOH [59], đồ án dựng lại đúng cách chia của bài từ nhật ký huấn luyện công bố kèm mã nguồn: XJTU và TJU học một mô hình cho mỗi batch, MIT và HUST một mô hình cho cả bộ với 23 và 20 cell test cố định; thí nghiệm ít mẫu chỉ cho $K = 1, \ldots, 4$ cell train đầu tiên có nhãn, đặc trưng sạc của các cell train còn lại đi vào loss vật lý. Validation như bài (20 % hàng ngẫu nhiên của cell có nhãn). Mỗi nhóm chạy 3 hạt giống với hai cách tiền xử lý: của đồ án, và bản sao của bài (lọc 3σ trên cả vòng đời, min–max theo từng cell); cách sau có rò rỉ (Mục 5.9) và chỉ dùng để so cùng điều kiện với số công bố, vốn lấy từ các tệp kết quả công bố cùng mã nguồn và tính như bài (MAE từng cell, trung bình qua cell, lần chạy, nhóm).

Ngân sách đo. Dùng đúng các fold và hạt giống của PINN-lai (3 lần lặp × 5 fold), nhưng thay vì đo đầy đủ một phần cell, mọi cell train được đo theo lịch $q \in \{0{,}5;\ 0{,}2;\ 0{,}1;\ 0{,}05\}$ của Mục 4.6; cell validation giữ nhãn đầy đủ, cell test không có nhãn, trục so sánh là phần trăm số chu kỳ của cell train có đo dung lượng. Ở chế độ đo thưa cả khi dùng, cell test cũng được đo theo cùng lịch (không có lần đo cuối), ước lượng cập nhật bằng (4.19) và sai số chỉ tính trên các chu kỳ không được đo.

5.9 Kiểm toán rò rỉ

Để đo định lượng tác động của các dạng rò rỉ thường gặp, cùng một mô hình (MLP, 70 % nhãn) được huấn luyện với bốn cách xử lý sai, mỗi cách chỉ đổi đúng một yếu tố so với giao thức chuẩn:

- *chia theo chu kỳ*: mỗi chu kỳ được gán ngẫu nhiên vào train/validation/test;
- *min–max theo cell*: đặc trưng và chỉ số chu kỳ được chuẩn hoá min–max theo toàn bộ vòng đời của từng cell, như trong mã nguồn PINN4SOH [59]; chỉ số chu kỳ sau chuẩn

hoá chính là "phần trăm tuổi thọ đã trôi qua";

- *lọc dùng cả vòng đời*: bộ lọc 3σ dùng trung bình và độ lệch chuẩn của cả vòng đời cell;
- *chuẩn hoá gồm cả test*: normaliser fit trên cả đặc trưng cell validation và test.

5.10 Chỉ số đánh giá

Với y_i là SOH thực đo và $\hat{y}_i$ là SOH dự đoán:

$$\mathrm{MAE} = \frac{1}{N}\sum |\hat{y}_i - y_i|, \quad \mathrm{RMSE} = \sqrt{\frac{1}{N}\sum (\hat{y}_i - y_i)^2}, \quad \mathrm{MAPE} = \frac{100\,\%}{N}\sum \left|\frac{\hat{y}_i - y_i}{y_i}\right|, \tag{5.2}$$

$$R^2 = 1 - \frac{\sum (\hat{y}_i - y_i)^2}{\sum (y_i - \bar{y})^2}, \qquad \mathrm{MAE}_{\mathrm{cell}} = \frac{1}{|\mathscr{C}_{\mathrm{test}}|}\sum_{c}\frac{1}{n_c}\sum_{n}|\hat{y}_{c,n} - y_{c,n}|. \tag{5.3}$$

Chỉ số chính là $\mathrm{MAE}_{\mathrm{cell}}$: mỗi cell có một phiếu, nên cell có tuổi thọ dài không lấn át kết quả. Ngoài ra đồ án báo cáo tỉ lệ cặp chu kỳ liền nhau có SOH dự đoán tăng, để đo mức vi phạm tính đơn điệu.

5.11 Phương pháp thống kê

Khoảng tin cậy. Tỉ số $\rho = \overline{\mathrm{MAE}}_{\mathrm{PINN}}/\overline{\mathrm{MAE}}_{\text{đối chứng}}$ có khoảng tin cậy 95 % theo bootstrap phân vị [15]: lấy lại mẫu *theo cell* (ghép cặp), 10 000 lần.

Kiểm định theo cell. Với $d_c = \mathrm{MAE}_c^{\mathrm{PINN}} - \mathrm{MAE}_c^{\text{đối chứng}}$, kiểm định dấu–hạng Wilcoxon [61] hai phía cho giả thuyết trung vị của d_c bằng 0. Kiểm định này không giả định phân phối chuẩn.

Hiệu chỉnh đa so sánh. Mỗi phép so sánh được thực hiện trên 4 bộ dữ liệu; p được hiệu chỉnh bằng phương pháp Holm [23]: sắp $p_{(1)} \le \ldots \le p_{(m)}$, đặt $\tilde{p}_{(i)} = \max_{j\le i} \min\left(1, (m-j+1)p_{(j)}\right)$.

Kiểm định bảo thủ ở mức fold. Các tập train của các fold chồng lấp nhau nên MAE của các fold không độc lập. Phép t hiệu chỉnh của Nadeau và Bengio [36, 8] dùng

$$t = \frac{\bar{d}}{\sqrt{\left(\frac{1}{J} + \frac{n_{\mathrm{test}}}{n_{\mathrm{train}}}\right) s_d^2}}, \qquad \text{bậc tự do } J-1, \tag{5.4}$$

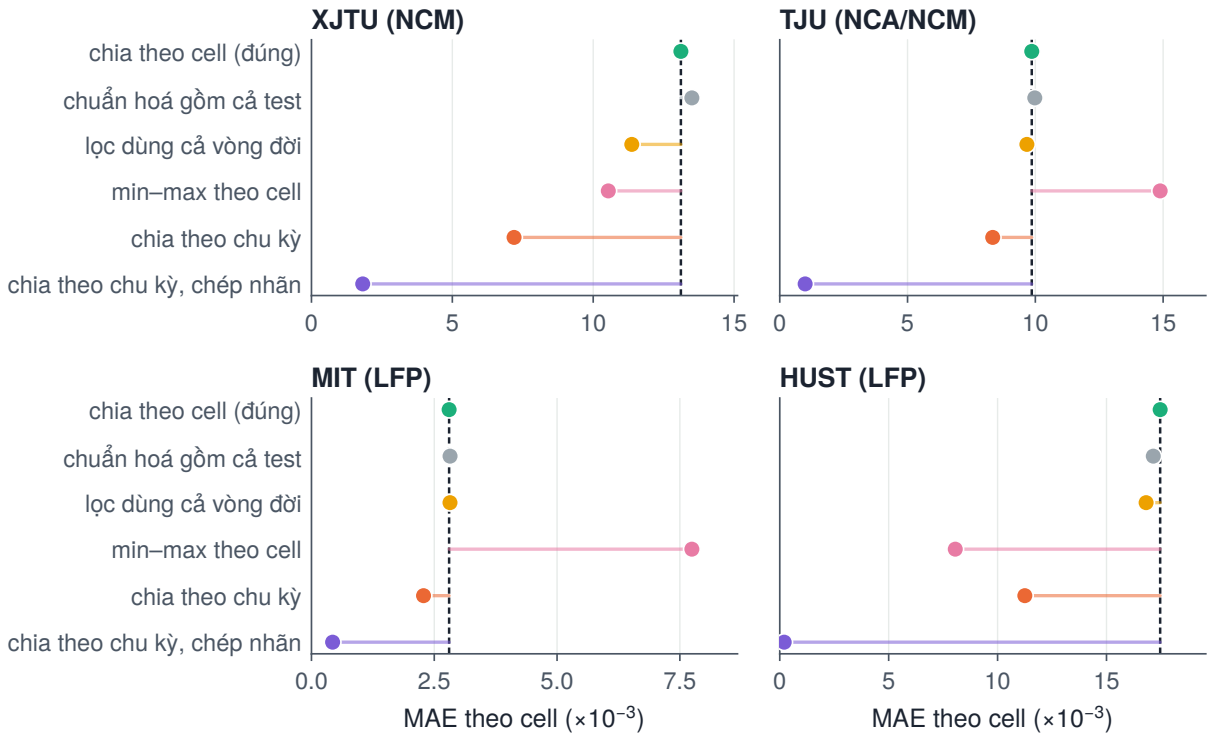
với $J = KR = 25$ hiệu theo fold. Hệ số $n_{\mathrm{test}}/n_{\mathrm{train}} \approx 0{,}29$ làm phương sai lớn hơn nhiều so với phép t thông thường, nên đây là kiểm định rất bảo thủ; kết luận được xem là vững khi qua được cả hai kiểm định.

CHƯƠNG 6

Kết quả và đánh giá

Chương này mở đầu bằng kiểm toán rò rỉ, để biết các con số sau đó có đáng tin không: cùng một mô hình được đánh giá dưới các cách chia đúng và sai. Các mục sau đi theo câu hỏi nghiên cứu: PINN và học có nhãn khi lượng nhãn thay đổi; so với các mô hình đối chứng, kể cả bốn mô hình học sâu của đề cương, bằng MAE, RMSE, MAPE và R^2; lợi ích đến từ phần nào của hàm mất mát và phần vật lý tác động lên mô hình ra sao; mô hình kết hợp PINN-lai và đầu vào có lịch sử; cuối cùng là dự báo SOH và RUL, bộ NASA và ngân sách đo.

6.1 Kiểm toán rò rỉ



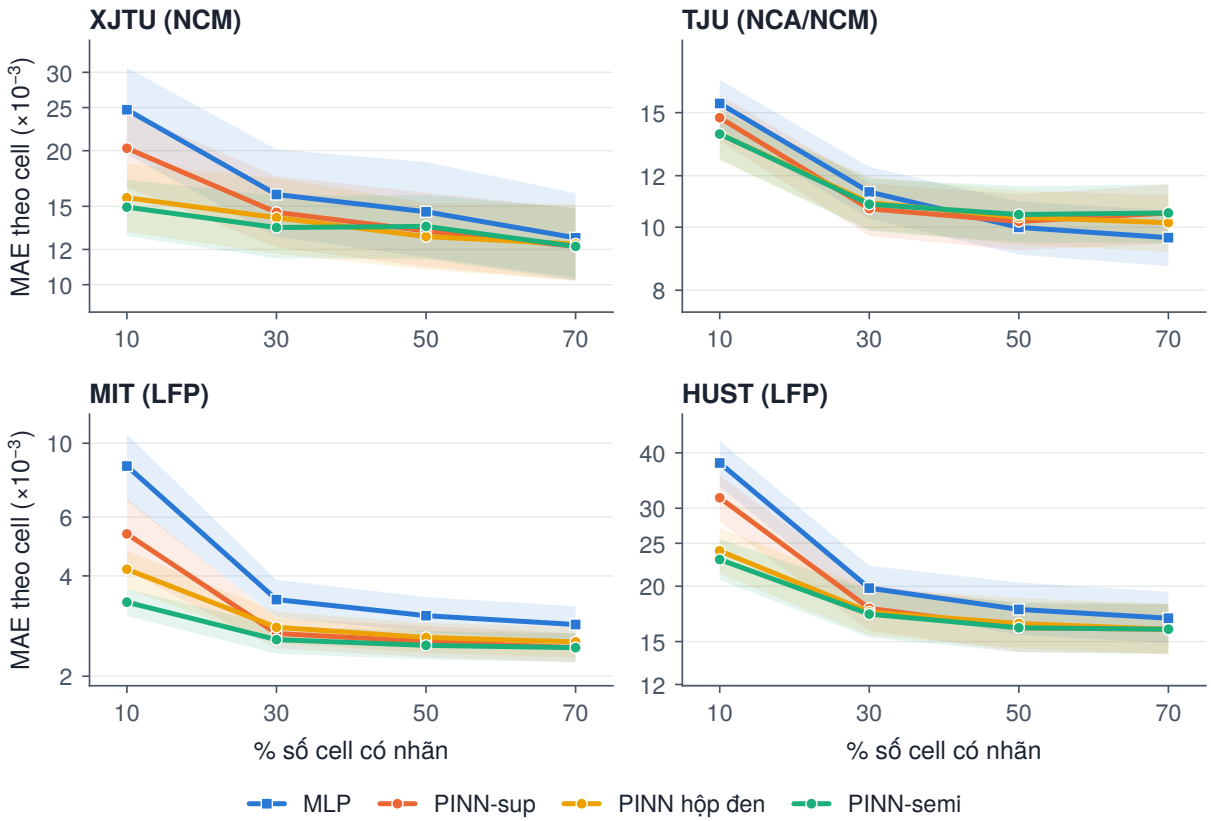
Hình 6.1. MAE theo cell của cùng một mô hình (MLP, 70 % nhãn) dưới các cách chia và chuẩn hoá khác nhau; vạch đứt là cách chia đúng (theo cell). Điểm càng lệch trái so với vạch, sai số càng bị đánh giá thấp giả tạo.

Hình 6.1 cho thấy mức độ nghiêm trọng của từng dạng rò rỉ. Chia theo chu kỳ làm sai số thấp đi 1,2–1,8 lần so với chia theo cell, dù mô hình và dữ liệu không đổi. Thiết lập cuối còn rõ hơn: một bộ "dự đoán" không dùng đặc trưng nào, chỉ chép nhãn của chu kỳ train gần nhất trong cùng cell, đạt sai số thấp hơn mọi mô hình thật được đánh giá đúng cách, đúng như Mệnh đề 5.1

dự báo. Chuẩn hoá min–max theo vòng đời cell làm sai số thấp giả tạo trên XJTU và HUST (tỉ số XJTU 0,80, HUST 0,46), vì đầu vào đã chứa vị trí tương đối của chu kỳ trong vòng đời; ở hai bộ này SOH cuối đời của mọi cell gần như bằng nhau (XJTU 0,78–0,89, HUST 0,80–0,82; Bảng 4.1), nên biết vị trí trong vòng đời gần như đủ để suy ra SOH. Ngược lại, trên TJU và MIT cùng phép chuẩn hoá đó làm sai số tăng (tỉ số TJU 1,51, MIT 2,76): SOH cuối đời ở đây trải rộng hơn (TJU 0,66–0,90, MIT 0,82–0,97), nên vị trí trong vòng đời không đủ để suy ra SOH, trong khi chuẩn hoá theo từng cell lại xoá mất mức tuyệt đối của đặc trưng, vốn là thông tin phân biệt cell này với cell khác. Dù theo chiều nào, con số đo được cũng không phản ánh sai số khi triển khai, vì tuổi thọ của một cell đang vận hành chưa biết trước. Hai dạng còn lại tác động nhỏ hơn (lọc dùng cả vòng đời: 0,87–1,01; chuẩn hoá gồm cả test: 0,98–1,03), nhưng vẫn là rò rỉ và vẫn được loại bỏ trong giao thức chuẩn. Mọi kết quả từ đây trở đi dùng giao thức chuẩn của Chương 5.

6.2 PINN và học có nhãn khi thay đổi lượng nhãn

Bảng 6.1 và Hình 6.2 là kết quả trung tâm của đồ án: sai số của mọi mô hình ở bốn mức nhãn.



Hình 6.2. MAE theo cell theo lượng nhãn: MLP và các biến thể có vật lý. Dải là khoảng tin cậy 95 % bootstrap theo cell; trục dọc thang log.

Bảng 6.1. MAE theo cell ($\times 10^{-3}$) của mọi mô hình theo lượng nhãn (phần trăm số cell có nhãn); in đậm là thấp nhất trong cột của mỗi bộ. Trung bình 5 lần lặp × 5 fold; mỗi cell được test 5 lần.

Bộ	Mô hình	10 %	30 %	50 %	70 %
XJTU	Ridge	18,22	15,54	14,81	14,09
	GPR	14,85	12,11	14,86	19,18
	GBDT	**14,49**	**10,85**	**10,19**	**9,51**
	MLP	24,72	15,95	14,58	12,74
	PINN-sup	20,25	14,54	13,21	12,19
	PINN hộp đen	15,68	14,15	12,82	12,34
	PINN-semi	14,93	13,44	13,52	12,19
TJU	Ridge	23,01	21,60	20,50	20,74
	GPR	13,50	9,22	8,01	8,17
	GBDT	**12,68**	**8,14**	**7,21**	**6,77**
	MLP	15,50	11,33	9,99	9,64
	PINN-sup	14,73	10,67	10,20	10,52
	PINN hộp đen	13,90	10,91	10,36	10,16
	PINN-semi	13,91	10,85	10,46	10,52
MIT	Ridge	3,53	3,24	3,17	3,13
	GPR	3,21	2,14	1,84	1,79
	GBDT	**3,09**	**1,99**	**1,73**	**1,58**
	MLP	8,54	3,40	3,04	2,86
	PINN-sup	5,34	2,69	2,54	2,44
	PINN hộp đen	4,19	2,80	2,61	2,54
	PINN-semi	3,34	2,58	2,48	2,44
HUST	Ridge	**22,88**	18,85	18,32	18,10
	GPR	28,82	21,24	18,50	17,22
	GBDT	24,13	18,63	**15,65**	**14,45**
	MLP	37,95	19,80	17,73	16,94
	PINN-sup	31,67	17,82	16,11	15,99
	PINN hộp đen	24,04	17,49	16,47	15,99
	PINN-semi	22,98	**17,30**	16,11	15,99

Khi có ít nhãn. Ở 10 % nhãn, PINN-semi vượt MLP với khoảng cách lớn nhất: tỉ số MAE là XJTU 0,60, TJU 0,90, MIT 0,39, HUST 0,61, có ý nghĩa trên cả bốn bộ. Ở mức này mỗi fold chỉ có 6–13 (XJTU 6, TJU 13, MIT 12, HUST 8) cell có nhãn, và MLP dễ quá khớp; loss vật lý trên các cell không nhãn buộc mạng phải cho quỹ đạo hợp lý trên chính những cell nó chưa có nhãn, nên bù được phần lớn thông tin thiếu.

Ở 30 % nhãn. PINN-semi có MAE theo cell thấp hơn MLP có ý nghĩa thống kê (Wilcoxon theo cell, hiệu chỉnh Holm) trên cả bốn bộ, với tỉ số MAE từ 0,76 (MIT) tới 0,96 (TJU). Với kiểm định bảo thủ ở mức fold, kết luận chỉ còn đứng vững trên MIT; XJTU, TJU và HUST có hướng cải thiện nhất quán nhưng biến thiên giữa các lần huấn luyện còn lớn so với mức cải thiện.

Khi có nhiều nhãn. Ở 70 % nhãn, mọi cell train đều có nhãn và không còn cell không nhãn, nên PINN-semi và PINN-sup trùng nhau; vật lý lúc này chỉ còn vai trò một bộ chuẩn hoá. Tỉ số MAE so với MLP là XJTU 0,96, TJU 1,09, MIT 0,85, HUST 0,94; cải thiện có ý nghĩa trên MIT; trên TJU MLP lại tốt hơn có ý nghĩa. Trung bình nhân của tỉ số qua bốn bộ tiến dần về 1 khi lượng nhãn tăng: 10 %: 0,60, 30 %: 0,86, 50 %: 0,92, 70 %: 0,96. Dữ liệu có nhãn càng đủ, ràng buộc vật lý càng ít thông tin mới.

Lượng nhãn tương đương. Bảng 6.2 quy đổi kết quả sang số nhãn tiết kiệm được. Một giá trị "> 70 %" nghĩa là mô hình học có nhãn chưa đạt được sai số đó ngay cả khi dùng toàn bộ nhãn train; "≤ 10 %" nghĩa là mô hình học có nhãn đã đạt sai số đó ngay ở mức nhãn thấp nhất. So với MLP, PINN-semi dùng 10 % nhãn đạt sai số mà MLP cần XJTU 45 %, TJU 17 %, MIT 33 %, HUST 25 % nhãn mới đạt, tức tiết kiệm 1,7–4,5 lần số nhãn; PINN-semi dùng 30 % nhãn tương đương MLP dùng XJTU 62 %, TJU 37 %, MIT > 70 %, HUST 61 %. So với mô hình học có nhãn tốt nhất ở từng mức thì khác: trên cả bốn bộ, mô hình học có nhãn tốt nhất đã đạt sai số của PINN-semi ngay ở 10 % nhãn; ở 30 % nhãn, PINN-semi vẫn tiết kiệm nhãn trên HUST (tương đương 38 %), còn trên XJTU, TJU và MIT mô hình tốt nhất chỉ cần 15–18 % nhãn để bằng PINN-semi 30 %.

Bảng 6.2. Lượng nhãn tương đương: mô hình học có nhãn cần bao nhiêu phần trăm cell có nhãn để đạt MAE của PINN-semi ở 10 % và 30 % nhãn ("tốt nhất": mô hình học có nhãn tốt nhất ở từng mức, trong Ridge, GPR, GBDT, MLP). Nội suy log-tuyến tính giữa các mức đo.

Bộ	PINN 10 % ≈ MLP	PINN 10 % ≈ tốt nhất	PINN 30 % ≈ MLP	PINN 30 % ≈ tốt nhất
XJTU	45 %	≤ 10 %	62 %	15 %
TJU	17 %	≤ 10 %	37 %	17 %
MIT	33 %	≤ 10 %	> 70 %	18 %
HUST	25 %	≤ 10 %	61 %	38 %

Bảng 6.3. Tỉ số MAE theo cell của PINN-semi so với MLP và GBDT ở từng mức nhãn (nhỏ hơn 1: PINN-semi tốt hơn). *: $p_{\text{Holm}} < 0{,}05$ theo cell; †: còn có ý nghĩa với kiểm định bảo thủ mức fold.

Bộ	Nhãn	so với MLP: tỉ số [KTC]	cell tốt hơn	p_{Holm}	so với GBDT: tỉ số [KTC]	cell tốt hơn	p_{Holm}
XJTU	10 %	0,60 [0,54; 0,68]*	91 %	$< 10^{-4}$	1,03 [0,93; 1,15]	47 %	0,8210
	30 %	0,84 [0,76; 0,93]*	65 %	0,0047	1,24 [1,11; 1,42]*	31 %	0,0004
	50 %	0,93 [0,81; 1,06]	45 %	0,7502	1,33 [1,17; 1,53]*	20 %	$< 10^{-4}$
	70 %	0,96 [0,90; 1,02]	53 %	0,4712	1,28 [1,11; 1,54]*	33 %	0,0010
TJU	10 %	0,90 [0,87; 0,93]*	75 %	$< 10^{-4}$	1,10 [1,02; 1,18]*	38 %	0,0340
	30 %	0,96 [0,93; 0,99]*	68 %	0,0041	1,33 [1,24; 1,44]*	28 %	$< 10^{-4}$
	50 %	1,05 [1,01; 1,09]	43 %	0,2363	1,45 [1,33; 1,58]*†	22 %	$< 10^{-4}$
	70 %	1,09 [1,04; 1,14]*	41 %	0,0086	1,55 [1,40; 1,72]*†	20 %	$< 10^{-4}$
MIT	10 %	0,39 [0,32; 0,48]*	90 %	$< 10^{-4}$	1,08 [1,00; 1,16]	45 %	0,1991
	30 %	0,76 [0,69; 0,83]*†	82 %	$< 10^{-4}$	1,30 [1,21; 1,40]*†	18 %	$< 10^{-4}$
	50 %	0,81 [0,75; 0,88]*	79 %	$< 10^{-4}$	1,43 [1,34; 1,54]*†	9 %	$< 10^{-4}$
	70 %	0,85 [0,79; 0,92]*	74 %	$< 10^{-4}$	1,54 [1,44; 1,67]*†	6 %	$< 10^{-4}$
HUST	10 %	0,61 [0,55; 0,67]*	92 %	$< 10^{-4}$	0,95 [0,89; 1,02]	61 %	0,0720
	30 %	0,87 [0,82; 0,92]*	71 %	$< 10^{-4}$	0,93 [0,86; 1,00]*	69 %	0,0042
	50 %	0,91 [0,87; 0,95]*	68 %	0,0008	1,03 [0,95; 1,12]	56 %	0,9939
	70 %	0,94 [0,90; 0,99]	65 %	0,0526	1,11 [1,01; 1,22]	43 %	0,0923

6.3 So với các mô hình học có nhãn khác

Ridge, dù chỉ là mô hình tuyến tính, tốt hơn MLP ở 10 % nhãn trên XJTU, MIT và HUST: khi rất ít nhãn, mô hình đơn giản ít quá khớp hơn. Nhưng Ridge cải thiện chậm khi thêm nhãn: MAE ở 70 % bằng 0,77–0,90 lần MAE ở 10 %, so với 0,33–0,62 lần của MLP. GPR chỉ dùng được 1 500 điểm huấn luyện do chi phí $O(n^3)$ theo số điểm, và kém GBDT trong 16/16 trường hợp (bộ × mức nhãn); dù vậy GPR vẫn có MAE thấp hơn PINN-semi trong 10/16 trường hợp, và thấp hơn ở cả bốn mức nhãn trên TJU và MIT. GBDT là đối thủ mạnh nhất: mô hình này tốt hơn PINN-semi có ý nghĩa thống kê ở 10 % (TJU); 30 % (XJTU, TJU và MIT); 50 % (XJTU, TJU và MIT); 70 % (XJTU, TJU và MIT); ngược lại PINN-semi tốt hơn GBDT có ý nghĩa ở 30 % (HUST). Ở 10 % nhãn, tỉ số MAE của PINN-semi so với GBDT là XJTU 1,03, TJU 1,10, MIT 1,08, HUST 0,95. Cây quyết định xử lý tốt các đặc trưng có phân phối lệch và các chế độ thí nghiệm khác hẳn nhau mà không cần chuẩn hoá cẩn thận; đây là ưu thế quen thuộc của mô hình cây trên dữ liệu dạng bảng. Phát biểu đúng mức vì vậy là: vật lý cải thiện rõ rệt *mô hình mạng nơ-ron* khi ít nhãn và đưa nó tới gần mô hình cây ở 10 % nhãn (tỉ số so với GBDT 0,95–1,10), nhưng chưa vượt được một mô hình cây được tinh chỉnh tốt, cũng như hồi quy Gauss, trên phần lớn các bộ dữ liệu.

6.4 So với các mô hình học sâu theo đề cương

Bảng 6.4, 6.5 và 6.6 cho MAE, R^2, RMSE và MAPE của các mô hình chính trên cùng các fold và cell có nhãn.

Bảng 6.4. MAE theo cell ($\times 10^{-3}$) trên test của mọi mô hình chính, 3 lần lặp × 5 fold, cùng fold và cell có nhãn; in đậm là thấp nhất mỗi hàng. PINN-lai là bản tinh chỉnh trên validation; mô hình cuối là PINN-lai dùng hay không dùng lịch sử theo validation (Mục 6.10).

Bộ	Nhãn	MLP	GBDT	PINN-semi	PINN-lai	Mô hình cuối
XJTU	10 %	23,27	14,01	14,65	**12,71**	**12,71**
	30 %	15,61	10,87	13,35	**10,78**	**10,78**
	50 %	14,10	10,18	13,20	**10,02**	**10,02**
	70 %	12,48	9,64	12,53	**9,50**	**9,50**
TJU	10 %	15,81	12,60	14,01	**11,70**	**11,70**
	30 %	11,71	8,06	11,39	8,00	**7,78**
	50 %	9,96	7,17	10,74	7,23	**6,92**
	70 %	9,71	6,96	10,80	7,11	**6,82**
MIT	10 %	9,02	3,15	3,29	**2,52**	**2,52**
	30 %	3,39	1,97	2,50	**1,75**	**1,75**
	50 %	3,06	1,74	2,45	**1,59**	**1,59**
	70 %	2,85	1,59	2,38	**1,48**	**1,48**
HUST	10 %	41,62	23,84	22,76	**20,36**	**20,36**
	30 %	20,00	18,73	17,10	15,99	**15,34**
	50 %	18,13	15,82	16,42	14,26	**13,17**
	70 %	17,19	14,60	16,38	13,76	**12,24**

Bảng 6.5. R^2 trên test, tính trên dự đoán ghép 5 fold của một lần lặp (mỗi cell đúng một lần), bỏ 10 chu kỳ đầu mỗi cell, trung bình 3 lần lặp; in đậm là cao nhất mỗi hàng.

Bộ	Nhãn	MLP	GBDT	PINN-semi	PINN-lai	Mô hình cuối
XJTU	10 %	0,434	0,793	0,813	**0,830**	**0,830**
	30 %	0,796	0,861	0,860	**0,875**	**0,875**
	50 %	0,825	0,879	0,856	**0,888**	**0,888**
	70 %	0,858	0,879	0,873	**0,890**	**0,890**
TJU	10 %	0,903	0,926	0,931	**0,941**	**0,941**
	30 %	0,954	0,970	0,957	0,973	**0,974**
	50 %	0,965	0,976	0,961	0,978	**0,979**
	70 %	0,968	0,978	0,963	0,980	**0,980**
MIT	10 %	0,679	0,973	0,974	**0,987**	**0,987**
	30 %	0,950	0,985	0,986	**0,991**	**0,991**
	50 %	0,964	0,990	0,986	**0,993**	**0,993**
	70 %	0,975	0,992	0,988	**0,994**	**0,994**
HUST	10 %	−0,083	0,783	0,770	**0,827**	**0,827**
	30 %	0,864	0,858	0,893	0,901	**0,907**
	50 %	0,878	0,896	0,902	0,917	**0,931**
	70 %	0,893	0,909	0,903	0,923	**0,939**

Bảng 6.6. Ở 30 % nhãn: RMSE theo cell ($\times 10^{-3}$) và MAPE (%, gộp mọi chu kỳ) trên test; in đậm là thấp nhất mỗi cột.

Mô hình	XJTU RMSE	MAPE	TJU RMSE	MAPE	MIT RMSE	MAPE	HUST RMSE	MAPE
MLP	23,10	1,47	13,94	1,20	4,65	0,41	26,07	2,12
GBDT	**14,37**	1,19	9,74	0,90	2,93	0,21	25,98	2,04
PINN-semi	19,42	1,32	13,54	1,16	3,34	0,28	22,84	1,83
PINN-lai	14,37	**1,16**	9,54	0,87	**2,47**	**0,18**	**21,86**	1,72
Mô hình cuối	14,37	1,16	**9,22**	**0,85**	2,47	0,18	22,38	**1,65**

6.5 Lợi ích đến từ đâu

Bảng 6.7. Tách nguồn gốc lợi ích ở 30 % nhãn: MAE theo cell ($\times 10^{-3}$), trong ngoặc là tỉ số so với MLP.

Mô hình (30 % nhãn)	XJTU	TJU	MIT	HUST
MLP	15,95	11,33	3,40	19,80
PINN-sup	14,54 (0,91)	10,67 (0,94)	2,69 (0,79)	17,82 (0,90)
chỉ đơn điệu	14,13 (0,89)	11,00 (0,97)	2,86 (0,84)	17,41 (0,88)
PINN-semi (Euler)	13,37 (0,84)	11,31 (1,00)	3,01 (0,89)	17,49 (0,88)
PINN hộp đen	14,15 (0,89)	10,91 (0,96)	2,80 (0,83)	17,49 (0,88)
PINN-semi	13,44 (0,84)	10,85 (0,96)	2,58 (0,76)	17,30 (0,87)

- *Vật lý chỉ trên cell có nhãn* (PINN-sup): ở 10 % nhãn tỉ số so với MLP là XJTU 0,82, TJU 0,95, MIT 0,63, HUST 0,83. Vật lý đóng vai trò bộ chuẩn hoá có giúp, nhưng còn xa mới bằng PINN-semi.
- *Thêm cell không nhãn* (PINN-semi so với PINN-sup): tỉ số XJTU 0,74, TJU 0,94, MIT 0,62, HUST 0,73 ở 10 % và XJTU 0,92, TJU 1,02, MIT 0,96, HUST 0,97 ở 30 % nhãn. Tính theo thang log, phần này chiếm 50–64 % mức giảm sai số của PINN-semi so với MLP ở 10 % nhãn, phần còn lại đến từ vật lý trên cell có nhãn. Ở mức nhãn thấp, dữ liệu không nhãn đóng góp ít nhất ngang với vật lý trên cell có nhãn, và nó chỉ có ích khi được nối với mô hình qua loss vật lý không dùng nhãn.
- *Phương trình động học so với chỉ đơn điệu*: chỉ với ràng buộc đơn điệu, mô hình đã đạt 62–95 % mức giảm sai số (thang log) của PINN-semi so với MLP ở 30 % nhãn. Khi bỏ $\mathscr{L}_{\text{ode}}$ và $\mathscr{L}_{\text{range}}$, MAE bằng XJTU 1,05, TJU 1,01, MIT 1,11, HUST 1,01 lần PINN-semi đầy đủ, chênh lệch lớn nhất ở MIT: phần còn lại của lợi ích đến từ cấu trúc động học.
- *Dạng phần dư*: MAE của phần dư Euler dọc quỹ đạo so với dạng đạo hàm riêng theo t là XJTU 0,99, TJU 1,04, MIT 1,17, HUST 1,01: ngang nhau trên XJTU và HUST; kém hơn trên TJU và MIT.

- *Động học hộp đen* (kiểu PINN4SOH) so với động học xám: tỉ số MAE của PINN hộp đen so với PINN-semi là XJTU 1,05, TJU 1,00, MIT 1,26, HUST 1,05 ở 10 % và XJTU 1,05, TJU 1,01, MIT 1,09, HUST 1,01 ở 30 % nhãn. Theo kiểm định Wilcoxon có hiệu chỉnh Holm, động học xám tốt hơn có ý nghĩa ở 10 % (MIT và HUST); 30 % (MIT); 50 % (HUST), hộp đen tốt hơn có ý nghĩa ở 50 % (XJTU); 11 trường hợp còn lại (trong 16 cặp bộ × mức nhãn) khác biệt không có ý nghĩa. Khác biệt lớn nhất ở MIT với 10 % nhãn, khi MAE của PINN hộp đen bằng 1,26 lần PINN-semi. Ở 30 % nhãn, sai số của PINN hộp đen gần như trùng với biến thể chỉ đơn điệu (chênh không quá 2 %). Điều này phù hợp với giả thuyết: khi G nhận cả u_t làm đầu vào, mạng có thể học $G \approx u_t$ nên phần dư động học bị thoả mãn tầm thường, chỉ còn ràng buộc đơn điệu và miền giá trị có tác dụng; động học xám không có lối thoát này vì r không phụ thuộc u_t và luôn không âm.

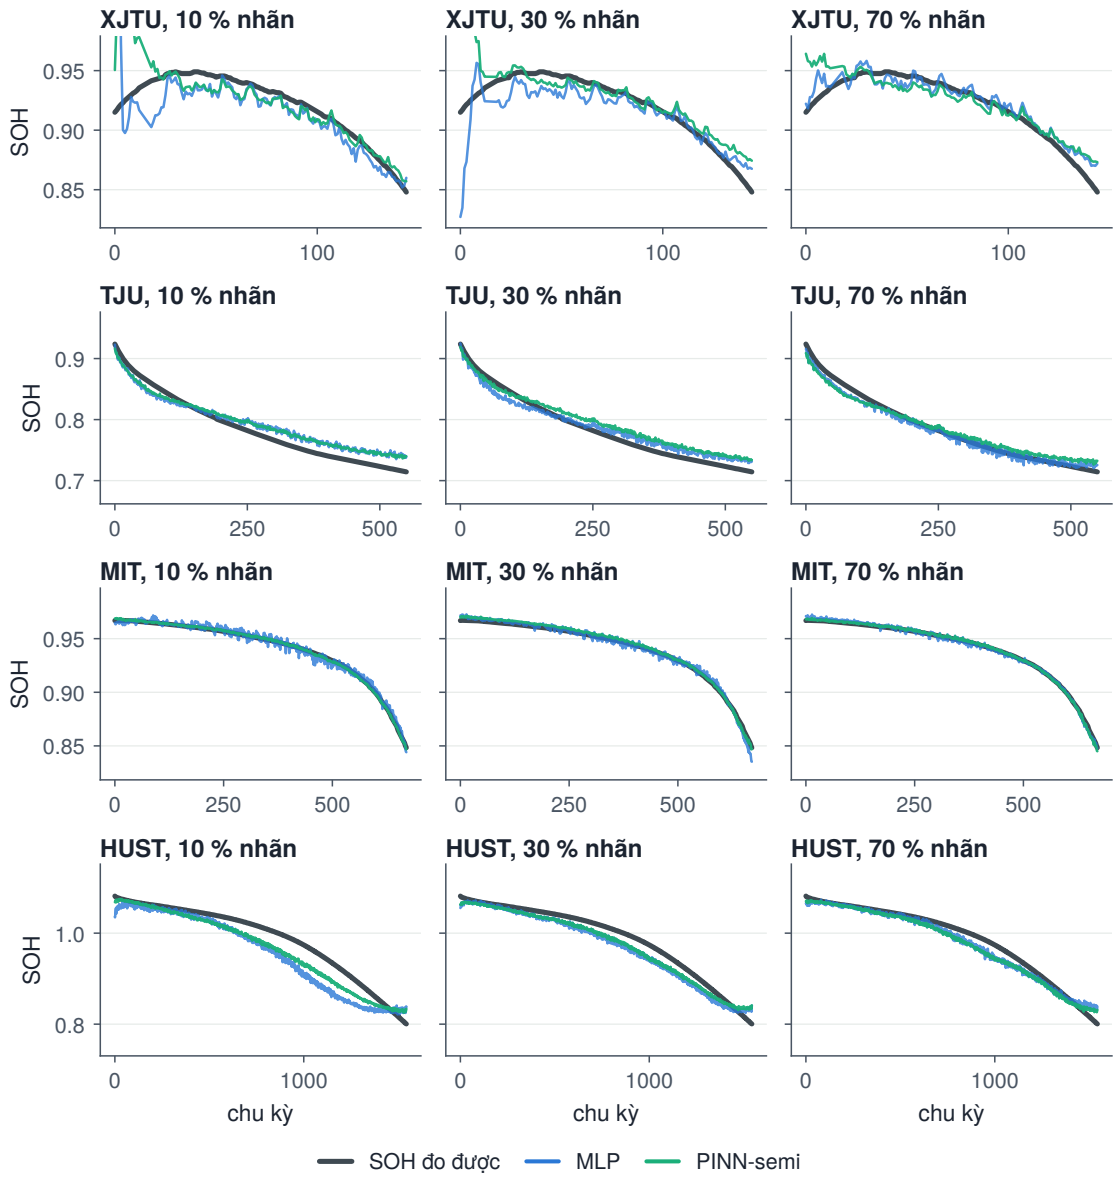
6.6 Quỹ đạo dự đoán theo lượng nhãn

Hình 6.3 đặt cạnh nhau dự đoán cho cùng một cell khi lượng nhãn tăng từ 10 lên 30 và 70 %. Khi ít nhãn, cả hai mô hình bám được hình dạng của quỹ đạo nhưng lệch mức, rõ nhất ở TJU và HUST; thêm nhãn chủ yếu làm giảm phần lệch mức này chứ không làm thay đổi hình dạng. Ở 10 % nhãn, dự đoán của MLP dao động mạnh hơn và có những đoạn đi lên, còn PINN-semi giữ được xu hướng giảm; khoảng cách giữa hai mô hình thu hẹp dần khi nhãn tăng.

6.7 Tham số vật lý học được

Cả hai tham số vật lý gần như không rời giá trị khởi tạo: λ nằm trong khoảng 0,96–0,97 trên mọi bộ (khởi tạo 1), E_a dịch XJTU 0,0, TJU 1,1, MIT 1,0, HUST 1,1 kJ/mol. Trên XJTU, nhiệt độ thí nghiệm trùng $T_{\text{ref}} = 25\,^{\circ}\text{C}$ nên $A(T) = 1$ và gradient theo E_a bằng 0; trên MIT và HUST, mọi cell cùng 30 °C nên $A(T)$ chỉ là một hằng số nhân, không tách được khỏi $k(\mathbf{x})$. Ngay cả trên TJU, nơi có ba mức nhiệt độ, E_a cũng chỉ dịch chừng 1 kJ/mol: với trọng số $\alpha = 0{,}02$, tín hiệu từ $\mathscr{L}_{\text{ode}}$ quá yếu để ước lượng E_a, và mạng $k(\mathbf{x})$ có thể tự hấp thụ ảnh hưởng của nhiệt độ qua đặc trưng sạc. Vì vậy hai tham số này nên được hiểu là phần cấu trúc của ràng buộc (dấu và dạng hàm của tốc độ suy giảm), không phải đại lượng vật lý được ước lượng từ dữ liệu.

Hai giải thích trên được tách bằng một thí nghiệm bổ sung trên NASA (4, 24, 43 °C) và TJU (25, 35, 45 °C): huấn luyện lại PINN-semi ở 70 % nhãn với α tăng lên 0,2 và 1, có hoặc không thêm ràng buộc Euler, và với khởi tạo $\lambda = 3$, $E_a = 60$ kJ/mol. Hiệu giữa giá trị học được của hai cách khởi tạo bằng 1,00–1,01 lần hiệu khởi tạo với λ và 0,99–1,01 lần với E_a, kể cả khi ràng buộc ODE mạnh gấp 50 lần: tham số đứng yên ở nơi được đặt. Giải thích hợp lý nhất nằm ở cấu trúc: tốc độ suy giảm chỉ xuất hiện dưới dạng tích $k(\mathbf{x})\, g(u)\, A(T)$, mà $k(\mathbf{x})$ nhận chính các đặc trưng sạc vốn đã mang thông tin về nhiệt độ và mức SOH, nên k bù lại mọi thay đổi của λ hay



Hình 6.3. Quỹ đạo SOH của cùng một cell test mỗi bộ khi có 10, 30 và 70 % số cell mang nhãn (lần lặp 0). Cell được chọn là cell có sai số MLP ở trung vị của bộ tại 30 % nhãn, bỏ qua các cell có nhãn nhảy bất thường giữa hai chu kỳ; trục dọc theo dải SOH thực đo nên vài chu kỳ đầu của XJTU vượt khỏi khung.

E_a. Sai số của các nhánh không khác cấu hình chuẩn có ý nghĩa (tỉ số MAE 0,93–1,12); thêm ràng buộc Euler cho tỉ số 0,93 trên NASA và 1,25 trên TJU (có ý nghĩa).

6.8 Kiểm tra phần vật lý

Mục 4.2.6 chỉ ra rằng ba hàm mất mát vật lý tác động vào hai hướng khác nhau của hàm F_φ: $\mathscr{L}_{\text{mono}}$ tác động lên tổng biến thiên dọc quỹ đạo thật của cell, $\mathscr{L}_{\text{ode}}$ tác động lên đạo hàm riêng theo thời gian khi giữ nguyên đặc trưng sạc. Mục này đo riêng từng hướng trên các cell test.

Dọc quỹ đạo: tính đơn điệu của dự đoán. Với mỗi cell test, đếm các cặp chu kỳ cách nhau ít nhất 10 chu kỳ mà SOH dự đoán ở chu kỳ sau cao hơn chu kỳ trước quá 0,002, tức đúng ngưỡng của $\mathscr{L}_{\text{mono}}$. Phép đếm này không cần nhãn, nên làm được với mọi mô hình; làm trên chính nhãn thật cho mức tham chiếu, vì dung lượng thật có thể hồi phục nhẹ sau thời gian nghỉ. Ở 30 % nhãn, dự đoán của MLP tăng ngược ở 13,6–31,1 % số cặp, của PINN-semi chỉ 3,0–12,0 %, trong khi nhãn thật là 0,1–7,7 %. Biến thể chỉ đơn điệu cho tỉ lệ gần như bằng PINN-semi (3,1–12,4 %): chính $\mathscr{L}_{\text{mono}}$, áp lên cặp chu kỳ của cả cell không nhãn, làm quỹ đạo dự đoán đơn điệu.

Theo thời gian: đạo hàm riêng và phần dư ODE. Đại lượng mà $\mathscr{L}_{\text{ode}}$ ràng buộc là $\partial F_\varphi / \partial t$, chỉ tính được từ chính mô hình. Trọng số mô hình không được lưu, nhưng huấn luyện là tất định, nên đồ án huấn luyện lại các lượt của MLP, PINN-semi, các biến thể cắt bỏ và PINN hộp đen ở 30 % nhãn, lần lặp đầu, cả 5 fold trên 4 bộ: 120/120 lượt cho MAE trùng từng bit với lượt đã báo cáo. Trên cell test của từng lượt, đo $\partial F_\varphi / \partial t$ bằng vi phân tự động, tốc độ r của động học xám, và tách tổng mức giảm SOH dự đoán trên vòng đời cell thành phần do biến thời gian $\sum_i [F_\varphi(\tilde{\mathbf{x}}_i, t_{i+1}) - F_\varphi(\tilde{\mathbf{x}}_i, t_i)]$ và phần do đặc trưng sạc $\sum_i [F_\varphi(\tilde{\mathbf{x}}_{i+1}, t_{i+1}) - F_\varphi(\tilde{\mathbf{x}}_i, t_{i+1})]$; hai phần cộng lại đúng bằng tổng (Bảng 6.8).

Bảng 6.8. Đo trên cell test của mô hình đã huấn luyện (30 % nhãn, lần lặp đầu, 5 fold). Bốn cột đầu: tỉ lệ điểm có $\partial F_\varphi / \partial t > 0$ (%). Ba cột giữa: trung vị qua các cell của phần giảm SOH dự đoán do riêng biến thời gian (%). Ba cột cuối: tốc độ suy giảm trung bình (SOH trên 1 000 chu kỳ).

	$\partial F_\varphi / \partial t > 0$ (%)				phần do thời gian (%)			tốc độ suy giảm		
Bộ	MLP	chỉ đ.điệu	PINN-semi	Euler	MLP	PINN-semi	Euler	r PINN-semi	r Euler	thực đo
XJTU	11,8	0,1	0,8	0,0	15	18	27	0,061	0,348	0,300
TJU	32,6	13,4	2,6	25,1	9	15	19	0,058	0,331	0,356
MIT	30,3	14,3	23,9	12,8	3	2	7	0,001	0,213	0,137
HUST	17,4	6,3	4,8	6,2	36	49	48	0,063	0,128	0,137

Ba nhận xét. Thứ nhất, MLP có $\partial F_\varphi / \partial t > 0$, tức SOH tăng theo thời gian khi đặc trưng giữ nguyên, ở 12–33 % số điểm test; PINN-semi giảm tỉ lệ này xuống 1–24 %, giảm rõ trên XJTU, TJU và HUST. Riêng MIT, ràng buộc được thoả theo cách tầm thường: r học được gần bằng 0 (MIT 0,001) và đạo hàm theo thời gian cũng gần bằng 0, nên dấu của đạo hàm chỉ còn là nhiễu quanh 0. Thứ hai, ở mọi mô hình, phần lớn mức giảm SOH dự đoán đi qua đặc trưng sạc chứ không qua biến thời gian: phần do thời gian chỉ chiếm 3–36 % với MLP và 2–49 % với PINN-semi; với PINN-semi, phần này dưới 25 % trên XJTU, TJU và MIT và cao nhất trên HUST (49 %). Mạng nghiệm nhận ra pin đã già chủ yếu nhờ đường sạc đã đổi dạng, và $\mathscr{L}_{\text{ode}}$ chỉ ràng buộc phần còn lại. Thứ ba, phần dư ODE nhỏ so với chính đạo hàm ($|\partial_t F_\varphi + r|$ bằng XJTU 14, TJU 16, HUST 22 % của $|\partial_t F_\varphi|$), nghĩa là ràng buộc được thoả trên cell chưa từng thấy.

Tốc độ suy giảm học được. Đồ án so tốc độ suy giảm thực đo của từng cell test (độ dốc của SOH theo chu kỳ) với tốc độ của mô hình. Độ dốc của SOH dự đoán bám sát thực đo ở cả MLP lẫn PINN-semi (tương quan hạng Spearman 0,30–0,99 với MLP, 0,31–0,99 với PINN-semi); trên HUST tương quan thấp hơn vì tốc độ của các cell gần như nhau (hệ số biến thiên 0,19, so với 0,39–1,66 ở các bộ khác). Tốc độ r của PINN-semi thì không: trung bình chỉ 0,001–0,063 so với 0,137–0,356 thực đo, và gần như không tương quan với tốc độ của từng cell (Spearman XJTU −0,26, TJU 0,10, MIT −0,14, HUST 0,09). Lý do nằm ở nhận xét thứ hai: ở dạng đạo hàm riêng, r được khớp với $-\partial F_\varphi / \partial t$, tức chỉ với phần suy giảm mà mạng gán cho biến thời gian. Dạng Euler khớp r với tổng biến thiên dọc quỹ đạo, nên r của nó xấp xỉ tốc độ thật (trung bình 0,128–0,348) và tương quan với tốc độ từng cell (Spearman XJTU 0,72, TJU 0,88, MIT 0,66, HUST −0,22), rõ trên XJTU, TJU và MIT. Đổi lại, dạng Euler có MAE cao hơn dạng đạo hàm riêng trên TJU và MIT (Mục 6.5).

Đồ án xếp tốc độ suy giảm theo khoảng SOH thực đo. Trên XJTU, MIT và HUST, tốc độ thực đo ở khoảng SOH thấp nhất cao gấp 2–175 lần ở khoảng SOH cao nhất: đây là hiện tượng đầu gối. Trên TJU, đường trung bình không đi lên đều theo SOH. Giữa các khoảng SOH, r chỉ thay đổi 1,4–1,9 lần (bỏ qua MIT, nơi $r \approx 0$) trong khi tốc độ thực đo thay đổi 3–175 lần, và với $\lambda \approx 0{,}96$ thừa số $g(u) = e^{\lambda(1-u)}$ chỉ tăng khoảng 1,2 lần khi SOH giảm từ 1 xuống 0,8: đầu gối trong dự đoán đến từ đặc trưng sạc, không đến từ thừa số đầu gối của động học.

Tóm lại, phần vật lý giúp mô hình chủ yếu qua ràng buộc dọc quỹ đạo: dự đoán của PINN-semi gần đơn điệu như nhãn thật, và đây cũng là phần mang lại phần lớn lợi ích về sai số (Mục 6.5). Ràng buộc ODE dạng đạo hàm riêng giữ cho SOH không tăng theo thời gian, nhưng tốc độ r của nó không phải là ước lượng tốc độ suy giảm của cell; muốn r diễn giải được theo nghĩa vật lý cần dạng Euler.

6.9 Mô hình kết hợp PINN-lai

6.9.1 Sai số còn lại nằm ở đâu

Trước khi thử cải tiến, cần biết sai số hiện tại có dạng gì. Với mỗi cell test, sai số theo chu kỳ $e_n = \hat{y}_n - y_n$ được tách thành ba phần:

$$e_n = \underbrace{b}_{\text{lệch mức}} + \underbrace{s_n}_{\text{trôi chậm}} + \underbrace{f_n}_{\text{dao động nhanh}}, \tag{6.1}$$

trong đó b là trung bình của e_n trên cả cell, s_n là trung bình trượt căn giữa 21 điểm của $e_n - b$, còn f_n là phần còn lại. Ở 30 % nhãn, với MLP, PINN-semi và GBDT trên bốn bộ, lệch mức chiếm 14–58 % tổng MSE và trôi chậm 32–57 %. Phần dao động nhanh, tức nhiễu giữa các chu kỳ liền nhau, chỉ chiếm 1–17 % tổng MSE ngoài bộ MIT; trên MIT, nơi sai số tuyệt đối rất nhỏ, phần này lên tới 25–34 %. Phần lớn sai số là lệch mức và trôi chậm: mô hình đoán sai SOH của cả

một cell, hoặc đoán sai tốc độ suy giảm trên một đoạn dài. Hai hệ quả rút ra. Một là làm trơn dự đoán chỉ giúp được một phần nhỏ. Hai là muốn giảm sai số đáng kể phải giảm phần lệch theo từng cell, và cách đơn giản nhất là lấy trung bình những mô hình có lệch theo cell khác nhau.

6.9.2 Chọn hướng trên tập validation

Giai đoạn phát triển dùng lần lặp 0, cả 5 fold, hai mức nhãn 10 % và 50 %. Mỗi fold có khoảng 10 % số cell làm validation, tách khỏi cả train lẫn test; mọi quyết định chỉ dựa trên MAE theo cell của tập này.

Ba nhóm kết quả hiện ra. Kết hợp với GBDT cho mức giảm lớn nhất: ở 10 % nhãn tỉ số chỉ còn 0,843, ở 50 % nhãn còn 0,804, thấp hơn cả GBDT đứng một mình (0,906). Nhóm mạng và chưng cất cho mức giảm vừa phải, khoảng 0,963 và 0,961; khi đã kết hợp với GBDT, chưng cất không còn thêm lợi ích (tỉ số 0,849 so với 0,851 của một mạng PINN-semi kết hợp GBDT), nên bị bỏ để mô hình gọn hơn. Ba hướng còn lại làm sai số tăng: ràng buộc đơn điệu mạnh hơn (1,065), thêm phần dư Euler (1,289) và nhất là đặc trưng tương đối (1,692). Phần dư Euler buộc r bằng tốc độ dọc quỹ đạo trong khi phần dư dạng đạo hàm riêng buộc $\partial F / \partial t = -r$, nên hai số hạng kéo mạng nghiệm về hai phía. Đặc trưng tương đối chia cho $|\mathbf{x}_{\text{ref}}|$, nên khuếch đại các đặc trưng có giá trị ban đầu gần 0 và làm phân phối đầu vào khác hẳn giữa các cell; trường hợp tệ nhất là HUST ở 10 % nhãn, sai số tăng 3,4 lần.

Trọng số $\omega = 0{,}5$ và 0,4 cho GBDT trọng số 0,5 và 0,6, kết quả gần như nhau trên validation (0,828 và 0,824), nên chọn $\omega = 0{,}5$ để không phải ước lượng thêm tham số. Cửa sổ lọc $w = 5, 10, 20$ cũng gần như nhau; chọn $w = 10$ vì nó gần tốt nhất với mọi mô hình nền đã thử. Cấu hình cuối được ấn định thành văn bản trước khi đọc bất kỳ dự đoán test nào.

6.9.3 Kết quả trên tập test

Đánh giá cuối dùng lần lặp 0, 1 và 2, cả 5 fold, 4 bộ và 4 mức nhãn. Mọi mô hình trong chương này, kể cả các mô hình cũ, được tính lại trên đúng ba lần lặp đó. Thành viên thứ nhất của nhóm mạng chạy lại đúng cấu hình PINN-semi và cho dự đoán trùng từng bit với kết quả ở Mục 6.2 ở 240/240 lượt; GBDT trùng ở 240/240 lượt.

PINN-lai có MAE thấp hơn PINN-semi ở 16/16 trường hợp (bộ × mức nhãn), 16 trong đó có ý nghĩa thống kê, với tỉ số 0,67–0,95. So với GBDT, PINN-lai tốt hơn ở 10/16 trường hợp, 8 có ý nghĩa; riêng ở 10 % nhãn, PINN-lai tốt hơn GBDT có ý nghĩa trên cả bốn bộ. GBDT có sai số thấp hơn PINN-lai ở XJTU (30–70 %) và TJU (30–70 %), phần lớn các trường hợp này không có ý nghĩa thống kê. GBDT vẫn tốt hơn có ý nghĩa ở TJU 70 %. So với MLP, tỉ số là 0,28–0,81; ở 10 % nhãn sai số chỉ còn 0,28–0,75 của MLP. Trên hai mức nhãn đã dùng khi phát triển (10 và 50 %), tỉ số so với PINN-semi trên test là 0,805, gần với 0,823 trên validation, nên việc chọn trên validation không làm kết quả test bị lạc quan đáng kể.

Bảng 6.9. MAE theo cell ($\times 10^{-3}$) trên test, lần lặp 0–2; in đậm là thấp nhất ở mỗi bộ và mức nhãn.

Bộ	Mô hình	10 %	30 %	50 %	70 %
XJTU	MLP	23,27	15,61	14,10	12,48
	GBDT	14,01	**10,87**	**10,18**	**9,64**
	PINN-semi	14,65	13,35	13,20	12,53
	PINN-lai	**12,83**	11,43	10,65	10,00
TJU	MLP	15,81	11,71	9,96	9,71
	GBDT	12,60	**8,06**	**7,17**	**6,96**
	PINN-semi	14,01	11,39	10,74	10,80
	PINN-lai	**11,79**	8,52	7,77	7,76
MIT	MLP	9,02	3,39	3,06	2,85
	GBDT	3,15	1,97	1,74	1,59
	PINN-semi	3,29	2,50	2,45	2,38
	PINN-lai	**2,52**	**1,79**	**1,67**	**1,59**
HUST	MLP	41,62	20,00	18,13	17,19
	GBDT	23,84	18,73	15,82	14,60
	PINN-semi	22,76	17,10	16,42	16,38
	PINN-lai	**20,52**	**16,19**	**14,29**	**13,78**

Bảng 6.10. Tỉ số MAE theo cell của PINN-lai so với từng mô hình (nhỏ hơn 1 là PINN-lai tốt hơn). *: Wilcoxon ghép cặp theo cell có ý nghĩa sau hiệu chỉnh Holm trên bốn bộ ($p < 0{,}05$).

Bộ	Nhãn	so với PINN-semi	so với GBDT	so với MLP	so với MLP-lai
XJTU	10 %	0,88*	0,92*	0,55*	0,80*
	30 %	0,86*	1,05	0,73*	0,99
	50 %	0,81*	1,05	0,76*	1,02
	70 %	0,80*	1,04	0,80*	1,02
TJU	10 %	0,84*	0,94*	0,75*	0,95*
	30 %	0,75*	1,06	0,73*	1,02
	50 %	0,72*	1,08	0,78*	1,03
	70 %	0,72*	1,11*	0,80*	1,06*
MIT	10 %	0,77*	0,80*	0,28*	0,49*
	30 %	0,71*	0,91*	0,53*	0,87*
	50 %	0,68*	0,96	0,54*	0,90*
	70 %	0,67*	1,00	0,56*	0,93*
HUST	10 %	0,90*	0,86*	0,49*	0,71*
	30 %	0,95*	0,86*	0,81*	1,01
	50 %	0,87*	0,90*	0,79*	0,98
	70 %	0,84*	0,94*	0,80*	1,00

Các chỉ số khác cho cùng một bức tranh. Ở 30 % nhãn, R^2 tính từ chu kỳ 10 của PINN-lai là 0,867–0,992 trên bốn bộ, so với 0,858–0,985 của GBDT và 0,860–0,986 của PINN-semi. Tỉ lệ cặp chu kỳ có dự đoán tăng ngược của PINN-lai là 0,7–8,4 %, thấp hơn PINN-semi (2,8–12,8 %) và GBDT (3,2–19,1 %).

6.9.4 Phân rã lợi ích

Tính trung bình nhân trên 16 trường hợp, nhóm ba mạng đưa tỉ số so với PINN-semi xuống 0,961, kết hợp với GBDT xuống 0,798, và bộ lọc quỹ đạo xuống 0,793; GBDT đứng một mình là 0,823. Bước kết hợp mang lại phần lớn lợi ích.

Lệch mức theo cell của trung bình ba PINN-semi và của GBDT chỉ tương quan ở mức vừa: hệ số Pearson 0,50–0,80 tùy bộ và mức nhãn, và ở 16–31 % số cell hai mô hình lệch ngược dấu nhau. Vì hai mô hình không lệch cùng một kiểu, lấy trung bình của chúng triệt tiêu được một phần lệch mức mà Mục 6.9.1 chỉ ra.

Câu hỏi còn lại là vật lý có còn cần khi đã có GBDT không. Để trả lời, cùng công thức được áp với ba mạng MLP thay cho ba mạng PINN-semi (MLP-lai): cùng GBDT, cùng bộ lọc. PINN-lai tốt hơn MLP-lai có ý nghĩa ở 7/16 trường hợp và kém hơn có ý nghĩa ở 1; tỉ số trung bình nhân là 0,716 ở 10 % nhãn và 1,002 ở 70 % nhãn. Phần vật lý vẫn đóng góp khi đã có GBDT, rõ nhất khi ít nhãn, và đóng góp ít dần khi nhãn nhiều lên, cùng xu hướng như ở Chương 6.

6.9.5 Khoảng dự đoán

Một con số SOH đơn lẻ chưa đủ cho các quyết định như thay pin hay giảm công suất [52]. PINN-lai được gắn thêm khoảng dự đoán bằng phương pháp dự đoán phù hợp tách tập [54, 32]. Trong mỗi fold, phần dư $|\tilde{y} - y|$ được tính trên tập validation của chính fold đó; với mức $1 - \alpha = 90\,\%$, lấy phân vị $\lceil (n+1)(1-\alpha) \rceil / n$ của các phần dư làm nửa độ rộng q, và khoảng cho một chu kỳ test là $[\tilde{y} - q, \tilde{y} + q]$. Dạng thích nghi chia phần dư cho $\sigma_n + \delta$, với $\sigma_n = |\bar{F} - g|$ là độ vênh giữa nhóm mạng và GBDT tại chu kỳ đó và δ là trung vị của σ trên validation; khoảng khi đó rộng ở những chu kỳ hai mô hình không đồng ý với nhau.

Độ phủ thực tế trên test là 84,9–92,6 % với độ rộng cố định và 86,3–92,9 % với độ rộng thích nghi, trung bình 88,8 %, tức thấp hơn mức 90 % đặt ra vài điểm phần trăm. Thiếu hụt này có nguyên nhân rõ: tập hiệu chỉnh của mỗi fold chỉ gồm vài đến mười mấy cell, và phần dư của các chu kỳ trong cùng một cell tương quan rất mạnh, nên số mẫu hiệu chỉnh thực chất là số cell chứ không phải số chu kỳ; phân vị ước lượng từ chừng ấy cell dao động nhiều giữa các fold. Độ rộng trung bình của dạng thích nghi là 0,65–10,19 % SOH, so với 0,63–11,23 % của dạng cố định. Bảo đảm của phương pháp là bảo đảm trung bình: nếu các cell hiệu chỉnh và cell test hoán đổi được cho nhau thì tỉ lệ chu kỳ nằm trong khoảng xấp xỉ 90 %, nhưng không phải cell nào cũng được phủ 90 %. Với độ rộng thích nghi, 14–25 % số cell có độ phủ dưới 80 %: đó là các cell bị

lệch mức cả đời, đúng loại sai số chiếm phần lớn MSE.

6.9.6 Tinh chỉnh trọng số ghép trên validation

Đề cương của PINN-lai cố định $\omega = \frac{1}{2}$ trong (4.12) và $w = 10$ trong (4.13). Hai giá trị này chọn được trên validation mà không phải huấn luyện lại: với mỗi bộ và mức nhãn, (ω, w) được chọn trên lưới $\omega \in \{0{,}3;\ 0{,}4;\ 0{,}5;\ 0{,}6;\ 0{,}7\}$, $w \in \{5, 10, 20, 40\}$ bằng MAE theo cell trung bình trên validation của 3 lần lặp × 5 fold, rồi đánh giá đúng một lần trên test (cột PINN-lai của Bảng 6.11). Validation nghiêng về GBDT ($\omega = 0{,}3$) ở XJTU, TJU, MIT khi có từ 30 % nhãn và chọn cửa sổ dài ($w = 40$) ở HUST. Trên test, sai số còn 0,92–1,00 lần bản gốc (trung bình nhân 0,965), giảm có ý nghĩa ở 5/16 trường hợp bộ × mức nhãn; PINN-lai tinh chỉnh thấp hơn GBDT cùng mức nhãn có ý nghĩa ở 11/16 trường hợp và không trường hợp nào cao hơn có ý nghĩa. Ở 50 % nhãn, nó không khác GBDT học với 70 % nhãn có ý nghĩa trên cả bốn bộ.

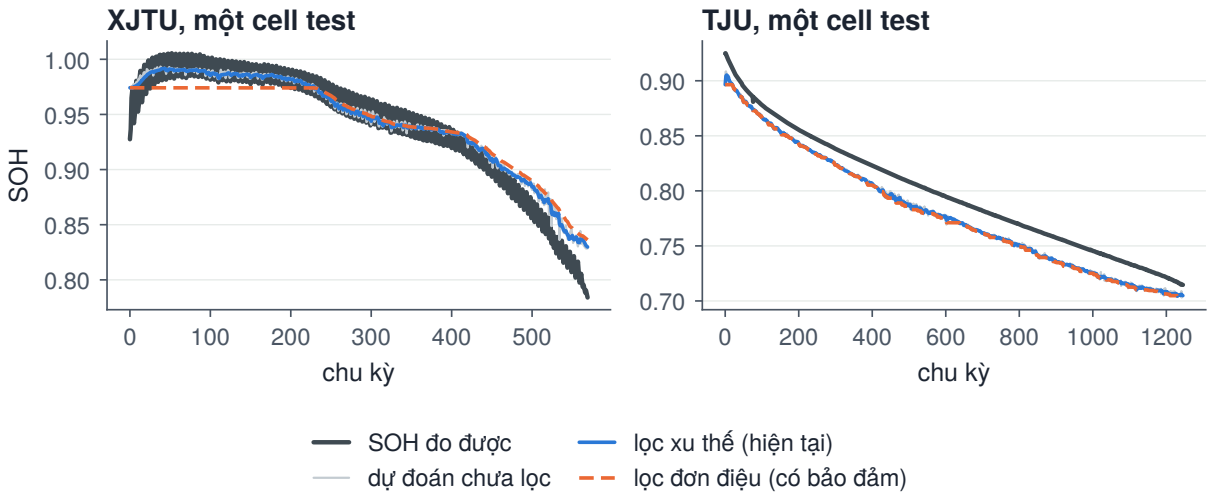
6.9.7 Bộ lọc có giữ SOH không tăng không

Theo Mệnh đề 4.5(iv), bộ lọc (4.10) không bảo đảm dãy đầu ra không tăng, và trên test điều này xảy ra thường xuyên: đầu ra của PINN-lai tăng ở 28–44 % số bước giữa hai chu kỳ liên tiếp, bước tăng lớn nhất là 0,11 SOH. Dãy (4.14) thì không bao giờ tăng. Khi (w, a) của nó được chọn trên validation riêng cho từng bộ rồi so trên test với bộ lọc xu thế, tỉ số MAE gần như bằng 1 trên TJU và HUST (0,99–1,00), nhưng là 1,01–1,06 trên MIT và 1,76–1,94 trên XJTU, kém hơn có ý nghĩa ở mọi mức nhãn trên XJTU và MIT.

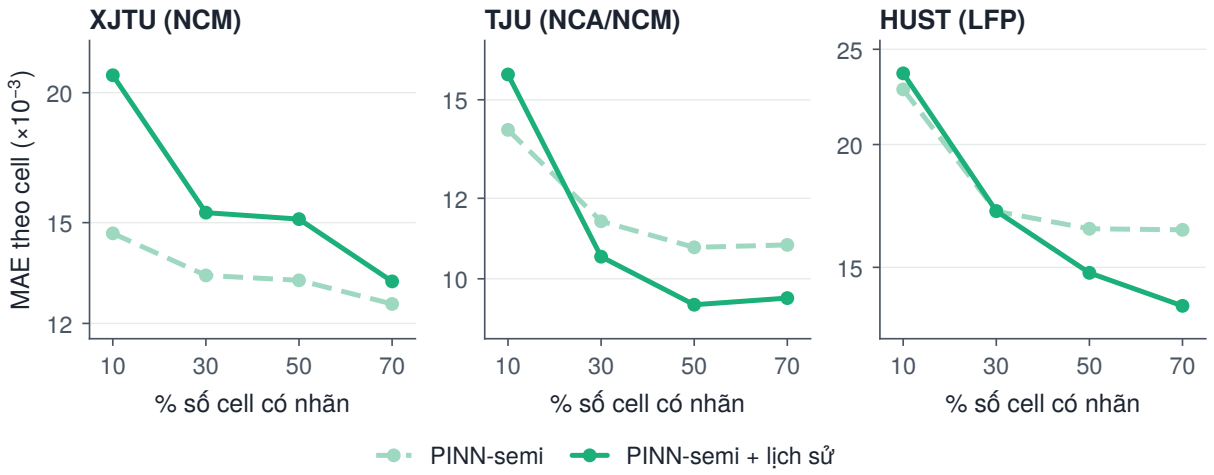
Nguyên nhân nằm ở nhãn, không ở bộ lọc. Dung lượng đo được của XJTU tăng trong vài chục chu kỳ đầu (trung vị 0,03 SOH), và 5 % số bước tăng quá 0,5 % SOH; trên NASA, tỉ lệ này là 12 % vì dung lượng hồi phục sau mỗi lần nghỉ. TJU và HUST gần như không có bước tăng thật. Dãy không tăng bắt đầu từ dự đoán ở chu kỳ đầu nên không theo được đoạn dung lượng tăng (Hình 6.4). PINN-lai vì vậy giữ bộ lọc xu thế, và đồ án mô tả nó đúng là làm trơn theo xu thế giảm, không phải ràng buộc không tăng. Ràng buộc cứng chỉ hợp với các bộ mà dung lượng đo được thật sự không tăng, như TJU và HUST.

6.10 Đầu vào có lịch sử của cell

Dạng lịch sử được chọn ở bước khám phá, trên validation của lần lặp 0 với 30 và 70 % nhãn, rồi chốt trước khi chạy đánh giá cuối. Lịch sử giảm MAE validation của PINN-semi trên XJTU, TJU và HUST (tỉ số 0,87–0,95) và của GBDT trên XJTU và HUST (0,95–0,97); với PINN-semi trên MIT và với GBDT trên TJU và MIT, không có dạng nào đạt ngưỡng 2 % nên các mô hình này giữ đặc trưng gốc. Trên NASA, tính trung bình qua các cách chia, mọi dạng đều kém hơn đặc trưng gốc (Mục 6.14).



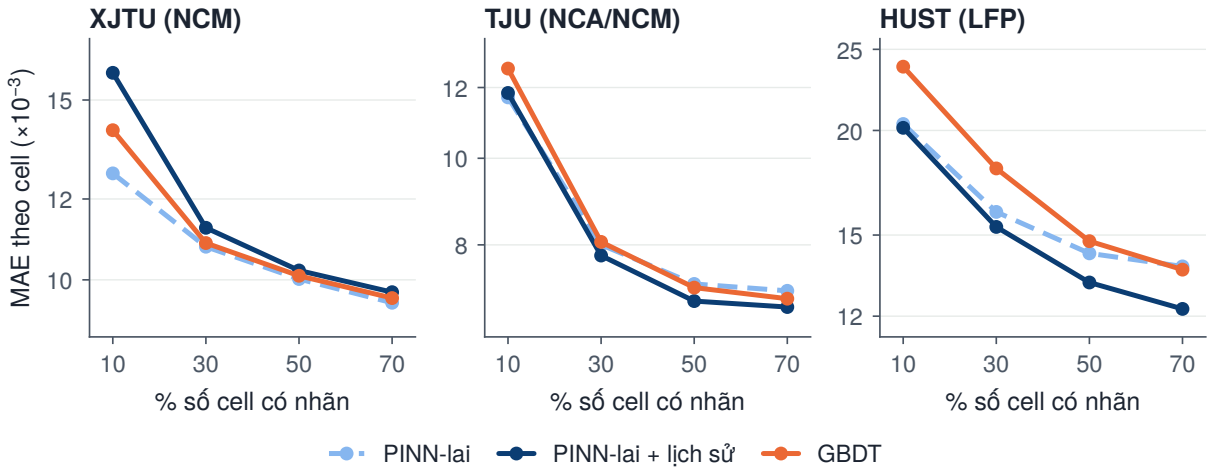
Hình 6.4. Một cell test của XJTU có dung lượng tăng đầu đời và một cell TJU (30 % nhãn, lần lặp 0): SOH đo được, dự đoán của PINN-lai trước khi lọc, sau bộ lọc xu thế và sau bộ lọc không tăng (4.14) với (w, a) chọn trên validation.



Hình 6.5. MAE theo cell trên test của PINN-semi không có (nét đứt) và có lịch sử (nét liền), trên ba bộ có dạng lịch sử được chọn; trên MIT không dạng nào được chọn.

Trên test (Bảng 6.11), lịch sử giúp rõ trên TJU và HUST khi có từ 30 % nhãn: MAE của PINN-semi còn 0,84–1,00 lần bản gốc (tốt hơn có ý nghĩa ở 5/6 trường hợp, Hình 6.5) và của PINN-lai còn 0,89–0,97 lần (6/6, Hình 6.6). Trên XJTU thì ngược lại: PINN-semi có lịch sử kém bản gốc ở mọi mức nhãn (1,05–1,42 lần), PINN-lai kém 1,02–1,25 lần. Ở 10 % nhãn, lịch sử không giảm sai số có ý nghĩa trên bộ nào (PINN-semi 1,04–1,42 lần, PINN-lai 0,99–1,25 lần).

Lựa chọn ở bước khám phá sai trên XJTU vì nó chỉ dựa trên một lần lặp. Với lần lặp 0, tỉ số MAE validation của PINN-semi có và không có lịch sử trên XJTU là 0,92–0,94 ở 30 và 70 % nhãn; với lần lặp 2, nó là 1,30–1,50; trung bình ba lần lặp là 1,06–1,17, gần với tỉ số trên test (1,06–1,15). Mỗi fold của XJTU chỉ có 6 cell validation, nên tác động của lịch sử đổi theo cách



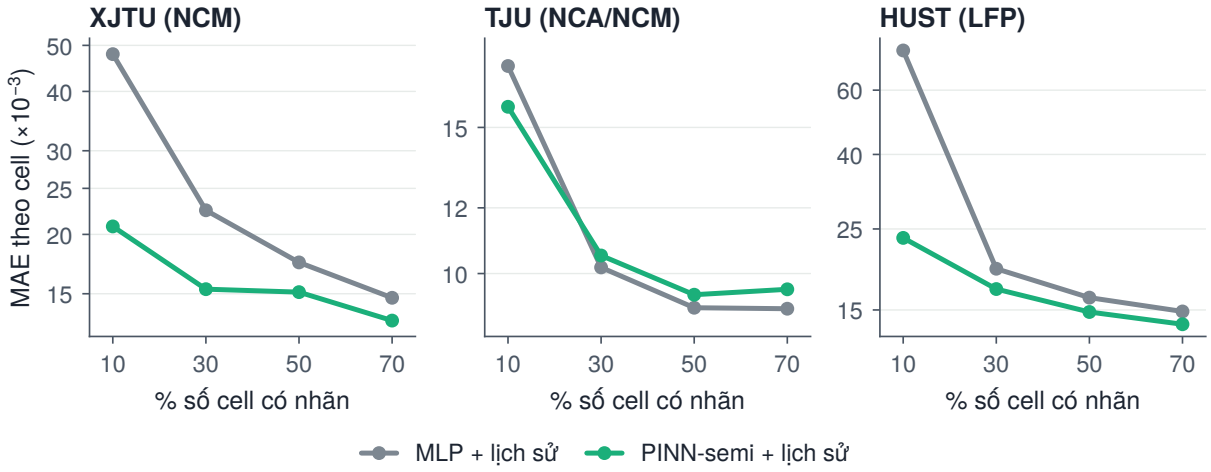
Hình 6.6. MAE theo cell trên test của PINN-lai tinh chỉnh không có (nét đứt) và có lịch sử (nét liền), cạnh GBDT có hoặc không lịch sử chọn trên validation.

Bảng 6.11. MAE theo cell ($\times 10^{-3}$) trên test, 3 lần lặp × 5 fold, cùng fold và hạt giống với Mục 6.9.3. PINN-lai là bản tinh chỉnh trên validation (Mục 6.9.6); GBDT là bản có hoặc không lịch sử, chọn trên validation; mô hình cuối là PINN-lai dùng hay không dùng lịch sử theo validation của từng bộ và mức nhãn. */†: tốt hơn/kém hơn có ý nghĩa (Wilcoxon ghép cặp theo cell, $p < 0{,}05$) so với cột không lịch sử ngay trước; ở cột cuối, so với GBDT.

Bộ	Nhãn	PINN-semi	+ lịch sử	GBDT	PINN-lai	+ lịch sử	Mô hình cuối
XJTU	10 %	14,65	20,79†	14,01	12,71	15,95†	12,71*
	30 %	13,35	15,34	10,87	10,78	11,25	10,78*
	50 %	13,20	15,12	10,09	10,02	10,21	10,02
	70 %	12,53	13,17	9,60	9,50	9,73	9,50
TJU	10 %	14,01	15,88†	12,60	11,70	11,83	11,70*
	30 %	11,39	10,51*	8,06	8,00	7,78*	7,78*
	50 %	10,74	9,43*	7,17	7,23	6,92*	6,92*
	70 %	10,80	9,57*	6,96	7,11	6,82*	6,82
MIT	10 %	3,29	–	3,15	2,52	–	2,52*
	30 %	2,50	–	1,97	1,75	–	1,75*
	50 %	2,45	–	1,74	1,59	–	1,59*
	70 %	2,38	–	1,59	1,48	–	1,48*
HUST	10 %	22,76	23,63	23,84	20,36	20,15	20,36*
	30 %	17,10	17,11	18,02	15,99	15,34*	15,34*
	50 %	16,42	14,81*	14,75	14,26	13,17*	13,17*
	70 %	16,38	13,71*	13,64	13,76	12,24*	12,24*

chia cell. Ở 10 % nhãn, đầu vào có lịch sử có số chiều gấp đôi đến gấp bốn trong khi chỉ còn vài cell có nhãn; ngay cả MLP có lịch sử cũng kém MLP gốc 1,12–2,06 lần ở mức nhãn này.

Validation của đủ ba lần lặp đã có sẵn trong các lượt trên, nên có thể chọn lại mà không dùng test: với mỗi bộ và mức nhãn, PINN-lai dùng hay không dùng lịch sử, cùng trọng số trộn và cửa sổ lọc, được chọn theo MAE validation trung bình của 3 lần lặp × 5 fold; GBDT được chọn có hay không lịch sử theo cùng cách. Bước này được đặt ra sau khi đã thấy kết quả test ở trên, nên là phân tích hậu kiểm chứ không thuộc đề cương. Validation chọn lịch sử ở TJU và HUST với 30 %, 50 % và 70 % nhãn và bỏ nó ở mọi trường hợp còn lại, trùng với các trường hợp lịch sử có lợi trên test. Với lựa chọn này, PINN-lai (cột cuối của Bảng 6.11) có MAE thấp hơn GBDT ở 16/16 trường hợp bộ × mức nhãn (tỉ số 0,80–0,99), có ý nghĩa ở 13. Khi GBDT cũng được qua bộ lọc xu thế với cửa sổ chọn trên validation, tỉ số là 0,82–0,99, thấp hơn có ý nghĩa ở 11/16 và không trường hợp nào cao hơn có ý nghĩa.



Hình 6.7. MAE theo cell trên test của MLP và PINN-semi khi cả hai cùng có đầu vào lịch sử.

Ràng buộc vật lý giúp nhiều nhất khi ít nhãn và không giúp ở mọi bộ (Hình 6.7). Khi cả hai cùng có lịch sử, PINN-semi có MAE bằng 0,31–0,89 lần MLP ở 10 % nhãn, tốt hơn có ý nghĩa trên cả ba bộ. Từ 30 % nhãn, tỉ số là 0,68–0,92 trên XJTU và HUST nhưng 1,03–1,06 trên TJU, nơi MLP có lịch sử tốt hơn PINN-semi có lịch sử (có ý nghĩa ở 70 % nhãn). Không có lịch sử, TJU cũng như vậy (1,08–1,11 ở 50 và 70 % nhãn): bộ này gộp ba nhóm hoá học và nhiều nhóm điều kiện, nên một động học dùng chung cho mọi cell có thể không khớp với từng nhóm.

6.11 So với PINN4SOH trên đúng cách chia của bài

Bảng 6.12 và Hình 6.8 so mô hình của đồ án với số công bố của PINN4SOH trên đúng các cell test của bài. Trước hết, bản dựng lại có đáng tin không: PINN động học hộp đen của đồ án, khi dùng bản sao tiền xử lý của bài, có MAE bằng 0,97–1,28 lần số công bố, tức cùng cỡ với bài dù cấu hình mạng và lịch học khác. Cùng điều kiện đó, PINN-lai có MAE bằng 0,84–1,10 lần

PINN4SOH, thấp hơn có ý nghĩa thống kê theo cell trên HUST.

Bảng 6.12. MAE theo cell ($\times 10^{-3}$) trên đúng cách chia của PINN4SOH. Hai cột đầu là số công bố của bài; hai cột tiếp theo là mô hình của đồ án với bản sao tiền xử lý của bài (có rò rỉ); ba cột cuối dùng tiền xử lý không rò rỉ của đồ án. Hộp đen: PINN động học hộp đen kiểu PINN4SOH. Trung bình 3 hạt giống, rồi qua các batch như bài.

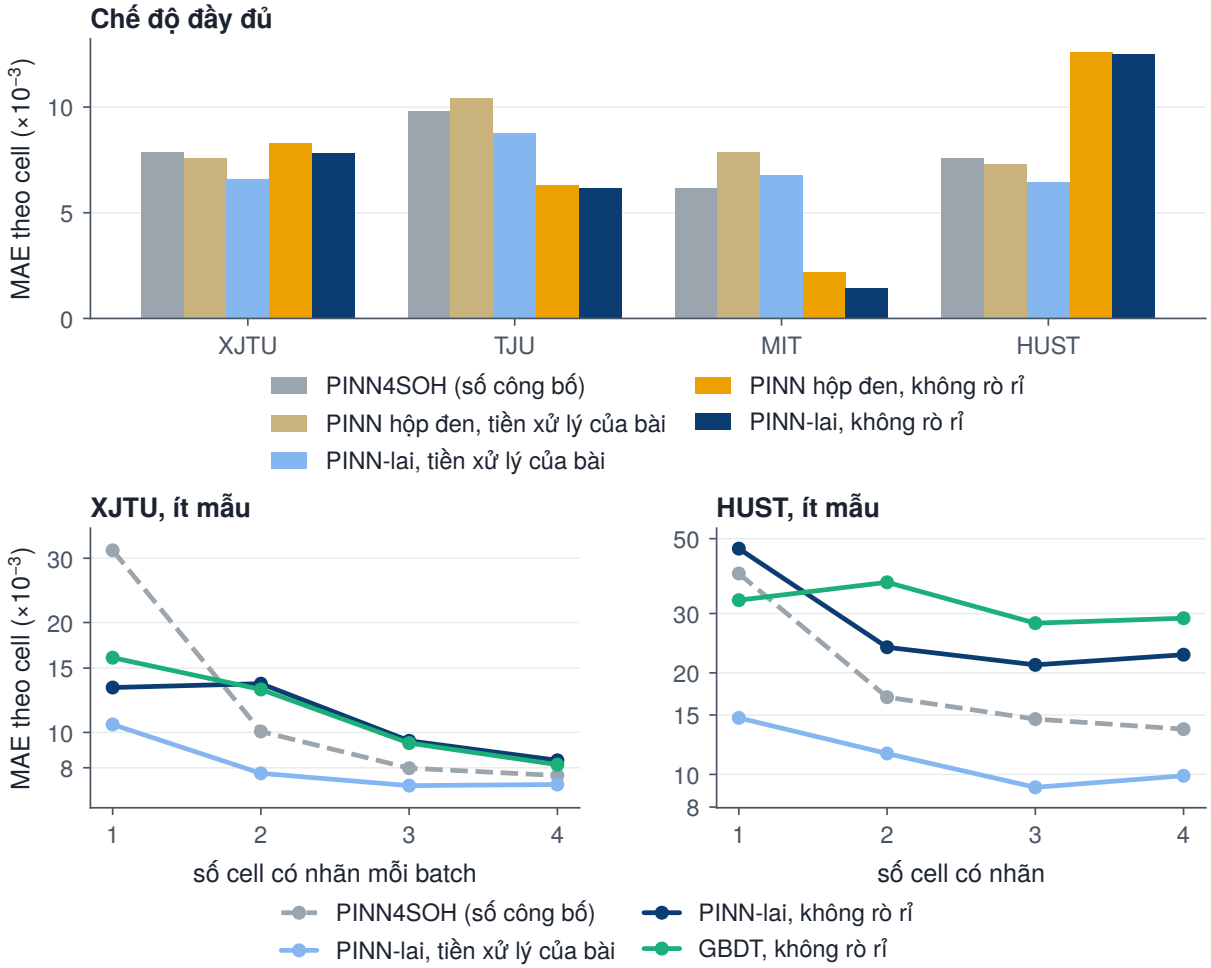
Bộ	PINN4SOH	MLP	Hộp đen	PINN-lai	Hộp đen	GBDT	PINN-lai
XJTU	7,85	21,02	7,59	6,62	8,32	7,28	7,81
TJU	9,79	13,61	10,45	8,78	6,30	6,40	6,16
MIT	6,18	7,45	7,88	6,80	2,18	1,44	1,43
HUST	7,57	7,77	7,31	6,45	12,60	13,65	12,51

Tiền xử lý của bài vừa thêm một thông tin rò rỉ vừa bỏ đi một thông tin thật, và hai tác động này cân nhau khác nhau theo bộ. Đổi sang tiền xử lý không rò rỉ, sai số của PINN hộp đen tăng 1,10–1,72 lần trên XJTU và HUST: chỉ số chu kỳ sau min–max theo từng cell chính là phần đời đã qua của cell, thông tin mà một mô hình triển khai thật không thể có. Ngược lại, sai số giảm còn 0,28–0,60 lần trên TJU và MIT: min–max theo từng cell xoá mức tuyệt đối của đặc trưng sạc, vốn mang thông tin về SOH. Với tiền xử lý không rò rỉ, PINN-lai có sai số thấp hơn số công bố của PINN4SOH trên TJU và MIT (tỉ số 0,23–0,63, có ý nghĩa thống kê theo cell trên TJU và MIT), ngang trên XJTU (tỉ số 0,99), và chỉ cao hơn trên HUST (tỉ số 1,65), đúng bộ mà tiền xử lý của bài có lợi nhất.

Ở chế độ ít mẫu (Hình 6.8, dưới), với tiền xử lý của bài, PINN-lai có sai số thấp hơn PINN4SOH ở mọi mức $K = 1, \dots, 4$ trên cả XJTU và HUST (tỉ số 0,33–0,94): các cell train không nhãn đi vào loss vật lý và bù cho số nhãn ít, rõ nhất khi chỉ một cell có nhãn. Với tiền xử lý không rò rỉ, PINN-lai chỉ thấp hơn số công bố ở XJTU với $K = 1$ (tỉ số 0,42); ở các mức còn lại tỉ số là 1,10–1,66. Khi chỉ có vài cell có nhãn, biết cell đã đi được bao nhiêu phần đời gần như là biết SOH, nên con số ít mẫu của bài phần lớn đến từ việc chuẩn hoá theo cả vòng đời cell.

6.12 Dự báo SOH tương lai, dung lượng còn lại và RUL

Sai số SOH theo tầm dự báo. Bảng 6.13 cho sai số ở kịch bản thực tế hơn, khi cell test không được đo dung lượng lần nào và lịch sử SOH là ước lượng PINN-lai. Ba mô hình chỉ dựa vào lịch sử của chính cell đều kém xa: trên toàn bộ phần đời còn lại, sai số của mô hình kết hợp chỉ bằng 0,21–0,46 lần sai số của dự báo giữ nguyên, 0,39–0,60 lần của ngoại suy tuyến tính và 0,27–0,58 lần của khớp vật lý theo cell, khác biệt có ý nghĩa trên cả bốn bộ ở cả hai kịch bản. Khớp vật lý theo cell còn kém cả ngoại suy tuyến tính ở XJTU và HUST: ba tham số khớp trên vài trăm điểm có nhiễu không đủ để phân biệt một quỹ đạo sắp gãy với một quỹ đạo đang chậm dần, đúng nhược điểm đã biết của cách tiếp cận này. Các mô hình học từ nhiều cell tránh



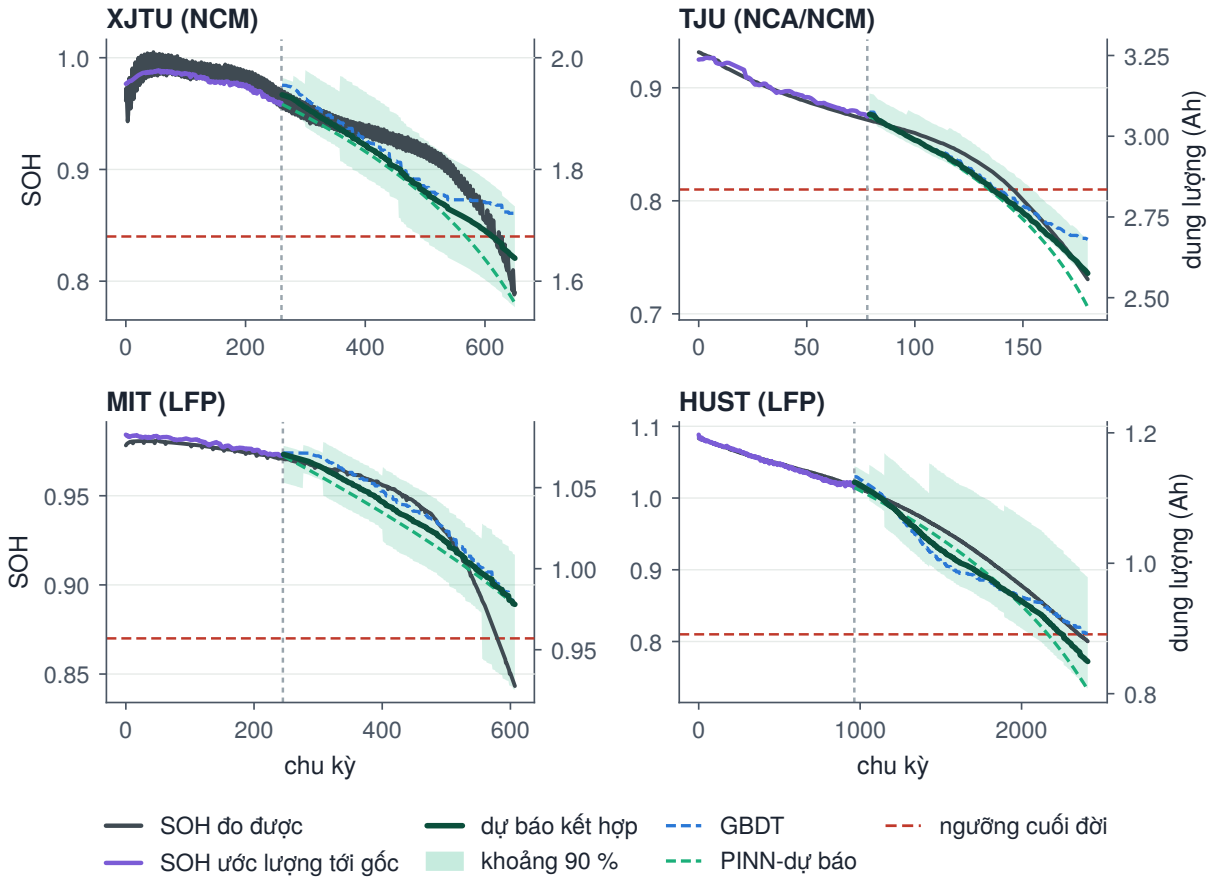
Hình 6.8. So với PINN4SOH trên đúng cách chia của bài. Trên: chế độ đầy đủ, mỗi bộ năm cột (số công bố, rồi PINN hộp đen và PINN-lai của đồ án với tiền xử lý của bài và với tiền xử lý không rò rỉ). Dưới: chế độ ít mẫu, MAE theo số cell có nhãn (thang log).

được điều đó vì dạng đường cong được rút ra từ cell khác có đặc trưng sạc tương tự. Giữa ba mô hình học từ nhiều cell, khác biệt nhỏ hơn nhiều: so với GBDT, mô hình kết hợp có tỉ số sai số 0,91–1,06 và tốt hơn có ý nghĩa trên TJU, kém hơn có ý nghĩa trên HUST; so với PINN-dự báo, tỉ số 0,88–1,00, thấp hơn có ý nghĩa trên XJTU, MIT và HUST. Quy ra dung lượng, sai số của mô hình kết hợp ở tầm $0{,}5L$ là 20–57 mAh.

Cái giá của việc không đo dung lượng. Khi lịch sử là dung lượng đo thật, sai số trên toàn bộ phần đời còn lại bằng 0,74; 0,63; 0,93; 0,41 lần sai số khi lịch sử là ước lượng (lần lượt XJTU, TJU, MIT, HUST). Chênh lệch lớn nhất ở HUST, nơi ở tầm ngắn $0{,}1L$ sai số tăng từ 2,8 lên 13,7 ($\times 10^{-3}$): sai số của dự báo ngắn hạn gần như bằng sai số ước lượng mức SOH tại gốc, nên chất lượng của mô hình ước lượng quyết định chất lượng dự báo ở tầm ngắn. Ở MIT, nơi PINN-lai ước lượng SOH rất sát, hai kịch bản gần như trùng nhau. Hình 6.9 minh hoạ một cell mỗi bộ: lịch sử ước lượng, dự báo từ gốc ở 40 % đời và khoảng 90 %, với trục phải là dung lượng theo Ah.

Bảng 6.13. MAE theo cell ($\times 10^{-3}$) của SOH dự báo ở ba tầm, kịch bản lịch sử ước lượng (không đo dung lượng cell test); in đậm là thấp nhất. Hai cột cuối: mô hình kết hợp khi lịch sử là dung lượng đo, và sai số của mô hình kết hợp quy ra dung lượng (mAh) ở kịch bản ước lượng.

Bộ	Tầm	Giữ nguyên	Tuyến tính	Vật lý theo cell	GBDT	PINN-dự báo	Kết hợp	Kết hợp, đo	Kết hợp (mAh)
XJTU	0,1L	14,2	12,2	23,4	**10,8**	12,4	10,8	5,4	22
	0,25L	36,2	28,8	39,6	**16,2**	23,5	18,8	13,8	38
	0,5L	70,2	58,8	62,3	**26,5**	32,3	28,4	22,5	57
TJU	0,1L	15,0	11,0	9,9	9,0	**8,1**	8,4	3,0	29
	0,25L	38,3	23,5	18,5	12,9	13,1	**12,0**	7,2	42
	0,5L	56,5	18,9	17,7	**10,7**	13,0	12,1	11,5	42
MIT	0,1L	8,9	4,3	**3,9**	5,7	7,2	5,5	4,9	6
	0,25L	26,2	15,3	14,7	**7,9**	10,7	8,8	8,0	10
	0,5L	53,0	39,7	37,6	**17,0**	19,6	17,8	16,8	20
HUST	0,1L	22,2	**13,0**	35,9	14,3	14,2	13,7	2,8	15
	0,25L	66,3	30,0	103,0	25,4	25,6	**24,9**	8,3	27
	0,5L	136,6	69,1	111,1	**32,0**	37,1	33,1	20,5	36



Hình 6.9. Dự báo cho một cell test mỗi bộ (lần lặp 0, gốc ở 40 % đời, cell có sai số ở trung vị): lịch sử SOH ước lượng tới gốc, dự báo của GBDT, PINN-dự báo và mô hình kết hợp kèm khoảng 90 %; trục phải là dung lượng (Ah).

RUL. Bảng 6.14 cho thấy khác biệt rõ nhất giữa các mô hình nằm ở RUL. GBDT không ngoại suy được ra ngoài miền tầm dự báo đã thấy khi học, nên khi RUL dài nó dự báo SOH đi ngang và cắt ngưỡng quá muộn; sai số RUL của GBDT gấp 1,1–1,5 lần của mô hình kết hợp, và mô hình kết hợp tốt hơn GBDT có ý nghĩa trên cả bốn bộ. Nghiệm đóng của PINN-dự báo tiếp tục cong theo hệ số λ đã học nên cắt ngưỡng đúng lúc hơn; giữa mô hình kết hợp và PINN-dự báo, sai số RUL không khác có ý nghĩa trên bộ nào. Như vậy mô hình kết hợp gần bằng GBDT về sai số SOH và gần bằng PINN-dự báo về RUL, là mô hình duy nhất không kém ở cả hai chỉ số. Tỉ lệ dự báo RUL nằm trong ± 20 % RUL thật là 38 %; 65 %; 48 %; 52 % và sai số tương đối trung vị 32 %; 13 %; 21 %; 19 % (cùng thứ tự bốn bộ); sai số giảm khi gốc dự báo tiến gần cuối đời, vì phần quỹ đạo còn phải ngoại suy ngắn lại.

Bảng 6.14. MAE của RUL (chu kỳ), kịch bản lịch sử ước lượng, trung bình qua gốc ở 25, 50, 75 % đời; cột RUL thực là trung bình RUL thật tại các gốc. Ba cột cuối của mô hình kết hợp: MAE khi lịch sử là dung lượng đo, tỉ lệ dự báo nằm trong ± 20 % RUL thật và độ phủ thực tế của khoảng RUL 90 %.

Bộ	RUL thực	Tuyến tính	Vật lý theo cell	GBDT	PINN-dự báo	Kết hợp	Kết hợp, đo	Trong ± 20 %	Độ phủ khoảng
XJTU	231	529	499	145	99	**96**	85	38 %	70 %
TJU	131	50	45	23	23	**20**	14	65 %	84 %
MIT	344	836	877	131	118	**113**	112	48 %	67 %
HUST	923	1354	1360	312	**216**	218	104	52 %	65 %

Hệ số λ học được. Mạng chỉ thấy đặc trưng tại gốc, không được cho biết bộ dữ liệu, nhưng dấu của λ khớp với hình dạng quỹ đạo của từng bộ. Trung vị λ là 3,4; −0,6; 6,7; 4,0 (lần lượt XJTU, TJU, MIT, HUST), với tỉ lệ gốc có $\lambda > 0$ là 83 %; 44 %; 89 %; 100 %. Ở XJTU, MIT và HUST, λ dương ở phần lớn gốc: tốc độ suy giảm được dự báo tăng dần, đúng với quỹ đạo có điểm đầu gối. Ở TJU, nơi nhiều cell giảm nhanh ở đầu đời rồi chậm lại, trung vị λ âm và chỉ khoảng một nửa số gốc có $\lambda > 0$: mạng tự chọn nhánh suy giảm chậm dần của nghiệm đóng. Cùng một dạng phương trình bao được cả hai kiểu quỹ đạo nhờ để dấu của λ tự do.

Khoảng dự báo. Khoảng 90 % có độ phủ thực tế 78–84 % trên toàn bộ phần đời còn lại và 62–84 % với khoảng RUL, thấp hơn mức đặt ra. Tập validation chỉ có 10 % số cell, trong khi sai số dự báo của một cell tương quan mạnh giữa các tầm; phân vị ước lượng từ vài cell vì vậy hẹp hơn phân bố sai số của cell mới. Khoảng này cho biết bậc độ lớn của bất định, nhưng chưa đủ tin cậy để dùng như một cam kết 90 %.

6.13 Dự báo khi dung lượng hồi phục

Bảng 6.15 so bản dự báo có xét hồi phục với bản ở Mục 6.12, ghép cặp trên cùng gốc. Rõ nhất là tầm ngắn: với lịch sử đo, trong tầm $0{,}1L$ sau gốc thường, bản mới giảm sai số có ý nghĩa trên

XJTU, MIT và HUST (tỉ số 0,77–0,85), vì mức xu thế bền xuất phát đúng hơn và GBDT không còn làm lệch đoạn đầu của đường dự báo. Trên toàn bộ phần đời còn lại, khác biệt nhỏ hơn: tỉ số là 0,98–1,02 với lịch sử đo và 0,95–1,04 với lịch sử ước lượng; bản mới tốt hơn có ý nghĩa trên không bộ nào (lịch sử đo) và trên TJU, MIT và HUST (lịch sử ước lượng), kém hơn có ý nghĩa trên TJU.

Ngay sau một lần hồi phục, bộ lọc quỹ đạo của bản cũ trộn điểm vừa nhảy vào đường hồi quy, nên cú nhảy làm lệch cả mức lẫn độ dốc của xu thế; bản mới tách cú nhảy khỏi xu thế rồi giữ lại hay bỏ đi theo ρ. Trên XJTU, bộ có nhiều gốc loại này nhất (14 cell), bản mới giảm sai số 5 % trên toàn bộ phần đời còn lại (chưa có ý nghĩa thống kê) và 30 % trong tầm ngắn (có ý nghĩa thống kê); trên MIT, tỉ số là 0,62 nhưng chỉ có 6 cell nên chưa đủ để kết luận. Trên NASA, tỉ số là 1,05 trên toàn bộ phần đời còn lại và 0,96 trong tầm ngắn, chưa có ý nghĩa thống kê.

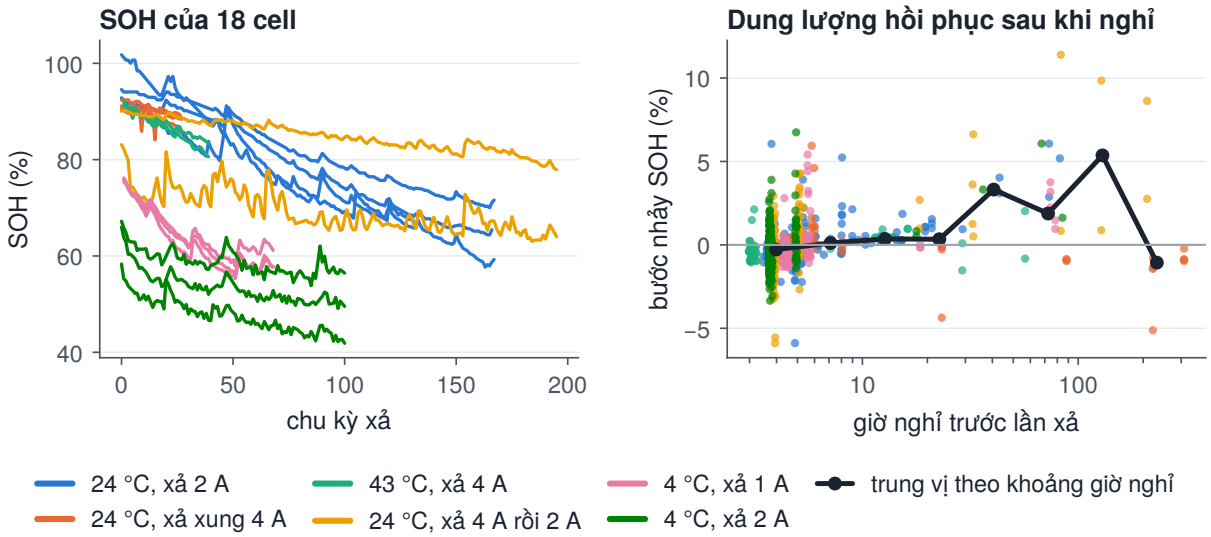
Cặp (ρ, τ_r) ước lượng trên cell train cho thấy hai kiểu hồi phục: ở XJTU và NASA, phần lớn cú nhảy được giữ lại (trung vị ρ: XJTU 1,0, NASA 1,0), còn ở MIT, phần hồi phục mất ngay ở chu kỳ sau (MIT $\rho = 0{,}0$); $\tau_r = 0{,}5$ chu kỳ ở mọi bộ, tức không có phần hồi phục tắt dần chậm. Trên NASA, điều này khớp với nhận xét của SambaMixer [21] rằng hồi phục gắn với thời gian nghỉ. Dao động đều chỉ được phát hiện ở 22 % số gốc của XJTU, hầu hết thuộc nhóm R2.5. Về RUL, bản mới có sai số thấp hơn có ý nghĩa trên MIT; khoảng 90 % có độ phủ 52–84 % trên toàn bộ phần đời còn lại, thấp hơn mức đặt ra vì cùng lý do ở Mục 6.12.

Bảng 6.15. MAE theo cell ($\times 10^{-3}$) của mô hình kết hợp trên toàn bộ phần đời còn lại, bản E22 và bản có xét hồi phục, ghép cặp trên cùng gốc. Bốn cột đầu: gốc thường, lịch sử ước lượng và lịch sử đo; bốn cột sau: gốc ngay sau một lần hồi phục (lịch sử đo), trên toàn bộ phần đời còn lại và trong tầm $0{,}1L$. $^{*}/^{\dagger}$: tốt hơn/kém hơn có ý nghĩa (Wilcoxon ghép cặp theo cell, $p < 0{,}05$); –: không có gốc sau hồi phục.

Bộ	Ước lượng, E22	Ước lượng, mới	Đo, E22	Đo, mới	Sau hồi phục, E22	Sau hồi phục, mới	Ngắn hạn, E22	Ngắn hạn, mới
XJTU	22,5	23,0	16,7	16,5	15,4	14,9	6,0	4,2*
TJU	11,6	11,0*	7,3	7,7†	26,0	27,7	7,0	7,7
MIT	12,0	11,4*	11,2	10,7	18,9	10,6	10,1	4,2
HUST	27,0	25,7*	11,1	11,3	–	–	–	–
NASA	52,6	54,6	23,6	23,5	22,5	23,8	11,2	11,4

6.14 Bộ dữ liệu NASA

Dữ liệu. 18 cell của NASA chia thành sáu nhóm theo nhiệt độ và chế độ xả (Hình 6.10). Khác bốn bộ kia, giữa các lần xả có những khoảng nghỉ dài, và dung lượng hồi phục sau đó: sau khoảng nghỉ dưới 10 giờ, SOH giảm trung vị 0,27 % so với lần xả trước; sau khoảng nghỉ 10–24 giờ, nó tăng trung vị 0,40 %; sau khoảng nghỉ từ 24 giờ trở lên, tăng trung vị 1,36 %. Đây là các mẫu gây nhiễu mà mọi mô hình phải xử lý khi ước lượng SOH.



Hình 6.10. Bộ NASA. Trái: SOH theo chu kỳ xả của 18 cell, màu theo nhóm điều kiện thí nghiệm. Phải: thay đổi SOH so với lần xả trước theo thời gian nghỉ trước lần xả (thang log), đường đậm là trung vị theo khoảng.

Ước lượng SOH. Bộ NASA được đánh giá bằng đúng giao thức của Chương 5: kiểm định chéo 5 fold theo cell, phân tầng theo sáu nhóm giao thức, 3 lần lặp, ở 30 và 70 % nhãn (Bảng 6.16, Hình 6.12). PINN-lai có sai số thấp nhất ở cả hai mức nhãn, 6,17 % và 5,13 % SOH. So với MLP, tỉ số MAE theo cell là 0,68 và 0,70; so với một PINN-semi là 0,79 và 0,76 (đều có ý nghĩa thống kê); so với GBDT là 0,96 và 0,92, không có ý nghĩa. Sai số trên NASA lớn hơn nhiều so với bốn bộ kia vì bộ này chỉ có 18 cell trải trên sáu nhóm giao thức và ba mức nhiệt độ: khi một nhóm chỉ có hai đến bốn cell, cell test thường không có cell train nào cùng điều kiện, và SOH tính theo danh định 2,0 Ah của cell 4 °C thấp hơn cell 24 °C ở cùng số chu kỳ tới 0,4.

Thời gian nghỉ. Thêm thời gian nghỉ trước lần xả làm đặc trưng thứ 17, theo ý tưởng của SambaMixer [21], không cải thiện có ý nghĩa: tỉ số MAE của PINN-lai có và không có đặc trưng này là 1,02 ($p = 0{,}52$) (30 % nhãn) và 0,98 ($p = 0{,}52$) (70 % nhãn). Lý do nằm ở đầu vào. Ở các chu kỳ ngay sau khoảng nghỉ dài (dài hơn hai lần trung vị của cell), sai số của PINN-lai không lớn hơn các chu kỳ khác (5,09 so với 5,13 % ở 70 % nhãn): đặc trưng sạc được đo sau khoảng nghỉ, nên đã phản ánh trạng thái vừa hồi phục, và thời gian nghỉ không mang thêm thông tin.

So với SambaMixer. Bảng 6.17 dùng đúng cách chia NASA-L của SambaMixer: tám cell train, hai cell giữ lại để dừng sớm, đánh giá trên các cell 6, 7 và 47. PINN-lai có MAE 6,78, 3,54 và 2,05 % SOH, cao hơn SambaMixer trên cả ba cell và chỉ tốt hơn CNN-BiGRU trên cell 47. SambaMixer nhận chuỗi điện áp, dòng điện, nhiệt độ của chính lần xả cần ước lượng; với dòng xả không đổi, thời gian xả nhân với dòng điện chính là dung lượng, nên nhãn gần như nằm sẵn

Bảng 6.16. Bộ NASA, kiểm định chéo 5 fold theo cell × 3 lần lặp: MAE theo cell (% SOH) ở hai mức nhãn, không và có thời gian nghỉ trước lần xả làm đặc trưng thứ 17; in đậm là thấp nhất mỗi cột.

Mô hình	30 %, 16 đặc trưng	30 %, thêm giờ nghỉ	70 %, 16 đặc trưng	70 %, thêm giờ nghỉ
MLP	9,16	10,58	7,03	6,91
GBDT	6,64	6,45	5,73	5,37
PINN-semi	7,46	7,56	6,23	6,58
3 PINN-semi	7,07	7,71	6,10	6,25
PINN-lai	**6,17**	**6,23**	**5,13**	**5,11**

trong đầu vào. Đồ án dùng đoạn sạc trước lần xả, là dữ liệu BMS ghi được ở mọi chu kỳ mà không phải xả sâu cell. Sai số lớn nhất ở cell 6, vốn bắt đầu ở 101 % SOH trong khi các cell train cùng nhóm bắt đầu quanh 92 %, với 75–84 % số chu kỳ có đặc trưng sạc nằm ngoài miền của cell train. Đầu vào có lịch sử (Mục 4.4) không được chọn cho NASA: dạng tốt nhất trên validation, tính trung bình qua kiểm định chéo và cách chia NASA-L, vẫn có MAE bằng 1,03–1,11 lần đặc trưng gốc với PINN-semi và 1,27 lần với GBDT. Có thể vì dung lượng NASA nhảy lên sau mỗi lần nghỉ: đặc trưng sạc của chu kỳ hiện tại phản ánh ngay cú nhảy đó, còn trung bình trượt làm nó trễ đi.

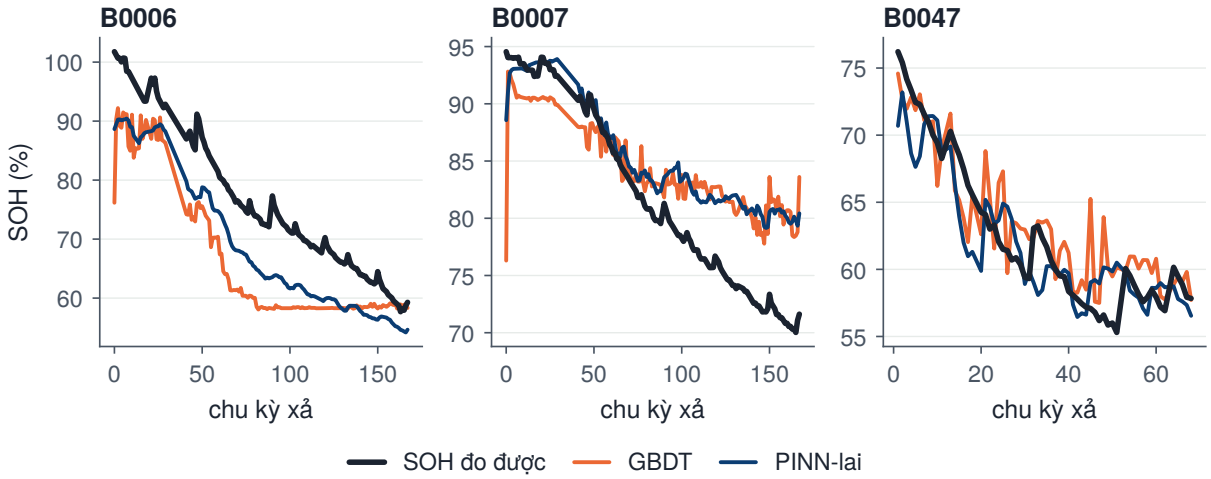
Bảng 6.17. Cách chia NASA-L của SambaMixer: MAE (% SOH) trên ba cell đánh giá. Hai cột đầu lấy từ bài của SambaMixer [21], đầu vào là đường xả của chính chu kỳ cần ước lượng; các cột sau là của đồ án, đầu vào là 16 đặc trưng của lần sạc trước đó, trung bình 3 hạt giống.

Cell	CNN-BiGRU	SambaMixer-L	MLP	GBDT	PINN-lai
B0006	2,45	1,17	3,94	10,01	6,78
B0007	1,86	1,20	4,43	4,48	3,54
B0047	2,55	0,51	5,55	2,13	2,05
Trung bình	2,29	0,96	4,64	5,54	4,12

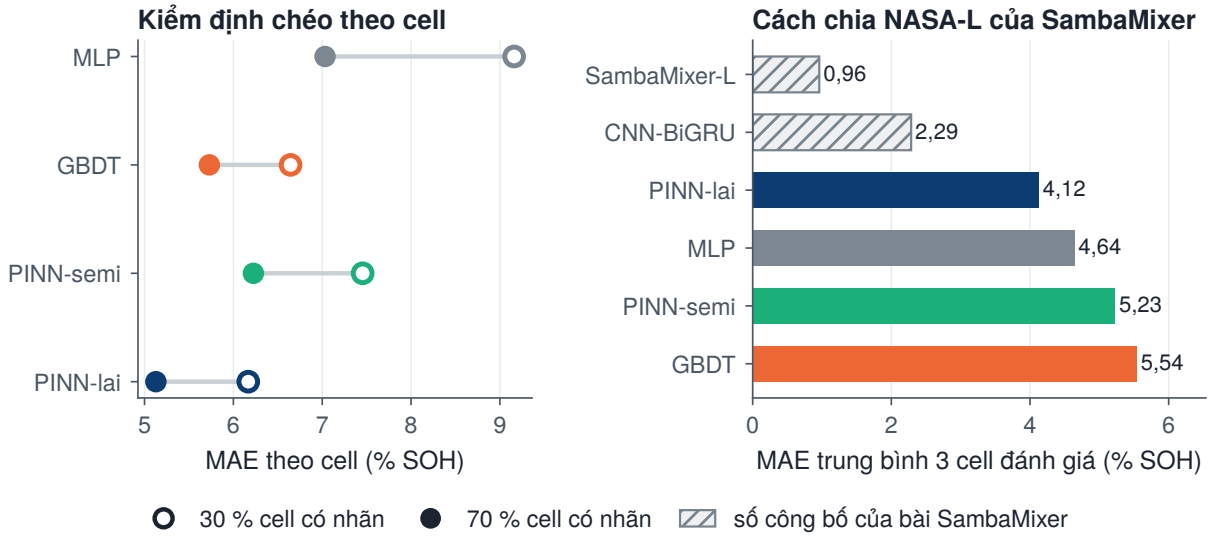
6.15 Ngân sách đo dung lượng

6.15.1 Đo thưa khi huấn luyện

Hình 6.13 đặt hai cách gắn nhãn lên cùng một trục: phần trăm số chu kỳ của cell train có đo dung lượng. Gắn nhãn đầy đủ cho 30 % số cell tương ứng 43–44 % số chu kỳ train, 70 % số cell là toàn bộ. Đo mỗi 0,05L chu kỳ trên mọi cell chỉ dùng 1,2–6,0 % số chu kỳ, ít hơn 7–37 lần, nhưng PINN-lai học theo cách này có MAE thấp hơn PINN-lai học với 30 % số cell trên cả bốn bộ (tỉ số 0,85–0,93, cả bốn có ý nghĩa thống kê; Bảng 6.18). So với 70 % số cell, tỉ số là 0,97–1,05: tốt hơn có ý nghĩa ở TJU, kém hơn có ý nghĩa ở MIT, khác biệt không có ý nghĩa ở XJTU và HUST.



Hình 6.11. SOH đo được và ước lượng trên ba cell đánh giá của cách chia NASA-L (hạt giống 0, 16 đặc trưng sạc).

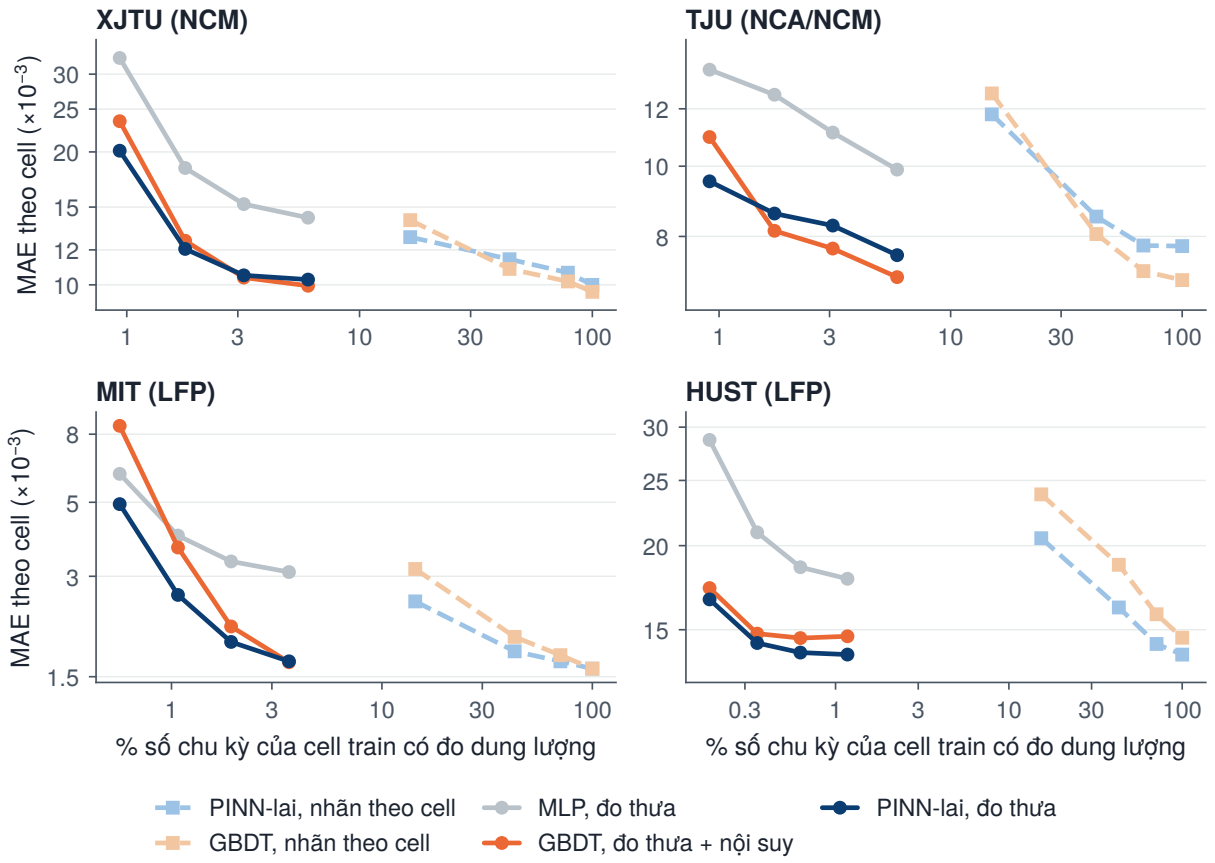


Hình 6.12. MAE theo cell trên NASA. Trái: kiểm định chéo theo cell ở 30 % (vòng rỗng) và 70 % nhãn (vòng đặc). Phải: trung bình ba cell đánh giá của cách chia NASA-L, cạnh số công bố của bài SambaMixer (gạch chéo).

Khi trọng số trộn và cửa sổ lọc được chọn trên validation cho cả hai cách gắn nhãn (Mục 6.9.6, phân tích hậu kiểm), hai tỉ số này là 0,86–0,90 và 0,99–1,05.

Lợi ích nằm ở chỗ đặt nhãn hơn là ở mô hình. Phần lớn sai số là lệch mức và trôi chậm riêng của từng cell (Mục 6.9.1); mô hình chỉ học được phần này khi thấy nhãn của chính cell đó, trong khi các chu kỳ liền nhau của một cell gần như lặp lại thông tin của nhau. Đo kín một phần cell dồn công đo vào thông tin lặp lại và bỏ trống độ lệch của các cell còn lại. Vì vậy GBDT học nhãn nội suy tuyến tính giữa các lần đo ở lịch 0,05L cũng có sai số bằng 1,00–1,04 lần GBDT học với 70 % số cell; điều tương tự đúng với mọi mô hình.

Không thành phần nào của PINN-lai tốt nhất ở mọi lịch đo. Ở lịch 0,05L, GBDT học nhãn



Hình 6.13. MAE theo cell trên test theo phần trăm số chu kỳ của cell train có đo dung lượng (hai trục thang log). Nét đứt: nhãn theo cell (10, 30, 50, 70 % số cell có nhãn đầy đủ); nét liền: đo thưa mọi cell train theo lịch qL, $q = 0{,}5; 0{,}2; 0{,}1; 0{,}05$.

nội suy tốt hơn trung bình ba PINN-semi trên cả bốn bộ. Ở lịch thưa nhất ($0{,}5L$, khoảng ba lần đo mỗi cell), nội suy tuyến tính qua nửa đời cell bỏ qua đoạn suy giảm nhanh về cuối, và GBDT kém hơn ba PINN-semi trên XJTU và MIT (tới 3,0 lần); MLP chỉ học trên các lần đo cũng kém ba PINN-semi 1,1–2,1 lần, vì ràng buộc đơn điệu và động học trên mọi hàng là thứ nối các lần đo với nhau. Trọng số chọn trên validation đi theo lịch đo: $\omega = 0{,}3$ (nghiêng về GBDT) ở lịch $0{,}05L$ trên XJTU, TJU và MIT, $\omega = 0{,}7$ ở lịch $0{,}5L$ trên XJTU và MIT.

Bảng 6.18. MAE theo cell ($\times 10^{-3}$) trên test, trung bình 3 lần lặp; trong ngoặc là phần trăm số chu kỳ của cell train có đo dung lượng (70 % số cell là toàn bộ). Hai cột đo thưa: mọi cell train được đo ở chu kỳ đầu, sau mỗi qL chu kỳ và ở chu kỳ cuối. Cột cuối: đo thêm cell test theo cùng lịch, cập nhật bằng bộ lọc Kalman, sai số trên các chu kỳ không được đo.

Bộ	PINN-lai, 30 % cell	PINN-lai, 70 % cell	GBDT, 70 % cell	PINN-lai, đo mỗi $0{,}1L$	PINN-lai, đo mỗi $0{,}05L$	đo cả cell mới mỗi $0{,}1L$
XJTU	11,43 (44,1)	10,00	9,64	10,51 (3,2)	10,28 (6,0)	7,46
TJU	8,52 (42,6)	7,76	6,96	8,28 (3,1)	7,54 (5,9)	4,13
MIT	1,79 (42,7)	1,59	1,59	1,91 (1,9)	1,67 (3,6)	1,18
HUST	16,19 (43,1)	13,78	14,60	13,87 (0,6)	13,78 (1,2)	5,00

6.15.2 Đo thưa cả khi dùng

Khi cell mới cũng được đo theo lịch $0{,}1L$ (1–3 % số chu kỳ của nó) và ước lượng được cập nhật bằng bộ lọc Kalman (4.19), MAE trên các chu kỳ không được đo của PINN-lai học từ nhãn thưa còn 1,2–7,5 ($\times 10^{-3}$), bằng 0,34–0,77 lần GBDT học với 70 % số cell có nhãn đầy đủ nhưng không đo cell mới. Với cùng lịch đo khi dùng, PINN-lai học với 70 % số cell cho 1,0–7,4: khi cell mới đã được đo, chênh lệch giữa hai cách huấn luyện không quá 0,6 ($\times 10^{-3}$).

6.15.3 Đo cell mới: một lần lúc nhận hay đo định kỳ

Với mô hình học từ nhãn theo cell (10–70 % cell có nhãn, năm bộ kể cả NASA), đo cell mới mỗi $0{,}1L$ đưa sai số xuống còn 0,33–0,72 lần không hiệu chỉnh, mỗi $0{,}25L$ còn 0,51–1,01 lần. Một lần đo duy nhất lúc nhận pin gần như không giúp (tỉ số 0,87–1,13) và còn làm kém đi có ý nghĩa ở XJTU và TJU: dung lượng của nhiều cell còn tăng trong vài chục chu kỳ đầu, nên độ lệch đo ở chu kỳ đầu không đại diện cho về sau. Khi đo dày, dịch ước lượng theo sai số của lần đo gần nhất đã đủ tốt (hơn bộ lọc có ý nghĩa ở TJU và HUST); bộ lọc có lợi khi đo thưa (mỗi $0{,}25L$, tốt hơn có ý nghĩa trên XJTU, TJU và MIT), vì nó trả độ lệch về mức chung khi lần đo đã xa. Khoảng 90 % của bộ lọc hẹp hơn nhiều so với khoảng phù hợp cố định nhưng độ phủ thực tế chỉ 73–92 %.

6.16 Thảo luận chung

Gộp các so sánh chính lại: PINN-lai ở 30 % số cell có nhãn có MAE thấp hơn MLP và PINN-semi ở 70 % trên cả bốn bộ, tức kết hợp vật lý, dữ liệu không nhãn và mô hình cây bù được hơn một nửa số cell có nhãn; nhưng nó vẫn kém GBDT ở 70 %. Cùng mô hình học từ các lần đo thưa trên mọi cell train (1,2–6,0 % số chu kỳ) có MAE thấp hơn khi có 30 % số cell có nhãn ở cả 20 cặp mô hình và bộ dữ liệu; với mọi mô hình trừ MLP, nó lấy lại ít nhất 59 % khoảng cách từ 30 % đến 70 % số cell có nhãn (Mục 6.15). Câu hỏi đáng đặt ra vì vậy không phải là 30 % nhãn có thắng 70 % nhãn hay không, mà là nên đặt các lần đo dung lượng ở đâu.

Khi nào nên dùng PINN bán giám sát? Giữa các mạng nơ-ron, PINN bán giám sát nên được dùng thay cho MLP khi số cell có nhãn ít (khoảng 10–30 %) và khi có nhiều cell chưa đo dung lượng. So với GBDT thì khác: trong cùng một bộ dữ liệu, GBDT đơn lẻ có sai số thấp hơn PINN-semi ở phần lớn các trường hợp. Ghép GBDT với nhóm PINN thì tốt hơn cả hai (Mục 6.9).

Khi nào lợi ích nhỏ? Khi đã có đủ nhãn (70 %), và trên TJU, nơi tỉ số so với MLP chỉ ở mức 0,90–1,09 trên mọi mức nhãn. TJU gộp ba nhóm hoá học và chín nhóm điều kiện; có thể biến thiên giữa các nhóm lớn hơn phần mà ràng buộc vật lý dùng chung giải thích được.

Hạn chế. (i) Khoảng dự báo 90 % chưa đạt độ phủ danh nghĩa, và vài lần đo dung lượng chỉ sửa được mức chứ chưa sửa được hình dạng của quỹ đạo dự báo. (ii) Trọng số vật lý được chọn ở một thí nghiệm sơ bộ và giữ cố định. (iii) Ràng buộc vật lý chưa được đưa vào chính mô hình cây; PINN-lai chỉ ghép hai mô hình ở mức dự đoán. (iv) Cell validation có nhãn đầy đủ và nằm ngoài ngân sách nhãn ở mọi thí nghiệm, kể cả khi đo thưa. (v) Ở 30 % nhãn, kết luận ở mức fold chỉ vững trên MIT. (vi) Tham số vật lý λ, E_a không được dữ liệu xác định, kể cả khi tăng trọng số ODE (Mục 6.7). (vii) Ở dạng đạo hàm riêng, tốc độ r học được không phải tốc độ suy giảm thật của cell (Mục 6.8). (viii) PINN-lai được đánh giá với ba lần lặp thay vì năm; quy tắc chọn có hay không lịch sử theo mức nhãn được đặt ra sau khi đã xem test (Mục 6.10).

CHƯƠNG 7

Kết luận và hướng phát triển

7.1 Kết luận

Đồ án xây dựng một mô hình PINN bán giám sát cho bài toán ước lượng SOH của cell lithium-ion và đánh giá nó bằng một giao thức không rò rỉ trên bốn bộ dữ liệu công khai. Trả lời các câu hỏi nghiên cứu:

CH1. Cùng 30 % nhãn, PINN-semi có sai số thấp hơn MLP có ý nghĩa thống kê trên cả bốn bộ (tỉ số MAE 0,76–0,96).

CH2. Lợi ích lớn nhất khi ít nhãn (10 %: tỉ số 0,39–0,90, có ý nghĩa trên cả bốn bộ) và giảm dần khi lượng nhãn tăng. Ở 70 % nhãn, khi không còn cell không nhãn, cải thiện chỉ còn có ý nghĩa trên MIT, và trên TJU MLP tốt hơn.

CH3. PINN-semi có MAE thấp hơn MLP trong 14/16, thấp hơn Ridge trong 15/16 và GPR trong 6/16 trường hợp (bộ × mức nhãn), nhưng GBDT tốt hơn PINN-semi trong 14/16 trường hợp, 10 trong đó có ý nghĩa thống kê: trong các mô hình đơn lẻ, GBDT mạnh nhất.

CH4. Ở 10 % nhãn, 50–64 % mức giảm sai số (thang log) của PINN-semi so với MLP đến từ việc áp loss vật lý lên cell không nhãn, phần còn lại từ vật lý trên cell có nhãn. Ở 30 % nhãn, riêng ràng buộc đơn điệu đã mang lại 62–95 % mức giảm đó. Đo trực tiếp trên mô hình đã huấn luyện, vật lý tác động chủ yếu qua ràng buộc dọc quỹ đạo (Mục 6.8).

CH5. Học trên một bộ và dùng nguyên cho bộ khác, sai số của mô hình kết hợp gấp 14,6 lần sai số trong bộ (GBDT: 12,4 lần, MLP: 29,2 lần); phần lớn là lệch mức của cả quỹ đạo. Thích nghi không nhãn giúp ở 6 cặp nhưng làm kém đi ở 5 cặp; học lặp bằng nhãn giả hội tụ về chính dự đoán ban đầu.

CH6. Có. PINN-lai, nhóm ba PINN-semi kết hợp GBDT và bộ lọc quỹ đạo, có MAE thấp hơn PINN-semi ở 16/16 trường hợp (tỉ số 0,67–0,95) và thấp hơn GBDT ở 10/16 trường hợp, 8 có ý nghĩa thống kê; GBDT chỉ còn tốt hơn có ý nghĩa ở 1 trường hợp. Phần lớn lợi ích đến từ việc kết hợp hai mô hình có lệch theo cell chỉ tương quan ở mức vừa; phần vật lý vẫn giúp khi ít nhãn (so với cùng công thức dùng MLP, tỉ số 0,72 ở 10 % nhãn).

CH7. Có, với độ chính xác giảm dần theo tầm. Khi cell test không được đo dung lượng, mô hình kết hợp (PINN-dự báo và GBDT) dự báo SOH trên toàn bộ phần đời còn lại với MAE 11,6–27,0 ($\times 10^{-3}$), bằng 0,21–0,60 lần các mô hình chỉ dựa vào lịch sử của chính cell; GBDT gần ngang về SOH nhưng không ngoại suy được ra ngoài tầm đã học nên sai số

RUL gấp 1,1–1,5 lần. Khoảng 90 % chỉ đạt độ phủ 78–84 %. Tách phần hồi phục và dao động đều ra khỏi xu thế giảm sai số tầm ngắn có ý nghĩa trên XJTU, MIT và HUST.

CH8. Trên đúng cách chia của PINN4SOH, với tiền xử lý không rò rỉ, PINN-lai có sai số bằng 0,23–0,63 lần số công bố trên TJU và MIT, ngang trên XJTU và chỉ kém trên HUST, nơi chỉ số chu kỳ chuẩn hoá theo từng cell cho mô hình của bài biết phần đời đã qua. Cùng tiền xử lý với bài, PINN-lai bằng 0,84–1,10 lần ở chế độ đầy đủ và 0,33–0,94 lần ở chế độ ít mẫu, nhờ các cell không nhãn đi vào loss vật lý.

CH9. Nên tính nhãn theo số lần đo dung lượng và rải các lần đo lên mọi cell thay vì đo kín một phần cell. Đo mỗi $0{,}05L$ (1,2–6,0 % số chu kỳ train) cho PINN-lai sai số bằng 0,85–0,93 lần gắn nhãn đầy đủ cho 30 % số cell (43–44 % số chu kỳ) và 0,97–1,05 lần khi gắn cho 70 % số cell; cả năm mô hình đều hưởng lợi theo cùng hướng. Đo thêm cell mới theo lịch $0{,}1L$ và cập nhật bằng bộ lọc Kalman đưa MAE xuống 1,2–7,5 ($\times 10^{-3}$), bằng 0,34–0,77 lần GBDT học với 70 % cell có nhãn đầy đủ.

CH10. Lịch sử của cell giúp khi đủ nhãn, nhưng không ở mọi bộ: trên TJU và HUST từ 30 % nhãn, nó giảm sai số của PINN-lai còn 0,89–0,97 lần; trên XJTU và ở 10 % nhãn thì không. Khi dùng hay không dùng lịch sử được chọn trên validation của đủ ba lần lặp (phân tích hậu kiểm), PINN-lai có sai số thấp hơn GBDT ở 16/16 trường hợp bộ × mức nhãn, có ý nghĩa ở 13. Bộ lọc xu thế không bảo đảm SOH không tăng (đầu ra tăng ở 28–44 % số bước); ép không tăng làm sai số trên XJTU tăng 1,8–1,9 lần vì dung lượng đo được của XJTU tăng ở đầu đời.

Về phương pháp đánh giá, cách chia theo chu kỳ và chuẩn hoá theo cả vòng đời cell làm sai số trông thấp hơn thực tế; giao thức theo cell của đồ án có các tính chất được chứng minh và cho phép so ghép cặp theo cell.

7.2 Đối chiếu với đề cương

Bảng 7.1 đối chiếu các mục tiêu và nhiệm vụ của giai đoạn 1 trong đề cương với phần đã thực hiện.

7.3 Hướng phát triển

1. Đưa ràng buộc vật lý vào chính mô hình cây, ví dụ dùng loss đơn điệu và loss động học để tạo nhãn giả cho GBDT trên cell không nhãn.
2. Lịch đo chủ động: chọn cell và chu kỳ đo tiếp theo theo độ bất định của mô hình thay vì lịch đều, và kiểm chứng trên dữ liệu vận hành thật, nơi các lần kiểm tra dung lượng cách nhau không đều.

Bảng 7.1. Đối chiếu mục tiêu và nhiệm vụ của đề cương (giai đoạn 1) với phần đã thực hiện.

Đề cương	Đã thực hiện	Mục
Kiến thức nền: học máy, học sâu cho chuỗi thời gian, dữ liệu pin và ràng buộc hoá lý	MLP, CNN, LSTM, Transformer, mã hoá vị trí, sequence-to-sequence, GCN; cơ chế suy giảm; PINN	2.2, 4.2
Tái lập thống kê mô tả; phân tích dữ liệu thô, ngoại lai, mẫu gây nhiễu	Thống kê năm bộ; lọc ngoại lai nhân quả; hồi phục dung lượng sau khoảng nghỉ của NASA	4.1, 6.14
Chạy và so sánh ≥ 4 mô hình nền (MLP, CNN, LSTM, Transformer) bằng MAE, RMSE, MAPE	Bốn mô hình nền cùng GBDT, Ridge, GPR, PINN; MAE, RMSE, MAPE, R^2; kiểm định ghép cặp theo cell	6.4
Tinh chỉnh mô hình, giải thích vì sao tốt lên hay xấu đi	Độ dài cửa sổ; trọng số ghép và cửa sổ lọc; dạng lịch sử; bộ lọc đơn điệu	6.9.6, 6.10, 6.9.7
Đề xuất cải tiến có cơ sở lý thuyết cho giai đoạn 2	PINN bán giám sát, PINN-lai, dự báo bằng nghiệm đóng của động học	4.2, 4.3, 4.5
Xác định phạm vi SOH, RUL; đầu vào, đầu ra, ràng buộc thực tế	Ước lượng SOH trực tuyến từ đoạn sạc; dự báo SOH, dung lượng, RUL	6.12
Thiết kế chỉ số; kịch bản lỗi; phương án dự phòng khi độ tin cậy thấp	MAE theo cell; kiểm toán rò rỉ; khoảng dự đoán 90 %; cập nhật bằng vài lần đo dung lượng	6.1, 6.9.5, 6.15.3
Bản mẫu, trực quan hoá dữ liệu	Đường ống tái lập được; công cụ dòng lệnh ước lượng và dự báo cho một cell; hình quỹ đạo	5.1

3. Dùng điện lượng tích luỹ thay cho chỉ số chu kỳ làm biến thời gian, để chuyển giữa các giao thức sạc tốt hơn.
4. Cho k chỉ phụ thuộc vào cell để λ và E_a được dữ liệu xác định (Mục 6.7).

Tài liệu tham khảo

[1] A. N. Angelopoulos, S. Bates. Conformal prediction: a gentle introduction. *Foundations and Trends in Machine Learning*, 16(4):494–591, 2023.

[2] S. Arlot, A. Celisse. A survey of cross-validation procedures for model selection. *Statistics Surveys*, 4:40–79, 2010.

[3] P. M. Attia, A. Bills, F. Brosa Planella, et al. Review—"Knees" in lithium-ion battery aging trajectories. *Journal of The Electrochemical Society*, 169:060517, 2022.

[4] M. Aykol, C. B. Gopal, A. Anapolsky, et al. Perspective—Combining physics and machine learning to predict battery lifetime. *Journal of The Electrochemical Society*, 168:030525, 2021.

[5] S. Bai, J. Z. Kolter, V. Koltun. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv:1803.01271*, 2018.

[6] R. E. Barlow, D. J. Bartholomew, J. M. Bremner, H. D. Brunk. *Statistical Inference under Order Restrictions*. Wiley, 1972.

[7] C. R. Birkl, M. R. Roberts, E. McTurk, P. G. Bruce, D. A. Howey. Degradation diagnostics for lithium ion cells. *Journal of Power Sources*, 341:373–386, 2017.

[8] R. R. Bouckaert, E. Frank. Evaluating the replicability of significance tests for comparing learning algorithms. *Advances in Knowledge Discovery and Data Mining (PAKDD)*, 3–12, 2004.

[9] C. Braun, J. Raible, M. F. Huber. Physics-informed machine learning in prognostics and health management: a systematic literature review. arXiv:2608.10047, 2026.

[10] L. Breiman. Bagging predictors. *Machine Learning*, 24(2):123–140, 1996.

[11] M. Broussely, S. Herreyre, P. Biensan, et al. Aging mechanism in Li ion cells and calendar life predictions. *Journal of Power Sources*, 97–98:13–21, 2001.

[12] W. S. Cleveland. Robust locally weighted regression and smoothing scatterplots. *Journal of the American Statistical Association*, 74(368):829–836, 1979.

[13] T. G. Dietterich. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923, 1998.

[14] M. Doyle, T. F. Fuller, J. Newman. Modeling of galvanostatic charge and discharge of the lithium/polymer/insertion cell. *Journal of The Electrochemical Society*, 140(6):1526–1533, 1993.

[15] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[16] P. Fermín-Cueto, E. McTurk, M. Allerhand, et al. Identification and machine learning prediction of knee-point and knee-onset in capacity degradation curves of lithium-ion cells. *Energy and AI*, 1:100006, 2020.

[17] J. H. Friedman. Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.

[18] L. Grinsztajn, E. Oyallon, G. Varoquaux. Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems*, 35, 2022.

[19] G. Hinton, O. Vinyals, J. Dean. Distilling the knowledge in a neural network. arXiv:1503.02531, 2015.

[20] W. He, N. Williard, M. Osterman, M. Pecht. Prognostics of lithium-ion batteries based on Dempster–Shafer theory and the Bayesian Monte Carlo method. *Journal of Power Sources*, 196(23):10314–10321, 2011.

[21] J. I. Olalde-Verano, S. Kirch, C. Pérez-Molina, S. Martín. SambaMixer: State of health prediction of Li-ion batteries using Mamba state space models. *IEEE Access*, 2024. doi:10.1109/ACCESS.2024.3524321.

[22] S. Hochreiter, J. Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.

[23] S. Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.

[24] X. Hu, L. Xu, X. Lin, M. Pecht. Battery lifetime prognostics. *Joule*, 4(2):310–346, 2020.

[25] S. Kapoor, A. Narayanan. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804, 2023.

[26] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, L. Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3:422–440, 2021.

[27] G. Ke, Q. Meng, T. Finley, et al. LightGBM: a highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 2017.

[28] T. N. Kipf, M. Welling. Semi-supervised classification with graph convolutional networks. *International Conference on Learning Representations*, 2017.

[29] A. S. Krishnapriyan, A. Gholami, S. Zhe, R. M. Kirby, M. W. Mahoney. Characterizing possible failure modes in physics-informed neural networks. *Advances in Neural Information Processing Systems*, 34, 2021.

[30] B. Lakshminarayanan, A. Pritzel, C. Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. *Advances in Neural Information Processing Systems*, 30, 2017.

[31] D.-H. Lee. Pseudo-label: the simple and efficient semi-supervised learning method for deep neural networks. *ICML Workshop on Challenges in Representation Learning*, 2013.

[32] J. Lei, M. G'Sell, A. Rinaldo, R. J. Tibshirani, L. Wasserman. Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523):1094–1111, 2018.

[33] I. Loshchilov, F. Hutter. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019.

[34] J. Lu, R. Xiong, J. Tian, C. Wang, F. Sun. Deep learning to estimate lithium-ion battery state of health without additional degradation experiments. *Nature Communications*, 14:2760, 2023.

[35] G. Ma, S. Xu, B. Jiang, et al. Real-time personalized health status prediction of lithium-ion batteries using deep transfer learning. *Energy & Environmental Science*, 15:4083–4094, 2022.

[36] C. Nadeau, Y. Bengio. Inference for the generalization error. *Machine Learning*, 52:239–281, 2003.

[37] S. Navidi, A. Thelen, T. Li, C. Hu. Physics-informed machine learning for battery degradation diagnostics: a comparison of state-of-the-art methods. arXiv:2404.04429, 2024.

[38] G. Piombo, S. Fasolato, R. Heymer, et al. Full factorial design of experiments dataset for parallel-connected lithium-ion cells imbalanced performance investigation. *Data in Brief*, 53:110227, 2024.

[39] M. B. Pinson, M. Z. Bazant. Theory of SEI formation in rechargeable batteries: capacity fade, accelerated aging and lifetime prediction. *Journal of The Electrochemical Society*, 160(2):A243–A250, 2013.

[40] G. L. Plett. *Battery Management Systems, Volume I: Battery Modeling*. Artech House, 2015.

[41] M. Raissi, P. Perdikaris, G. E. Karniadakis. Physics-informed neural networks: a deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.

[42] C. E. Rasmussen, C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.

[43] R. R. Richardson, M. A. Osborne, D. A. Howey. Gaussian process regression for forecasting battery state of health. *Journal of Power Sources*, 357:209–219, 2017.

[44] D. Roman, S. Saxena, V. Robu, M. Pecht, D. Flynn. Machine learning pipeline for battery state-of-health estimation. *Nature Machine Intelligence*, 3:447–456, 2021.

[45] A. Saxena, J. Celaya, E. Balaban, et al. Metrics for evaluating performance of prognostic techniques. In *International Conference on Prognostics and Health Management*, IEEE, 2008.

[46] B. Saha, K. Goebel. Battery data set. *NASA Ames Prognostics Data Repository*, NASA Ames Research Center, Moffett Field, CA, 2007.

[47] J. Schmalstieg, S. Käbitz, M. Ecker, D. U. Sauer. A holistic aging model for Li(NiMnCo)O_2 based 18650 lithium-ion batteries. *Journal of Power Sources*, 257:325–334, 2014.

[48] K. A. Severson, P. M. Attia, N. Jin, et al. Data-driven prediction of battery cycle life before capacity degradation. *Nature Energy*, 4:383–391, 2019.

[49] L. Su, Y. Xu, Z. Dong. State-of-health estimation of lithium-ion batteries: a comprehensive literature review from cell to pack levels. *Energy Conversion and Economics*, 5(4):224–242, 2024.

[50] V. Sulzer, P. Mohtat, A. Aitio, et al. The challenge and opportunity of battery lifetime prediction from field data. *Joule*, 5(8):1934–1955, 2021.

[51] A. Tarvainen, H. Valpola. Mean teachers are better role models: weight-averaged consistency targets improve semi-supervised deep learning results. *Advances in Neural Information Processing Systems*, 30, 2017.

[52] A. Thelen, X. Huan, N. Paulson, S. Onori, Z. Hu, C. Hu. Probabilistic machine learning for battery health diagnostics and prognostics—review and perspectives. *npj Materials Sustainability*, 2:14, 2024.

[53] S. Varma, R. Simon. Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91, 2006.

[54] V. Vovk, A. Gammerman, G. Shafer. *Algorithmic Learning in a Random World*. Springer, 2005.

[55] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 2017.

[56] T. Waldmann, M. Wilka, M. Kasper, M. Fleischhammer, M. Wohlfahrt-Mehrens. Temperature dependent ageing mechanisms in lithium-ion batteries – a post-mortem study. *Journal of Power Sources*, 262:129–135, 2014.

[57] J. Wang, P. Liu, J. Hicks-Garner, et al. Cycle-life model for graphite-$LiFePO_4$ cells. *Journal of Power Sources*, 196(8):3942–3948, 2011.

[58] S. Wang, Y. Teng, P. Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5):A3055–A3081, 2021.

[59] F. Wang, Z. Zhai, Z. Zhao, Y. Di, X. Chen. Physics-informed neural network for lithium-ion battery degradation stable modeling and prognosis. *Nature Communications*, 15:4332, 2024.

[60] P. Wen, Z.-S. Ye, Y. Li, S. Chen, P. Xie, S. Zhao. Physics-informed neural networks for prognostics and health management of lithium-ion batteries. arXiv:2301.00776, 2023.

[61] F. Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.

[62] D. H. Wolpert. Stacked generalization. *Neural Networks*, 5(2):241–259, 1992.

[63] Y. Zhang, R. Xiong, H. He, M. G. Pecht. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries. *IEEE Transactions on Vehicular Technology*, 67(7):5695–5705, 2018.

[64] H. Zhang, et al. BatteryML: an open-source platform for machine learning on battery degradation. *arXiv:2310.14714*, 2023.

[65] J. Zhu, Y. Wang, Y. Huang, et al. Data-driven capacity estimation of commercial lithium-ion batteries from voltage relaxation. *Nature Communications*, 13:2261, 2022.