ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



ĐỒ ÁN CHUYÊN NGÀNH

Dự đoán thông số sức khoẻ của pin bằng mô hình học sâu được hỗ trợ từ thông tin hoá lý của hệ pin

Sinh viên thực hiện: Huỳnh Quốc Thắng
Nhóm: 15
Học kỳ: HK261

TP. Hồ Chí Minh, tháng 10/2026

Tóm tắt

Đồ án nghiên cứu bài toán ước lượng trạng thái sức khoẻ (SOH) của cell lithium-ion khi chỉ một phần nhỏ cell có nhãn dung lượng. Mô hình đề xuất là một mạng nơ-ron có thông tin vật lý (PINN) bán giám sát: mạng nghiệm dự đoán SOH từ 16 đặc trưng đoạn sạc, gắn với một động học suy giảm dạng xám luôn không âm, có hệ số đầu gối và hệ số Arrhenius; ba hàm mất mát vật lý không dùng nhãn nên áp được lên cell chưa đo dung lượng. Đồ án thiết kế và chứng minh một giao thức đánh giá không rò rỉ (kiểm định chéo 5 fold theo cell, phân tầng theo chế độ thí nghiệm, lặp 5 lần), lý giải từng con số của cách chia, đo định lượng tác động của các dạng rò rỉ thường gặp, và so sánh PINN với sáu mô hình đối chứng ở bốn mức nhãn trên bốn bộ dữ liệu công khai (387 cell, 3.420 lượt huấn luyện). Ở 10 % nhãn, tỉ số sai số giữa PINN bán giám sát và mạng nơ-ron cùng kiến trúc chỉ học có nhãn là 0,39–0,90, trong đó khoảng một nửa đến hai phần ba mức giảm đến từ cell không nhãn; khi tăng lên 70 % nhãn, lợi ích giảm dần (tỉ số 0,85–1,09). Trên bộ dữ liệu mới không có nhãn, PINN vẫn cho sai số dùng được trong khi mạng học có nhãn thất bại. Tuy vậy, một mô hình gradient boosting được tinh chỉnh tốt vẫn có sai số thấp nhất trên phần lớn các bộ dữ liệu.

Từ khoá: pin lithium-ion, trạng thái sức khoẻ, PINN, học bán giám sát, rò rỉ dữ liệu, kiểm định chéo.

Mục lục

Tóm tắt **i**

1 Giới thiệu **1**

1.1 Bối cảnh . . . 1

1.2 Phát biểu bài toán . . . 1

1.3 Câu hỏi nghiên cứu . . . 1

1.4 Đóng góp . . . 2

1.5 Bố cục . . . 2

2 Cơ sở lý thuyết và các công trình liên quan **3**

2.1 Suy giảm dung lượng của pin lithium-ion . . . 3

2.2 Các hướng ước lượng SOH . . . 3

2.3 Mạng nơ-ron có thông tin vật lý . . . 4

2.4 Học bán giám sát . . . 4

2.5 Đánh giá mô hình và rò rỉ dữ liệu . . . 4

2.6 Tổng hợp và khoảng trống . . . 5

3 Dữ liệu **6**

3.1 Nguồn dữ liệu . . . 6

3.2 Đặc trưng đầu vào . . . 6

3.3 Tiền xử lý . . . 7

3.4 Thống kê mô tả . . . 7

4 Phương pháp **8**

4.1 Tổng quan . . . 8

4.2 Mạng nghiệm . . . 8

4.3 Động học suy giảm dạng xám . . . 9

4.4 Hàm mất mát . . . 9

4.5 Cơ chế bán giám sát . . . 9

4.6 Phần vật lý nằm ở đâu . . . 10

4.7 Tính chất của mô hình . . . 10
4.8 Các mô hình đối chứng . . . 11
4.9 Cấu hình huấn luyện . . . 12

5 Thiết kế thí nghiệm và giao thức đánh giá 13
5.1 Các yêu cầu đối với giao thức . . . 13
5.2 Đơn vị chia: cell, không phải chu kỳ . . . 13
5.3 Chọn số fold K . . . 15
5.4 Chọn tỉ lệ validation . . . 16
5.5 Phân tầng theo chế độ thí nghiệm . . . 17
5.6 Chọn số lần lặp R . . . 18
5.7 Ghép cặp và hạt giống . . . 19
5.8 Quy trình chống rò rỉ trong cùng bộ dữ liệu . . . 19
5.9 Chuyển miền giữa các bộ dữ liệu . . . 20
5.10 Kiểm toán rò rỉ . . . 21
5.11 Chỉ số đánh giá . . . 22
5.12 Phương pháp thống kê . . . 22

6 Kết quả và thảo luận 24
6.1 Kiểm toán rò rỉ . . . 24
6.2 So sánh ở 30 % nhãn . . . 25
6.3 PINN và học có nhãn khi thay đổi lượng nhãn . . . 25
6.4 So với các mô hình học có nhãn khác . . . 29
6.5 Lợi ích đến từ đâu . . . 30
6.6 Các chỉ số mở rộng và hình dự đoán . . . 31
6.7 RMSE và R^2 cho mọi mô hình . . . 34
6.8 Chuyển miền . . . 37
6.9 Tham số vật lý học được . . . 39
6.10 Kiểm tra phần vật lý . . . 39
6.11 Thảo luận chung . . . 42

7 Kết luận và hướng phát triển 44
7.1 Kết luận . . . 44

7.2 Hướng phát triển 45

Danh sách hình vẽ

4.1 Kiến trúc mô hình: mạng nghiệm dự đoán SOH, mạng tốc độ mô tả động học suy giảm; hai mạng gắn với nhau qua các hàm mất mát vật lý. 8

5.1 Mô phỏng chia theo chu kỳ. Trái: khoảng cách trung bình tới chu kỳ train gần nhất theo q. Phải: sai số của phép chép nhãn trên quỹ đạo SOH thật (điểm) so với cận $\mathbb{E}[d] \cdot \overline{|\Delta y|}$ (nét đứt); trục dọc thang log. 15

5.2 Cách chia thật của bộ XJTU ở lần lặp đầu tiên, mức 30 % nhãn. Mỗi cột là một cell, mỗi hàng là một fold; cell được xếp theo nhóm chế độ thí nghiệm. 18

5.3 Số cell test của từng nhóm thí nghiệm trong từng fold (lần lặp đầu tiên). 18

5.4 Trái: tỉ số MAE PINN-semi/MLP ở 30 % nhãn theo số lần lặp; đường là trung bình, dải là khoảng nhỏ nhất–lớn nhất giữa các tổ hợp lần lặp. Phải: độ rộng khoảng tin cậy 95 %. 19

5.5 Phần dữ liệu nào được dùng cho bước nào (ô màu: có dùng). Trái: đánh giá trong cùng bộ; phải: chuyển miền. Với MLP, cột loss vật lý không áp dụng. 20

6.1 MAE theo cell của cùng một mô hình (MLP, 70 % nhãn) dưới các cách chia và chuẩn hoá khác nhau. 24

6.2 MAE từng cell ở 30 % nhãn, trung bình 5 lần lặp: trục ngang MLP, trục dọc PINN-semi; điểm dưới đường chéo (xanh lục) là cell mà PINN-semi có sai số thấp hơn. 25

6.3 MAE theo cell theo lượng nhãn: MLP và các biến thể có vật lý. Dải là khoảng tin cậy 95 % bootstrap theo cell; trục dọc thang log. 27

6.4 MAE theo cell theo lượng nhãn: PINN-semi so với các mô hình học có nhãn. . 27

6.5 Tỉ số MAE theo cell của PINN-semi so với MLP, GBDT và PINN-sup theo lượng nhãn (vạch: khoảng tin cậy 95 %). Dưới 1: PINN-semi tốt hơn. 28

6.6 SOH dự đoán so với thực đo trên tập test (30 % nhãn). Hàng trên: MLP; hàng dưới: PINN-semi. 32

6.7 Quỹ đạo SOH trên ba cell test mỗi bộ (cell có sai số MLP ở phân vị 25, 50 và 75 %). 33

6.8 MAE theo từng khoảng SOH thực đo (30 % nhãn). 33

6.9 RMSE theo cell (hàng trên, thang log) và R^2 tính từ chu kỳ thứ 10 (hàng dưới) theo lượng nhãn. 36

6.10 MAE theo cell trên tập test của bộ đích (thang log); hàng: số cell đích có nhãn k, cột: mô hình; ô gạch chéo: cùng một bộ, không chuyển miền. 38

6.11 Tỉ lệ cặp chu kỳ có SOH dự đoán tăng ngược ở 30 % nhãn; vạch ngang là cùng phép đếm trên nhãn thật. 40

6.12 Tốc độ suy giảm của từng cell test: thực đo (trục ngang) so với độ dốc dự đoán và tốc độ r học được (trục dọc); đường chéo là trùng khớp. 41

6.13 Tốc độ suy giảm theo khoảng SOH thực đo (trục ngang giảm dần): thực đo, độ dốc dự đoán và tốc độ r học được. 42

Danh sách bảng

2.1 Tóm tắt các hướng tiếp cận liên quan. 5

3.1 Thống kê bốn bộ dữ liệu sau tiền xử lý. "Nhóm" là số chế độ thí nghiệm khác nhau dùng để phân tầng. 7

4.1 Hiểu biết vật lý và thành phần mô hình tương ứng. 10

4.2 Các mô hình được so sánh. 12

4.3 Cấu hình huấn luyện chung cho MLP và các biến thể PINN. 12

5.1 Sai số của phép "dự đoán" chỉ chép nhãn của chu kỳ train gần nhất trong cùng cell khi chia theo chu kỳ, so với cận của Mệnh đề 5.1 và với sai số thật khi chia theo cell (MAE theo cell, $\times 10^{-3}$). 14

5.2 Khả thi của số fold K với validation 10 % và mức nhãn cao nhất 70 % số cell (số lượt tính với 5 lần lặp). 16

5.3 Đánh đổi khi chọn tỉ lệ validation (mức nhãn cao nhất 70 %, 5 lần lặp). 16

5.4 Mô phỏng lấy lại theo số lần lặp: tỉ số MAE PINN-semi/MLP ở 30 % nhãn. SD là độ lệch chuẩn của ước lượng giữa các tổ hợp lần lặp; KTC là độ rộng khoảng tin cậy 95 % bootstrap theo cell. 18

5.5 Các thí nghiệm và số lượt huấn luyện. 23

6.1 Kiểm toán rò rỉ: MAE theo cell ($\times 10^{-3}$) của MLP với 70 % nhãn, trung bình 2 lần lặp × 5 fold; trong ngoặc là tỉ số so với giao thức chuẩn. 24

6.2 MAE theo cell ($\times 10^{-3}$) của mọi mô hình theo lượng nhãn (phần trăm số cell có nhãn); in đậm là thấp nhất trong cột của mỗi bộ. Trung bình 5 lần lặp × 5 fold; mỗi cell được test 5 lần. 26

6.3 Lượng nhãn tương đương: mô hình học có nhãn cần bao nhiêu phần trăm cell có nhãn để đạt MAE của PINN-semi ở 10 % và 30 % nhãn ("tốt nhất": mô hình học có nhãn tốt nhất ở từng mức, trong Ridge, GPR, GBDT, MLP). Nội suy log-tuyến tính giữa các mức đo. 28

6.4 Tỉ số MAE theo cell của PINN-semi so với MLP và GBDT ở từng mức nhãn (nhỏ hơn 1: PINN-semi tốt hơn). *: $p_{\text{Holm}} < 0{,}05$ theo cell; †: còn có ý nghĩa với kiểm định bảo thủ mức fold. 29

6.5 Tách nguồn gốc lợi ích ở 30 % nhãn: MAE theo cell ($\times 10^{-3}$), trong ngoặc là tỉ số so với MLP. 30

6.6 Chỉ số gộp mọi chu kỳ trên tập test (MAE, RMSE, MaxAE theo điểm phần trăm SOH). 31

6.7 RMSE theo cell ($\times 10^{-3}$, bốn cột đầu) và R^2 tính từ chu kỳ thứ 10 (bốn cột sau) theo lượng nhãn; in đậm là tốt nhất trong cột của mỗi bộ. R^2 ghép dự đoán của 5 fold thành toàn bộ bộ dữ liệu, trung bình qua 5 lần lặp. 35

6.8 R^2 trên tập test của bộ đích qua 12 cặp chuyển miền (mỗi cặp trung bình 5 hạt giống). 37

6.9 Chuyển miền: MAE theo cell trên tập test của bộ đích, trung bình 5 hạt giống; in đậm là thấp nhất trong cùng một k. Mọi mô hình dùng cùng cách chia và cùng normaliser. 37

6.10 Tham số vật lý học được của PINN-semi ở 30 % nhãn (trung bình ± độ lệch chuẩn qua 25 lượt). Giá trị khởi tạo: $\lambda = 1$, $E_a = 30\,\mathrm{kJ/mol}$. 39

6.11 Tỉ lệ cặp chu kỳ cách nhau ít nhất 10 chu kỳ mà SOH dự đoán tăng quá 0,002 (%), 30 % nhãn, mọi cell test của 5 lần lặp; cột đầu là cùng phép đếm trên chính nhãn thật. 40

6.12 Đo trên cell test của mô hình đã huấn luyện (30 % nhãn, lần lặp đầu, 5 fold). Bốn cột đầu: tỉ lệ điểm có $\partial F_\varphi / \partial t > 0$ (%). Ba cột giữa: trung vị qua các cell của phần giảm SOH dự đoán do riêng biến thời gian (%). Ba cột cuối: tốc độ suy giảm trung bình (SOH trên 1 000 chu kỳ). 40

CHƯƠNG 1

Giới thiệu

1.1 Bối cảnh

Pin lithium-ion là nguồn năng lượng chính của xe điện, thiết bị di động và hệ thống lưu trữ điện. Trong quá trình sử dụng, dung lượng của pin giảm dần do các phản ứng phụ bên trong cell: lớp SEI dày lên, lithium bị mất khỏi chu trình, vật liệu điện cực bị suy thoái. Trạng thái sức khoẻ (State of Health, SOH) đo mức suy giảm này và thường được định nghĩa bằng tỉ số giữa dung lượng hiện tại và dung lượng danh định:

$$\mathrm{SOH}_n = \frac{Q_n}{Q_{\text{danh định}}}, \tag{1.1}$$

trong đó Q_n là dung lượng đo được ở chu kỳ thứ n. Hệ thống quản lý pin (BMS) cần SOH để ước tính quãng đường còn lại, điều chỉnh chiến lược sạc và cảnh báo thời điểm thay pin; với pin xe điện, mốc cuối đời thường được chọn ở SOH khoảng 0,8.

Khó khăn thực tế nằm ở nhãn. Muốn biết chính xác Q_n phải xả đầy cell theo một quy trình chuẩn, mất nhiều giờ và phải dừng vận hành. Ngược lại, dữ liệu điện áp và dòng điện trong lúc sạc được BMS ghi lại ở mọi chu kỳ, của mọi cell, gần như không tốn chi phí. Bài toán vì vậy có dạng điển hình của học ít nhãn: rất nhiều dữ liệu đầu vào nhưng chỉ một phần nhỏ có nhãn.

1.2 Phát biểu bài toán

Xét tập cell $\mathscr{C}$. Mỗi cell c có chuỗi chu kỳ $n = 0, 1, \dots, L_c$; ở mỗi chu kỳ, từ đoạn sạc CC–CV ta trích được vector đặc trưng $\mathbf{x}_{c,n} \in \mathbb{R}^{16}$. Nhãn $y_{c,n} = \mathrm{SOH}_{c,n}$ chỉ được biết trên một tập con các cell huấn luyện $\mathscr{C}_L \subset \mathscr{C}_{\text{train}}$; các cell còn lại $\mathscr{C}_U = \mathscr{C}_{\text{train}} \setminus \mathscr{C}_L$ chỉ có đặc trưng sạc. Mục tiêu là học hàm

$$\hat{y} = F(\mathbf{x}_{c,n}, n) \tag{1.2}$$

sao cho sai số trên các cell *chưa từng xuất hiện* khi huấn luyện là nhỏ nhất. Mô hình chỉ dùng dữ liệu của chu kỳ hiện tại, nên có thể chạy trực tuyến trong BMS.

1.3 Câu hỏi nghiên cứu

CH1. Khi cùng một lượng cell có nhãn, mô hình PINN bán giám sát có sai số thấp hơn mô hình học có nhãn thuần tuý không?

CH2. Lợi ích đó thay đổi thế nào khi lượng nhãn đi từ rất ít (10 % số cell) tới nhiều (70 %)? Mô hình học có nhãn cần bao nhiêu nhãn để đạt sai số của PINN?

CH3. So với các mô hình học có nhãn mạnh khác (hồi quy tuyến tính, hồi quy Gauss, gradient boosting), PINN đứng ở đâu?

CH4. Lợi ích đến từ đâu: từ vai trò chuẩn hoá (regularization) của vật lý, từ dữ liệu không nhãn, từ phương trình động học hay chỉ từ ràng buộc đơn điệu?

CH5. Mô hình có chuyển được từ bộ dữ liệu này sang bộ khác mà không cần (hoặc chỉ cần rất ít) nhãn của bộ đích không?

Mọi câu hỏi trên chỉ có ý nghĩa nếu giao thức đánh giá không rò rỉ thông tin. Vì vậy một phần lớn của đồ án dành cho việc thiết kế, lý giải và chứng minh giao thức chia dữ liệu (Chương 5).

1.4 Đóng góp

1. Một mô hình PINN bán giám sát cho bài toán ước lượng SOH: mạng nghiệm kết hợp động học suy giảm dạng xám (tốc độ suy giảm luôn không âm, có hệ số đầu gối và hệ số Arrhenius), cùng ba hàm mất mát vật lý không dùng nhãn nên áp được lên cell chưa đo dung lượng.
2. Một giao thức đánh giá không rò rỉ: chia theo cell, kiểm định chéo 5 fold phân tầng theo chế độ thí nghiệm, lặp 5 lần, với lý do chọn từng con số và chứng minh các tính chất của cách chia.
3. Kiểm toán rò rỉ định lượng: đo mức sai số bị đánh giá thấp giả tạo khi chia theo chu kỳ, khi chuẩn hoá theo cả vòng đời cell, khi lọc ngoại lai bằng dữ liệu tương lai.
4. So sánh hệ thống PINN với sáu mô hình đối chứng ở bốn mức nhãn trên bốn bộ dữ liệu công khai (387 cell), tổng cộng 3.420 lượt huấn luyện, có kiểm định thống kê và hiệu chỉnh đa so sánh.
5. Thí nghiệm chuyển miền đầy đủ giữa bốn bộ dữ liệu với quy trình chuẩn hoá không dùng dữ liệu test.

1.5 Bố cục

Chương 2 trình bày cơ sở lý thuyết và các công trình liên quan. Chương 3 mô tả bốn bộ dữ liệu và cách tiền xử lý. Chương 4 trình bày mô hình, các hàm mất mát và các mô hình đối chứng. Chương 5 là thiết kế thí nghiệm: cách chọn số chia, cách chống rò rỉ khi đánh giá trong cùng bộ và khi chuyển miền, cùng các phương pháp thống kê. Chương 6 trình bày và thảo luận kết quả. Chương 7 kết luận và nêu hướng phát triển.

CHƯƠNG 2

Cơ sở lý thuyết và các công trình liên quan

2.1 Suy giảm dung lượng của pin lithium-ion

Dung lượng của cell lithium-ion giảm theo hai nhóm cơ chế chính [4]: mất lithium khả dụng (loss of lithium inventory, LLI), chủ yếu do lớp SEI phát triển trên bề mặt anode, và mất vật liệu hoạt động (loss of active material, LAM) do nứt hạt, bong tách hoặc hoà tan kim loại chuyển tiếp. Trong giai đoạn đầu, dung lượng thường giảm chậm và gần tuyến tính; ở giai đoạn sau nhiều cell đi vào vùng "đầu gối" (knee), nơi tốc độ suy giảm tăng nhanh [2]. Các phản ứng phụ phụ thuộc nhiệt độ theo quy luật dạng Arrhenius: nhiệt độ cao làm SEI phát triển nhanh hơn [24]. Hai quan sát này là cơ sở cho phần động học xám ở Chương 4: tốc độ suy giảm luôn không âm, tăng khi SOH giảm và tăng theo nhiệt độ.

2.2 Các hướng ước lượng SOH

Mô hình cơ chế. Mô hình điện hoá giả hai chiều (P2D) của Doyle, Fuller và Newman [7] và các dạng rút gọn như mô hình hạt đơn mô tả chi tiết quá trình bên trong cell; mô hình mạch tương đương [17] đơn giản hơn và được dùng nhiều trong BMS. Ưu điểm là diễn giải được; nhược điểm là cần nhiều tham số khó đo, việc hiệu chỉnh tham số theo lão hoá tốn kém.

Học máy dựa trên đặc trưng. Severson và cộng sự [22] cho thấy đặc trưng trích từ đường cong xả của 100 chu kỳ đầu đủ để dự đoán tuổi thọ của 124 cell LFP bằng hồi quy tuyến tính có chuẩn hoá. Richardson, Osborne và Howey [20] dùng hồi quy Gauss để dự báo SOH kèm độ bất định. Roman và cộng sự [21] xây dựng một quy trình học máy hoàn chỉnh cho ước lượng SOH. Zhu và cộng sự [29] dùng đặc trưng của điện áp hồi phục sau sạc và công bố bộ dữ liệu TJU. Nhóm phương pháp này cho kết quả tốt khi có đủ nhãn, nhưng phụ thuộc nhiều vào lượng nhãn và phân phối dữ liệu huấn luyện.

Học sâu. Mạng hồi quy LSTM [28], mạng tích chập và các kiến trúc dựa trên chú ý học trực tiếp từ chuỗi đo. Các mô hình này mạnh khi có nhiều dữ liệu có nhãn và dễ quá khớp khi ít nhãn.

Học chuyển giao. Ma và cộng sự [15] dùng học chuyển giao sâu để cá nhân hoá dự báo sức khoẻ cho từng cell và công bố bộ dữ liệu HUST. Hướng này giảm nhu cầu nhãn ở miền đích

nhưng vẫn cần một phần nhãn để thích nghi.

Mô hình lai và PINN. Mạng nơ-ron có thông tin vật lý (PINN) của Raissi, Perdikaris và Karniadakis [18] đưa phần dư của phương trình vi phân vào hàm mất mát; phần dư này được tính tại các điểm không cần nhãn. Karniadakis và cộng sự [12] tổng kết hướng học máy có thông tin vật lý, còn Aykol và cộng sự [3] thảo luận việc kết hợp vật lý với học máy cho bài toán tuổi thọ pin. Wen và cộng sự [26] áp dụng PINN cho dự báo và quản lý sức khoẻ pin. Gần với đồ án nhất là PINN4SOH của Wang và cộng sự [25]: dùng chính bốn bộ dữ liệu của đồ án, 16 đặc trưng đoạn sạc, mạng nghiệm $u(\mathbf{x}, t)$ và một mạng động học dạng hộp đen $G(\mathbf{x}, t, u, u_{\mathbf{x}}, u_t)$.

2.3 Mạng nơ-ron có thông tin vật lý

Xét phương trình $\mathcal{N}[u] = 0$ với nghiệm $u(\mathbf{z})$. PINN xấp xỉ u bằng mạng u_φ và cực tiểu

$$\mathcal{L}(\varphi) = \frac{1}{|D|} \sum_{(\mathbf{z},y)\in D} \left(u_\varphi(\mathbf{z}) - y\right)^2 + \lambda \frac{1}{|P|} \sum_{\mathbf{z}\in P} \left(\mathcal{N}[u_\varphi](\mathbf{z})\right)^2, \tag{2.1}$$

trong đó D là tập điểm có nhãn và P là tập điểm "collocation" chỉ cần đầu vào. Khi phương trình đã biết, số hạng thứ hai đóng vai trò tín hiệu học bổ sung không cần nhãn. Với pin, phương trình suy giảm không được biết chính xác, nên một phần của $\mathcal{N}$ phải học từ dữ liệu: đây là chỗ khác nhau giữa động học hộp đen (học hoàn toàn) và động học xám (giữ cấu trúc vật lý, chỉ học phần chưa biết).

2.4 Học bán giám sát

Học bán giám sát tận dụng dữ liệu không nhãn qua một giả định về cấu trúc của dữ liệu, ví dụ tính trơn của hàm cần học hoặc tính nhất quán của dự đoán. Trong đồ án, giả định được dùng là giả định vật lý: quỹ đạo SOH của mọi cell, kể cả cell chưa đo dung lượng, phải thoả phương trình suy giảm, không tăng theo thời gian và nằm trong miền giá trị hợp lý. Các ràng buộc này tính được chỉ từ đặc trưng sạc, nên mỗi cell không nhãn đều đóng góp gradient cho mạng nghiệm.

2.5 Đánh giá mô hình và rò rỉ dữ liệu

Kiểm định chéo là cách chuẩn để ước lượng sai số tổng quát [1]. Khi dữ liệu có cấu trúc nhóm, ở đây là các chu kỳ thuộc cùng một cell, việc chia phải theo nhóm; nếu không, các mẫu gần như trùng nhau sẽ nằm ở cả hai phía train và test. Kapoor và Narayanan [11] tổng kết rò rỉ dữ liệu là một nguyên nhân phổ biến khiến kết quả học máy trong khoa học không tái lập được; các dạng

thường gặp gồm chia không đúng đơn vị, tiền xử lý dùng thống kê của tập test và chọn mô hình trên tập test [23].

Khi so sánh hai mô hình bằng kiểm định chéo lặp lại, các tập huấn luyện chồng lấp nhau nên kết quả các fold không độc lập; phép kiểm t thông thường vì vậy quá lạc quan [6]. Nadeau và Bengio [16] đề xuất hiệu chỉnh phương sai, được Bouckaert và Frank [5] kiểm chứng cho kiểm định chéo lặp lại. Khi thực hiện nhiều phép so sánh, phương pháp Holm [10] kiểm soát xác suất mắc ít nhất một sai lầm loại I.

2.6 Tổng hợp và khoảng trống

Bảng 2.1. Tóm tắt các hướng tiếp cận liên quan.

Công trình	Phương pháp	Vật lý	Không nhãn	Ghi chú
Severson 2019 [22]	đặc trưng xả + hồi quy tuyến tính	không	không	dự đoán tuổi thọ sớm, bộ MIT
Richardson 2017 [20]	hồi quy Gauss	không	không	có độ bất định
Roman 2021 [21]	quy trình học máy	không	không	so sánh nhiều mô hình
Zhu 2022 [29]	điện áp hồi phục + học máy	không	không	bộ TJU
Ma 2022 [15]	học chuyển giao sâu	không	một phần	bộ HUST
Raissi 2019 [18]	PINN tổng quát	có	có	phương trình đã biết
Wang 2024 [25]	PINN, động học hộp đen	có	không	cùng bốn bộ dữ liệu
Đồ án	PINN bán giám sát, động học xám	có	có	loss vật lý không dùng nhãn

Từ các công trình trên có thể rút ra ba khoảng trống. Thứ nhất, các mô hình học có nhãn phụ thuộc mạnh vào lượng nhãn, trong khi dữ liệu sạc không nhãn hầu như chưa được khai thác. Thứ hai, các PINN cho pin hiện có dùng nhãn trong phần vật lý hoặc chỉ áp vật lý lên cell có nhãn, nên vật lý chỉ đóng vai trò chuẩn hoá chứ không thay được nhãn. Thứ ba, kết quả công bố thường dựa trên một cách chia duy nhất, ít khi kiểm định thống kê và ít khi kiểm tra rò rỉ. Đồ án nhắm vào cả ba điểm này.

CHƯƠNG 3

Dữ liệu

3.1 Nguồn dữ liệu

Đồ án dùng bốn bộ dữ liệu lão hoá pin công khai. Tất cả là cell hình trụ 18650 được sạc–xả lặp lại trong phòng thí nghiệm cho tới khi dung lượng giảm sâu.

- **XJTU** — Đại học Giao thông Tây An, công bố cùng PINN4SOH [25]: 55 cell NCM, dung lượng danh định 2,0 Ah, sáu chế độ thí nghiệm (sạc 2C, sạc 3C, xả ngẫu nhiên R2.5 và R3, bước ngẫu nhiên RW, mô phỏng quỹ đạo vệ tinh) ở nhiệt độ phòng.
- **TJU** — Zhu và cộng sự [29]: 130 cell thuộc ba nhóm hoá học (NCA, NCM và hỗn hợp NCM+NCA), thử ở 25, 35 và 45 °C với nhiều tốc độ sạc, tạo thành chín nhóm điều kiện.
- **MIT** — Severson và cộng sự [22]: cell LFP/graphite 1,1 Ah, nhiều giao thức sạc nhanh khác nhau, chia thành ba đợt thí nghiệm, buồng nhiệt 30 °C.
- **HUST** — Ma và cộng sự [15]: 77 cell LFP/graphite 1,1 Ah, cùng chế độ sạc nhanh và 77 chế độ xả nhiều bước khác nhau, 30 °C.

Đặc trưng đoạn sạc của cả bốn bộ được trích theo cùng một quy trình và công bố kèm PINN4SOH [25]; nhờ vậy bốn bộ có chung không gian đặc trưng và có thể thử chuyển miền giữa chúng.

3.2 Đặc trưng đầu vào

Mỗi chu kỳ được mô tả bằng 16 đặc trưng thống kê của đoạn sạc CC–CV:

- điện áp trong pha dòng không đổi: trung bình, độ lệch chuẩn, độ nhọn, độ lệch, độ dốc, entropy;
- dòng điện trong pha áp không đổi: trung bình, độ lệch chuẩn, độ nhọn, độ lệch, độ dốc, entropy;
- điện lượng nạp và thời gian của pha CC và của pha CV.

Ngoài 16 đặc trưng, mô hình nhận thêm biến thời gian $t_n = n/1000$, với n là chỉ số chu kỳ gốc. Hằng số 1000 dùng chung cho mọi cell; không chuẩn hoá theo tuổi thọ riêng của từng cell, vì làm vậy sẽ đưa thông tin tương lai vào đầu vào (Mục 5.10).

3.3 Tiền xử lý

Nhãn. $y_{c,n} = Q_{c,n}/Q_{\text{danh định}}$ với dung lượng danh định của từng bộ ở Bảng 3.1. Chu kỳ thiếu dung lượng được giữ lại với nhãn trống và chỉ dùng cho loss vật lý.

Lọc ngoại lai nhân quả. Chu kỳ n bị loại nếu có đặc trưng không hữu hạn, hoặc nếu có đặc trưng lệch xa so với 50 chu kỳ liền trước của chính cell đó. Với đặc trưng thứ j:

$$m_{n,j} = \text{median}(x_{n-50..n-1,j}), \quad s_{n,j} = \max\Big(\frac{\text{IQR}(x_{n-50..n-1,j})}{1{,}349},\, 0{,}01\,|m_{n,j}|\Big), \quad z_{n,j} = \frac{|x_{n,j} - m_{n,j}|}{s_{n,j}}, \tag{3.1}$$

và chu kỳ bị loại nếu $\max_j z_{n,j} > 5$ (cần ít nhất 10 chu kỳ lịch sử). Hệ số 1,349 đổi khoảng tứ phân vị sang độ lệch chuẩn của phân phối chuẩn; ngưỡng 5 được chọn trước khi huấn luyện để tỉ lệ chu kỳ bị loại (1,6 %) tương đương bộ lọc 3σ dùng cả vòng đời (2,2 %). Sau lọc còn 305.802 chu kỳ.

Chuẩn hoá. Mỗi đặc trưng được chuẩn hoá z-score bằng trung bình μ và độ lệch chuẩn σ tính trên đặc trưng của các cell huấn luyện (cả có nhãn và không nhãn): $\tilde{\mathbf{x}} = (\mathbf{x} - \mu)/(\sigma + 10^{-6})$.

3.4 Thống kê mô tả

Bảng 3.1. Thống kê bốn bộ dữ liệu sau tiền xử lý. "Nhóm" là số chế độ thí nghiệm khác nhau dùng để phân tầng.

Bộ	Hoá học	Cell	Chu kỳ	Nhóm	Tuổi thọ (min / trung vị / max)	SOH đầu	SOH cuối	$Q_{\text{đđ}}$ (Ah)
XJTU	NCM	55	22.431	6	110 / 392 / 942	0,83–1,00	0,78–0,89	2,0
TJU	NCA/NCM	130	56.697	9	25 / 377 / 1.246	0,88–0,98	0,66–0,90	3,5 / 2,5
MIT	LFP	125	82.450	3	36 / 622 / 2.156	0,95–1,00	0,82–0,97	1,1
HUST	LFP	77	144.224	1	1.123 / 1.855 / 2.672	1,06–1,12	0,80–0,82	1,1
Tổng		387	305.802					

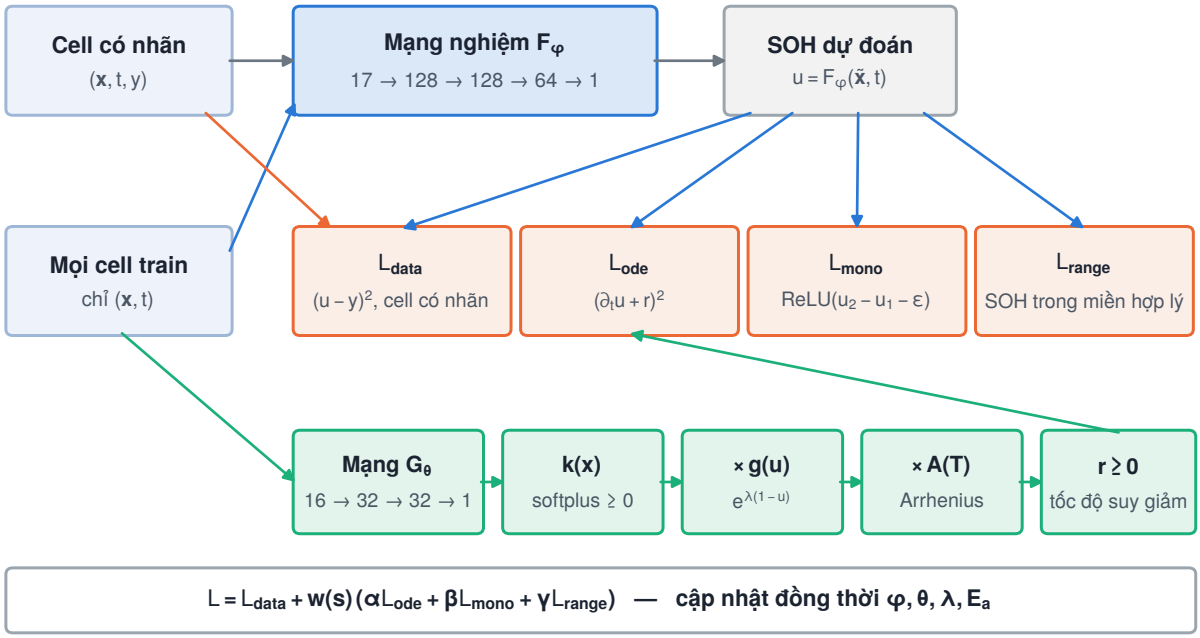
Bốn bộ khác nhau rõ rệt về hoá học, tuổi thọ và mức đa dạng điều kiện vận hành. XJTU và TJU (họ niken) có tuổi thọ ngắn và nhiều chế độ; MIT và HUST (LFP) có tuổi thọ dài hơn nhiều. SOH đầu đời của HUST lớn hơn 1 do dung lượng thực tế của cell mới cao hơn dung lượng danh định. TJU là bộ duy nhất có nhiều mức nhiệt độ, nên cũng là bộ duy nhất mà hệ số Arrhenius có thể học được (Mục 6.9).

CHƯƠNG 4

Phương pháp

4.1 Tổng quan

Mô hình gồm hai mạng nối với nhau qua hàm mất mát (Hình 4.1). Mạng nghiệm F_φ dự đoán SOH; mạng tốc độ G_θ cùng hai tham số vật lý λ, E_a mô tả tốc độ suy giảm. Khi suy luận chỉ cần F_φ.



Hình 4.1. Kiến trúc mô hình: mạng nghiệm dự đoán SOH, mạng tốc độ mô tả động học suy giảm; hai mạng gắn với nhau qua các hàm mất mát vật lý.

4.2 Mạng nghiệm

$$u = F_\varphi(\tilde{\mathbf{x}}, t), \qquad F_\varphi : \mathbb{R}^{17} \to \mathbb{R}, \tag{4.1}$$

là perceptron nhiều lớp 17–128–128–64–1 với hàm kích hoạt SiLU.

4.3 Động học suy giảm dạng xám

$$r(\tilde{\mathbf{x}}, u, T) = \underbrace{\operatorname{softplus}\left(G_\theta(\tilde{\mathbf{x}})\right)}_{k(\mathbf{x})} \underbrace{e^{\lambda\ \operatorname{clip}(1-u,\,-0{,}5,\,1)}}_{g(u)} \underbrace{e^{-\frac{E_a}{R_g}\left(\frac{1}{T}-\frac{1}{T_{\text{ref}}}\right)}}_{A(T)}, \tag{4.2}$$

với G_θ là perceptron 16–32–32–1, $\lambda = \operatorname{softplus}(\lambda_{\text{raw}})$, $E_a = 10^4 \operatorname{softplus}(e_{\text{raw}})$ J/mol, $R_g = 8{,}314$ J/(mol·K), $T_{\text{ref}} = 298{,}15$ K. Thừa số k là tốc độ cơ sở phụ thuộc trạng thái điện hoá (thể hiện qua đặc trưng sạc), g làm suy giảm tăng nhanh khi SOH thấp (hiện tượng đầu gối), A là hệ số Arrhenius. Phương trình mà mạng nghiệm phải thoả:

$$\frac{\partial u}{\partial t} = -\,r(\tilde{\mathbf{x}}, u, T). \tag{4.3}$$

4.4 Hàm mất mát

Với cặp chu kỳ (n_1, n_2) của cùng một cell, $n_2 \geq n_1 + h$, $h \sim \mathcal{U}\{5, \ldots, 50\}$, ký hiệu $u_i = F_\varphi(\tilde{\mathbf{x}}_{n_i}, t_{n_i})$:

$$\mathcal{L}_{\text{data}} = \frac{1}{B}\sum (u - y)^2 \qquad \text{(chỉ chu kỳ có nhãn)}, \tag{4.4}$$

$$\mathcal{L}_{\text{ode}} = \frac{1}{B}\sum \left(\partial_t u_1 + r(\tilde{\mathbf{x}}_{n_1}, u_1, T)\right)^2, \tag{4.5}$$

$$\mathcal{L}_{\text{mono}} = \frac{1}{B}\sum \operatorname{ReLU}(u_2 - u_1 - \varepsilon), \qquad \varepsilon = 0{,}002, \tag{4.6}$$

$$\mathcal{L}_{\text{range}} = \frac{1}{B}\sum \big[\operatorname{ReLU}(u_1 - 1{,}15) + \operatorname{ReLU}(0{,}4 - u_1) + \mathbb{1}_{\text{đầu}}\big(\operatorname{ReLU}(u_1 - 1{,}10) + \operatorname{ReLU}(0{,}85 - u_1)\big)\big], \tag{4.7}$$

$$\mathcal{L} = \mathcal{L}_{\text{data}} + w(s)\left(\alpha\mathcal{L}_{\text{ode}} + \beta\mathcal{L}_{\text{mono}} + \gamma\mathcal{L}_{\text{range}}\right), \qquad w(s) = \min\left(1, s/(0{,}2S)\right), \tag{4.8}$$

với $\alpha = 0{,}02$, $\beta = 0{,}5$, $\gamma = 1$, $S = 4000$ bước. $\mathbb{1}_{\text{đầu}} = 1$ nếu n_1 là chu kỳ đầu của cell. Đạo hàm $\partial_t u$ tính bằng vi phân tự động.

4.5 Cơ chế bán giám sát

PINN-semi lấy một nửa số cặp chu kỳ từ cell có nhãn và một nửa từ cell không nhãn. Ba loss vật lý không chứa y (Mệnh đề 4.2), nên gradient của chúng theo φ trên cell không nhãn là tín hiệu học thật sự: mạng nghiệm bị buộc phải cho quỹ đạo hợp lý vật lý trên chính những cell mà nó sẽ phải tổng quát tới.

4.6 Phần vật lý nằm ở đâu

Mạng nghiệm F_φ tự nó là một perceptron nhiều lớp bình thường, giống hệt MLP đối chứng. Điều làm mô hình trở thành PINN nằm ở hàm mất mát và ở các điểm mà hàm mất mát được tính, không nằm ở kiến trúc mạng hay ở bước suy luận. Vật lý ở đây là vật lý ở mức hiện tượng: những quy luật định tính đã biết về lão hoá pin (dung lượng không tự hồi phục, suy giảm nhanh dần khi pin già, phản ứng phụ tăng theo nhiệt độ), được viết thành phương trình và bất đẳng thức. Đồ án không giải mô hình điện hoá chi tiết (P2D, mô hình hạt đơn) và không mô hình hoá đặc trưng sạc bằng phương trình nào. Bảng 4.1 nối từng hiểu biết vật lý với thành phần tương ứng.

Bảng 4.1. Hiểu biết vật lý và thành phần mô hình tương ứng.

Hiểu biết vật lý	Biểu diễn	Tác động vào đâu	Cần nhãn
Dung lượng không tăng theo thời gian vận hành	$\partial u/\partial t = -r, r \geq 0$	đạo hàm riêng $\partial F_\varphi/\partial t$ tại điểm $(\tilde{\mathbf{x}}_{n_1}, t_{n_1})$, qua $\mathscr{L}_{\text{ode}}$	không
Quỹ đạo SOH thực tế không tăng (cho phép hồi phục nhỏ ε)	$u_2 \leq u_1 + \varepsilon$	cặp chu kỳ (n_1, n_2) thật của cùng cell, qua $\mathscr{L}_{\text{mono}}$	không
Suy giảm nhanh dần khi pin già (đầu gối)	$g(u) = e^{\lambda(1-u)}$	thừa số trong r	không
Phản ứng phụ tăng theo nhiệt độ	$A(T)$ dạng Arrhenius	thừa số trong r	không
SOH nằm trong miền hợp lý, cell mới gần 1	các hàm ReLU chặn	giá trị u_1, qua $\mathscr{L}_{\text{range}}$	không
Dung lượng đo được	$(u - y)^2$	chu kỳ có nhãn, qua $\mathscr{L}_{\text{data}}$	có

Có ba điểm cần phân biệt. Thứ nhất, các ràng buộc được tính tại *điểm collocation*: mọi chu kỳ của mọi cell train, kể cả cell chưa đo dung lượng, ghép thành cặp (n_1, n_2); đây là chỗ dữ liệu không nhãn đi vào mô hình. Thứ hai, $\mathscr{L}_{\text{ode}}$ ràng buộc đạo hàm riêng theo t khi giữ nguyên đặc trưng sạc, còn $\mathscr{L}_{\text{mono}}$ ràng buộc tổng biến thiên dọc quỹ đạo thật, nơi cả $\mathbf{x}$ lẫn t cùng đổi; hai ràng buộc này tác động vào hai hướng khác nhau của hàm F_φ, và Mục 6.10 đo riêng từng hướng. Thứ ba, khi suy luận chỉ dùng F_φ: vật lý định hình hàm được học, chứ không tham gia vào việc tính dự đoán.

4.7 Tính chất của mô hình

Mệnh đề 4.1 (Tốc độ suy giảm không âm)**.** *Với mọi tham số θ, λ_{raw}, e_{raw} và mọi $(\tilde{\mathbf{x}}, u, T)$, $T > 0$: $r(\tilde{\mathbf{x}}, u, T) \geq 0$. Do đó mọi nghiệm của (4.3) không tăng theo t.*

Chứng minh. $\mathrm{softplus}(z) = \ln(1 + e^z) > 0$ với mọi z thực vì $1 + e^z > 1$. Hai thừa số còn lại là hàm mũ của số thực nên dương. Tích của ba số dương là dương; trong số học dấu phẩy động, softplus có thể tràn dưới về 0 nên phát biểu đúng là $r \geq 0$. Khi đó $\partial u/\partial t = -r \leq 0$. □

Mệnh đề 4.2 (Loss vật lý không dùng nhãn)**.** *$\mathscr{L}_{ode}$, $\mathscr{L}_{mono}$, $\mathscr{L}_{range}$ chỉ phụ thuộc đặc trưng và thời điểm của cặp chu kỳ ($\tilde{\mathbf{x}}_{n_i}$, t_{n_i}), nhiệt độ T và tham số $(\varphi, \theta, \lambda, E_a)$; không phụ thuộc y. Vì vậy chúng tính được trên mọi cell chỉ có dữ liệu sạc.*

Chứng minh. Trực tiếp từ định nghĩa: không biểu thức nào chứa y; $\partial_t u_1$ là đạo hàm của F_φ theo đầu vào t, không qua nhãn. □

Mệnh đề 4.3 (Tập không của loss đơn điệu)**.** *$\mathscr{L}_{mono} = 0$ khi và chỉ khi $u_2 \leq u_1 + \varepsilon$ với mọi cặp trong batch; khi vi phạm, gradient theo $u_2 - u_1$ bằng $1/B$ cho mỗi cặp vi phạm, không phụ thuộc mức vi phạm.*

Chứng minh. $\mathrm{ReLU}(z) \geq 0$ và bằng 0 khi và chỉ khi $z \leq 0$, nên tổng các số hạng không âm bằng 0 khi và chỉ khi từng số hạng bằng 0. Đạo hàm của ReLU bằng 1 trên $z > 0$. □

Mệnh đề 4.4 (Dạng tích phân của phần dư)**.** *Nếu u thoả (4.3) dọc một quỹ đạo và r khả vi liên tục theo t trên $[t_1, t_2]$, thì phần dư dạng Euler $\rho = u_2 - u_1 + r_1 \Delta t$ thoả $|\rho| \leq \frac{1}{2} \max |\dot{r}| \, \Delta t^2$.*

Chứng minh. $u_2 - u_1 = -\int_{t_1}^{t_2} r(s)\, ds = -r_1 \Delta t - \int_{t_1}^{t_2} (r(s) - r_1)\, ds$, và $|r(s) - r_1| \leq \max |\dot{r}| \, (s - t_1)$. Lấy tích phân được cận $\frac{1}{2} \max |\dot{r}| \Delta t^2$. □

Mệnh đề 4.4 cho thấy dạng Euler dọc quỹ đạo và dạng đạo hàm riêng $\partial_t u$ là hai ràng buộc khác nhau: dạng thứ nhất ràng buộc tổng biến thiên dọc chuỗi chu kỳ thực (khi đặc trưng $\mathbf{x}$ cũng thay đổi), dạng thứ hai ràng buộc đạo hàm theo t khi giữ $\mathbf{x}$ cố định. Cả hai được so sánh ở Chương 6.

4.8 Các mô hình đối chứng

Mọi mô hình dùng cùng đầu vào $[\tilde{\mathbf{x}}, t]$, cùng cách chia, cùng tập cell có nhãn và cùng normaliser.

Bảng 4.2. Các mô hình được so sánh.

Mô hình	Nhóm	Mô tả
Ridge	học có nhãn	hồi quy tuyến tính chuẩn hoá L2; $\alpha \in \{10^{-3}, \dots, 10^{3}\}$ chọn theo validation
GPR	học có nhãn	hồi quy Gauss [19], nhân RBF + nhiễu trắng, 1 500 điểm có nhãn chọn ngẫu nhiên
GBDT	học có nhãn	gradient boosting trên cây [9], dạng histogram [13]; số cây chọn theo validation
MLP	học có nhãn	cùng kiến trúc với mạng nghiệm, chỉ $\mathscr{L}_{\text{data}}$
PINN-sup	vật lý trên cell có nhãn	như PINN-semi nhưng loss vật lý chỉ tính trên cell có nhãn
PINN hộp đen	vật lý, bán giám sát	động học dạng PINN4SOH [25]: $u_t = G(\mathbf{x}, t, u, u_{\mathbf{x}}, u_t)$, cùng loss không nhãn
PINN-semi	vật lý, bán giám sát	mô hình đề xuất

Hai biến thể cắt bỏ dùng để tách nguồn gốc lợi ích: *chỉ đơn điệu* ($\alpha = \gamma = 0$) và *PINN-semi dạng Euler* (dùng phần dư dọc quỹ đạo thay cho $\partial_t u$, $\alpha = 2$).

4.9 Cấu hình huấn luyện

Bảng 4.3. Cấu hình huấn luyện chung cho MLP và các biến thể PINN.

Thành phần	Giá trị
Bộ tối ưu	AdamW [14], tốc độ học $2 \cdot 10^{-3}$, weight decay 10^{-5}
Lịch tốc độ học	cosine, giảm về 10^{-4} trong 4 000 bước
Batch	512 điểm có nhãn; 512 cặp chu kỳ cho loss vật lý
Cắt gradient	chuẩn $L_2 \le 5$
Dừng sớm	MAE trên validation mỗi 100 bước, dừng sau 12 lần không cải thiện, giữ trọng số tốt nhất

Trọng số vật lý (α, β) và dạng phần dư được chọn trước theo MAE validation ở một thí nghiệm sơ bộ và giữ cố định trong toàn bộ các thí nghiệm của báo cáo; không có siêu tham số nào được chọn theo tập test.

CHƯƠNG 5

Thiết kế thí nghiệm và giao thức đánh giá

Chương này trả lời ba câu hỏi về cách đánh giá: chia dữ liệu theo đơn vị nào và thành bao nhiêu phần, vì sao chọn đúng các con số đó, và làm sao bảo đảm không có thông tin của tập test lọt vào quá trình huấn luyện, kể cả khi chuyển mô hình từ bộ dữ liệu này sang bộ khác.

5.1 Các yêu cầu đối với giao thức

Y1. *Không rò rỉ*: mô hình và mọi bước tiền xử lý không được dùng bất kỳ thông tin nào của cell test.

Y2. *Phủ hết dữ liệu*: mỗi cell đều phải được dùng làm test, để kết quả không phụ thuộc vào việc chọn may rủi một nhóm cell test.

Y3. *Phủ hết điều kiện thí nghiệm*: mỗi fold phải có cell của mọi chế độ thí nghiệm, để không có fold nào chỉ kiểm tra trên một chế độ lạ.

Y4. *Đủ nhãn ở mức thấp nhất*: ở 10 % nhãn, bộ nhỏ nhất (XJTU, 55 cell) vẫn phải có vài cell có nhãn.

Y5. *Đủ cell validation* để dừng sớm và chọn siêu tham số ổn định.

Y6. *Đủ chỗ cho mức nhãn cao nhất*: tập train phải chứa được 70 % số cell có nhãn.

Y7. *Ước lượng ổn định*: đủ số lần lặp để kết quả không phụ thuộc một cách xáo ngẫu nhiên.

Y8. *Ghép cặp*: mọi mô hình dùng đúng cùng các tập cell, để so sánh được theo từng cell.

5.2 Đơn vị chia: cell, không phải chu kỳ

Các chu kỳ liên tiếp của một cell gần như giống nhau: SOH chỉ thay đổi rất ít giữa hai chu kỳ kề nhau. Nếu chia ngẫu nhiên theo chu kỳ, gần như mọi chu kỳ test đều có một chu kỳ "hàng xóm" trong tập train, và bài toán suy biến thành nội suy dọc một quỹ đạo đã biết nhãn.

Mệnh đề 5.1 (Cận sai số khi chia theo chu kỳ)**.** *Giả sử mỗi chu kỳ được đưa vào train độc lập với xác suất q. Xét bộ dự đoán không dùng đặc trưng nào, chỉ chép nhãn của chu kỳ train gần nhất trong cùng cell. Khi bỏ qua hiệu ứng ở hai đầu cell, khoảng cách d tới chu kỳ train gần nhất thoả*

$$\mathbb{E}[d] = \frac{1}{1-(1-q)^2}, \tag{5.1}$$

và sai số tuyệt đối kỳ vọng không vượt quá $\mathbb{E}[d] \cdot \overline{|\Delta y|}$*, với* $\overline{|\Delta y|}$ *là biến thiên nhãn trung bình giữa hai chu kỳ liền kề.*

Chứng minh. $d > j$ khi và chỉ khi $2j$ chu kỳ ở khoảng cách $1, \dots, j$ về hai phía đều không thuộc train, xác suất $(1-q)^{2j}$. Vì d nhận giá trị nguyên dương, $\mathbb{E}[d] = \sum_{j\geq 0} P(d > j) = \sum_j (1-q)^{2j} = 1/(1-(1-q)^2)$. Gọi $n^* = n + sd$, $s \in \{-1, +1\}$, là chu kỳ train gần nhất. Theo bất đẳng thức tam giác, $|y_n - y_{n^*}| \leq \sum_{i=0}^{d-1} |\Delta y_{n+si}|$, với $\Delta y_m = y_{m+s} - y_m$. Lấy kỳ vọng theo cách chia và theo vị trí n của chu kỳ test, phân bố đều trên cell:

$$\mathbb{E}\Big[\sum_{i=0}^{d-1} |\Delta y_{n+si}|\Big] = \sum_{i\geq 0} \mathbb{E}\big[\mathbb{1}\{d > i\}\, |\Delta y_{n+si}|\big] = \sum_{i\geq 0} P(d > i)\, \overline{|\Delta y|} = \mathbb{E}[d] \cdot \overline{|\Delta y|},$$

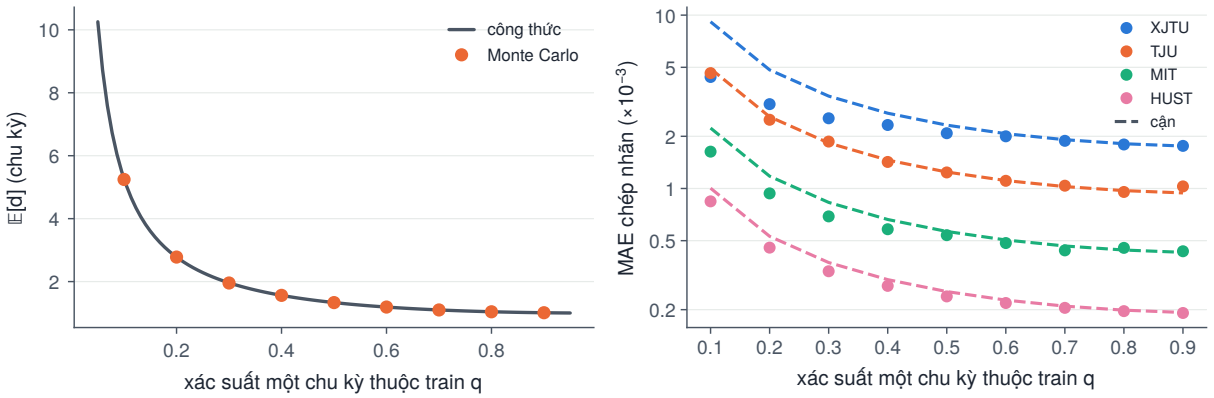
vì sự kiện $\{d > i\}$ chỉ phụ thuộc cách chia nên độc lập với n, và khi n phân bố đều (bỏ qua hai đầu cell) thì $\mathbb{E}_n|\Delta y_{n+si}| = \overline{|\Delta y|}$ với mọi i. □

Với $q = 0{,}7$, $\mathbb{E}[d] = 1{,}099$ chu kỳ. Bảng 5.1 so sánh cận này với sai số đo được: bộ chép nhãn không học gì vẫn đạt sai số nhỏ hơn mô hình thật nhiều lần, và khớp với cận lý thuyết. Một mô hình được đánh giá theo cách chia này vì vậy có thể đạt kết quả rất tốt chỉ bằng cách nhớ quỹ đạo, không phải bằng cách học quan hệ giữa đặc trưng sạc và SOH. Đơn vị chia của đồ án là cell: mọi chu kỳ của một cell nằm trọn trong train, validation hoặc test.

Bảng 5.1. Sai số của phép "dự đoán" chỉ chép nhãn của chu kỳ train gần nhất trong cùng cell khi chia theo chu kỳ, so với cận của Mệnh đề 5.1 và với sai số thật khi chia theo cell (MAE theo cell, $\times 10^{-3}$).

Bộ	$\overline{\lvert\Delta y\rvert}$ ($\times 10^{-3}$)	Cận $\mathbb{E}[d]\,\overline{\lvert\Delta y\rvert}$	Nội suy, đo được	MLP, chia theo cell
XJTU	1,74	1,91	1,82	13,11
TJU	0,93	1,03	0,99	9,86
MIT	0,42	0,47	0,43	2,80
HUST	0,19	0,21	0,20	17,46

Để kiểm tra mệnh đề trên toàn bộ dải q, đồ án mô phỏng hai lần (Hình 5.1). Thứ nhất, gán ngẫu nhiên 10^6 vị trí vào train với xác suất q và đo khoảng cách trung bình tới vị trí train gần nhất: kết quả Monte Carlo lệch công thức (5.1) không quá 0,3 %. Thứ hai, áp phép chép nhãn lên quỹ đạo SOH thật của cả 387 cell với q từ 0,1 tới 0,9: 35 trong 36 điểm nằm dưới hoặc trong khoảng 5 % quanh cận; các điểm vượt nhẹ đến từ hai đầu cell, nơi chu kỳ train gần nhất chỉ có ở một phía. Ở mọi $q \geq 0{,}5$, sai số chép nhãn nhỏ hơn MLP được đánh giá đúng cách từ 5 lần trở lên.



Hình 5.1. Mô phỏng chia theo chu kỳ. Trái: khoảng cách trung bình tới chu kỳ train gần nhất theo q. Phải: sai số của phép chép nhãn trên quỹ đạo SOH thật (điểm) so với cận $\mathbb{E}[d] \cdot \overline{|\Delta y|}$ (nét đứt); trục dọc thang log.

5.3 Chọn số fold K

Mỗi fold gồm ba phần: test $1/K$, validation v, train $1 - 1/K - v$. Yêu cầu Y6 buộc train chứa được $f_{\max} = 70\,\%$ số cell.

Mệnh đề 5.2 (Số fold nhỏ nhất)**.** *Điều kiện* $1 - 1/K - v \geq f_{\max}$ *tương đương* $K \geq 1/(1 - v - f_{\max})$. *Với* $v = 0{,}10$ *và* $f_{\max} = 0{,}70$*, số fold nhỏ nhất là* $K = 5$.

Chứng minh. Biến đổi tương đương: $1 - v - f_{\max} \geq 1/K \Leftrightarrow K \geq 1/(1 - v - f_{\max}) = 1/0{,}2 = 5$. □

Trong các giá trị khả thi ($K \geq 5$), $K = 5$ được chọn vì ba lý do. Một là mỗi fold có nhiều cell test nhất (XJTU: 11 cell), nên MAE của từng fold ổn định hơn. Hai là chi phí tính toán nhỏ nhất: số lượt huấn luyện tỉ lệ với K. Ba là tỉ lệ train 70 % trùng với giao thức 70/15/15 thường dùng trong các công trình trước, nên mức 70 % nhãn ở đây tương ứng với trường hợp "dùng hết nhãn" của các công trình đó. $K = 10$ cũng khả thi nhưng chỉ còn 5–6 cell test mỗi fold ở XJTU và gấp đôi chi phí; kiểm định chéo bỏ-một-cell cần tới 55–130 lượt cho mỗi cấu hình. Bảng 5.2 tóm tắt các lựa chọn.

Bảng 5.2. Khả thi của số fold K với validation 10 % và mức nhãn cao nhất 70 % số cell (số lượt tính với 5 lần lặp).

Bộ	K	Train (cell)	Val	Test/fold	70 % nhãn	Lượt/mô hình/mức
XJTU	3	30 (55 %)	6	18–19	không	15
	4	35 (64 %)	6	13–14	không	20
	5	38 (69 %)	6	11	đạt	25
	10	43 (78 %)	6	5–6	đạt	50
TJU	3	73 (56 %)	13	43–44	không	15
	4	84 (65 %)	13	32–33	không	20
	5	91 (70 %)	13	26	đạt	25
	10	104 (80 %)	13	13	đạt	50
MIT	3	71 (57 %)	12	41–42	không	15
	4	81 (65 %)	12	31–32	không	20
	5	88 (70 %)	12	25	đạt	25
	10	100 (80 %)	12	12–13	đạt	50
HUST	3	43 (56 %)	8	25–26	không	15
	4	49 (64 %)	8	19–20	không	20
	5	53 (69 %)	8	15–16	đạt	25
	10	61 (79 %)	8	7–8	đạt	50

5.4 Chọn tỉ lệ validation

Validation dùng để dừng sớm và chọn siêu tham số của các đối chứng (Ridge, GBDT). Bảng 5.3 cho thấy đánh đổi: $v = 5$ % chỉ còn 3 cell validation ở XJTU, quá ít để dừng sớm ổn định; $v = 15$ % buộc $K \geq 7$ (Mệnh đề 5.2), mỗi fold XJTU chỉ còn khoảng 8 cell test và chi phí tăng 40 %. $v = 10$ % là điểm cân bằng: 6 cell validation ở bộ nhỏ nhất và vẫn giữ được $K = 5$. Cần lưu ý cell validation có nhãn và nằm ngoài "ngân sách nhãn" của các mức 10–70 %; điều này giống nhau cho mọi mô hình.

Bảng 5.3. Đánh đổi khi chọn tỉ lệ validation (mức nhãn cao nhất 70 %, 5 lần lặp).

Validation v	$K_{\min}$	Val (cell XJTU)	Test/fold XJTU	Lượt/mô hình/mức
5 %	4	3	13,8	20
10 %	5	6	11,0	25
15 %	7	8	7,9	35
20 %	10	11	5,5	50

5.5 Phân tầng theo chế độ thí nghiệm

Các cell trong cùng một bộ được thử ở nhiều chế độ khác nhau (Bảng 3.1). Nếu chia hoàn toàn ngẫu nhiên, có thể một fold không có cell nào của một chế độ, trong khi fold khác lại toàn cell của chế độ đó. Thuật toán chia dùng bộ đếm chạy liên tục qua các nhóm:

1. Xáo thứ tự cell trong từng nhóm (với hạt giống của lần lặp r); chọn ngẫu nhiên điểm bắt đầu k_0.
2. Duyệt các nhóm theo thứ tự cố định; cell thứ i trong thứ tự duyệt toàn cục được gán vào fold $(k_0 + i) \bmod K$.
3. Ở fold k: test là các cell thuộc fold k; từ phần còn lại lấy $\mathrm{round}(vN)$ cell làm validation theo vòng tròn qua các nhóm; phần còn lại là train.
4. Ở mức nhãn f: lấy $\mathrm{round}(fN)$ cell train làm cell có nhãn theo một thứ tự vòng tròn cố định qua các nhóm; các cell train còn lại là cell không nhãn.

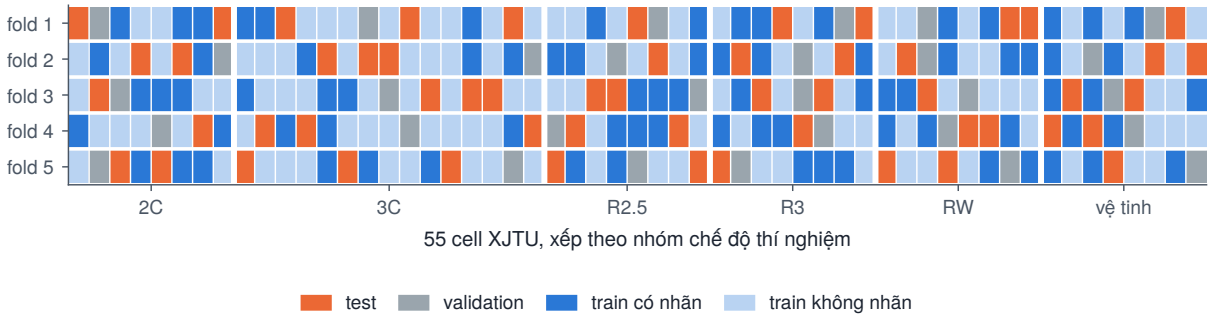
Mệnh đề 5.3 (Phân hoạch và cân bằng)**.** *Với mỗi lần lặp: (i) các tập test của K fold rời nhau và hợp lại bằng toàn bộ $\mathscr{C}$, nên mỗi cell được test đúng một lần; (ii) số cell test của hai fold bất kỳ lệch nhau không quá 1; (iii) trong mỗi nhóm thí nghiệm b có n_b cell, số cell của nhóm trong mỗi fold bằng $\lfloor n_b/K \rfloor$ hoặc $\lceil n_b/K \rceil$.*

Chứng minh. (i) Mỗi cell nhận đúng một chỉ số fold, nên các tập test là các lớp tương đương của ánh xạ gán fold. (ii) Chỉ số i chạy từ 0 tới $N-1$; trong N số nguyên liên tiếp, số phần tử có cùng số dư modulo K bằng $\lfloor N/K \rfloor$ hoặc $\lceil N/K \rceil$. (iii) Các cell của nhóm b chiếm n_b chỉ số liên tiếp trong thứ tự duyệt, nên lập luận của (ii) áp dụng với n_b thay cho N. □

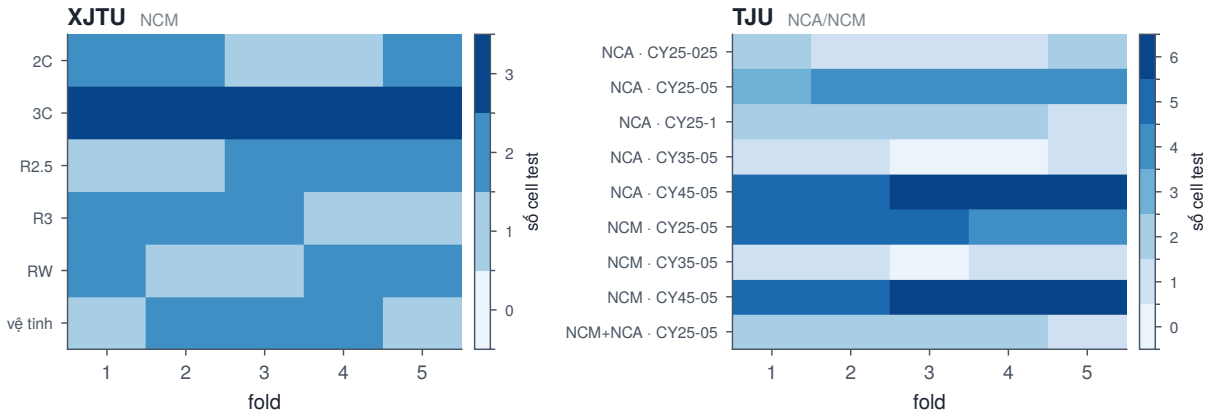
Mệnh đề 5.4 (Tập có nhãn lồng nhau)**.** *Với cùng fold và lần lặp, nếu $f_1 < f_2$ thì tập cell có nhãn ở mức f_1 là tập con của tập ở mức f_2.*

Chứng minh. Thứ tự vòng tròn ở bước 4 chỉ phụ thuộc hạt giống, không phụ thuộc f; tập có nhãn là $\mathrm{round}(fN)$ phần tử đầu của cùng một thứ tự, và $\mathrm{round}(f_1 N) \le \mathrm{round}(f_2 N)$. □

Mệnh đề 5.4 bảo đảm rằng khi tăng mức nhãn, khác biệt duy nhất là có thêm nhãn; đường cong theo lượng nhãn vì vậy không bị lẫn với việc đổi sang một nhóm cell khác. Kiểm tra trên cả 5 lần lặp của 4 bộ dữ liệu cho thấy mọi cell đều được test đúng một lần ở mỗi lần lặp và số cell của một nhóm trong các fold lệch nhau không quá 1, đúng như Mệnh đề 5.3. Hình 5.2 minh hoạ cách chia thật của XJTU và Hình 5.3 là số cell test của từng nhóm trong từng fold.



Hình 5.2. Cách chia thật của bộ XJTU ở lần lặp đầu tiên, mức 30 % nhãn. Mỗi cột là một cell, mỗi hàng là một fold; cell được xếp theo nhóm chế độ thí nghiệm.



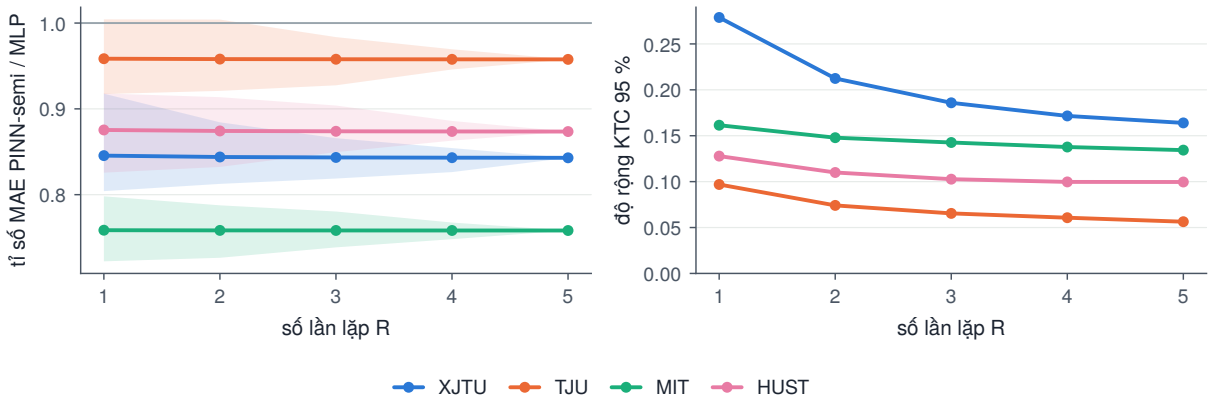
Hình 5.3. Số cell test của từng nhóm thí nghiệm trong từng fold (lần lặp đầu tiên).

5.6 Chọn số lần lặp R

Một lần kiểm định chéo cho mỗi cell đúng một dự đoán, nên kết quả vẫn phụ thuộc một cách xáo ngẫu nhiên. Lặp lại với R cách xáo khác nhau cho mỗi cell R dự đoán từ R mô hình khác nhau; sai số của cell được lấy trung bình qua các lần lặp. Để chọn R, đồ án mô phỏng lấy lại trên kết quả thật: với mỗi $R' \in \{1, \dots, 5\}$, lấy mọi tổ hợp R' trong 5 lần lặp, tính lại tỉ số MAE giữa PINN-semi và MLP ở 30 % nhãn (Bảng 5.4, Hình 5.4).

Bảng 5.4. Mô phỏng lấy lại theo số lần lặp: tỉ số MAE PINN-semi/MLP ở 30 % nhãn. SD là độ lệch chuẩn của ước lượng giữa các tổ hợp lần lặp; KTC là độ rộng khoảng tin cậy 95 % bootstrap theo cell.

Bộ	SD, R=1	SD, R=4	KTC, R=1	KTC, R=5	Dải ước lượng, R=1	Ước lượng, R=5
XJTU	0,039	0,009	0,279	0,164	0,804–0,918	0,843
TJU	0,038	0,010	0,097	0,056	0,917–1,004	0,958
MIT	0,028	0,007	0,161	0,134	0,722–0,798	0,758
HUST	0,037	0,009	0,128	0,100	0,826–0,918	0,874



Hình 5.4. Trái: tỉ số MAE PINN-semi/MLP ở 30 % nhãn theo số lần lặp; đường là trung bình, dải là khoảng nhỏ nhất–lớn nhất giữa các tổ hợp lần lặp. Phải: độ rộng khoảng tin cậy 95 %.

Có hai quan sát. Độ dao động của ước lượng giữa các tổ hợp giảm gần như $1/\sqrt{R}$: một lần lặp duy nhất cho tỉ số dao động trong một dải đủ rộng để đổi kết luận ở XJTU và TJU, còn với 4–5 lần lặp ước lượng gần như cố định. Ngược lại, độ rộng khoảng tin cậy chỉ giảm chậm rồi bão hoà, vì phần còn lại đến từ khác biệt thật giữa các cell, không giảm được bằng cách lặp thêm. $R = 5$ vì vậy là điểm mà thêm lần lặp không còn đổi kết luận, trong khi chi phí (25 lượt cho mỗi mô hình, mỗi mức nhãn, mỗi bộ) vẫn chạy được trên CPU.

5.7 Ghép cặp và hạt giống

Ở fold k của lần lặp r, mọi mô hình dùng chung hạt giống $100r + k$ cho việc chọn cell có nhãn, khởi tạo trọng số và lấy mẫu batch. Mọi mô hình vì vậy thấy đúng cùng cell train, cùng cell có nhãn, cùng cell validation và được đánh giá trên đúng cùng cell test. Nhờ đó so sánh được theo từng cell (Mục 5.12).

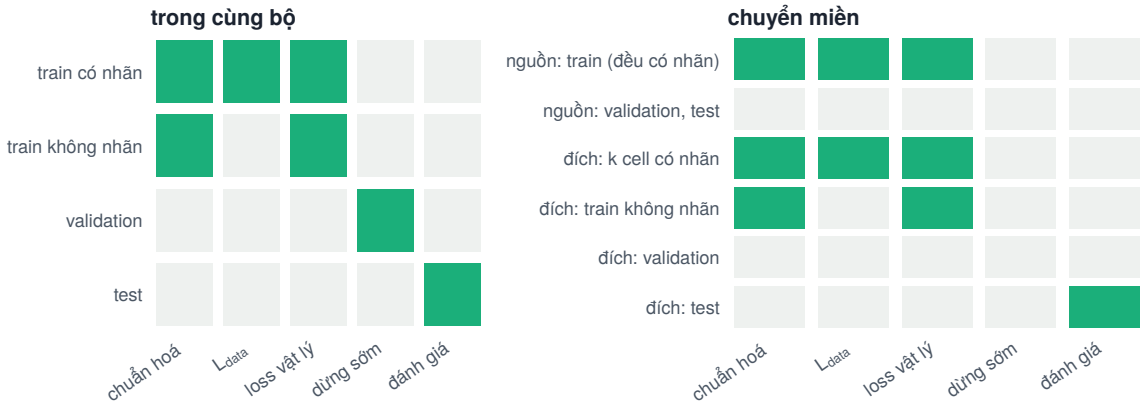
5.8 Quy trình chống rò rỉ trong cùng bộ dữ liệu

Định nghĩa 5.5 (Rò rỉ)**.** Một giao thức bị rò rỉ nếu tham số của mô hình đã huấn luyện, hoặc bất kỳ quyết định tiền xử lý hay chọn mô hình nào, phụ thuộc vào đặc trưng hoặc nhãn của cell test, hoặc vào thông tin không có tại thời điểm dự đoán (chẳng hạn các chu kỳ tương lai của chính cell).

Hình 5.5 liệt kê phần dữ liệu nào được dùng cho bước nào. Bốn quy tắc:

1. Normaliser chỉ fit trên đặc trưng của cell train (có nhãn và không nhãn).
2. Bộ lọc ngoại lai quyết định giữ hay bỏ chu kỳ n chỉ bằng các chu kỳ trước n của chính cell đó.

3. Biến thời gian $t = n/1000$ dùng hằng số chung, không chuẩn hoá theo tuổi thọ từng cell.
4. Dừng sớm và chọn siêu tham số chỉ dựa trên validation; tập test chỉ được dùng một lần để đánh giá.



Hình 5.5. Phần dữ liệu nào được dùng cho bước nào (ô màu: có dùng). Trái: đánh giá trong cùng bộ; phải: chuyển miền. Với MLP, cột loss vật lý không áp dụng.

Mệnh đề 5.6 (Ước lượng không chệch)**.** *Giả sử các cell là mẫu độc lập cùng phân phối từ một tổng thể. Theo bốn quy tắc trên, tham số $\hat{\theta}$ của mô hình là hàm của dữ liệu cell train và cell validation, độc lập với dữ liệu cell test. Khi đó $\mathbb{E}[\mathrm{MAE}_{test} \mid \hat{\theta}]$ bằng sai số kỳ vọng của $\hat{\theta}$ trên một cell mới của tổng thể.*

Chứng minh. Bộ lọc của một cell test chỉ dùng dữ liệu của chính cell đó và không thay đổi khi dữ liệu của cell khác thay đổi; normaliser, các hàm mất mát và tiêu chí dừng sớm không chứa dữ liệu cell test. Do đó $\hat{\theta}$ đo được theo σ-đại số sinh bởi dữ liệu train và validation. Vì các cell độc lập, dữ liệu một cell test c độc lập với $\hat{\theta}$, nên $\mathbb{E}[\mathrm{MAE}_c \mid \hat{\theta}] = \mathbb{E}_{c' \sim \text{tổng thể}}[\mathrm{MAE}_{c'}(\hat{\theta})]$. Lấy trung bình qua các cell test được điều phải chứng minh. □

5.9 Chuyển miền giữa các bộ dữ liệu

Ở thí nghiệm chuyển miền, mô hình học trên bộ nguồn và được đánh giá trên bộ đích. Có hai thiết lập: không có cell đích nào có nhãn ($k = 0$) và có $k = 3$ cell đích có nhãn. Quy trình:

1. Bộ nguồn được chia 70/15/15 theo cell; mọi cell train của bộ nguồn (70 % số cell) đều có nhãn. Phần validation và test của bộ nguồn không tham gia huấn luyện hay chọn mô hình.
2. Bộ đích được chia 70/15/15 theo cell với cùng hạt giống. Chỉ 15 % cell test của bộ đích được dùng để đánh giá; chúng không tham gia bất kỳ bước nào khác. Phần validation của bộ đích không được dùng.

3. k cell có nhãn của bộ đích được lấy từ phần train của bộ đích; các cell train còn lại của bộ đích là cell không nhãn.
4. Normaliser của *mọi* mô hình (MLP, GBDT và PINN-semi) fit trên cùng một tập: đặc trưng của cell train bộ nguồn và cell train bộ đích. Như vậy khác biệt giữa các mô hình chỉ còn là mô hình và hàm mất mát.
5. $\mathscr{L}_{\text{data}}$ dùng cell có nhãn của bộ nguồn và k cell có nhãn của bộ đích; khi $k > 0$, một nửa mỗi batch lấy từ k cell đích để chúng không bị dữ liệu nguồn lấn át. PINN-semi áp loss vật lý lên mọi cell train của cả hai bộ.
6. MLP và PINN-semi huấn luyện một số bước cố định (2 500), không dừng sớm; số cây của GBDT chọn trên validation của bộ nguồn. Không mô hình nào được chọn theo bất kỳ nhãn nào của bộ đích.

Mệnh đề 5.7 (Chuyển miền không rò rỉ)**.** *Với quy trình trên, tham số mô hình độc lập với đặc trưng và nhãn của các cell test bộ đích.*

Chứng minh. Cell test bộ đích không thuộc tập fit normaliser (bước 4), không thuộc tập của $\mathscr{L}_{\text{data}}$ hay loss vật lý (bước 5), và không có bước chọn mô hình nào (bước 6). Áp dụng lập luận của Mệnh đề 5.6. □

Ở một thiết kế trước đó, MLP fit normaliser chỉ trên dữ liệu nguồn còn PINN fit trên cả nguồn và đích, nên một phần khác biệt có thể đến từ normaliser chứ không phải từ vật lý. Bước 4 loại bỏ yếu tố này. Ngoài 4 cặp cùng hoá học (HUST ↔ MIT, XJTU ↔ TJU), đồ án chạy đủ 12 cặp nguồn–đích có hướng, 5 hạt giống cho mỗi cặp.

5.10 Kiểm toán rò rỉ

Để đo định lượng tác động của các dạng rò rỉ thường gặp, cùng một mô hình (MLP, 70 % nhãn) được huấn luyện với bốn cách xử lý sai, mỗi cách chỉ đổi đúng một yếu tố so với giao thức chuẩn:

- *chia theo chu kỳ*: mỗi chu kỳ được gán ngẫu nhiên vào train/validation/test;
- *min–max theo cell*: đặc trưng và chỉ số chu kỳ được chuẩn hoá min–max theo toàn bộ vòng đời của từng cell, như trong mã nguồn PINN4SOH [25]; chỉ số chu kỳ sau chuẩn hoá chính là "phần trăm tuổi thọ đã trôi qua";
- *lọc dùng cả vòng đời*: bộ lọc 3σ dùng trung bình và độ lệch chuẩn của cả vòng đời cell;
- *chuẩn hoá gồm cả test*: normaliser fit trên cả đặc trưng cell validation và test.

5.11 Chỉ số đánh giá

Với y_i là SOH thực đo và $\hat{y}_i$ là SOH dự đoán:

$$\mathrm{MAE} = \frac{1}{N}\sum|\hat{y}_i - y_i|, \quad \mathrm{RMSE} = \sqrt{\frac{1}{N}\sum(\hat{y}_i - y_i)^2}, \quad \mathrm{MAPE} = \frac{100\,\%}{N}\sum\left|\frac{\hat{y}_i - y_i}{y_i}\right|, \tag{5.2}$$

$$R^2 = 1 - \frac{\sum(\hat{y}_i - y_i)^2}{\sum(y_i - \bar{y})^2}, \qquad \mathrm{MAE}_{\mathrm{cell}} = \frac{1}{|\mathscr{C}_{\mathrm{test}}|}\sum_{c}\frac{1}{n_c}\sum_{n}|\hat{y}_{c,n} - y_{c,n}|. \tag{5.3}$$

Chỉ số chính là $\mathrm{MAE}_{\mathrm{cell}}$: mỗi cell có một phiếu, nên cell có tuổi thọ dài không lấn át kết quả. Ngoài ra đồ án dùng sai số ở giai đoạn cuối đời (SOH $\leq$ 0,9), sai số thời điểm SOH chạm 0,85 (theo chu kỳ), và tổng mức tăng ngược của quỹ đạo dự đoán trên 100 chu kỳ.

5.12 Phương pháp thống kê

Khoảng tin cậy. Tỉ số $\rho = \overline{\mathrm{MAE}}_{\mathrm{PINN}}/\overline{\mathrm{MAE}}_{\text{đối chứng}}$ có khoảng tin cậy 95 % theo bootstrap phân vị [8]: lấy lại mẫu *theo cell* (ghép cặp), 10 000 lần.

Kiểm định theo cell. Với $d_c = \mathrm{MAE}_c^{\mathrm{PINN}} - \mathrm{MAE}_c^{\text{đối chứng}}$, kiểm định dấu–hạng Wilcoxon [27] hai phía cho giả thuyết trung vị của d_c bằng 0. Kiểm định này không giả định phân phối chuẩn.

Hiệu chỉnh đa so sánh. Mỗi phép so sánh được thực hiện trên 4 bộ dữ liệu; p được hiệu chỉnh bằng phương pháp Holm [10]: sắp $p_{(1)} \leq \ldots \leq p_{(m)}$, đặt $\tilde{p}_{(i)} = \max_{j\leq i}\min\left(1, (m-j+1)p_{(j)}\right)$.

Kiểm định bảo thủ ở mức fold. Các tập train của các fold chồng lấp nhau nên MAE của các fold không độc lập. Phép t hiệu chỉnh của Nadeau và Bengio [16, 5] dùng

$$t = \frac{\bar{d}}{\sqrt{\left(\frac{1}{J} + \frac{n_{\mathrm{test}}}{n_{\mathrm{train}}}\right)s_d^2}}, \qquad \text{bậc tự do } J-1, \tag{5.4}$$

với $J = KR = 25$ hiệu theo fold. Hệ số $n_{\mathrm{test}}/n_{\mathrm{train}} \approx 0{,}29$ làm phương sai lớn hơn nhiều so với phép t thông thường, nên đây là kiểm định rất bảo thủ; kết luận được xem là vững khi qua được cả hai kiểm định.

Bảng 5.5. Các thí nghiệm và số lượt huấn luyện.

Thí nghiệm	Nội dung	Lượt
Kiểm định chéo chính	MLP, PINN-semi ở 4 mức; PINN-sup, 2 biến thể cắt bỏ ở 30 %	1.100
Đối chứng học có nhãn	Ridge, GPR, GBDT ở 4 mức nhãn	1.200
Mở rộng biến thể vật lý	PINN-sup ở 10, 50 %; PINN hộp đen ở 4 mức	600
Kiểm toán rò rỉ	4 cách chia/chuẩn hoá sai, MLP 70 % nhãn, 2 lần lặp	160
Chuyển miền	12 cặp nguồn–đích, $k \in \{0, 3\}$, 5 seed; MLP, GBDT, PINN-semi	360
Tổng		**3.420**

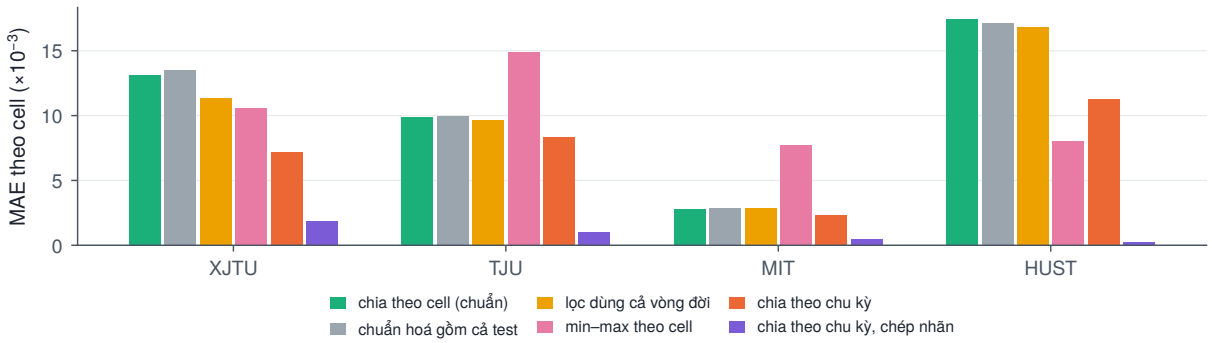
CHƯƠNG 6

Kết quả và thảo luận

6.1 Kiểm toán rò rỉ

Bảng 6.1. Kiểm toán rò rỉ: MAE theo cell ($\times 10^{-3}$) của MLP với 70 % nhãn, trung bình 2 lần lặp × 5 fold; trong ngoặc là tỉ số so với giao thức chuẩn.

Thiết lập	XJTU	TJU	MIT	HUST
Chia theo cell (chuẩn)	13,11	9,86	2,80	17,46
Chuẩn hoá gồm cả test	13,50 (1,03)	9,98 (1,01)	2,82 (1,01)	17,15 (0,98)
Lọc dùng cả vòng đời	11,37 (0,87)	9,67 (0,98)	2,82 (1,01)	16,82 (0,96)
Min–max theo cell	10,54 (0,80)	14,88 (1,51)	7,74 (2,76)	8,06 (0,46)
Chia theo chu kỳ	7,19 (0,55)	8,33 (0,85)	2,28 (0,81)	11,25 (0,64)
Chia theo chu kỳ, chép nhãn	1,82 (0,14)	0,99 (0,10)	0,43 (0,15)	0,20 (0,01)



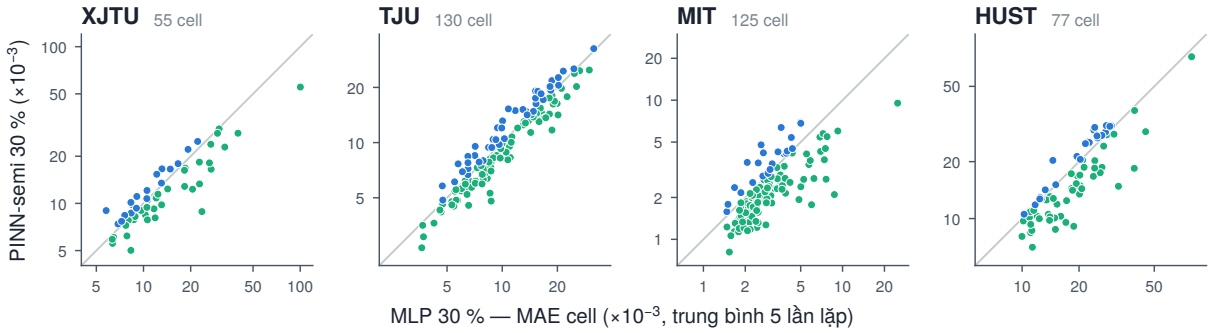
Hình 6.1. MAE theo cell của cùng một mô hình (MLP, 70 % nhãn) dưới các cách chia và chuẩn hoá khác nhau.

Bảng 6.1 cho thấy mức độ nghiêm trọng của từng dạng rò rỉ. Chia theo chu kỳ làm sai số thấp đi 1,2–1,8 lần so với chia theo cell, dù mô hình và dữ liệu không đổi. Hàng cuối của bảng còn rõ hơn: một bộ "dự đoán" không dùng đặc trưng nào, chỉ chép nhãn của chu kỳ train gần nhất trong cùng cell, đạt sai số thấp hơn mọi mô hình thật được đánh giá đúng cách, đúng như Mệnh đề 5.1 dự báo. Chuẩn hoá min–max theo vòng đời cell làm sai số thấp giả tạo trên XJTU và HUST (tỉ số XJTU 0,80, HUST 0,46), vì đầu vào đã chứa vị trí tương đối của chu kỳ trong vòng đời; ở hai bộ này SOH cuối đời của mọi cell gần như bằng nhau (XJTU 0,78–0,89, HUST 0,80–0,82; Bảng 3.1), nên biết vị trí trong vòng đời gần như đủ để suy ra SOH. Ngược lại, trên TJU và MIT

cùng phép chuẩn hoá đó làm sai số tăng (tỉ số TJU 1,51, MIT 2,76): SOH cuối đời ở đây trải rộng hơn (TJU 0,66–0,90, MIT 0,82–0,97), nên vị trí trong vòng đời không đủ để suy ra SOH, trong khi chuẩn hoá theo từng cell lại xoá mất mức tuyệt đối của đặc trưng, vốn là thông tin phân biệt cell này với cell khác. Dù theo chiều nào, con số đo được cũng không phản ánh sai số khi triển khai, vì tuổi thọ của một cell đang vận hành chưa biết trước. Hai dạng còn lại tác động nhỏ hơn (lọc dùng cả vòng đời: 0,87–1,01; chuẩn hoá gồm cả test: 0,98–1,03), nhưng vẫn là rò rỉ và vẫn được loại bỏ trong giao thức chuẩn. Mọi kết quả từ đây trở đi dùng giao thức chuẩn của Chương 5.

6.2 So sánh ở 30 % nhãn

Ở mức 30 % số cell có nhãn, PINN-semi có MAE theo cell thấp hơn MLP có ý nghĩa thống kê (Wilcoxon theo cell, hiệu chỉnh Holm) trên cả bốn bộ, với tỉ số MAE từ 0,76 (MIT) tới 0,96 (TJU). Với kiểm định bảo thủ ở mức fold, kết luận chỉ còn đứng vững trên MIT; XJTU, TJU và HUST có hướng cải thiện nhất quán (Hình 6.2: phần lớn cell nằm dưới đường chéo) nhưng biến thiên giữa các lần huấn luyện còn lớn so với mức cải thiện.



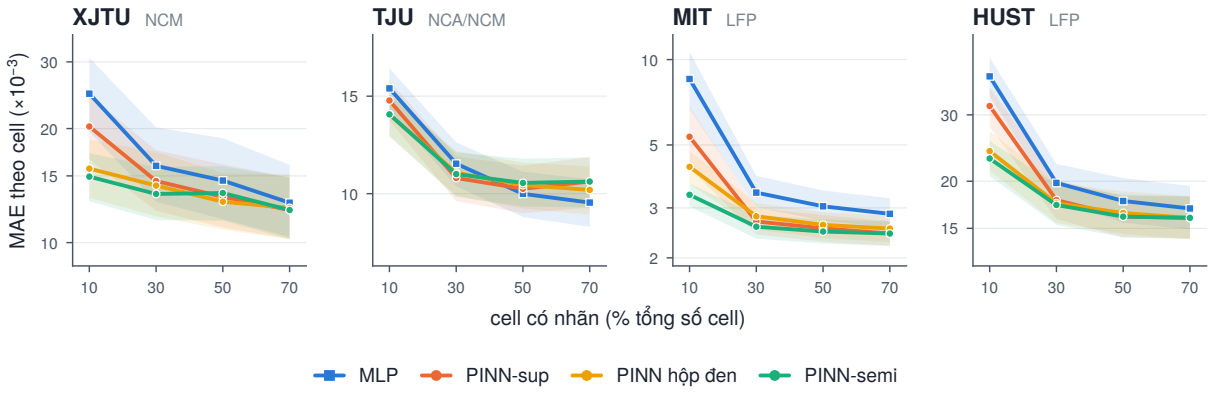
Hình 6.2. MAE từng cell ở 30 % nhãn, trung bình 5 lần lặp: trục ngang MLP, trục dọc PINN-semi; điểm dưới đường chéo (xanh lục) là cell mà PINN-semi có sai số thấp hơn.

6.3 PINN và học có nhãn khi thay đổi lượng nhãn

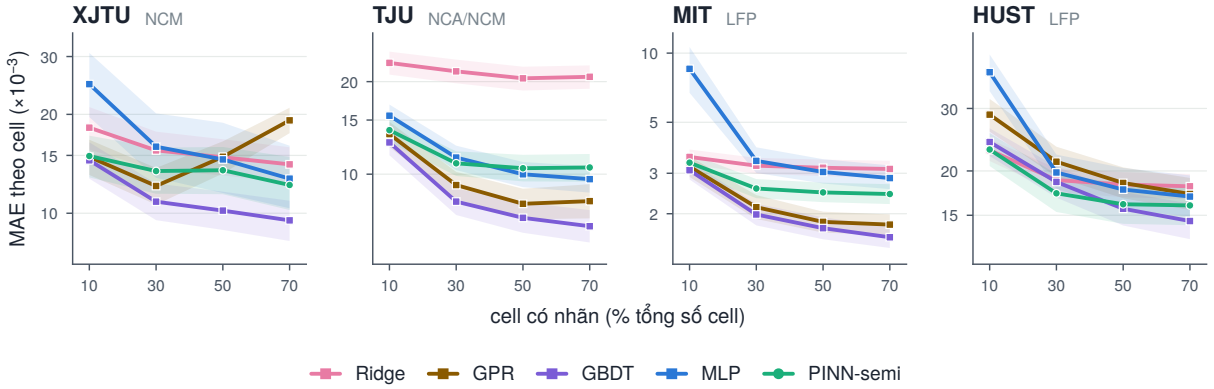
Bảng 6.2 và Hình 6.3, 6.4 là kết quả trung tâm của đồ án: sai số của mọi mô hình ở bốn mức nhãn.

Bảng 6.2. MAE theo cell ($\times 10^{-3}$) của mọi mô hình theo lượng nhãn (phần trăm số cell có nhãn); in đậm là thấp nhất trong cột của mỗi bộ. Trung bình 5 lần lặp × 5 fold; mỗi cell được test 5 lần.

Bộ	Mô hình	10 %	30 %	50 %	70 %
XJTU	Ridge	18,22	15,54	14,81	14,09
	GPR	14,85	12,11	14,86	19,18
	GBDT	**14,49**	**10,85**	**10,19**	**9,51**
	MLP	24,72	15,95	14,58	12,74
	PINN-sup	20,25	14,54	13,21	12,19
	PINN hộp đen	15,68	14,15	12,82	12,34
	PINN-semi	14,93	13,44	13,52	12,19
TJU	Ridge	23,01	21,60	20,50	20,74
	GPR	13,50	9,22	8,01	8,17
	GBDT	**12,68**	**8,14**	**7,21**	**6,77**
	MLP	15,50	11,33	9,99	9,64
	PINN-sup	14,73	10,67	10,20	10,52
	PINN hộp đen	13,90	10,91	10,36	10,16
	PINN-semi	13,91	10,85	10,46	10,52
MIT	Ridge	3,53	3,24	3,17	3,13
	GPR	3,21	2,14	1,84	1,79
	GBDT	**3,09**	**1,99**	**1,73**	**1,58**
	MLP	8,54	3,40	3,04	2,86
	PINN-sup	5,34	2,69	2,54	2,44
	PINN hộp đen	4,19	2,80	2,61	2,54
	PINN-semi	3,34	2,58	2,48	2,44
HUST	Ridge	**22,88**	18,85	18,32	18,10
	GPR	28,82	21,24	18,50	17,22
	GBDT	24,13	18,63	**15,65**	**14,45**
	MLP	37,95	19,80	17,73	16,94
	PINN-sup	31,67	17,82	16,11	15,99
	PINN hộp đen	24,04	17,49	16,47	15,99
	PINN-semi	22,98	**17,30**	16,11	15,99



Hình 6.3. MAE theo cell theo lượng nhãn: MLP và các biến thể có vật lý. Dải là khoảng tin cậy 95 % bootstrap theo cell; trục dọc thang log.



Hình 6.4. MAE theo cell theo lượng nhãn: PINN-semi so với các mô hình học có nhãn.

Khi có ít nhãn. Ở 10 % nhãn, PINN-semi vượt MLP với khoảng cách lớn nhất: tỉ số MAE là XJTU 0,60, TJU 0,90, MIT 0,39, HUST 0,61, có ý nghĩa trên cả bốn bộ. Ở mức này mỗi fold chỉ có 6–13 (XJTU 6, TJU 13, MIT 12, HUST 8) cell có nhãn, và MLP dễ quá khớp; loss vật lý trên các cell không nhãn buộc mạng phải cho quỹ đạo hợp lý trên chính những cell nó chưa có nhãn, nên bù được phần lớn thông tin thiếu.

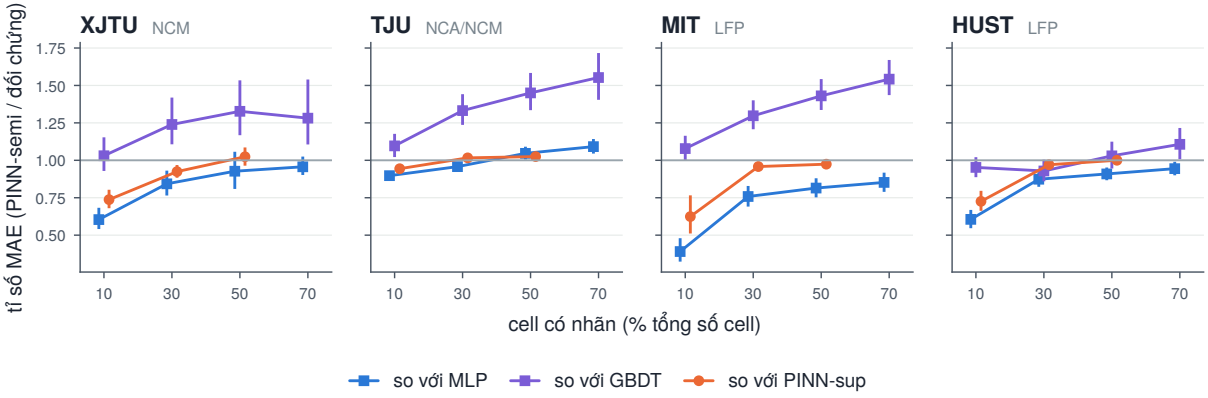
Khi có nhiều nhãn. Ở 70 % nhãn, mọi cell train đều có nhãn và không còn cell không nhãn, nên PINN-semi và PINN-sup trùng nhau; vật lý lúc này chỉ còn vai trò một bộ chuẩn hoá. Tỉ số MAE so với MLP là XJTU 0,96, TJU 1,09, MIT 0,85, HUST 0,94; cải thiện có ý nghĩa trên MIT; trên TJU MLP lại tốt hơn có ý nghĩa. Trung bình nhân của tỉ số qua bốn bộ tiến dần về 1 khi lượng nhãn tăng: 10 %: 0,60, 30 %: 0,86, 50 %: 0,92, 70 %: 0,96. Dữ liệu có nhãn càng đủ, ràng buộc vật lý càng ít thông tin mới.

Lượng nhãn tương đương. Bảng 6.3 quy đổi kết quả sang số nhãn tiết kiệm được. Một giá trị "> 70 %" nghĩa là mô hình học có nhãn chưa đạt được sai số đó ngay cả khi dùng toàn bộ

nhãn train; "≤ 10 %" nghĩa là mô hình học có nhãn đã đạt sai số đó ngay ở mức nhãn thấp nhất. So với MLP, PINN-semi dùng 10 % nhãn đạt sai số mà MLP cần XJTU 45 %, TJU 17 %, MIT 33 %, HUST 25 % nhãn mới đạt, tức tiết kiệm 1,7–4,5 lần số nhãn; PINN-semi dùng 30 % nhãn tương đương MLP dùng XJTU 62 %, TJU 37 %, MIT > 70 %, HUST 61 %. So với mô hình học có nhãn tốt nhất ở từng mức thì khác: trên cả bốn bộ, mô hình học có nhãn tốt nhất đã đạt sai số của PINN-semi ngay ở 10 % nhãn; ở 30 % nhãn, PINN-semi vẫn tiết kiệm nhãn trên HUST (tương đương 38 %), còn trên XJTU, TJU và MIT mô hình tốt nhất chỉ cần 15–18 % nhãn để bằng PINN-semi 30 %.

Bảng 6.3. Lượng nhãn tương đương: mô hình học có nhãn cần bao nhiêu phần trăm cell có nhãn để đạt MAE của PINN-semi ở 10 % và 30 % nhãn ("tốt nhất": mô hình học có nhãn tốt nhất ở từng mức, trong Ridge, GPR, GBDT, MLP). Nội suy log-tuyến tính giữa các mức đo.

Bộ	PINN 10 % ≈ MLP	PINN 10 % ≈ tốt nhất	PINN 30 % ≈ MLP	PINN 30 % ≈ tốt nhất
XJTU	45 %	≤ 10 %	62 %	15 %
TJU	17 %	≤ 10 %	37 %	17 %
MIT	33 %	≤ 10 %	> 70 %	18 %
HUST	25 %	≤ 10 %	61 %	38 %



Hình 6.5. Tỉ số MAE theo cell của PINN-semi so với MLP, GBDT và PINN-sup theo lượng nhãn (vạch: khoảng tin cậy 95 %). Dưới 1: PINN-semi tốt hơn.

Bảng 6.4. Tỉ số MAE theo cell của PINN-semi so với MLP và GBDT ở từng mức nhãn (nhỏ hơn 1: PINN-semi tốt hơn). *: $p_{\text{Holm}} < 0{,}05$ theo cell; †: còn có ý nghĩa với kiểm định bảo thủ mức fold.

Bộ	Nhãn	so với MLP: tỉ số [KTC]	cell tốt hơn	p_{Holm}	so với GBDT: tỉ số [KTC]	cell tốt hơn	p_{Holm}
XJTU	10 %	0,60 [0,54; 0,68]*	91 %	$< 10^{-4}$	1,03 [0,93; 1,15]	47 %	0,8210
	30 %	0,84 [0,76; 0,93]*	65 %	0,0047	1,24 [1,11; 1,42]*	31 %	0,0004
	50 %	0,93 [0,81; 1,06]	45 %	0,7502	1,33 [1,17; 1,53]*	20 %	$< 10^{-4}$
	70 %	0,96 [0,90; 1,02]	53 %	0,4712	1,28 [1,11; 1,54]*	33 %	0,0010
TJU	10 %	0,90 [0,87; 0,93]*	75 %	$< 10^{-4}$	1,10 [1,02; 1,18]*	38 %	0,0340
	30 %	0,96 [0,93; 0,99]*	68 %	0,0041	1,33 [1,24; 1,44]*	28 %	$< 10^{-4}$
	50 %	1,05 [1,01; 1,09]	43 %	0,2363	1,45 [1,33; 1,58]*†	22 %	$< 10^{-4}$
	70 %	1,09 [1,04; 1,14]*	41 %	0,0086	1,55 [1,40; 1,72]*†	20 %	$< 10^{-4}$
MIT	10 %	0,39 [0,32; 0,48]*	90 %	$< 10^{-4}$	1,08 [1,00; 1,16]	45 %	0,1991
	30 %	0,76 [0,69; 0,83]*†	82 %	$< 10^{-4}$	1,30 [1,21; 1,40]*†	18 %	$< 10^{-4}$
	50 %	0,81 [0,75; 0,88]*	79 %	$< 10^{-4}$	1,43 [1,34; 1,54]*†	9 %	$< 10^{-4}$
	70 %	0,85 [0,79; 0,92]*	74 %	$< 10^{-4}$	1,54 [1,44; 1,67]*†	6 %	$< 10^{-4}$
HUST	10 %	0,61 [0,55; 0,67]*	92 %	$< 10^{-4}$	0,95 [0,89; 1,02]	61 %	0,0720
	30 %	0,87 [0,82; 0,92]*	71 %	$< 10^{-4}$	0,93 [0,86; 1,00]*	69 %	0,0042
	50 %	0,91 [0,87; 0,95]*	68 %	0,0008	1,03 [0,95; 1,12]	56 %	0,9939
	70 %	0,94 [0,90; 0,99]	65 %	0,0526	1,11 [1,01; 1,22]	43 %	0,0923

6.4 So với các mô hình học có nhãn khác

Mô hình có MAE thấp nhất ở từng bộ (Bảng 6.2): XJTU: GBDT ở cả bốn mức nhãn; TJU: GBDT ở cả bốn mức nhãn; MIT: GBDT ở cả bốn mức nhãn; HUST: Ridge ở 10 %, PINN-semi ở 30 %, GBDT ở 50–70 %.

Ridge, dù chỉ là mô hình tuyến tính, tốt hơn MLP ở 10 % nhãn trên XJTU, MIT và HUST: khi rất ít nhãn, mô hình đơn giản ít quá khớp hơn. Nhưng Ridge cải thiện chậm khi thêm nhãn: MAE ở 70 % bằng 0,77–0,90 lần MAE ở 10 %, so với 0,33–0,62 lần của MLP. GPR chỉ dùng được 1 500 điểm huấn luyện do chi phí $O(n^3)$ theo số điểm, và kém GBDT trong 16/16 trường hợp (bộ × mức nhãn); dù vậy GPR vẫn có MAE thấp hơn PINN-semi trong 10/16 trường hợp, và thấp hơn ở cả bốn mức nhãn trên TJU và MIT. GBDT là đối thủ mạnh nhất: mô hình này tốt hơn PINN-semi có ý nghĩa thống kê ở 10 % (TJU); 30 % (XJTU, TJU và MIT); 50 % (XJTU, TJU và MIT); 70 % (XJTU, TJU và MIT); ngược lại PINN-semi tốt hơn GBDT có ý nghĩa ở 30 % (HUST). Ở 10 % nhãn, tỉ số MAE của PINN-semi so với GBDT là XJTU 1,03, TJU 1,10, MIT 1,08, HUST 0,95. Cây quyết định xử lý tốt các đặc trưng có phân phối lệch và các chế độ thí nghiệm khác hẳn nhau mà không cần chuẩn hoá cẩn thận; đây là ưu thế quen thuộc của mô hình cây trên dữ liệu dạng bảng. Phát biểu đúng mức vì vậy là: vật lý cải thiện rõ rệt *mô hình mạng nơ-ron* khi ít nhãn và đưa nó tới gần mô hình cây ở 10 % nhãn (tỉ số so với GBDT 0,95–1,10), nhưng chưa vượt được một mô hình cây được tinh chỉnh tốt, cũng như hồi quy Gauss, trên phần lớn các bộ dữ liệu.

6.5 Lợi ích đến từ đâu

Bảng 6.5. Tách nguồn gốc lợi ích ở 30 % nhãn: MAE theo cell ($\times 10^{-3}$), trong ngoặc là tỉ số so với MLP.

Mô hình (30 % nhãn)	XJTU	TJU	MIT	HUST
MLP	15,95	11,33	3,40	19,80
PINN-sup	14,54 (0,91)	10,67 (0,94)	2,69 (0,79)	17,82 (0,90)
chỉ đơn điệu	14,13 (0,89)	11,00 (0,97)	2,86 (0,84)	17,41 (0,88)
PINN-semi (Euler)	13,37 (0,84)	11,31 (1,00)	3,01 (0,89)	17,49 (0,88)
PINN hộp đen	14,15 (0,89)	10,91 (0,96)	2,80 (0,83)	17,49 (0,88)
PINN-semi	13,44 (0,84)	10,85 (0,96)	2,58 (0,76)	17,30 (0,87)

- *Vật lý chỉ trên cell có nhãn* (PINN-sup): ở 10 % nhãn tỉ số so với MLP là XJTU 0,82, TJU 0,95, MIT 0,63, HUST 0,83. Vật lý đóng vai trò bộ chuẩn hoá có giúp, nhưng còn xa mới bằng PINN-semi.
- *Thêm cell không nhãn* (PINN-semi so với PINN-sup): tỉ số XJTU 0,74, TJU 0,94, MIT 0,62, HUST 0,73 ở 10 % và XJTU 0,92, TJU 1,02, MIT 0,96, HUST 0,97 ở 30 % nhãn. Tính theo thang log, phần này chiếm 50–64 % mức giảm sai số của PINN-semi so với MLP ở 10 % nhãn, phần còn lại đến từ vật lý trên cell có nhãn. Ở mức nhãn thấp, dữ liệu không nhãn đóng góp ít nhất ngang với vật lý trên cell có nhãn, và nó chỉ có ích khi được nối với mô hình qua loss vật lý không dùng nhãn.
- *Phương trình động học so với chỉ đơn điệu*: chỉ với ràng buộc đơn điệu, mô hình đã đạt 62–95 % mức giảm sai số (thang log) của PINN-semi so với MLP ở 30 % nhãn. Khi bỏ $\mathscr{L}_{\text{ode}}$ và $\mathscr{L}_{\text{range}}$, MAE bằng XJTU 1,05, TJU 1,01, MIT 1,11, HUST 1,01 lần PINN-semi đầy đủ, chênh lệch lớn nhất ở MIT: phần còn lại của lợi ích đến từ cấu trúc động học.
- *Dạng phần dư*: MAE của phần dư Euler dọc quỹ đạo so với dạng đạo hàm riêng theo t là XJTU 0,99, TJU 1,04, MIT 1,17, HUST 1,01: ngang nhau trên XJTU và HUST; kém hơn trên TJU và MIT.
- *Động học hộp đen* (kiểu PINN4SOH) so với động học xám: tỉ số MAE của PINN hộp đen so với PINN-semi là XJTU 1,05, TJU 1,00, MIT 1,26, HUST 1,05 ở 10 % và XJTU 1,05, TJU 1,01, MIT 1,09, HUST 1,01 ở 30 % nhãn. Theo kiểm định Wilcoxon có hiệu chỉnh Holm, động học xám tốt hơn có ý nghĩa ở 10 % (MIT và HUST); 30 % (MIT); 50 % (HUST), hộp đen tốt hơn có ý nghĩa ở 50 % (XJTU); 11 trường hợp còn lại (trong 16 cặp bộ × mức nhãn) khác biệt không có ý nghĩa. Khác biệt lớn nhất ở MIT với 10 % nhãn, khi MAE của PINN hộp đen bằng 1,26 lần PINN-semi. Ở 30 % nhãn, sai số của PINN hộp đen gần như trùng với biến thể chỉ đơn điệu (chênh không quá 2 %). Điều này phù hợp với

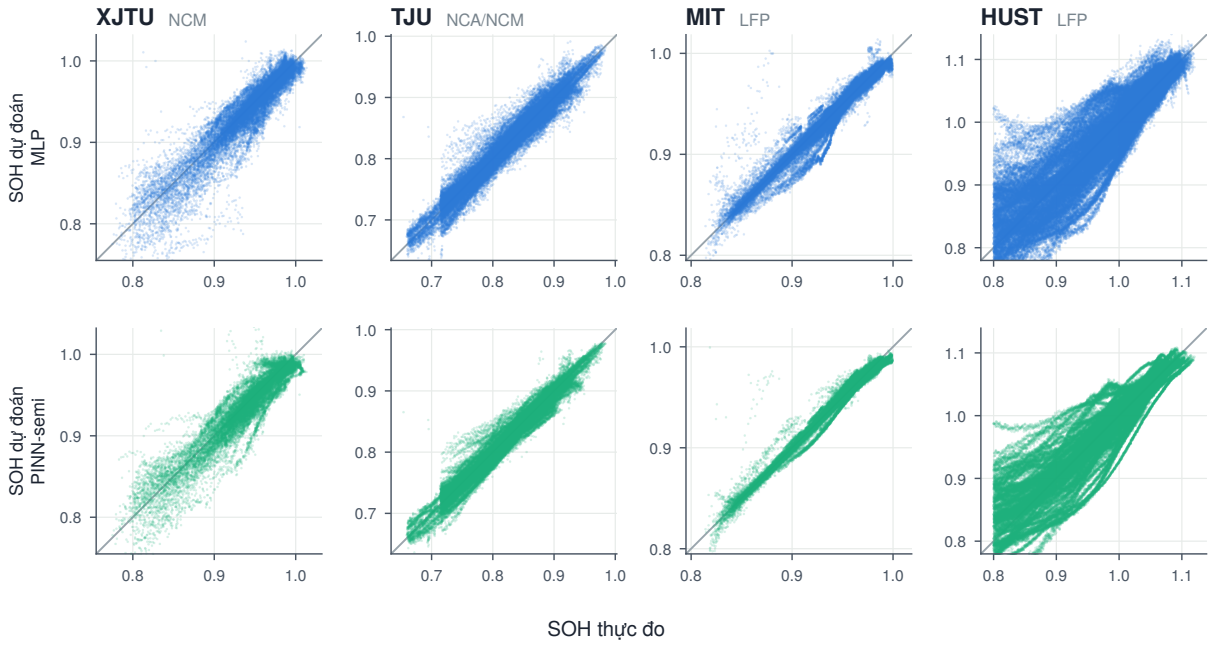
giả thuyết: khi G nhận cả u_t làm đầu vào, mạng có thể học $G \approx u_t$ nên phần dư động học bị thoả mãn tầm thường, chỉ còn ràng buộc đơn điệu và miền giá trị có tác dụng; động học xám không có lối thoát này vì r không phụ thuộc u_t và luôn không âm.

6.6 Các chỉ số mở rộng và hình dự đoán

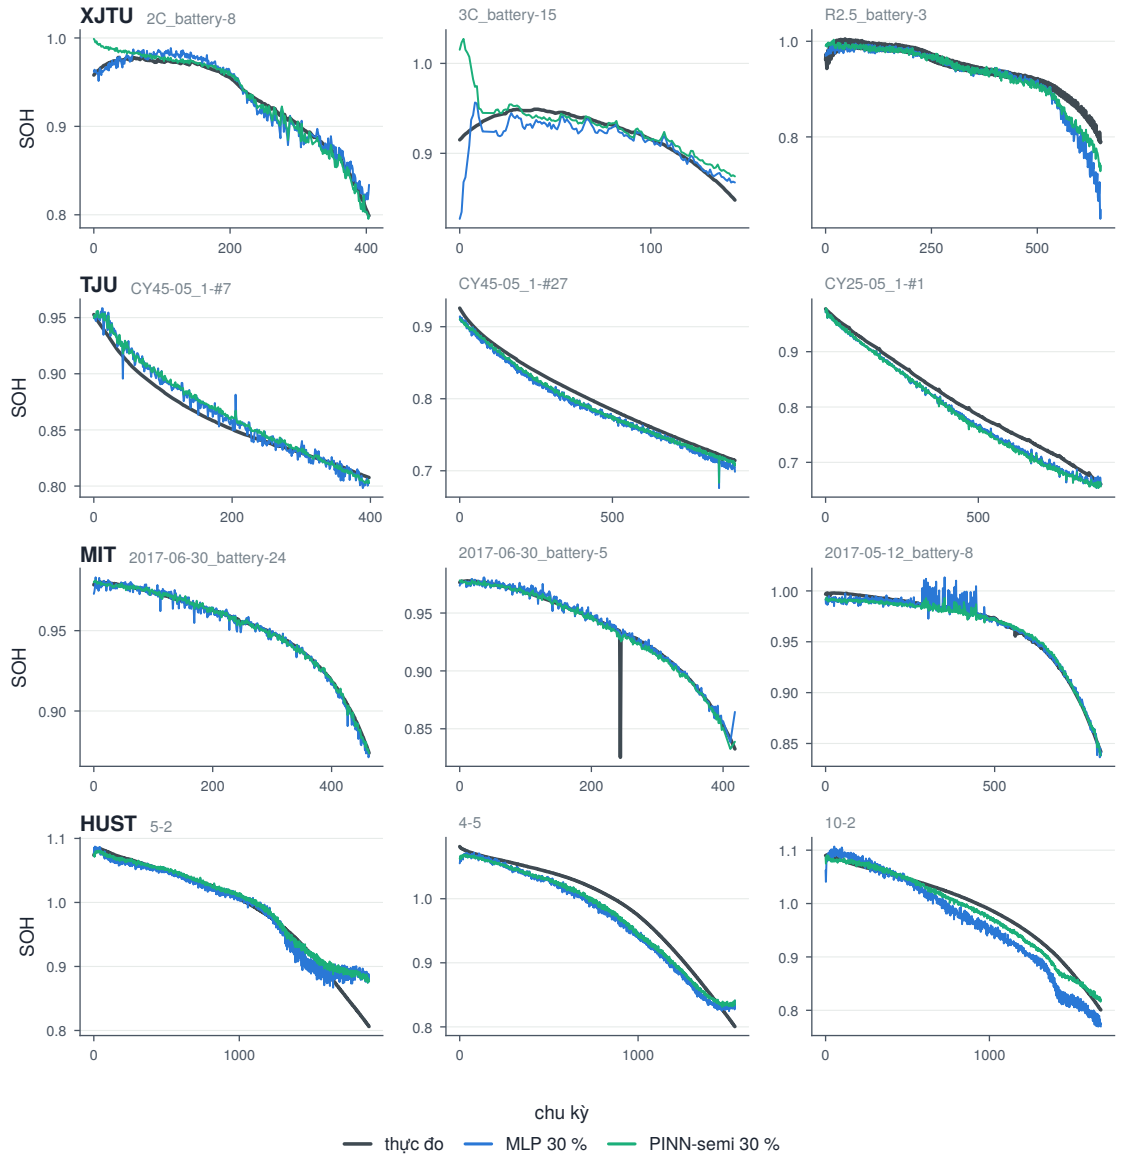
Bảng 6.6. Chỉ số gộp mọi chu kỳ trên tập test (MAE, RMSE, MaxAE theo điểm phần trăm SOH).

Bộ	Mô hình	MAE (%)	RMSE (%)	MAPE (%)	R^2	R^2 từ chu kỳ 10	MaxAE (%)
XJTU	MLP 30 %	1,37	3,43	1,49	0,403	0,804	221,9
	PINN-semi 30 %	1,22	2,21	1,32	0,753	0,858	83,0
	MLP 70 %	1,17	2,91	1,27	0,570	0,863	212,6
	PINN-semi 70 %	1,12	2,28	1,22	0,736	0,882	103,0
TJU	MLP 30 %	0,93	1,27	1,15	0,958	0,957	21,8
	PINN-semi 30 %	0,90	1,22	1,11	0,961	0,960	21,4
	MLP 70 %	0,79	1,09	0,97	0,969	0,969	21,5
	PINN-semi 70 %	0,82	1,14	1,02	0,966	0,965	21,0
MIT	MLP 30 %	0,39	0,74	0,41	0,953	0,952	23,4
	PINN-semi 30 %	0,27	0,43	0,29	0,984	0,984	18,0
	MLP 70 %	0,31	0,59	0,33	0,970	0,970	20,7
	PINN-semi 70 %	0,25	0,43	0,27	0,984	0,984	17,5
HUST	MLP 30 %	1,96	2,90	2,10	0,863	0,862	22,3
	PINN-semi 30 %	1,71	2,58	1,84	0,891	0,890	18,7
	MLP 70 %	1,67	2,51	1,79	0,897	0,897	19,6
	PINN-semi 70 %	1,57	2,37	1,70	0,909	0,908	16,2

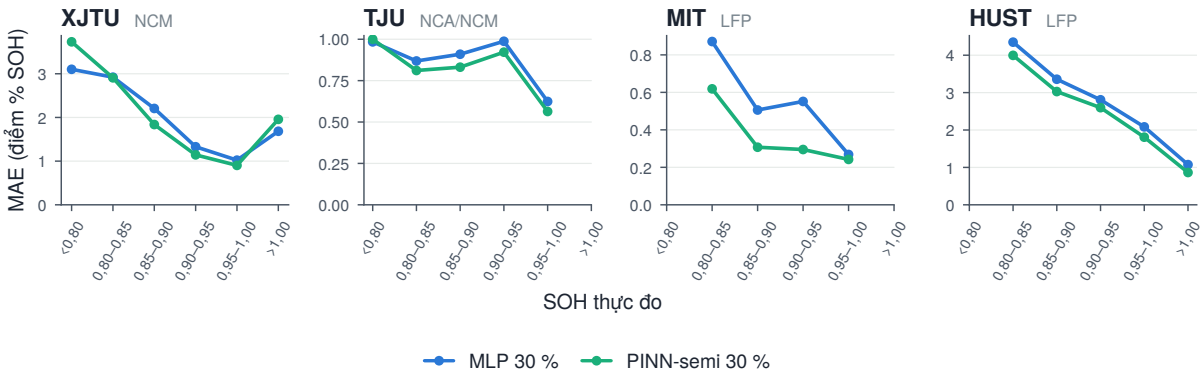
Ở 30 % nhãn, R^2 của PINN-semi cao hơn MLP trên cả bốn bộ; ở 70 % nhãn trên XJTU, MIT và HUST, trừ TJU. R^2 gộp của XJTU thấp (0,40–0,75) vì vài chu kỳ đầu của một số cell có đặc trưng khác xa dữ liệu huấn luyện và cho sai số rất lớn; tính từ chu kỳ thứ 10, R^2 của XJTU là 0,80–0,88. Hình 6.6–6.8 cho thấy dự đoán bám sát thực đo trong phần lớn vòng đời, PINN-semi cho quỹ đạo trơn hơn, và sai số tăng ở giai đoạn cuối đời.



Hình 6.6. SOH dự đoán so với thực đo trên tập test (30 % nhãn). Hàng trên: MLP; hàng dưới: PINN-semi.



Hình 6.7. Quỹ đạo SOH trên ba cell test mỗi bộ (cell có sai số MLP ở phân vị 25, 50 và 75 %).



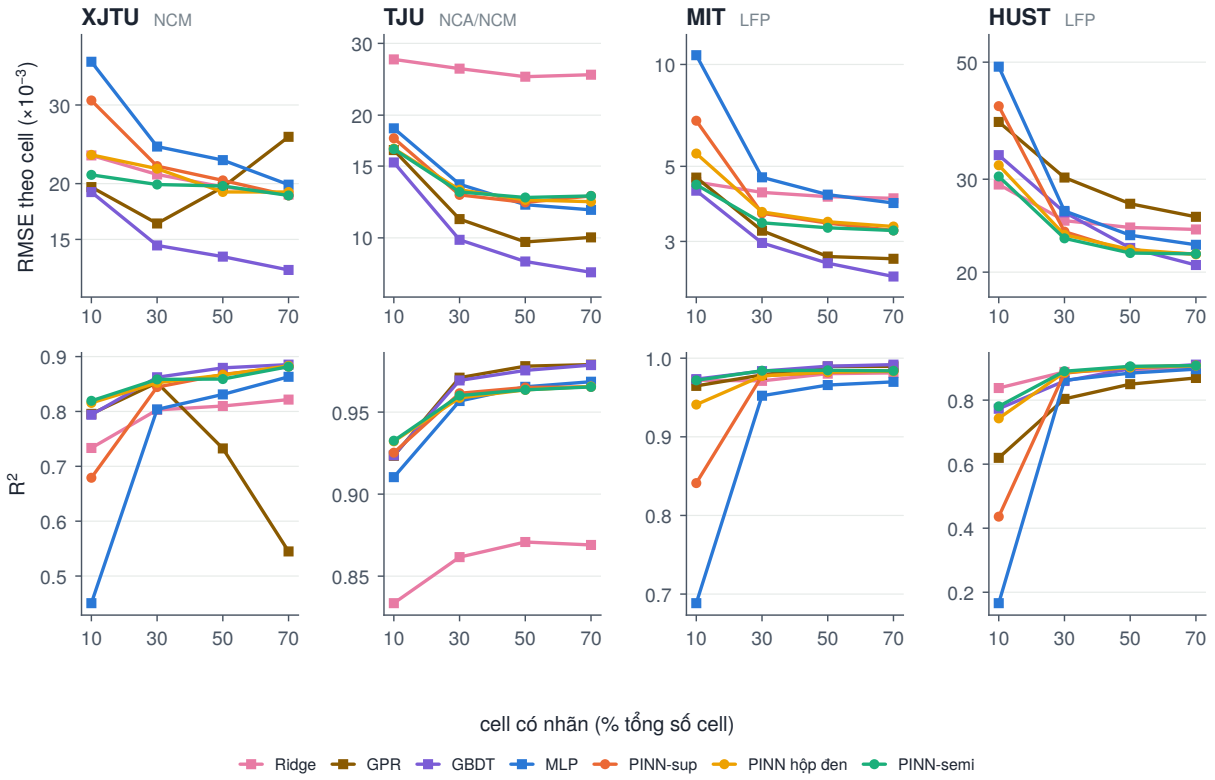
Hình 6.8. MAE theo từng khoảng SOH thực đo (30 % nhãn).

6.7 RMSE và R^2 cho mọi mô hình

MAE theo cell ở các mục trên cho mỗi cell một phiếu. Bảng 6.7 và Hình 6.9 bổ sung hai chỉ số quen thuộc: RMSE theo cell, nhạy với sai số lớn hơn MAE, và hệ số xác định R^2. R^2 được tính trên toàn bộ bộ dữ liệu: trong một lần lặp, năm fold phủ mỗi cell đúng một lần, nên dự đoán của năm fold ghép lại thành dự đoán cho mọi chu kỳ của mọi cell; R^2 tính trên đó rồi lấy trung bình qua năm lần lặp. Bảng dùng R^2 tính từ chu kỳ thứ 10 của mỗi cell, vì vài chu kỳ đầu của một số cell XJTU có đặc trưng bất thường và riêng chúng đã đủ kéo R^2 gộp xuống rất thấp: tính cả các chu kỳ đó, R^2 của MLP trên XJTU ở 10 % nhãn chỉ còn −0,18, tức kém hơn cả việc đoán bằng giá trị trung bình.

Bảng 6.7. RMSE theo cell ($\times 10^{-3}$, bốn cột đầu) và R^2 tính từ chu kỳ thứ 10 (bốn cột sau) theo lượng nhãn; in đậm là tốt nhất trong cột của mỗi bộ. R^2 ghép dự đoán của 5 fold thành toàn bộ bộ dữ liệu, trung bình qua 5 lần lặp.

		RMSE theo cell				R^2			
Bộ	Mô hình	10 %	30 %	50 %	70 %	10 %	30 %	50 %	70 %
XJTU	Ridge	23,13	20,97	19,67	18,90	0,733	0,803	0,810	0,822
	GPR	19,65	16,28	19,64	25,46	0,796	0,852	0,733	0,545
	GBDT	**19,15**	**14,54**	**13,73**	**12,81**	0,794	**0,862**	**0,879**	**0,885**
	MLP	37,49	24,21	22,58	19,89	0,451	0,804	0,831	0,863
	PINN-sup	30,71	21,89	20,34	18,82	0,679	0,844	0,867	0,882
	PINN hộp đen	23,20	21,61	19,16	19,15	0,816	0,852	0,867	0,883
	PINN-semi	20,92	19,91	19,76	18,82	**0,819**	0,858	0,859	0,882
TJU	Ridge	27,40	26,01	24,85	25,13	0,834	0,862	0,871	0,869
	GPR	16,42	11,12	9,77	10,03	0,923	**0,971**	**0,978**	**0,979**
	GBDT	**15,31**	**9,89**	**8,75**	**8,23**	0,924	0,969	0,975	0,979
	MLP	18,57	13,54	12,06	11,72	0,910	0,957	0,965	0,969
	PINN-sup	17,55	12,75	12,22	12,67	0,925	0,961	0,965	0,965
	PINN hộp đen	16,56	13,12	12,39	12,27	0,932	0,959	0,964	0,966
	PINN-semi	16,51	12,96	12,56	12,67	**0,933**	0,960	0,964	0,965
MIT	Ridge	4,49	4,19	4,07	4,02	0,972	0,971	0,980	0,981
	GPR	4,63	3,23	2,71	2,67	0,965	0,979	0,989	0,990
	GBDT	**4,24**	**2,97**	**2,59**	**2,36**	**0,973**	0,984	**0,990**	**0,992**
	MLP	10,65	4,64	4,12	3,90	0,688	0,952	0,966	0,970
	PINN-sup	6,82	3,63	3,40	3,23	0,841	0,978	0,982	0,984
	PINN hộp đen	5,46	3,67	3,43	3,32	0,941	0,977	0,982	0,983
	PINN-semi	4,41	3,41	3,29	3,23	0,972	**0,984**	0,985	0,984
HUST	Ridge	**29,31**	25,04	24,30	24,10	**0,838**	0,888	0,896	0,898
	GPR	38,52	30,22	26,95	25,46	0,620	0,804	0,850	0,869
	GBDT	33,32	25,97	22,23	**20,63**	0,773	0,860	0,898	**0,911**
	MLP	49,02	26,12	23,50	22,54	0,166	0,862	0,884	0,897
	PINN-sup	41,27	23,87	21,84	21,66	0,436	0,884	0,904	0,908
	PINN hộp đen	31,89	23,54	22,08	21,62	0,743	0,887	0,902	0,908
	PINN-semi	30,37	**23,18**	**21,74**	21,66	0,781	**0,890**	**0,906**	0,908



Hình 6.9. RMSE theo cell (hàng trên, thang log) và R^2 tính từ chu kỳ thứ 10 (hàng dưới) theo lượng nhãn.

Thứ hạng của các mô hình theo RMSE gần như trùng với theo MAE: hệ số tương quan hạng Spearman giữa hai chỉ số là 0,99 trên 120 tổ hợp bộ × mô hình × mức nhãn (XJTU 0,84, TJU 1,00, MIT 0,99, HUST 0,97). Vì vậy các kết luận ở Mục 6.3 giữ nguyên khi đổi thước đo. Ở 10 % nhãn, R^2 của PINN-semi so với MLP là XJTU 0,82 so với 0,45, TJU 0,93 so với 0,91, MIT 0,97 so với 0,69, HUST 0,78 so với 0,17; RMSE theo cell của PINN-semi bằng 0,41–0,89 lần MLP, có ý nghĩa thống kê trên cả bốn bộ (Wilcoxon theo cell, hiệu chỉnh Holm). So với GBDT, theo RMSE GBDT tốt hơn có ý nghĩa ở 30 % (XJTU, TJU và MIT); 50 % (XJTU, TJU và MIT); 70 % (XJTU, TJU và MIT); PINN-semi tốt hơn có ý nghĩa ở 10 % (HUST); 30 % (HUST). Mô hình có R^2 cao nhất ở 10 % nhãn là XJTU: PINN-semi (0,819); TJU: PINN-semi (0,933); MIT: GBDT (0,973); HUST: Ridge (0,838).

Với chuyển miền (Bảng 6.8), R^2 trên bộ đích âm với mọi mô hình khi bộ đích không có nhãn: trung vị −2800 cho MLP, −2,1 cho GBDT và −3,1 cho PINN-semi. Khi chuyển sang bộ khác, dự đoán lệch đều một khoảng lớn hơn cả độ biến thiên của SOH trong bộ đích, nên R^2 không phân biệt được một mô hình lệch ít với một mô hình lệch nhiều; MAE ở Mục 6.8 là thước đo phù hợp hơn. Với 3 cell đích có nhãn, độ lệch này được hiệu chỉnh và R^2 trung vị lên 0,57 cho PINN-semi, 0,55 cho GBDT, trong khi MLP vẫn ở −2,5.

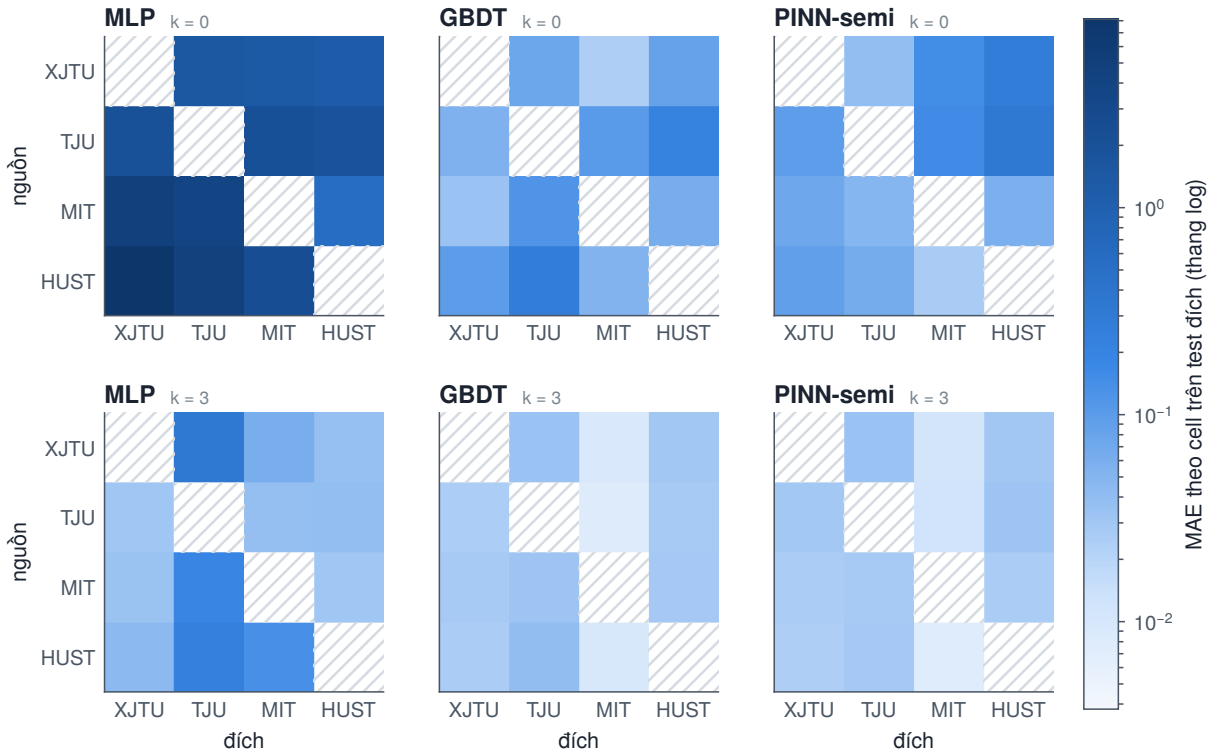
Bảng 6.8. R^2 trên tập test của bộ đích qua 12 cặp chuyển miền (mỗi cặp trung bình 5 hạt giống).

Mô hình	trung vị, k=0	nhỏ nhất ; lớn nhất	trung vị, k=3	nhỏ nhất ; lớn nhất
MLP	−2799,78	−33005,70 ; −82,87	−2,53	−86,17 ; 0,51
GBDT	−2,12	−20,40 ; 0,16	0,55	−0,38 ; 0,89
PINN-semi	−3,08	−30,09 ; 0,31	0,57	−0,27 ; 0,84

6.8 Chuyển miền

Bảng 6.9. Chuyển miền: MAE theo cell trên tập test của bộ đích, trung bình 5 hạt giống; in đậm là thấp nhất trong cùng một k. Mọi mô hình dùng cùng cách chia và cùng normaliser.

Nguồn → đích	Cùng họ	MLP, k=0	GBDT, k=0	PINN, k=0	MLP, k=3	GBDT, k=3	PINN, k=3
XJTU → TJU	có	1,478	0,074	**0,038**	0,322	0,034	**0,034**
XJTU → MIT	không	1,311	**0,024**	0,149	0,060	**0,009**	0,011
XJTU → HUST	không	1,181	**0,084**	0,273	0,036	0,030	**0,030**
TJU → XJTU	có	1,998	**0,056**	0,095	0,030	**0,025**	0,028
TJU → MIT	không	2,088	**0,100**	0,155	0,037	**0,008**	0,012
TJU → HUST	không	1,768	**0,215**	0,312	0,039	**0,027**	0,032
MIT → XJTU	không	4,649	**0,034**	0,073	0,033	0,027	**0,025**
MIT → TJU	không	3,647	0,119	**0,049**	0,183	0,032	**0,027**
MIT → HUST	có	0,542	0,061	**0,058**	0,031	0,028	**0,026**
HUST → XJTU	không	8,125	0,096	**0,090**	0,043	0,025	**0,024**
HUST → TJU	không	4,382	0,264	**0,065**	0,233	0,040	**0,027**
HUST → MIT	có	2,445	0,052	**0,026**	0,136	0,009	**0,008**



Hình 6.10. MAE theo cell trên tập test của bộ đích (thang log); hàng: số cell đích có nhãn k, cột: mô hình; ô gạch chéo: cùng một bộ, không chuyển miền.

Khi bộ đích không có nhãn ($k = 0$), MLP gần như không dùng được: MAE theo cell 0,54–8,13 (đơn vị SOH), tức dự đoán lệch hẳn khỏi miền giá trị. PINN-semi giữ sai số ở mức 0,026–0,312 nhờ loss vật lý áp lên dữ liệu sạc của bộ đích và ràng buộc miền giá trị, và tốt hơn MLP ở 12/12 cặp. Trung bình nhân của tỉ số PINN/MLP ở $k = 0$ là 0,034 cho các cặp cùng họ hoá học và 0,043 cho các cặp khác họ. Khi có 3 cell đích có nhãn, MLP cải thiện mạnh và khoảng cách thu hẹp (tỉ số 0,26 và 0,36); PINN-semi vẫn tốt hơn MLP ở 12/12 cặp. GBDT không ngoại suy ra ngoài miền nhãn của dữ liệu huấn luyện, nên ở $k = 0$ không lệch như MLP (MAE 0,024–0,264). So với GBDT, PINN-semi tốt hơn ở 6/12 cặp, tỉ số MAE trung bình nhân 1,12. Kết quả phụ thuộc rõ vào bộ nguồn: khi nguồn là LFP, PINN-semi tốt hơn GBDT ở 5/6 cặp; khi nguồn thuộc họ niken, chỉ 1/6 cặp. Ở $k = 3$, PINN-semi tốt hơn GBDT ở 8/12 cặp (tỉ số 0,99). Chuyển giữa hai họ hoá học (NCM/NCA và LFP) khó hơn hẳn: MAE trung bình nhân của PINN-semi ở $k = 0$ là 0,048 cho cặp cùng họ và 0,119 cho cặp khác họ, nhiều khả năng do đặc trưng sạc của hai họ khác nhau về bản chất. Chiều chuyển cũng quan trọng: từ họ niken sang LFP khó hơn (MAE trung bình nhân 0,210) so với từ LFP sang họ niken (0,067).

6.9 Tham số vật lý học được

Bảng 6.10. Tham số vật lý học được của PINN-semi ở 30 % nhãn (trung bình ± độ lệch chuẩn qua 25 lượt). Giá trị khởi tạo: $\lambda = 1$, $E_a = 30$ kJ/mol.

Bộ	λ	E_a (kJ/mol)	Nhiều mức nhiệt độ
XJTU	0,96 ± 0,00	30,0 ± 0,0	không
TJU	0,96 ± 0,00	28,9 ± 0,2	có
MIT	0,96 ± 0,00	29,0 ± 0,1	không
HUST	0,97 ± 0,02	28,9 ± 0,1	không

Cả hai tham số vật lý gần như không rời giá trị khởi tạo: λ nằm trong khoảng 0,96–0,97 trên mọi bộ (khởi tạo 1), E_a dịch XJTU 0,0, TJU 1,1, MIT 1,0, HUST 1,1 kJ/mol. Trên XJTU, nhiệt độ thí nghiệm trùng $T_{\text{ref}} = 25$ °C nên $A(T) = 1$ và gradient theo E_a bằng 0; trên MIT và HUST, mọi cell cùng 30 °C nên $A(T)$ chỉ là một hằng số nhân, không tách được khỏi $k(\mathbf{x})$. Ngay cả trên TJU, nơi có ba mức nhiệt độ, E_a cũng chỉ dịch chừng 1 kJ/mol: với trọng số $\alpha = 0{,}02$, tín hiệu từ $\mathscr{L}_{\text{ode}}$ quá yếu để ước lượng E_a, và mạng $k(\mathbf{x})$ có thể tự hấp thụ ảnh hưởng của nhiệt độ qua đặc trưng sạc. Vì vậy hai tham số này nên được hiểu là phần cấu trúc của ràng buộc (dấu và dạng hàm của tốc độ suy giảm), không phải đại lượng vật lý được ước lượng từ dữ liệu.

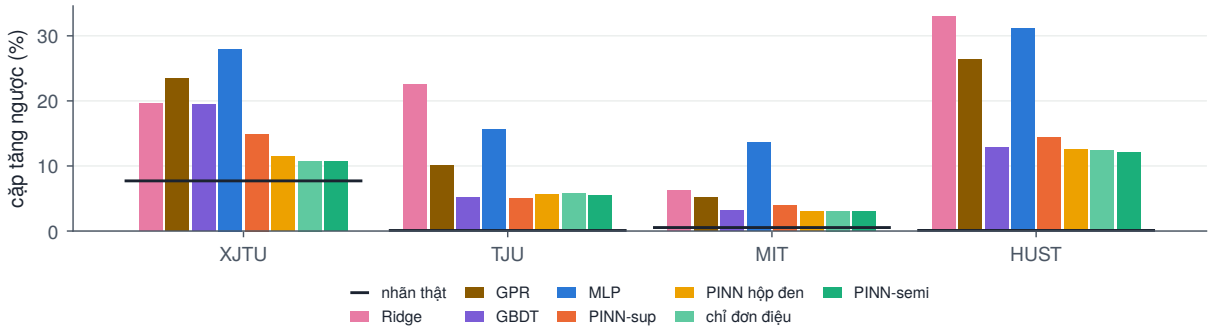
6.10 Kiểm tra phần vật lý

Mục 4.6 chỉ ra rằng ba hàm mất mát vật lý tác động vào hai hướng khác nhau của hàm F_φ: $\mathscr{L}_{\text{mono}}$ tác động lên tổng biến thiên dọc quỹ đạo thật của cell, $\mathscr{L}_{\text{ode}}$ tác động lên đạo hàm riêng theo thời gian khi giữ nguyên đặc trưng sạc. Mục này đo riêng từng hướng trên các cell test.

Dọc quỹ đạo: tính đơn điệu của dự đoán. Với mỗi cell test, đếm các cặp chu kỳ cách nhau ít nhất 10 chu kỳ mà SOH dự đoán ở chu kỳ sau cao hơn chu kỳ trước quá 0,002, tức đúng ngưỡng của $\mathscr{L}_{\text{mono}}$. Phép đếm này không cần nhãn, nên làm được với mọi mô hình; làm trên chính nhãn thật cho mức tham chiếu, vì dung lượng thật có thể hồi phục nhẹ sau thời gian nghỉ (Bảng 6.11, Hình 6.11). Ở 30 % nhãn, dự đoán của MLP tăng ngược ở 13,6–31,1 % số cặp, của PINN-semi chỉ 3,0–12,0 %, trong khi nhãn thật là 0,1–7,7 %. Biến thể chỉ đơn điệu cho tỉ lệ gần như bằng PINN-semi (3,1–12,4 %): chính $\mathscr{L}_{\text{mono}}$, áp lên cặp chu kỳ của cả cell không nhãn, làm quỹ đạo dự đoán đơn điệu.

Bảng 6.11. Tỉ lệ cặp chu kỳ cách nhau ít nhất 10 chu kỳ mà SOH dự đoán tăng quá 0,002 (%), 30 % nhãn, mọi cell test của 5 lần lặp; cột đầu là cùng phép đếm trên chính nhãn thật.

Bộ	Nhãn thật	MLP	GBDT	PINN-sup	PINN hộp đen	chỉ đơn điệu	PINN-semi
XJTU	7,7	28,0	19,4	14,9	11,5	10,8	10,7
TJU	0,1	15,7	5,2	5,0	5,6	5,7	5,5
MIT	0,5	13,6	3,2	3,9	3,0	3,1	3,0
HUST	0,1	31,1	12,9	14,3	12,5	12,4	12,0



Hình 6.11. Tỉ lệ cặp chu kỳ có SOH dự đoán tăng ngược ở 30 % nhãn; vạch ngang là cùng phép đếm trên nhãn thật.

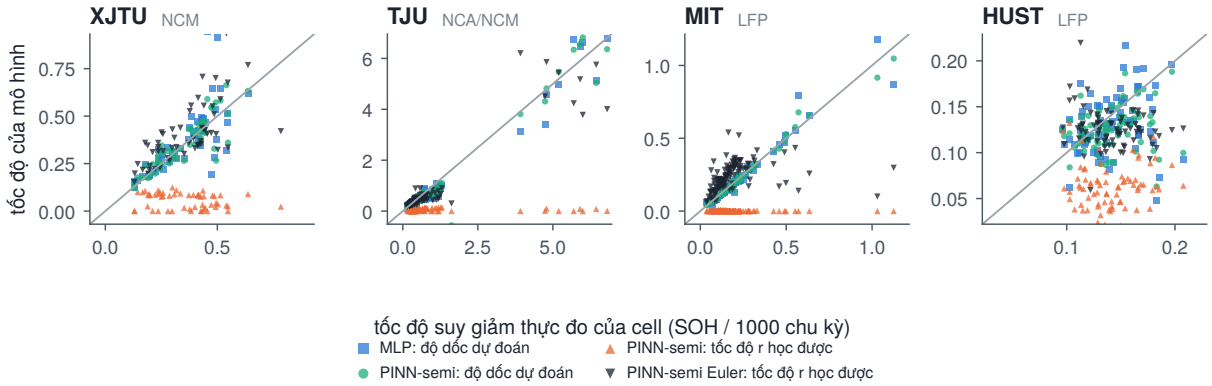
Theo thời gian: đạo hàm riêng và phần dư ODE. Đại lượng mà $\mathscr{L}_{\text{ode}}$ ràng buộc là $\partial F_\varphi / \partial t$, chỉ tính được từ chính mô hình. Trọng số mô hình không được lưu, nhưng huấn luyện là tất định, nên đồ án huấn luyện lại các lượt của MLP, PINN-semi, các biến thể cắt bỏ và PINN hộp đen ở 30 % nhãn, lần lặp đầu, cả 5 fold trên 4 bộ: 120/120 lượt cho MAE trùng từng bit với lượt đã báo cáo. Trên cell test của từng lượt, đo $\partial F_\varphi / \partial t$ bằng vi phân tự động, tốc độ r của động học xám, và tách tổng mức giảm SOH dự đoán trên vòng đời cell thành phần do biến thời gian $\sum_i [F_\varphi(\tilde{\mathbf{x}}_i, t_{i+1}) - F_\varphi(\tilde{\mathbf{x}}_i, t_i)]$ và phần do đặc trưng sạc $\sum_i [F_\varphi(\tilde{\mathbf{x}}_{i+1}, t_{i+1}) - F_\varphi(\tilde{\mathbf{x}}_i, t_{i+1})]$; hai phần cộng lại đúng bằng tổng (Bảng 6.12).

Bảng 6.12. Đo trên cell test của mô hình đã huấn luyện (30 % nhãn, lần lặp đầu, 5 fold). Bốn cột đầu: tỉ lệ điểm có $\partial F_\varphi / \partial t > 0$ (%). Ba cột giữa: trung vị qua các cell của phần giảm SOH dự đoán do riêng biến thời gian (%). Ba cột cuối: tốc độ suy giảm trung bình (SOH trên 1 000 chu kỳ).

	$\partial F_\varphi / \partial t > 0$ (%)				phần do thời gian (%)			tốc độ suy giảm		
Bộ	MLP	chỉ đ.điệu	PINN-semi	Euler	MLP	PINN-semi	Euler	r PINN-semi	r Euler	thực đo
XJTU	11,8	0,1	0,8	0,0	15	18	27	0,061	0,348	0,300
TJU	32,6	13,4	2,6	25,1	9	15	19	0,058	0,331	0,356
MIT	30,3	14,3	23,9	12,8	3	2	7	0,001	0,213	0,137
HUST	17,4	6,3	4,8	6,2	36	49	48	0,063	0,128	0,137

Ba nhận xét. Thứ nhất, MLP có $\partial F_\varphi / \partial t > 0$, tức SOH tăng theo thời gian khi đặc trưng giữ nguyên, ở 12–33 % số điểm test; PINN-semi giảm tỉ lệ này xuống 1–24 %, giảm rõ trên XJTU, TJU và HUST. Riêng MIT, ràng buộc được thoả theo cách tầm thường: r học được gần bằng 0 (MIT 0,001) và đạo hàm theo thời gian cũng gần bằng 0, nên dấu của đạo hàm chỉ còn là nhiễu quanh 0. Thứ hai, ở mọi mô hình, phần lớn mức giảm SOH dự đoán đi qua đặc trưng sạc chứ không qua biến thời gian: phần do thời gian chỉ chiếm 3–36 % với MLP và 2–49 % với PINN-semi; với PINN-semi, phần này dưới 25 % trên XJTU, TJU và MIT và cao nhất trên HUST (49 %). Mạng nghiệm nhận ra pin đã già chủ yếu nhờ đường sạc đã đổi dạng, và $\mathcal{L}_{\text{ode}}$ chỉ ràng buộc phần còn lại. Thứ ba, phần dư ODE nhỏ so với chính đạo hàm ($|\partial_t F_\varphi + r|$ bằng XJTU 14, TJU 16, HUST 22 % của $|\partial_t F_\varphi|$), nghĩa là ràng buộc được thoả trên cell chưa từng thấy.

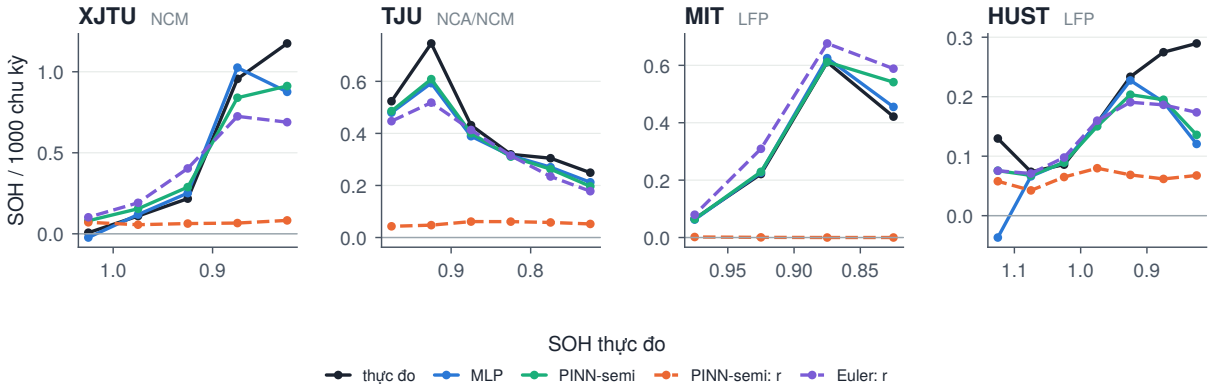
Tốc độ suy giảm học được. Hình 6.12 so tốc độ suy giảm thực đo của từng cell test (độ dốc của SOH theo chu kỳ) với tốc độ của mô hình. Độ dốc của SOH dự đoán bám sát thực đo ở cả MLP lẫn PINN-semi (tương quan hạng Spearman 0,30–0,99 với MLP, 0,31–0,99 với PINN-semi); trên HUST tương quan thấp hơn vì tốc độ của các cell gần như nhau (hệ số biến thiên 0,19, so với 0,39–1,66 ở các bộ khác). Tốc độ r của PINN-semi thì không: trung bình chỉ 0,001–0,063 so với 0,137–0,356 thực đo, và gần như không tương quan với tốc độ của từng cell (Spearman XJTU −0,26, TJU 0,10, MIT −0,14, HUST 0,09). Lý do nằm ở nhận xét thứ hai: ở dạng đạo hàm riêng, r được khớp với $-\partial F_\varphi / \partial t$, tức chỉ với phần suy giảm mà mạng gán cho biến thời gian. Dạng Euler khớp r với tổng biến thiên dọc quỹ đạo, nên r của nó xấp xỉ tốc độ thật (trung bình 0,128–0,348) và tương quan với tốc độ từng cell (Spearman XJTU 0,72, TJU 0,88, MIT 0,66, HUST −0,22), rõ trên XJTU, TJU và MIT. Đổi lại, dạng Euler có MAE cao hơn dạng đạo hàm riêng trên TJU và MIT (Mục 6.5).



Hình 6.12. Tốc độ suy giảm của từng cell test: thực đo (trục ngang) so với độ dốc dự đoán và tốc độ r học được (trục dọc); đường chéo là trùng khớp.

Hình 6.13 xếp tốc độ suy giảm theo khoảng SOH thực đo. Trên XJTU, MIT và HUST, tốc độ thực đo ở khoảng SOH thấp nhất cao gấp 2–175 lần ở khoảng SOH cao nhất: đây là hiện tượng đầu gối. Trên TJU, đường trung bình không đi lên đều theo SOH. Mỗi khoảng SOH gồm một

tập cell khác nhau, nên đây là đường trung bình chứ không phải đường của một cell. Độ dốc dự đoán của PINN-semi theo sát đường thực đo trên cả bốn bộ, nhưng r gần như phẳng: giữa các khoảng SOH, r chỉ thay đổi 1,4–1,9 lần (bỏ qua MIT, nơi $r \approx 0$), trong khi tốc độ thực đo thay đổi 3–175 lần. Với $\lambda \approx 0{,}96$ (Mục 6.9), thừa số $g(u) = e^{\lambda(1-u)}$ chỉ tăng khoảng 1,2 lần khi SOH giảm từ 1 xuống 0,8. Đầu gối trong dự đoán đến từ đặc trưng sạc, không đến từ thừa số đầu gối của động học.



Hình 6.13. Tốc độ suy giảm theo khoảng SOH thực đo (trục ngang giảm dần): thực đo, độ dốc dự đoán và tốc độ r học được.

Tóm lại, phần vật lý giúp mô hình chủ yếu qua ràng buộc dọc quỹ đạo: dự đoán của PINN-semi gần đơn điệu như nhãn thật, và đây cũng là phần mang lại phần lớn lợi ích về sai số (Mục 6.5). Ràng buộc ODE dạng đạo hàm riêng giữ cho SOH không tăng theo thời gian, nhưng tốc độ r của nó không phải là ước lượng tốc độ suy giảm của cell; muốn r diễn giải được theo nghĩa vật lý cần dạng Euler.

6.11 Thảo luận chung

Khi nào nên dùng PINN bán giám sát? Khi đã chọn mạng nơ-ron làm mô hình, PINN bán giám sát nên được dùng thay cho MLP khi số cell có nhãn ít (khoảng 10–30 %), khi có nhiều cell chưa đo dung lượng, và nhất là khi phải chạy trên một bộ dữ liệu mới chưa có nhãn: ở đó MLP thất bại hoàn toàn còn PINN-semi vẫn cho sai số dùng được. So với GBDT thì khác: trong cùng một bộ dữ liệu, GBDT có sai số thấp hơn ở phần lớn các trường hợp; khi chuyển miền, hai mô hình thắng thua tuỳ cặp (PINN-semi tốt hơn ở 6/12 cặp khi không có nhãn đích). Nếu chỉ cần sai số thấp nhất trên cùng một bộ dữ liệu, GBDT là lựa chọn đơn giản và mạnh hơn.

Khi nào lợi ích nhỏ? Khi đã có đủ nhãn (70 %), và trên TJU, nơi tỉ số so với MLP chỉ ở mức 0,90–1,09 trên mọi mức nhãn. TJU gộp ba nhóm hoá học và chín nhóm điều kiện; có thể phần biến thiên giữa các nhóm lớn hơn phần mà ràng buộc vật lý dùng chung cho mọi cell giải thích được.

Hạn chế. (i) Mô hình ước lượng SOH tại chu kỳ hiện tại, chưa dự báo SOH tương lai hay tuổi thọ còn lại. (ii) Trọng số vật lý được chọn ở một thí nghiệm sơ bộ và giữ cố định; chưa tối ưu riêng cho từng mức nhãn. (iii) GBDT là đối thủ mạnh và chưa được kết hợp với ràng buộc vật lý. (iv) Cell validation cần nhãn ngoài ngân sách nhãn. (v) Ở 30 % nhãn, kết luận ở mức fold chỉ vững trên MIT. (vi) Tham số vật lý λ, E_a chưa ước lượng được từ dữ liệu hiện có. (vii) Ở dạng đạo hàm riêng, tốc độ r học được chỉ phản ánh phần suy giảm mà mạng gán cho biến thời gian, không phải tốc độ suy giảm thật của cell (Mục 6.10).

CHƯƠNG 7

Kết luận và hướng phát triển

7.1 Kết luận

Đồ án xây dựng một mô hình PINN bán giám sát cho bài toán ước lượng SOH của cell lithium-ion và đánh giá nó bằng một giao thức không rò rỉ trên bốn bộ dữ liệu công khai. Trả lời các câu hỏi nghiên cứu:

CH1. Cùng 30 % nhãn, PINN-semi có sai số thấp hơn MLP có ý nghĩa thống kê trên cả bốn bộ (tỉ số MAE 0,76–0,96).

CH2. Lợi ích lớn nhất khi ít nhãn (10 %: tỉ số 0,39–0,90, có ý nghĩa trên cả bốn bộ) và giảm dần khi lượng nhãn tăng (trung bình nhân qua bốn bộ: 10 %: 0,60, 30 %: 0,86, 50 %: 0,92, 70 %: 0,96). Ở 70 % nhãn, khi không còn cell không nhãn, cải thiện chỉ còn có ý nghĩa trên MIT, và trên TJU MLP tốt hơn.

CH3. PINN-semi có MAE thấp hơn MLP trong 14/16, thấp hơn Ridge trong 15/16 và GPR trong 6/16 trường hợp (bộ × mức nhãn), nhưng GBDT tốt hơn PINN-semi trong 14/16 trường hợp, 10 trong đó có ý nghĩa thống kê. GBDT được tinh chỉnh tốt vẫn là mô hình mạnh nhất khi đánh giá trong cùng một bộ dữ liệu.

CH4. Ở 10 % nhãn, 50–64 % mức giảm sai số (thang log) của PINN-semi so với MLP đến từ việc áp loss vật lý lên cell không nhãn, phần còn lại từ vật lý trên cell có nhãn. Ở 30 % nhãn, riêng ràng buộc đơn điệu đã mang lại 62–95 % mức giảm đó. Động học xám tốt hơn động học hộp đen kiểu PINN4SOH có ý nghĩa ở 4 trong 16 trường hợp (bộ × mức nhãn) và kém hơn ở 1; khác biệt rõ nhất ở MIT khi ít nhãn. Đo trực tiếp trên mô hình đã huấn luyện, vật lý tác động chủ yếu qua ràng buộc dọc quỹ đạo: dự đoán của PINN-semi gần đơn điệu như nhãn thật; tốc độ r ở dạng đạo hàm riêng chỉ phản ánh phần suy giảm gán cho biến thời gian, còn dạng Euler cho r sát tốc độ thật (Mục 6.10).

CH5. Khi bộ đích không có nhãn, PINN-semi giữ MAE ở mức 0,026–0,312 trong khi MLP lệch tới 0,54–8,13; với 3 cell đích có nhãn, khoảng cách thu hẹp nhưng PINN-semi vẫn tốt hơn ở 12/12 cặp. So với GBDT, PINN-semi tốt hơn ở 6/12 cặp khi $k = 0$ và 8/12 cặp khi $k = 3$.

Về phương pháp đánh giá, đồ án cho thấy cách chia theo chu kỳ làm sai số trông thấp hơn thực tế, và chứng minh bằng một cận đơn giản rằng ngay cả bộ dự đoán không học gì cũng đạt sai số rất thấp dưới cách chia đó. Giao thức kiểm định chéo 5 fold theo cell, phân tầng theo chế độ thí nghiệm, lặp 5 lần, được chọn từ các ràng buộc rõ ràng và có các tính chất được chứng

minh: mỗi cell được test đúng một lần mỗi lần lặp, các fold cân bằng theo từng chế độ, tập nhãn lồng nhau giữa các mức, và ước lượng sai số không chệch.

7.2 Hướng phát triển

1. Kết hợp ràng buộc vật lý với mô hình cây: dùng dự đoán của GBDT làm đầu vào hoặc làm giá trị khởi đầu cho mạng nghiệm, hoặc dùng loss vật lý để tạo nhãn giả cho GBDT trên cell không nhãn.
2. Mở rộng sang dự báo SOH tương lai và tuổi thọ còn lại, với giao thức chia theo thời gian bên trong mỗi cell test.
3. Ước lượng độ bất định (tổ hợp nhiều mô hình hoặc dự đoán phù hợp) để BMS biết khi nào tin được dự đoán.
4. Dùng điện lượng tích luỹ thay cho chỉ số chu kỳ làm biến thời gian, để chuyển giữa các giao thức sạc tốt hơn.
5. Tăng trọng số của phần dư động học và dùng dữ liệu nhiều mức nhiệt độ để ước lượng được λ và E_a.
6. Kết hợp phần dư dạng đạo hàm riêng với dạng Euler dọc quỹ đạo, để vừa giữ sai số thấp vừa có tốc độ suy giảm r diễn giải được theo nghĩa vật lý.

Tài liệu tham khảo

[1] S. Arlot, A. Celisse. A survey of cross-validation procedures for model selection. *Statistics Surveys*, 4:40–79, 2010.

[2] P. M. Attia, A. Bills, F. Brosa Planella, et al. Review—"Knees" in lithium-ion battery aging trajectories. *Journal of The Electrochemical Society*, 169:060517, 2022.

[3] M. Aykol, C. B. Gopal, A. Anapolsky, et al. Perspective—Combining physics and machine learning to predict battery lifetime. *Journal of The Electrochemical Society*, 168:030525, 2021.

[4] C. R. Birkl, M. R. Roberts, E. McTurk, P. G. Bruce, D. A. Howey. Degradation diagnostics for lithium ion cells. *Journal of Power Sources*, 341:373–386, 2017.

[5] R. R. Bouckaert, E. Frank. Evaluating the replicability of significance tests for comparing learning algorithms. *Advances in Knowledge Discovery and Data Mining (PAKDD)*, 3–12, 2004.

[6] T. G. Dietterich. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923, 1998.

[7] M. Doyle, T. F. Fuller, J. Newman. Modeling of galvanostatic charge and discharge of the lithium/polymer/insertion cell. *Journal of The Electrochemical Society*, 140(6):1526–1533, 1993.

[8] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[9] J. H. Friedman. Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.

[10] S. Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.

[11] S. Kapoor, A. Narayanan. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804, 2023.

[12] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, L. Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3:422–440, 2021.

[13] G. Ke, Q. Meng, T. Finley, et al. LightGBM: a highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 2017.

[14] I. Loshchilov, F. Hutter. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019.

[15] G. Ma, S. Xu, B. Jiang, et al. Real-time personalized health status prediction of lithium-ion batteries using deep transfer learning. *Energy & Environmental Science*, 15:4083–4094, 2022.

[16] C. Nadeau, Y. Bengio. Inference for the generalization error. *Machine Learning*, 52:239–281, 2003.

[17] G. L. Plett. *Battery Management Systems, Volume I: Battery Modeling*. Artech House, 2015.

[18] M. Raissi, P. Perdikaris, G. E. Karniadakis. Physics-informed neural networks: a deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.

[19] C. E. Rasmussen, C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.

[20] R. R. Richardson, M. A. Osborne, D. A. Howey. Gaussian process regression for forecasting battery state of health. *Journal of Power Sources*, 357:209–219, 2017.

[21] D. Roman, S. Saxena, V. Robu, M. Pecht, D. Flynn. Machine learning pipeline for battery state-of-health estimation. *Nature Machine Intelligence*, 3:447–456, 2021.

[22] K. A. Severson, P. M. Attia, N. Jin, et al. Data-driven prediction of battery cycle life before capacity degradation. *Nature Energy*, 4:383–391, 2019.

[23] S. Varma, R. Simon. Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91, 2006.

[24] T. Waldmann, M. Wilka, M. Kasper, M. Fleischhammer, M. Wohlfahrt-Mehrens. Temperature dependent ageing mechanisms in lithium-ion batteries – a post-mortem study. *Journal of Power Sources*, 262:129–135, 2014.

[25] F. Wang, Z. Zhai, Z. Zhao, Y. Di, X. Chen. Physics-informed neural network for lithium-ion battery degradation stable modeling and prognosis. *Nature Communications*, 15:4332, 2024.

[26] P. Wen, Z.-S. Ye, Y. Li, S. Chen, P. Xie, S. Zhao. Physics-informed neural networks for prognostics and health management of lithium-ion batteries. arXiv:2301.00776, 2023.

[27] F. Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.

[28] Y. Zhang, R. Xiong, H. He, M. G. Pecht. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries. *IEEE Transactions on Vehicular Technology*, 67(7):5695–5705, 2018.

[29] J. Zhu, Y. Wang, Y. Huang, et al. Data-driven capacity estimation of commercial lithium-ion batteries from voltage relaxation. *Nature Communications*, 13:2261, 2022.